

Mnohorozměrné statistické metody

KMA/MSM Blanka Šedivá

verze 2026/2027

14. září 2026

Mnohorozměrné statistické metody (KMA/MSM)

2026/2027

- Blanka Šedivá: `sediva@kma.zcu.cz`
- úterý 3 - 6 hodina (9:20 - 12:50)
- učebna UC 233, UC 210 lze používat vlastní počítače

Vztah mezi pravděpodobností a statistikou

• Pravděpodobnost

- pracuje s náhodnými veličinami (= matematické objekty),
- $X \sim F(x; \Theta)$ náhodná veličina X má distribuci $F(x)$ s parametry Θ
- když $x \in \mathbb{R}$, jedná se o jednorozměrnou náhodnou veličinu,
- když $x \in \mathbb{R}^k$, jedná se o k –rozměrnou veličinu
- náhodná veličina je často stručně popsány svými charakteristikami - střední hodnota, rozptyl, kovariance, ...
- zajímají nás též operace s náhodnými veličinami X^2 , $X + Y$, $X_n \rightarrow X$, $\frac{dX}{dt}$, $\int X dt, \dots$

• Statistika

- pracuje s daty, které vnímá jako realizace náhodných veličin
- deskriptivní statistika + vizualizace
- statistika

(Vícerozměrné) statistické modelování

- modelování náhodných dějů
 - pravděpodobnostní prostor $(\Omega, \mathcal{A}, \mathcal{P})$
 - náhodná veličina X , distribuční funkce $F(x)$, funkce hustoty $f(x)$ (pravděpodobnostní funkce $P(x)$)
 - charakteristiky náhodné veličiny - střední hodnota $\mathbb{E}X$, rozptyl $\text{var } X$, kovariance, ...
- simulační techniky (z modelů generují data)
- zpracování dat (popisy dat, vizualizace informace, ...)
- principy statistické inference (z dat odvozují modely)
 - analýza struktury dat (identifikace vhodných modelů)
 - bodové a intervalové odhady charakteristik modelů na základě dat
 - testování statistických hypotéz

(Vícerozměrné) statistické metody

Multivariate statistics:

https://en.wikipedia.org/wiki/Multivariate_statistics

- metody zaměřené na popis a analýzu struktury vícerozměrných dat
 - základní statistické zpracování dat
 - grafická interpretace vícerozměrných dat
 - identifikace vhodného pravděpodobnostního modelu
 - modely redukce dimenze dat
- metody zkoumající vztah více proměnných
 - existence rozdílů mezi různými skupinami
 - modely závislostí mezi náhodnými veličinami
- regresní metody
- klasifikační metody
 - klasifikační modely s dodatečnou informací (s učitelem, supervised methods)
 - klasifikační modely bez dodatečné informace (bez učitele, unsupervised methods)

Analýza struktury (vícerozměrných) dat

- základní statistické zpracování
 - určování charakteristik polohy a variability dat
 - identifikace odlehklých hodnot
 - transformace data (data scaling, data normalization)
 - data preprocessing
- grafická vizualizace vícerozměrných dat
- volba vhodného pravděpodobnostního vícerozměrného modelu
 - diskrétní a spojitě vícerozměrné modely náhodných veličin
 - výběrová vícerozměrná rozdělení
 - simulační modely vícerozměrných dat
 - ověřování shody dat s modely rozdělení (testy o shodnosti středních hodnot, kovariančních matic, ...)
- modely redukce dimenze dat
 - selekce příznaků (feature selection)
 - extrakce příznaků (feature extraction)- lineární × nelineární
 - ...

Analýza závislostí a vztahů u vícerozměrných data

- symetrický vztah proměnných (testy závislosti)
 - diskrétní proměnné: kontingenční tabulky (dvou a vícerozměrné)
 - spojité proměnné: korelace, odhady založené na kopulích
- $\mathbf{X}$ vektor vysvětlujících proměnných (dimense k), $\mathbf{Y}$ vektor vysvětlovaných proměnných (dimense n)
- dimense vysvětlovaných proměnných $k = 1$
 - Y je binární (data jsou rozděleny do dvou skupin) a X jsou spojitá : shoda středních hodnot, shoda rozptylů, shoda variačních matic, logitové modely
 - Y je diskrétní konečné (data jsou rozděleny do více skupin): ANOVA1, diskrétní regresní modely
 - Y je diskrétní nekonečné: diskrétní regresní modely
 - Y je spojitá: lineární a nelineární klasické regresní modely
- dimense vysvětlovaných proměnných $k > 1$
- kritéria hodnocení kvality modelů (nejčastěji založené na R^2 nebo maximálně věrohodnostní funkci)

Regresní metody

- nesymetrický vztah, nezávislé proměnné, závislé proměnné
- podle typu modelovaného vztahu
 - jednorozměrné a vícerozměrné modely
 - lineární a nelineární modely
- podle metod odhadu parametrů
 - metoda nejmenších čtverců
 - metoda maximální věrohodnosti
- problémy spojené s více dimensemi
 - multikolinearita
 - selection features (hledání vhodných prediktorů)
 - structural equations models

Klasifikační metody

- metody měření vzdáleností pro vícerozměrná data
- metody s dodatečnou informací (supervised method), kdy máme k dispozici informaci o "správné" klasifikaci
 - klasifikace na základě separace dat (diskriminační analýza)
 - klasifikace na základě modelů vztahů u vícerozměrných dat
- metody bez dodatečné informace (unsupervised method), kdy nemáme k dispozici informaci o "správné" klasifikaci hledáme rozklad dat na jednotlivé podskupiny (shluková analýza, regresní stromy, ...)
- metody hodnocení kvality klasifikace
 - kritéria založená na rozdělených datech (trénovací a testovací data)
 - metody založené na principu crossvalidace (random subsampling, k-fold cross-validation, leave-one-out cross validation)
 - metody založené na permutačních testech