Mnohorozměrné statistické metody

KMA/MSM Blanka Šedivá

verze 2026/2027
6. října 2026

Mnohorozměrné statistické metody (KMA/MSM)

2026/2027

- Blanka Šedivá: `sediva@kma.zcu.cz`
- úterý 3.–6. hodina (9:20–12:50)
- učebna UC 233, UC 210; lze používat vlastní počítače

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Vztah mezi pravděpodobností a statistikou

- Pravděpodobnost
  - pracuje s náhodnými veličinami (= matematické objekty),
  - $X \sim F(x; \Theta)$: náhodná veličina X má rozdělení s distribuční funkcí F a parametry Θ
  - když $x \in \mathbb{R}$, jedná se o jednorozměrnou náhodnou veličinu,
  - když $\boldsymbol{x} \in \mathbb{R}^k$, jedná se o k-rozměrnou náhodnou veličinu (náhodný vektor) $\boldsymbol{X}$
  - náhodná veličina je často stručně popsána svými charakteristikami – střední hodnota, rozptyl, kovariance, ...
  - zajímají nás též operace s náhodnými veličinami X^2, $X + Y$, $X_n \to X$, $\frac{\mathrm{d}X}{\mathrm{d}t}$, $\int X \, \mathrm{d}t$,...
- Statistika
  - pracuje s daty, která vnímá jako realizace náhodných veličin
  - deskriptivní statistika + vizualizace
  - statistická inference (odhady parametrů, testování hypotéz)

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

(Vícerozměrné) statistické modelování

- modelování náhodných dějů
  - pravděpodobnostní prostor $(\Omega, \mathcal{A}, \mathcal{P})$
  - náhodná veličina X, distribuční funkce $F(x)$, funkce hustoty $f(x)$ (pravděpodobnostní funkce $P(x)$)
  - charakteristiky náhodné veličiny – střední hodnota $\mathbb{E}X$, rozptyl $\operatorname{var} X$, kovariance, ...
- simulační techniky (z modelů generují data)
- zpracování dat (popisy dat, vizualizace informace, ...)
- principy statistické inference (z dat odvozuji modely)
  - analýza struktury dat (identifikace vhodných modelů)
  - bodové a intervalové odhady charakteristik modelů na základě dat
  - testování statistických hypotéz

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

(Vícerozměrné) statistické metody

Multivariate statistics:
`https://en.wikipedia.org/wiki/Multivariate_statistics`

- metody zaměřené na popis a analýzu struktury vícerozměrných dat
  - základní statistické zpracování dat
  - grafická interpretace vícerozměrných dat
  - identifikace vhodného pravděpodobnostního modelu
  - modely redukce dimenze dat
- metody zkoumající vztah více proměnných
  - existence rozdílů mezi různými skupinami
  - modely závislostí mezi náhodnými veličinami
- regresní metody
- klasifikační metody
  - klasifikační modely s dodatečnou informací (s učitelem, supervised methods)
  - klasifikační modely bez dodatečné informace (bez učitele, unsupervised methods)

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Analýza struktury (vícerozměrných) dat

- základní statistické zpracování
  - určování charakteristik polohy a variability dat
  - identifikace odlehlých hodnot
  - transformace dat (data scaling, data normalization)
  - předzpracování dat (data preprocessing)
- grafická vizualizace vícerozměrných dat
- volba vhodného pravděpodobnostního vícerozměrného modelu
  - diskrétní a spojité vícerozměrné modely náhodných veličin
  - výběrová vícerozměrná rozdělení
  - simulační modely vícerozměrných dat
  - ověřování shody dat s modely rozdělení (testy o shodě středních hodnot, variančních matic, . . .)
- modely redukce dimenze dat
  - selekce příznaků (feature selection)
  - extrakce příznaků (feature extraction) – lineární $\times$ nelineární
  - . . .

Analýza závislostí a vztahů u vícerozměrných dat

- symetrický vztah proměnných (testy závislosti)
  - diskrétní proměnné: kontingenční tabulky (dvou- a vícerozměrné)
  - spojité proměnné: korelace, odhady založené na kopulích
- $\boldsymbol{X}$ vysvětlující proměnné (dimenze k), $\boldsymbol{Y}$ vysvětlované proměnné (dimenze m)
- dimenze vysvětlovaných proměnných $m = 1$
  - Y je binární (dvě skupiny), $\boldsymbol{X}$ spojité: shoda středních hodnot, rozptylů a variančních matic, logitové modely
  - Y nabývá konečně mnoha hodnot (více skupin): jednofaktorová ANOVA, diskrétní regresní modely
  - Y nabývá spočetně mnoha hodnot (počty): diskrétní regresní modely
  - Y je spojitá: lineární a nelineární klasické regresní modely
- dimenze vysvětlovaných proměnných $m > 1$: MANOVA, vícerozměrná regrese
- kritéria hodnocení kvality modelů (nejčastěji založená na R^2 nebo na věrohodnostní funkci)

Regresní metody

- nesymetrický vztah: nezávislé (vysvětlující) proměnné $\rightarrow$ závislé (vysvětlované) proměnné
- podle typu modelovaného vztahu
  - jednorozměrné a vícerozměrné modely
  - lineární a nelineární modely
- podle metod odhadu parametrů
  - metoda nejmenších čtverců
  - metoda maximální věrohodnosti
- problémy spojené s více dimenzemi
  - multikolinearita
  - výběr vhodných prediktorů (feature selection)
  - modely strukturních rovnic (structural equation models, SEM)

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Klasifikační metody

- metody měření vzdáleností pro vícerozměrná data
- metody s dodatečnou informací (supervised methods), kdy máme k dispozici informaci o „správné“ klasifikaci
  - klasifikace na základě separace dat (diskriminační analýza)
  - klasifikace na základě modelů vztahů u vícerozměrných dat (logistická regrese, klasifikační a regresní stromy, . . .)
- metody bez dodatečné informace (unsupervised methods), kdy nemáme k dispozici informaci o „správné“ klasifikaci
  hledáme rozklad dat na jednotlivé podskupiny (shluková analýza – hierarchické metody, K-means, . . .)
- metody hodnocení kvality klasifikace
  - kritéria založená na rozdělených datech (trénovací a testovací data)
  - metody založené na principu křížové validace (random subsampling, K-fold cross-validation, leave-one-out cross-validation)
  - metody založené na permutačních testech

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI