

Přednáška 1: Vícerozměrná náhodná veličina

KMA/MSM Blanka Šedivá

verze 2026/2027
14. září 2026

Vícerozměrná náhodná veličina

Definice

Nechť náhodné veličiny $X_1, \dots, X_k$ jsou definovány na pravděpodobnostním prostoru $(\Omega, \mathcal{A}, \mathcal{P})$. Potom $\mathbf{X} = (X_1, \dots, X_k)$ nazýváme **náhodným vektorem**.

Někdy používáme též termín k -rozměrná náhodná veličina, k -rozměrný náhodný vektor, vektorová náhodná veličina, uspořádaná k -tice náhodných veličin, a podobně.

Každý náhodný jev $[\mathbf{X} \leq \mathbf{x}] = \bigcap_{j=1}^k [X_j \leq x_j]$ náleží do σ -algebry $\mathcal{A}$ a jsme schopni určit jeho pravděpodobnost $\mathcal{P}$.

Sdružené distribuční funkce a sdružené funkce hustoty

Definice

Reálnou funkci $F(\mathbf{x}) = \mathcal{P}(\mathbf{X} \leq \mathbf{x})$ nazýváme **distribuční funkcí náhodného vektoru** (nebo také **sdruženou (simultánní, joint) distribuční funkcí**), kde zápis $\mathcal{P}(\mathbf{X} \leq \mathbf{x})$ chápeme

$$\mathcal{P}(\mathbf{X} \leq \mathbf{x}) = \mathcal{P} \bigcap_{j=1}^k (X_j \leq x_j) = \mathcal{P}(X_1 \leq x_1 \wedge X_2 \leq x_2 \wedge \dots \wedge X_k \leq x_k)$$

Vlastnosti sdružené distribuční funkce:

- 1 $F(\mathbf{x}) \in \langle 0, 1 \rangle$ pro všechna $\mathbf{x} \in \mathbf{R}^k$.
- 2 $F(\mathbf{x})$ je neklesající funkce vzhledem ke každému x_j kde $j = 1, \dots, k$.

$$\mathcal{P}(X \leq x) \leq \mathcal{P}(X \leq \tilde{x}) \text{ pro všechna } x < \tilde{x}$$

- 3 $F(\mathbf{x})$ je zprava spojitá pro každé x_j , kde $j = 1, \dots, k$.
- 4 $\lim_{x_j \rightarrow -\infty} F(\mathbf{x}) = 0$ pro všechny $j = 1, \dots, k$.

Diskrétní a spojitý vektor

- Jestliže $\mathbf{X}$ nabývá nejvýše spočetně mnoha hodnot, pak $\mathbf{X}$ nazýváme **diskrétním náhodným vektorem**.
Pro diskrétní náhodný vektor zavádíme **pravděpodobnostní funkci** P vztahem

$$P(\mathbf{x}) = \mathcal{P}(X_1 = x_1 \wedge X_2 = x_2 \wedge \cdots \wedge X_k = x_k)$$

- Pokud existuje reálná funkce $f : \mathbb{R}^k \rightarrow \mathbb{R}$ taková, že pro všechna $\mathbf{x} \in \mathbb{R}^k$ platí

$$F(x_1, \dots, x_k) = \int_{-\infty}^{x_k} \cdots \int_{-\infty}^{x_1} f(\xi_1, \dots, \xi_n) d\xi_1 \dots d\xi_k,$$

pak vektor $\mathbf{X}$ nazýváme **spojitým náhodným vektorem** a funkci f nazýváme **sduženou funkcí hustoty** náhodného vektoru $\mathbf{X}$.

Pro sduženou funkci hustoty f platí

$$f(x_1, \dots, x_k) = \frac{\partial^k F(x_1, \dots, x_k)}{\partial x_1 \dots \partial x_k} \quad \text{pro skoro všechna } \mathbf{x}.$$

Marginální rozdělení

Definice

Nechť $k_1, k_2, \dots, k_r$ jsou různá celá čísla taková, že $1 \leq k_i \leq k$ pro $i = 1, 2, \dots, r$, kde $1 \leq r \leq k - 1$.

Pak rozdělení vektoru $(X_{k_1}, X_{k_2}, \dots, X_{k_r})$ nazýváme **marginální rozdělení vektoru X** .

Pro marginální distribuční funkci $G(x_1, x_2, \dots, x_r)$ pak platí

$$G(x_1, x_2, \dots, x_r) = F(x_1, x_2, \dots, x_r, \infty, \infty, \dots, \infty).$$

Pro diskrétní náhodné vektory

$$P_j(x_j) = \sum_{x_k} \dots \sum_{x_{j+1}} \sum_{x_{j-1}} \dots \sum_{x_1} P(x_1, \dots, x_j, \dots, x_k)$$

Pro spojitě náhodné vektory $f_j(x_j) =$

$$\int_{x_k \in R} \dots \int_{x_{j+1} \in R} \int_{x_{j-1} \in R} \dots \int_{x_1 \in R} f(\xi_1, \dots, \xi_i, \dots, \xi_k) d\xi_1 \dots d\xi_{j-1} d\xi_{j+1} \dots d\xi_k$$

Vztah marginálních a sdružených funkcí

- Pro náhodný vektor $\mathbf{X}$ se sdruženou funkcí hustoty $f(\mathbf{x})$ jsou marginální funkce $f_j(x_j), j = 1, 2, \dots, k$ dány jednoznačně.
- Naopak tvrzení neplatí, na základě znalosti marginálních rozdělání nelze (bez dalších dodatečných upřesnění) jednoznačně určit sdruženou funkci.
- $f_\alpha(x, y) = 1 + \alpha(2x - 1)(2y - 1) \quad \alpha \in \langle -1, 1 \rangle, \quad x, y \in (0, 1),$
kde marginální rozdělání jsou rovnoměrná rozdělání pro libovolné hodnoty parametru α .

Nezávislost náhodných veličin

- Náhodné veličiny $X_1, X_2, \dots, X_k$ jsou nezávislé, pokud pro všechny $\mathbf{x} = (x_1, x_2, \dots, x_k) \in \mathbb{R}^k$ platí

$$F(x_1, x_2, \dots, x_k) = F_1(x_1) \cdot F_2(x_2) \cdot \dots \cdot F_k(x_k)$$

- Nezávislost nevyplývá automaticky z párové nezávislosti, kdy jsou navzájem nezávislé všechny vybrané dvojice složek.
- Pak náhodné veličiny $X_1, X_2, \dots, X_k$ jsou nezávislé právě tehdy, když

$$f(x_1, x_2, \dots, x_k) = f_1(x_1) \cdot f_2(x_2) \cdot \dots \cdot f_k(x_k).$$

- Náhodné vektory $\mathbf{X}_1$ a $\mathbf{X}_2$ jsou nezávislé, pokud sdružená distribuční funkce vektoru $(\mathbf{X}_1, \mathbf{X}_2)$ je rovna součinu distribučních funkcí vektorů $\mathbf{X}_1$ a $\mathbf{X}_2$.

Podmíněné rozdělení

Nechť $\mathbf{X} = (X, Y)$ je dvourozměrný náhodný vektor, pak

- pravděpodobnostní funkci podmíněného rozdělení lze určit podle vztahu $P(x | y) = \frac{P(x, y)}{P_y(y)}$,

- distribuční funkci podmíněného rozdělení lze určit podle vztahu $F(x | y) = P(X \leq x | Y = y) = \sum_{t \leq x} \frac{P(t, y)}{P_y(y)}$.

- funkce hustoty podmíněného rozdělení je dána vztahem $f(x | y) = \frac{f(x, y)}{f_y(y)}$,

- a distribuční funkce podmíněného rozdělení je dána vztahem $F(x | y) = \lim_{\Delta y \rightarrow 0} P(X \leq x | y - \Delta y \leq Y \leq y + \Delta y) = \frac{\int_{-\infty}^x f(t, y) dt}{f_y(y)}$.

Střední hodnota

Střední hodnota náhodného vektoru $\mathbf{X} = (X_1, X_2, \dots, X_k)$ je vektor středních hodnot marginálních rozdělení

$$\mathbb{E}\mathbf{X} = (\mathbb{E}(X_1), \mathbb{E}(X_2), \dots, \mathbb{E}(X_k)).$$

Věta

Nechť jsou $\mathbf{A}$ a $\mathbf{B}$ matice konstant odpovídajících rozměrů a necht $\mathbf{X}$ a $\mathbf{Y}$ jsou náhodné vektory stejných rozměrů, pro jejichž složky existují střední hodnoty, pak platí

$$\mathbb{E}(\mathbf{A} \cdot \mathbf{X} + \mathbf{B} \cdot \mathbf{Y}) = \mathbf{A} \cdot \mathbb{E}\mathbf{X} + \mathbf{B} \cdot \mathbb{E}\mathbf{Y}.$$

Rozptyl

Variance (rozptyl) náhodného vektoru $\mathbf{X} = (X_1, X_2, \dots, X_k)$ je vektor rozptylů marginálních rozdělání

$$\text{var } \mathbf{X} = (\text{var}(X_1), \text{var}(X_2), \dots, \text{var}(X_k)),$$

$$\text{kde } \text{var}(X_i) = \mathbb{E}((X_i - \mathbb{E}(X_i))^2) = \mathbb{E}(X_i^2) - \mathbb{E}^2(X_i).$$

Věta

Nechť vektor $\mathbf{X} = (X_1, X_2, \dots, X_k)$ má spojitě rozdělení se sdruženou distribuční funkcí $f(\mathbf{x})$. Je-li $g(x_1, x_2, \dots, x_k)$ borelovsky měřitelná funkce, pak platí

$$\mathbb{E}(g(X_1, X_2, \dots, X_k)) = \int_{x_k} \dots \int_{x_1} g(x_1, x_2, \dots, x_k) \cdot f(x_1, x_2, \dots, x_k) \, dx_1 \dots dx_k$$

Kovariance mezi složkami vektoru $\text{cov}(X_i, X_j)$

Kovariance dvou složek náhodného vektoru $\mathbf{X} = (X_1, X_2, \dots, X_k)$ je

$$\text{cov}(X_i, X_j) = \mathbb{E}((X_i - \mathbb{E}(X_i)) \cdot (X_j - \mathbb{E}(X_j))).$$

Kovarianci značíme $\text{cov}(X_i, X_j)$ nebo též σ_{ij} .

Vlastnosti kovariance

Nechť X_i a X_j jsou složky náhodného vektoru $\mathbf{X}$ a necht existují jejich konečné druhé momenty, pak platí

- i) $-\infty < \text{cov}(X_i, X_j) < +\infty$,
- ii) $\text{cov}(X_i, X_j) = \mathbb{E}(X_i \cdot X_j) - \mathbb{E}(X_i) \cdot \mathbb{E}(X_j)$,
- iii) $\text{cov}(X_i, X_i) = \text{var}(X_i)$,
- iv) $\text{cov}(X_i, X_j) = \text{cov}(X_j, X_i) \quad \dots$ kovariance je symetrická,
- v) $\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j)$,
- vi) pokud X_i a X_j jsou nezávislé, pak $\text{cov}(X_i, X_j) = 0$.

Varianční matice

Varianční matici náhodného vektoru $\mathbf{X} = (X_1, X_2, \dots, X_k)$, jehož složky mají konečný druhý moment ($E(X_i^2) < \infty$ pro všechna $i = 1, 2, \dots, k$), je matice typu $k \times k$.

$$\mathbf{Var} \mathbf{X} = \begin{pmatrix} \text{var } X_1 & \text{cov}(X_1, X_2) & \dots & \text{cov}(X_1, X_k) \\ \text{cov}(X_2, X_1) & \text{var } X_2 & \dots & \\ \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots \\ \text{cov}(X_k, X_1) & \dots & \dots & \text{var } X_k \end{pmatrix}$$

Varianční matici značíme $\mathbf{V}(\mathbf{X})$, nebo $\mathbf{V}_{\mathbf{X}}$, případně též $\mathbf{Var} \mathbf{X}$.

Vlastnosti varianční matice

Věta

- i) Varianční matice $\mathbf{Var} \mathbf{X}$ je symetrická čtvercová matice.
- ii) $\mathbf{c}^T \cdot (\mathbf{Var} \mathbf{X}) \cdot \mathbf{c} \geq 0$.
- iii) Pro varianční matici $\mathbf{Var} \mathbf{X}$ platí následující vzorce

$$\mathbf{Var} \mathbf{X} = \mathbb{E}(\mathbf{X} - \mathbb{E}(\mathbf{X})) \cdot \mathbb{E}(\mathbf{X} - \mathbb{E}(\mathbf{X}))^T = \mathbb{E}(\mathbf{X}\mathbf{X}^T) - \mathbb{E}(\mathbf{X}) \cdot \mathbb{E}(\mathbf{X})^T.$$

- iv) $\text{diag}(\mathbf{Var} \mathbf{X}) = \text{var} \mathbf{X}$.
- v) $\mathbf{Var}(\mathbf{a} + \mathbf{BX}) = \mathbf{B} \cdot \mathbf{Var} \mathbf{X} \cdot \mathbf{B}^T$.

Kovarianční maticí vektorů $\mathbf{X}$ a $\mathbf{Y}$

Kovarianční maticí vektorů $\mathbf{X}$ a $\mathbf{Y}$ rozumíme matici

$$\mathbf{Cov}(\mathbf{X}, \mathbf{Y}) = (\text{cov}(X_i, Y_j))_{i,j}$$

pro $i = 1, \dots, k ; j = 1, \dots, m$.

- Tato matice není obecně čtvercová (rozměry závisí na rozměrech vektorů $\mathbf{X}$ a $\mathbf{Y}$.)
- Kovarianční matice dvou vektorů předpokládá existenci konečných druhých momentů složek vektorů.

Vlastnosti kovarianční matice

Vlastnosti kovarianční maticí

- i) $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}(\mathbf{X} - \mathbb{E}(\mathbf{X})) \cdot (\mathbf{Y} - \mathbb{E}(\mathbf{Y}))^T$
- ii) $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}(\mathbf{X}\mathbf{Y}) - (\mathbb{E}\mathbf{X})(\mathbb{E}\mathbf{Y})^T$
- iii) $\text{Cov}(\mathbf{X}, \mathbf{Y}) = (\text{Cov}(\mathbf{Y}, \mathbf{X}))^T$
- v) $\text{Cov}(\mathbf{X}, \mathbf{X}) = \text{Var}(\mathbf{X})$
- iv) $\text{Var}(\mathbf{X} + \mathbf{Y}) = \text{Var}(\mathbf{X}) + \text{Cov}(\mathbf{X}, \mathbf{Y}) + \text{Cov}(\mathbf{Y}, \mathbf{X}) + \text{Var}(\mathbf{Y})$
- vi) $\text{Cov}(\mathbf{a} + \mathbf{B} \cdot \mathbf{X}, \mathbf{c} + \mathbf{D} \cdot \mathbf{Y}) = \mathbf{B} \cdot \text{Cov}(\mathbf{X}, \mathbf{Y}) \cdot \mathbf{D}^T$

Korelace mezi složkami vektoru $\text{cor}(X_i, X_j)$

Korelace mezi složkami vektoru X_i a X_j je dána vztahem

$$\text{cor}(X_i, X_j) = \rho_{ij} = \frac{\text{cov}(X_i, X_j)}{\sqrt{\text{var}(X_i) \cdot \text{var}(X_j)}} = \frac{\sigma_{ij}}{\sigma_i \cdot \sigma_j}$$

Prvky $\text{cor}(X_i, X_j)$ uspořádané do matice vytváří **korelační matici**, kterou značíme **Cor $\mathbf{X}$** .

Vlastnosti

Nechť X_i a X_j jsou složky náhodného vektoru $\mathbf{X}$ a necht existují jejich konečné druhé momenty. Pak pro korelaci platí

- i) $-1 < \text{cor}(X_i, X_j) < +1$,
- ii) $\text{cor}(X_i, X_j) = \text{cor}(X_j, X_i)$,
- iii) $\text{cor}(X_i, X_i) = 1$ pro všechna $i = 1, 2, \dots, k$,
- iv) pokud X_i a X_j jsou nezávislé, pak $\text{cor}(X_i, X_j) = 0$.

Nezávislé náhodné veličiny - střední hodnota

Věta

Nechť X_1, X_2 jsou nezávislé náhodné veličiny a necht' $\mathbb{E}|X_i| < \infty$ pro $i = 1, 2$. Pak platí

$$\mathbb{E}(X_1 \cdot X_2) = \mathbb{E}(X_1) \cdot \mathbb{E}(X_2).$$

Uvedený vztah lze zobecnit pro k nezávislých náhodných veličin

$$\mathbb{E}\left(\prod_{i=1}^k X_i\right) = \prod_{i=1}^k \mathbb{E}(X_i).$$

Nezávislé náhodné veličiny - rozptyl

Věta

Nechť $X_1, X_2, \dots, X_k$ jsou nezávislé náhodné veličiny s konečnými druhými momenty, pak $\text{cov}(X_1, X_2) = 0$ a platí

$$\text{var}(X_1 + X_2 + \dots + X_k) = \text{var}(X_1) + \text{var}(X_2) + \dots + \text{var}(X_k).$$

Uvedený vztah lze zobecnit, pro libovolný vektor $\mathbf{a} = (a_1, a_2, \dots, a_k) \in \mathbb{R}^k$ tak, že platí

$$\text{var}\left(\sum_{i=1}^k a_i \cdot X_i\right) = \sum_{i=1}^k a_i^2 \cdot \text{var}(X_i).$$

Podmíněné rozdělení a jeho charakteristiky

Uvažujme dvourozměrný případ, kdy $\mathbf{X} = (X, Y)$. Pak podmíněnou střední hodnotou veličiny Y za podmínky $X = x$ rozumíme střední hodnotu podmíněného rozdělení a platí

$$\mathbb{E}(Y|x) = \int y \cdot f(y|x) dy$$

a analogicky pro rozptyl

$$\text{var}(Y|x) = \mathbb{E}(Y^2|x) - \mathbb{E}^2(Y|x).$$

Pro vícerozměrné náhodné vektory lze definovat i podmíněnou kovarianci a korelaci.

$$\text{cov}(X, Y|z) = \mathbb{E}((X - \mathbb{E}(X))|z) \cdot \mathbb{E}((Y - \mathbb{E}(Y))|z).$$

Vlastnosti podmíněných charakteristik

Protože $\mathbb{E}(Y|X = x)$ můžeme chápat jako funkci proměnné x , kterou označíme $h(x)$, pak $h(X) = \mathbb{E}(Y|X)$ a $\text{var}(Y|X)$ jsou náhodné proměnné. Tyto dvě náhodné proměnné mají zajímavé vlastnosti.

Věta

Pro náhodný vektor (X, Y) platí

- (i) $\mathbb{E}(Y) = \mathbb{E}(\mathbb{E}(Y|X))$
- (ii) $\text{var}(Y) = \mathbb{E}(\text{var}(Y|X)) + \text{var}(\mathbb{E}(Y|X))$

Vztahy lze rozšířit i pro vektory

- (i) $\mathbb{E}(\mathbf{Y}) = \mathbb{E}(\mathbb{E}(\mathbf{Y}|X))$
- (ii) $\mathbf{Var}(\mathbf{Y}) = \mathbb{E}(\mathbf{Var}(\mathbf{Y}|X)) + \mathbf{Var}(\mathbb{E}(\mathbf{Y}|X))$

Příklad

Mějme danou sdruženou funkci hustoty:

$$f(x, y) = c \left(\frac{x}{2} + \frac{y}{3} \right) \quad x \in (0; 2), y \in (0; 3)$$

Střední hodnota

$\mathbb{E}(\mathbf{X}) = (\mathbb{E}X, \mathbb{E}Y)$... z marginálních funkcí

$$\mathbb{E}X = \int_0^2 x \cdot \frac{1}{6} \left(\frac{3x}{2} + \frac{3}{2} \right) dx = \frac{7}{6}$$

$$\mathbb{E}Y = \int_0^3 y \cdot \frac{1}{6} \left(1 + \frac{2y}{3} \right) dy = \frac{7}{4}$$

Poznámka: Zde by se daly počítat střední hodnoty i u podmíněných rozdělení, teoreticky u všeho, kde známe funkci hustoty.

Rozptyl

$$\text{var}(\mathbf{X}) = (\text{var}(X), \text{var}(Y))$$

$$\text{var} X = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = \int_0^2 x^2 \cdot \frac{1}{6} \left(\frac{3x}{2} + \frac{3}{2} \right) dx - \left(\frac{7}{6} \right)^2 = \frac{11}{36}$$

$$\text{var} Y = \mathbb{E}(Y^2) - (\mathbb{E}(Y))^2 = \int_0^3 y^2 \cdot \frac{1}{6} \left(1 + \frac{2y}{3} \right) dy - \left(\frac{7}{4} \right)^2 = \frac{11}{16}$$

$$\text{cov}(X, Y) = \text{cov}(Y, X) = \mathbb{E}(X \cdot Y) - \mathbb{E}X \cdot \mathbb{E}Y =$$

$$\int_0^2 \int_0^3 x \cdot y \cdot f(x, y) dx dy - \frac{7}{6} \cdot \frac{7}{4} = 2 - \frac{7}{6} \cdot \frac{7}{4} = -\frac{1}{24} \Rightarrow \text{jsou závislé}$$