Přednáška 3: Simulování náhodných veličin

KMA/MSM Blanka Šedivá

verze 2026/2027
8. října 2026

Obsah

1. Úvod a generování pseudonáhodných čísel
2. Obecné metody simulování
3. Generování náhodných vektorů

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Simulování náhodných veličin

Proč potřebujeme simulovat náhodné veličiny?

- Chování řady statistických postupů (odhadů, testových statistik, procedur apod.) často nelze studovat exaktně (analyticky).
- Rozdělení může být příliš složité nebo prakticky nepoužitelné.
- Chování při konečných rozsazích výběru sledujeme pomocí simulací.
- Je-li posloupnost generována algoritmem, **není náhodná**. Důležité je, aby se **chovala jako náhodná**.

Výpočty v Pythonu

Všechny příklady z přednášky (včetně kódu a grafů) jsou v notebooku `P03_generovani.ipynb`. Použité funkce:

- generátor: `rng = np.random.default_rng(seed)` (PCG64), metody `random`, `uniform`, `exponential`, `laplace`, `standard_normal`, `multivariate_normal`,
- inverzní metoda: `np.searchsorted(np.cumsum(p), u)` pro diskrétní rozdělení, `scipy.stats.<rozdělení>.ppf` pro F^{-1},
- zamítací metoda: hustoty `scipy.stats.<rozdělení>.pdf`, logická maska přijetí,
- kontrola výsledku: `scipy.stats.kstest`, porovnání průměrů a rozptylů s teorií,
- vícerozměrné normální rozdělení: `np.linalg.cholesky`.

`https://numpy.org/doc/stable/reference/random/generator.html`

Simulování a zákon velkých čísel

- Nechť $X_1, X_2, \ldots, X_n$ je náhodný výběr z rozdělení náhodné veličiny X a $\mathbb{E}|g(X)| < \infty$. Pak podle silného zákona velkých čísel

$$\mu_n = \frac{1}{n}\sum_{i=1}^{n} g(X_i) \overset{n\to\infty}{\longrightarrow} \mu = \mathbb{E}g(X) \quad \text{(skoro jistě)},$$

  speciálně
  - $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \overset{n\to\infty}{\longrightarrow} \mathbb{E}X$,
  - $\frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2 \overset{n\to\infty}{\longrightarrow} \operatorname{var} X$,
  - $\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}(X_i \le c) \overset{n\to\infty}{\longrightarrow} \mathcal{P}(X \le c)$ (relativní četnost),
  - $\text{median}(X_1, X_2, \ldots, X_n) \overset{n\to\infty}{\longrightarrow} \text{median}(X)$ (je-li medián jednoznačný).
- Přesnost Monte Carlo odhadu průměru je řádu $\sigma/\sqrt{n}$ – pro desetinásobné zpřesnění potřebujeme stokrát více simulací.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Generování náhodných (pseudonáhodných) čísel z rovnoměrného rozdělení

- lineární kongruentní generátor $x_i = (ax_{i-1} + c) \bmod m$, $u_i = x_i/m$ $(i = 1, 2, \dots)$
  jednoduchý, ale s periodou nejvýše m; body $(u_i, u_{i+1}, \dots)$ leží na nadrovinách
- multiplikativní rekurzivní generátor
  $x_i = (a_1 x_{i-1} + \cdots + a_k x_{i-k}) \bmod m \ \ (i = k, k+1, \dots)$
- kombinované generátory, např. MRG32k3a (L'Ecuyer):
  $x_i = (1403580\, x_{i-2} - 810728\, x_{i-3}) \bmod m_1$, $m_1 = 2^{32} - 209$,
  $y_i = (527612\, y_{i-1} - 1370589\, y_{i-3}) \bmod m_2$, $m_2 = 2^{32} - 22853$,
  $u_i = \frac{x_i - y_i + m_1}{m_1 + 1}$ pokud $x_i \le y_i$ a $u_i = \frac{x_i - y_i}{m_1 + 1}$ pokud $x_i > y_i$

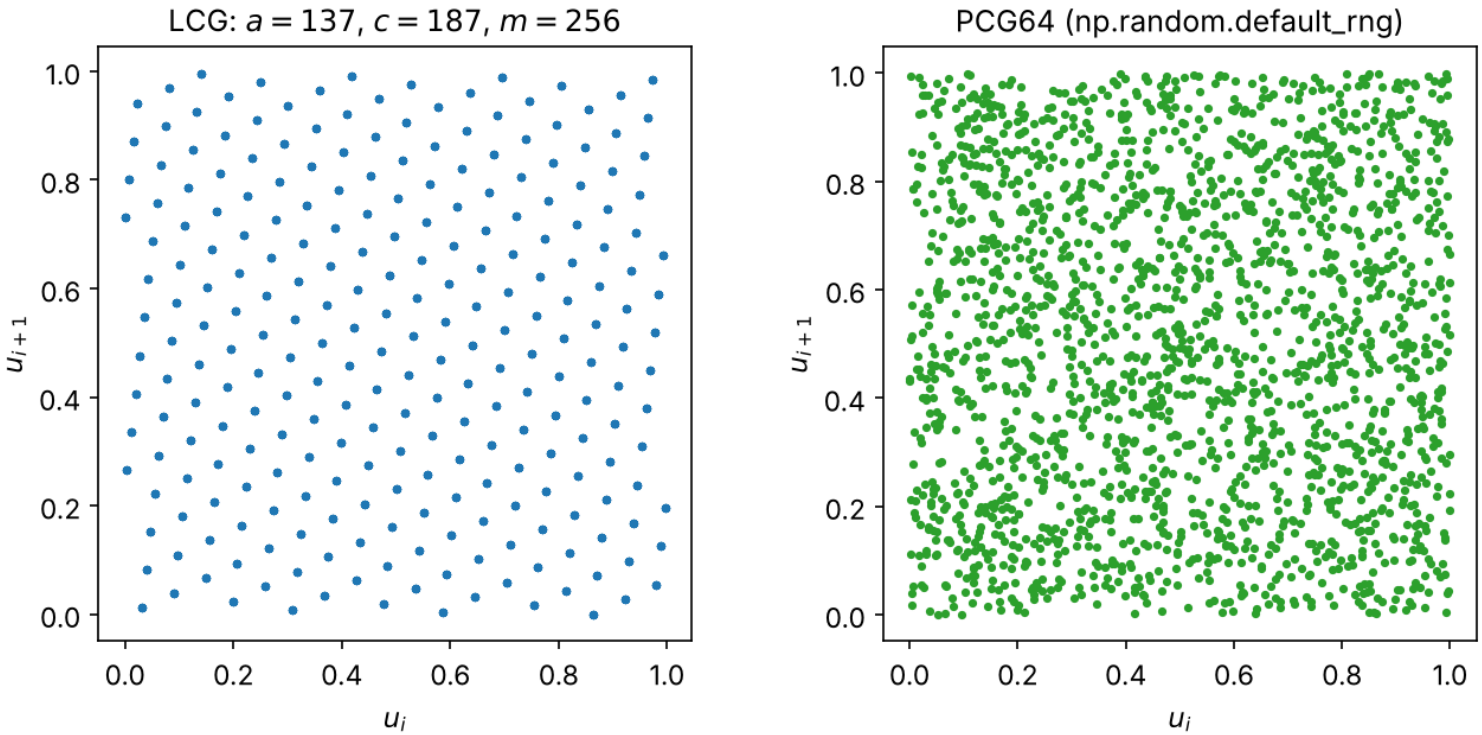
FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Současné generátory pseudonáhodných čísel

- současné generátory: Mersenne Twister (MT19937, perioda $2^{19937} - 1$), PCG64 (výchozí v NumPy), Philox (paralelní výpočty)
- kvalitu pseudonáhodných generátorů testuje řada testů (baterie TestU01, Diehard, NIST)
- seed = počáteční stav generátoru; stejný seed dává stejnou posloupnost, simulace je tak reprodukovatelná
- Více např. Dirk P. Kroese, Thomas Taimre, Zdravko I. Botev: Handbook of Monte Carlo Methods, Wiley, 2011. ISBN: 9780470177938

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Lineární kongruentní generátor – mřížková struktura



Dvojice (u_i, u_{i+1}) z LCG leží na několika rovnoběžných přímkách (nadrovinách); moderní generátor vyplní čtverec rovnoměrně.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Obecné metody simulování náhodných veličin

- metoda inverzní transformace
  využívá znalost distribuční funkce
- zamítací metoda
  využívá znalost funkce hustoty
- doplňková přijímací metoda (acceptance-complement)
  $f = f_1 + f_2$, $f_1 \leq g$; kandidáta x z g přijmeme s pravděp. $f_1(x)/g(x)$, jinak generujeme z hustoty úměrné f_2
- kompoziční metoda
  lze využít, pokud umíme napsat funkci hustoty jako směs $f(x) = \sum_j p_j f_j(x)$ jiných funkcí hustoty
- transformační metoda
  hledaná veličina je funkcí veličin, které umíme generovat (např. Box-Mullerova transformace)

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Metoda inverzní transformace

Uvažujeme náhodnou veličinu X s distribuční funkcí $F(x)$ a zobecněnou inverzní distribuční funkcí $F^{-1}(t) = \inf\{x : F(x) \geq t\}$. Pokud U má rovnoměrné rozdělení na intervalu $(0, 1)$, pak náhodná veličina $X = F^{-1}(U)$ má distribuční funkci F.

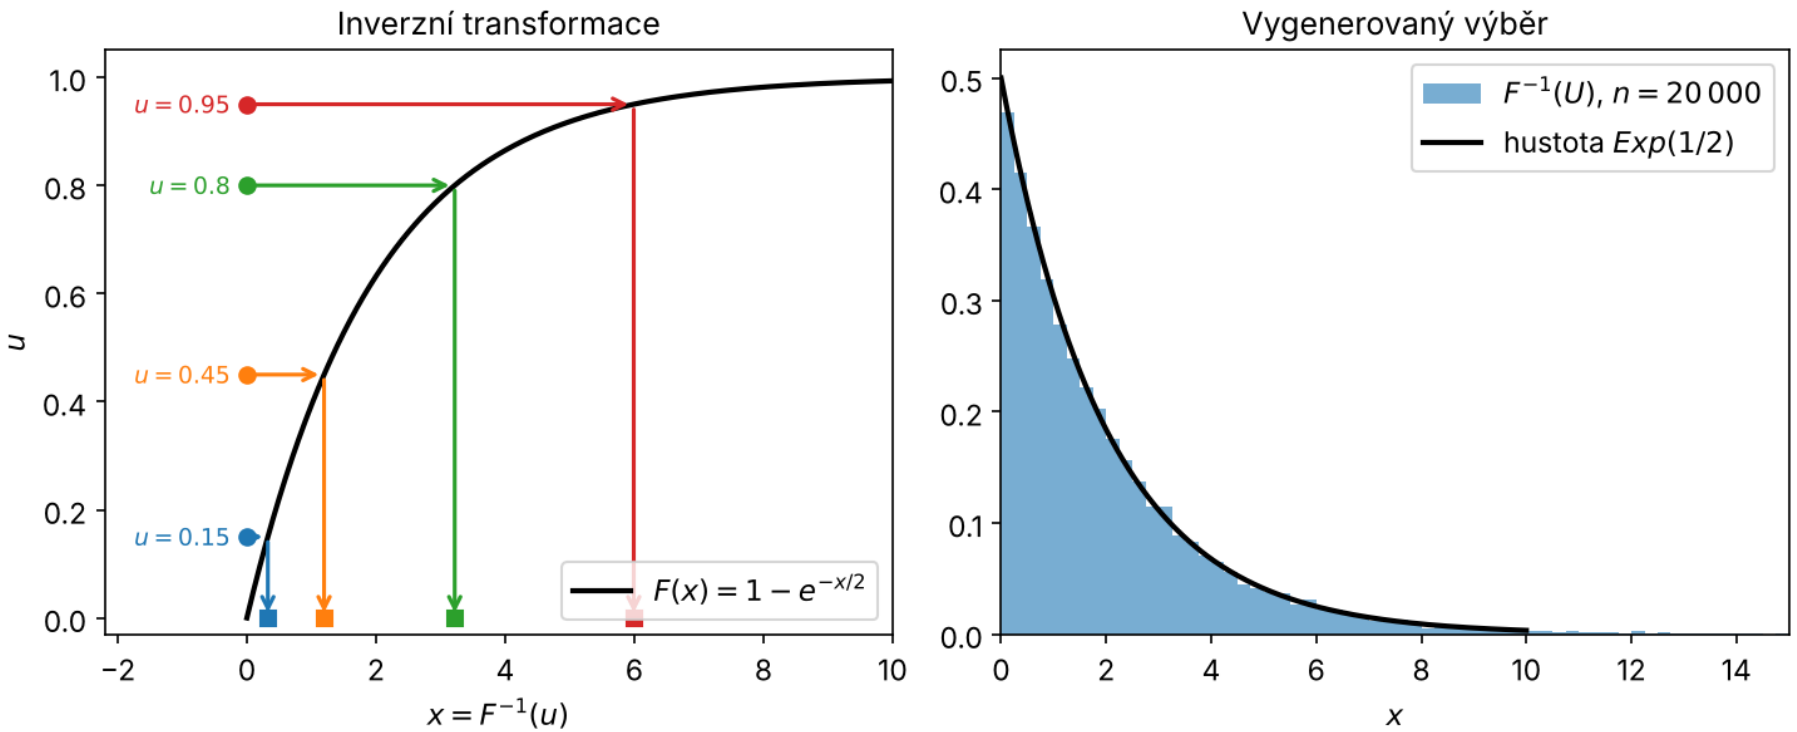
Pro generování výběru $x_1, x_2, x_3, \ldots$ lze použít následující postup

- nageneruji u_i z rovnoměrného rozdělení na intervalu $(0, 1)$,
- $x_i = F^{-1}(u_i)$.

Metoda je vhodná pro situace, kdy umím explicitně vyjádřit funkci F^{-1} (exponenciální, Weibullovo, Cauchyho rozdělení, ...).
Funkci F^{-1} lze v některých případech nahradit vhodnou aproximací. Hodnotu x_i lze získat i numerickým řešením rovnice $F(x_i) = u_i$.
Pro diskrétní veličinu s hodnotami $a_1 < a_2 < \ldots$ volíme $x_i = a_j$, kde j je nejmenší index, pro který $u_i \leq p_1 + \cdots + p_j$.

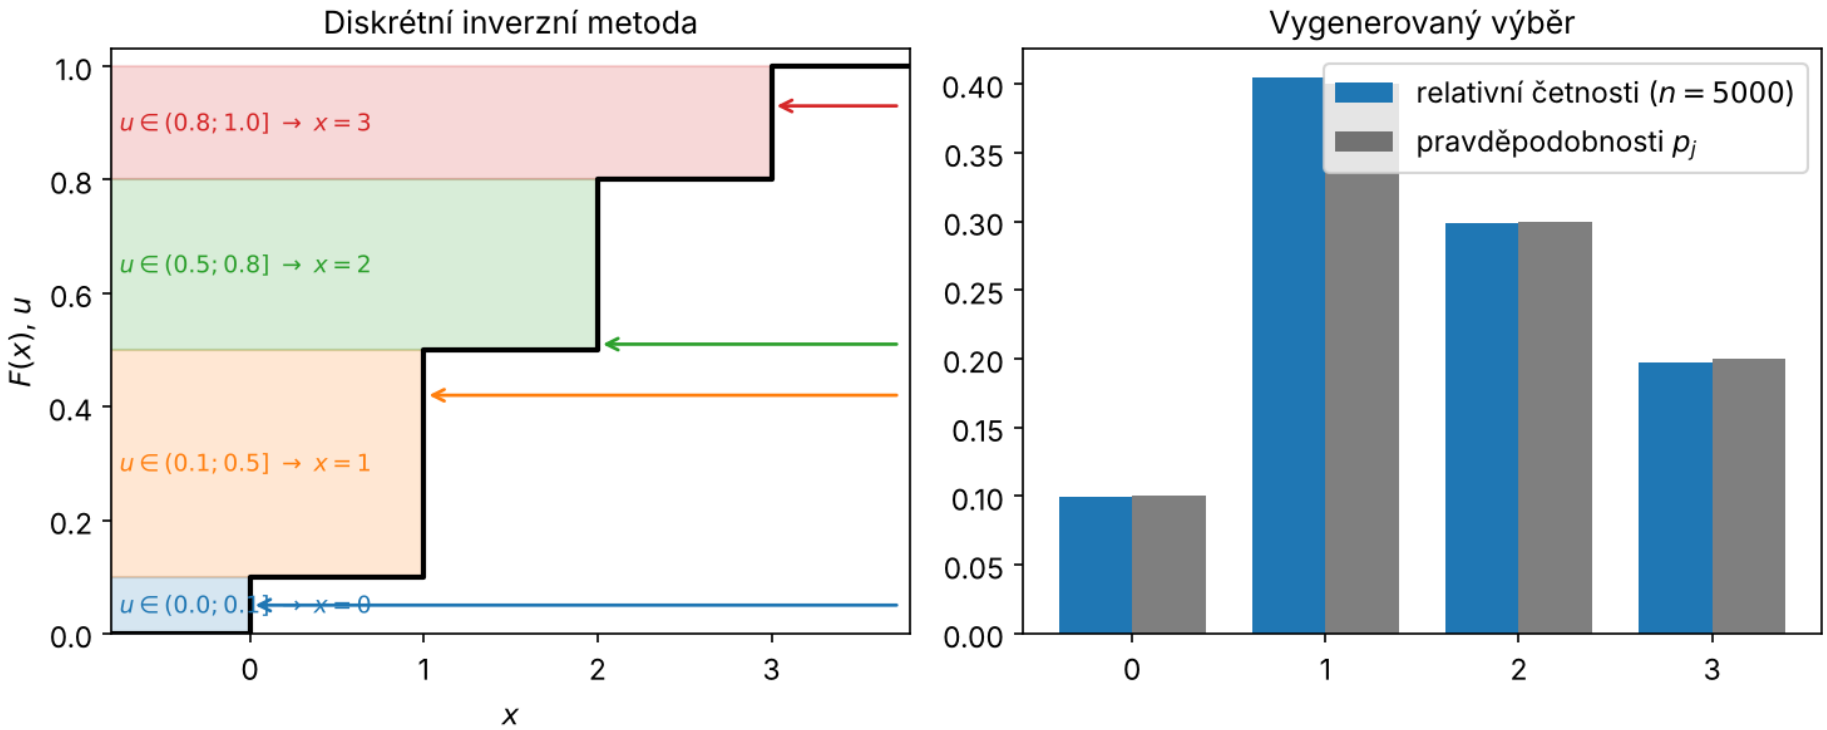
FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Metoda inverzní transformace – spojité rozdělení



Hodnoty u rovnoměrně rozložené na svislé ose se přes F^{-1} zobrazí na x – tam, kde je F strmá (velká hustota), se body zhušťují.

Metoda inverzní transformace – diskrétní rozdělení



Interval $(0, 1)$ rozdělíme na úseky délky p_j; hodnota u určí, do kterého úseku padne, a tím i hodnotu $x = a_j$.

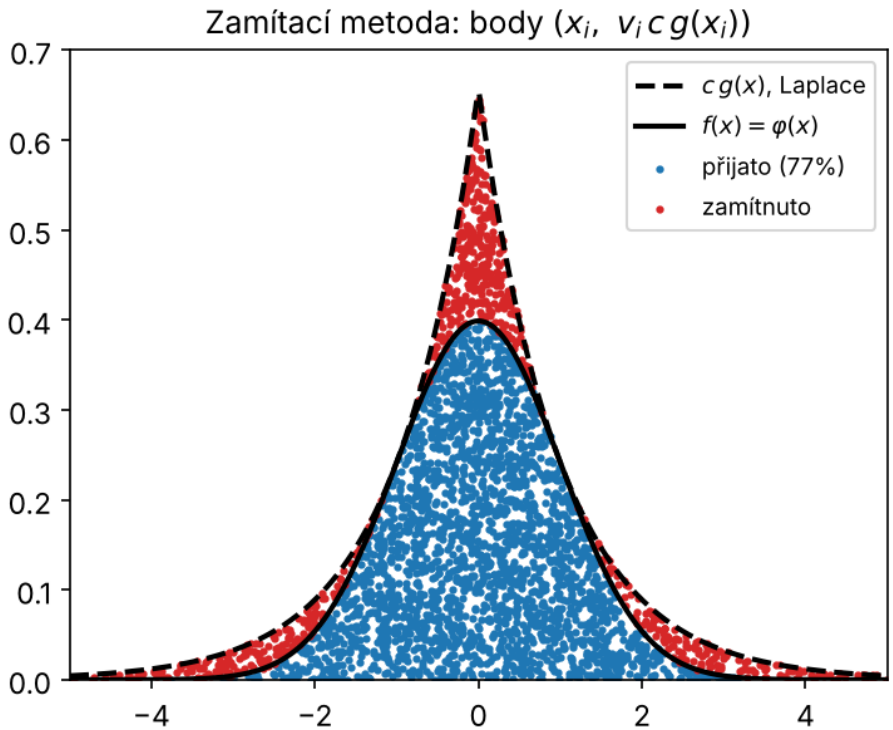
Zamítací metoda

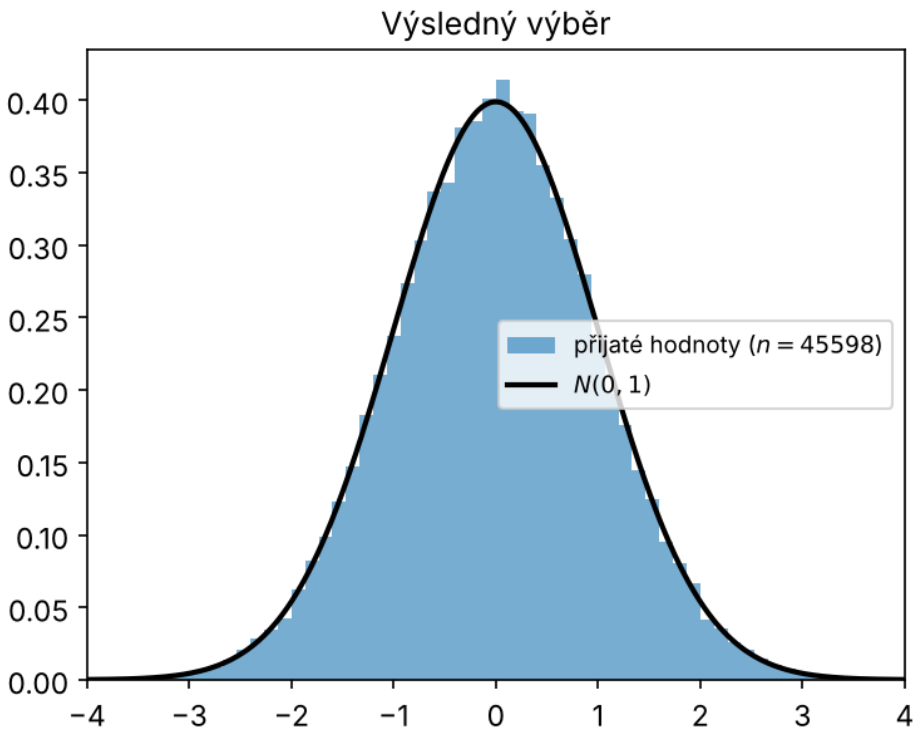
Nechť X je náhodná veličina s hustotou $f(x)$ a nechť existuje dominující funkce hustoty $g(x)$, ze které umíme generovat, a konstanta $c \geq 1$ tak, že $f(x) \leq c \cdot g(x)$ pro všechna x. Pak lze pro generování výběru $x_1, x_2, x_3, \ldots$ použít následující postup

- nageneruji x_i s hustotou $g(x)$,
- nageneruji v_i z rovnoměrného rozdělení na intervalu $(0, 1)$ nezávisle na x_i,
- pokud platí $v_i \leq \frac{f(x_i)}{c \cdot g(x_i)}$, je x_i akceptováno do výběru, jinak je zamítnuto.

Pravděpodobnost přijetí je $\frac{1}{c}$, střední počet pokusů na jednu přijatou hodnotu je c. Konstantu proto volíme co nejmenší, $c = \sup_x \frac{f(x)}{g(x)}$. Funkci f stačí znát až na normovací konstantu.

Zamítací metoda – $N(0,1)$ z Laplaceova rozdělení





Body $(x_i, v_i c\, g(x_i))$ jsou rovnoměrně rozložené pod křivkou $c\,g$; přijmeme ty, které leží pod f. Přijaté x_i mají hustotu f.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Zamítací metoda pro funkci hustoty s omezeným nosičem

Pokud funkce $f(x)$ je nenulová na konečném intervalu (a, b) (označme $M = \max_{a \leq x \leq b} f(x)$), pak lze použít následující postup

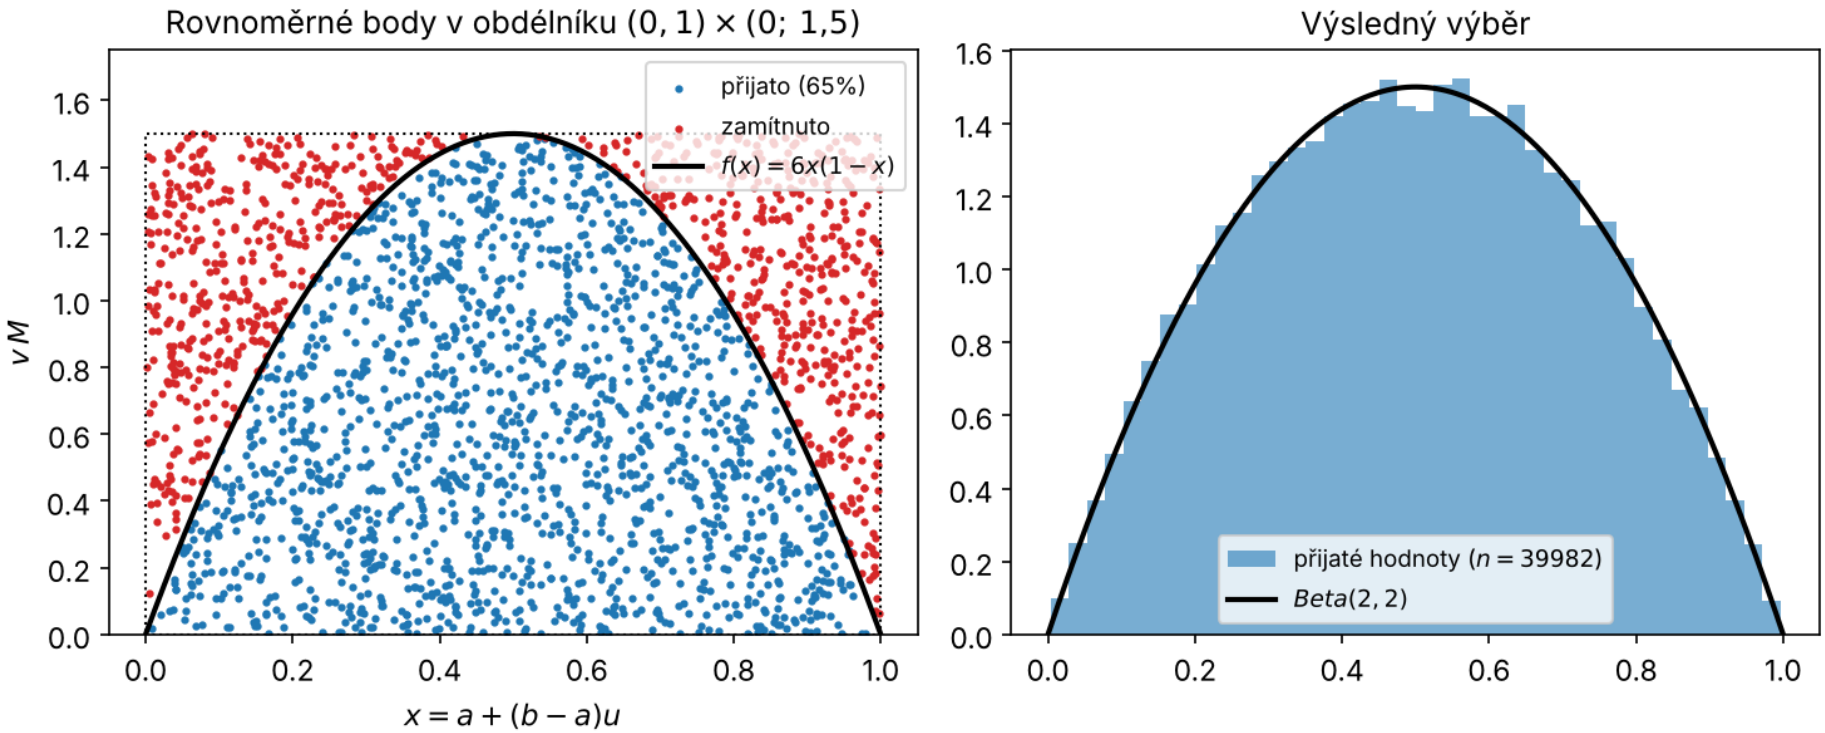
- nageneruji u_i a v_i, dvě nezávislé veličiny z $R(0, 1)$,
- $x_i = a + (b - a) \cdot u_i$,
- pokud platí $v_i \cdot M \leq f(x_i)$, je x_i akceptováno do výběru.

Jde o speciální případ zamítací metody s $g \sim R(a, b)$ a $c = M(b - a)$.

Výhoda: není třeba znát distribuční funkci ani inverzní funkci F^{-1}.
Nevýhoda: pravděpodobnost přijetí je $\frac{1}{M(b-a)}$; pokud funkce $f(x)$ vymezuje v obdélníku $(a, b) \times (0, M)$ malou plochu, bude zamítnuto mnoho dvojic (u_i, v_i).
Modifikací je metoda sevření (squeeze): f obklopíme jednoduchými funkcemi $h_1 \leq f \leq h_2$ a o přijetí většinou rozhodneme bez výpočtu f.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Zamítací metoda s omezeným nosičem – *Beta*(2, 2)



Rovnoměrně rozložené body v obdélníku $(a, b) \times (0, M)$; podíl přijatých je roven ploše pod f dělené plochou obdélníku, tj. $\frac{1}{M(b-a)} = \frac{2}{3}$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Generování náhodných vektorů pomocí inverzní metody

Uvažujme dvourozměrnou náhodnou veličinu s distribuční funkcí $F(x, y)$. Označme $F_X(x)$ marginální distribuční funkci a $F(y \mid x)$ podmíněnou distribuční funkci.
Pro generování výběru (x_i, y_i) použijeme následující postup

- nageneruji u_i a v_i, dvě nezávislé veličiny z $R(0, 1)$,
- $x_i = F_X^{-1}(u_i)$,
- $y_i = F^{-1}(v_i \mid x_i)$ (inverze podmíněné distribuční funkce při pevném x_i).

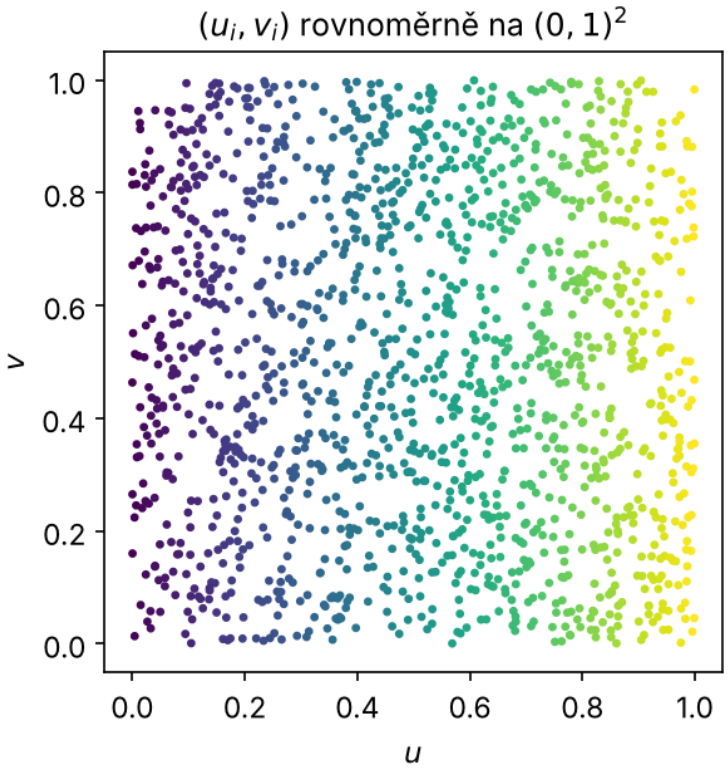
Pro k-rozměrný vektor postupně generujeme x_1 z F_1, x_2 z $F(x_2 \mid x_1)$, $\ldots$, x_k z $F(x_k \mid x_1, \ldots, x_{k-1})$.

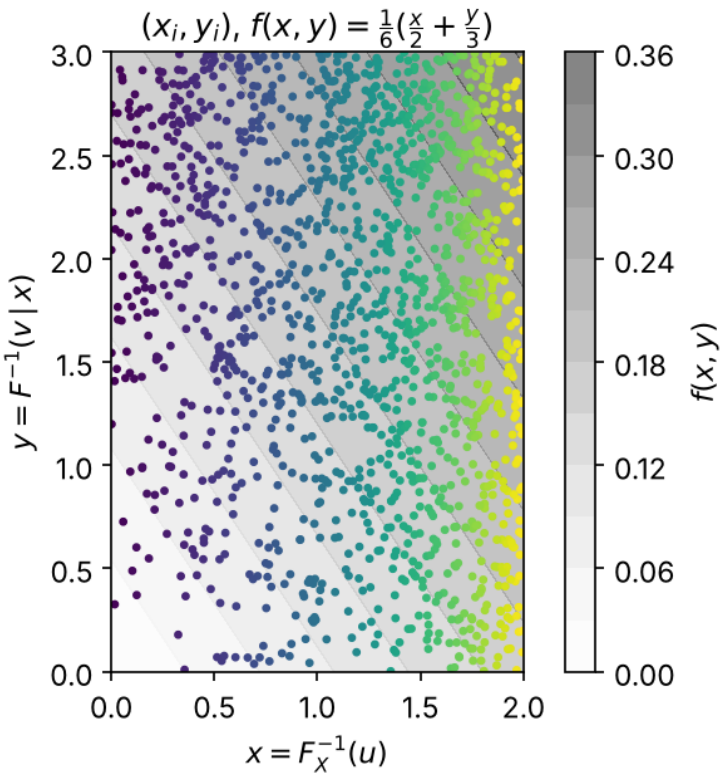
Příklad (P01b): $f(x, y) = \frac{1}{6}\left(\frac{x}{2} + \frac{y}{3}\right)$, $x \in (0, 2)$, $y \in (0, 3)$,

- $F_X(x) = \frac{x^2+2x}{8} \Rightarrow x = -1 + \sqrt{1 + 8u}$,
- $F(y \mid x) = \frac{xy/3+y^2/9}{x+1} \Rightarrow y = \frac{-3x+\sqrt{9x^2+36v(x+1)}}{2}$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Inverzní metoda pro náhodný vektor – ukázka





Barva odpovídá hodnotě u: x závisí jen na u, y na v a x. Rovnoměrné body se zhustí tam, kde je hustota $f(x, y)$ velká (vpravo nahoře).

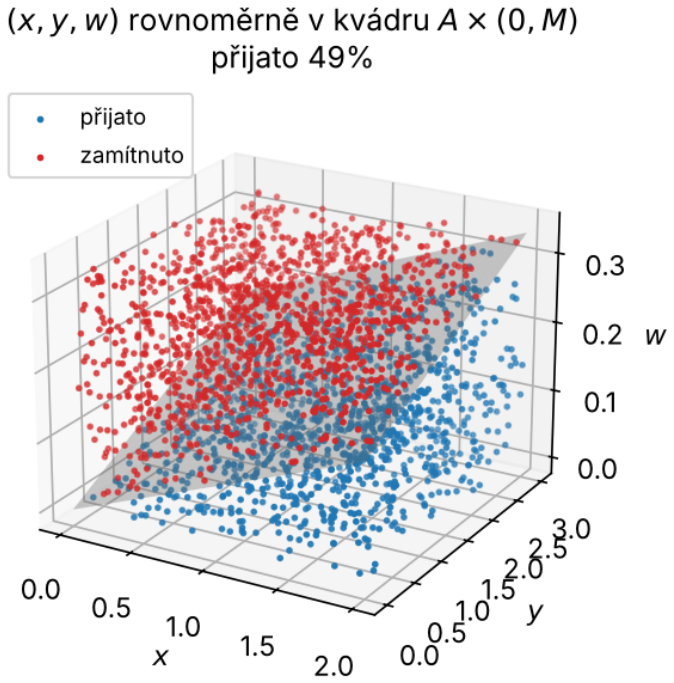
Generování náhodných vektorů pomocí zamítací metody

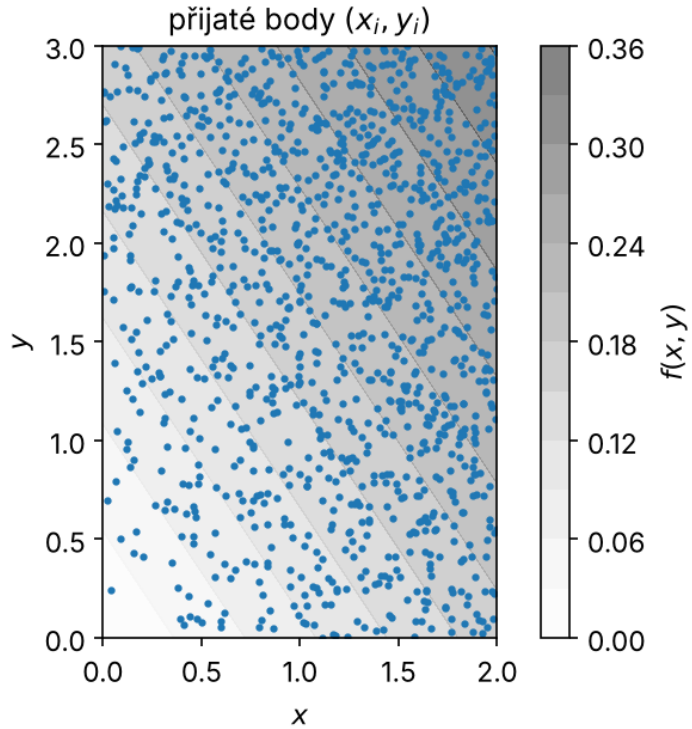
Uvažujme dvourozměrnou náhodnou veličinu s funkcí hustoty $f(x, y)$.
Předpokládejme, že funkce je nenulová na omezené oblasti A.
Označme maximum $M = \max_{(x,y)\in A} f(x, y)$.
Pro generování výběru (x_i, y_i) použijeme následující postup

- nageneruji trojici x_i, y_i, w_i rovnoměrně z oblasti vymezené plochou A a výškou M, tj. (x_i, y_i) rovnoměrně z A a w_i z $R(0, M)$,
- pokud platí $w_i \leq f(x_i, y_i)$, je (x_i, y_i) akceptováno do výběru.

Pravděpodobnost přijetí je $\frac{1}{M \cdot |A|}$, kde $|A|$ je obsah oblasti A; s rostoucí dimenzí obvykle rychle klesá.
Rovnoměrné rozdělení na složité oblasti A získáme opět zamítáním z obdélníku, který A obsahuje.

Zamítací metoda pro náhodný vektor – ukázka

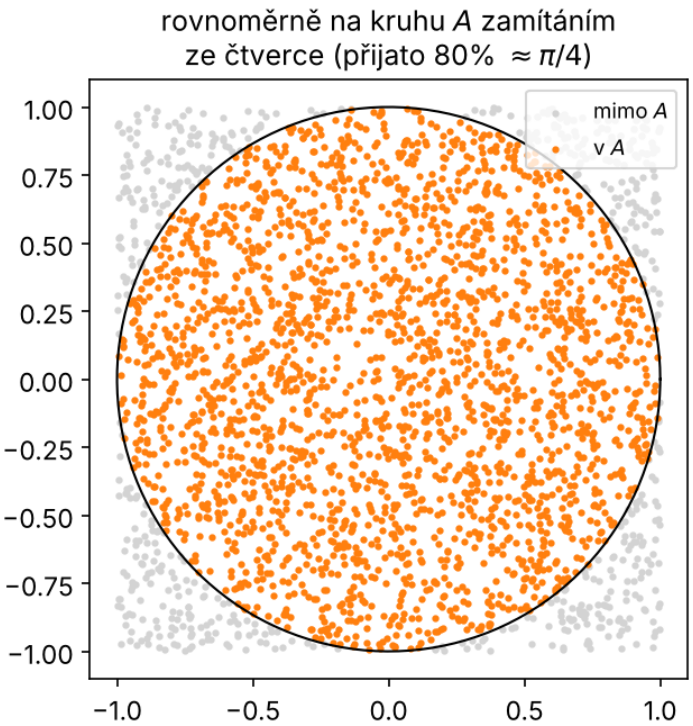


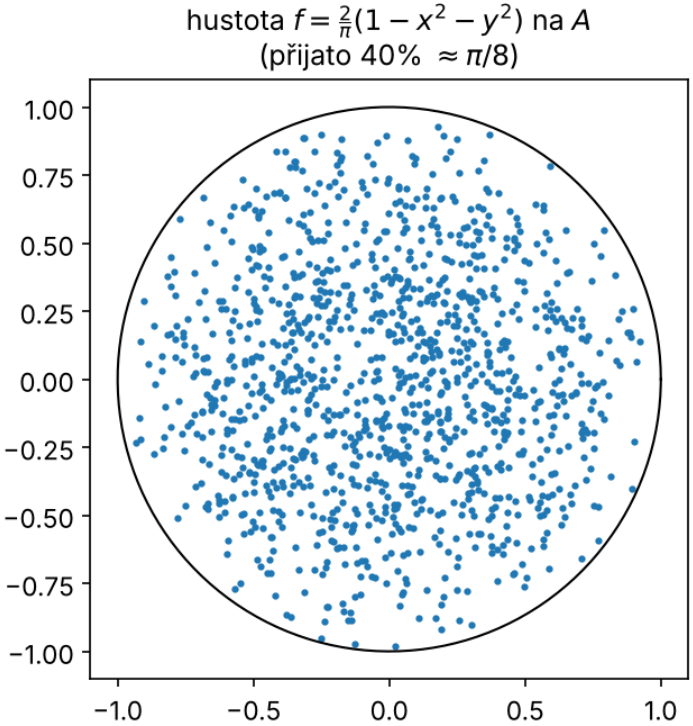


Body (x, y, w) rovnoměrně v kvádru $A \times (0, M)$; přijmeme ty pod plochou f (přijato $\frac{1}{M|A|} = \frac{1}{2}$). Průmět přijatých bodů má hustotu f.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Zamítací metoda na neobdélníkové oblasti





Rovnoměrné rozdělení na kruhu získáme zamítáním ze čtverce (přijato $\pi/4$); druhým zamítáním podle výšky $w \leq f(x, y)$ pak hustotu f na kruhu.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Generování vícerozměrného normálního rozdělení

Využijeme vlastnost lineární transformace (P02b): je-li $\boldsymbol{Z} \sim N_k(\boldsymbol{0}, \boldsymbol{I})$, pak $\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{L}\boldsymbol{Z} \sim N_k(\boldsymbol{\mu}, \boldsymbol{L}\boldsymbol{L}^T)$.

Pro generování výběru z $N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ použijeme následující postup

- rozložíme $\boldsymbol{\Sigma} = \boldsymbol{L}\boldsymbol{L}^T$ (Choleského rozklad, $\boldsymbol{L}$ dolní trojúhelníková),
- nageneruji k nezávislých veličin $z_1, \ldots, z_k$ z $N(0, 1)$,
- položím $\boldsymbol{x} = \boldsymbol{\mu} + \boldsymbol{L}\boldsymbol{z}$.

Místo $\boldsymbol{L}$ lze použít $\boldsymbol{\Sigma}^{1/2}$ nebo spektrální rozklad $\boldsymbol{\Sigma} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^T$, $\boldsymbol{L} = \boldsymbol{V}\boldsymbol{\Lambda}^{1/2}$.

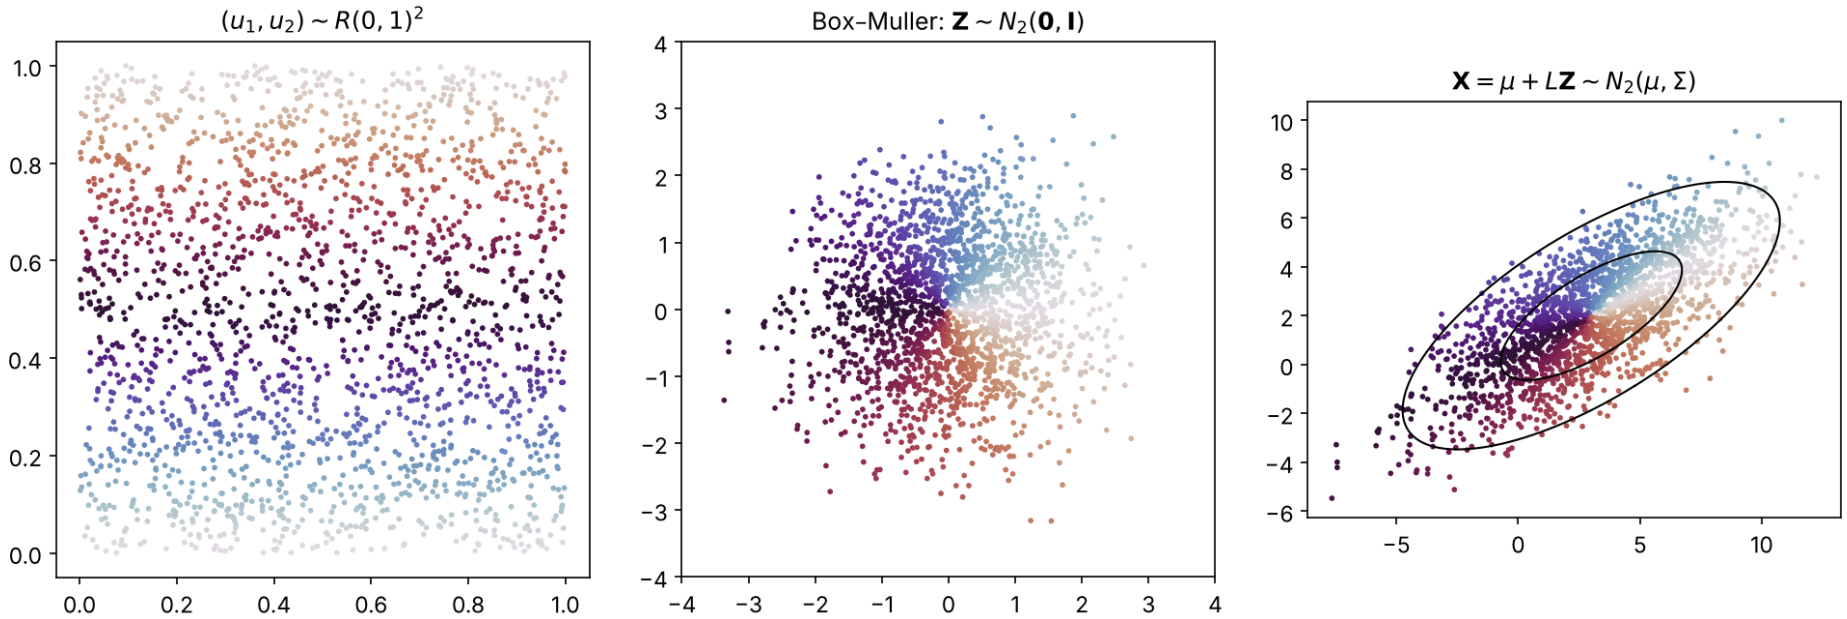
Box-Mullerova transformace: jsou-li $U_1, U_2 \sim R(0, 1)$ nezávislé, pak

$$Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2), \qquad Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

jsou nezávislé $N(0, 1)$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Generování $N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ – Box–Muller a Choleského rozklad



Box–Mullerova transformace převede rovnoměrné body na $N_2(\mathbf{0}, \boldsymbol{I})$ (barva podle u_2 = úhel), lineární transformace $\boldsymbol{\mu} + \boldsymbol{Lz}$ je převede na $N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$; elipsy obsahují 50 a 95 % pravděpodobnosti.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI