KMA/MSM – cvičení 4: Vícerozměrná data

(verze s výsledky)

Úlohy v částech A–C řešte nejprve „ručně“, výsledky ověřte v Pythonu; úlohy v části D jsou počítačové. Viz notebook `P04_vicerozmerna_data.ipynb`. Značení: n počet pozorování, k dimenze, S korigovaná výběrová varianční matice (dělitel $n-1$), S_0 ML odhad (dělitel n).

A. Datová matice a výběrové statistiky

1. **Výběrové charakteristiky ručně.** Je dána datová matice ($n=4$, $k=2$)

$$\mathcal{X} = \begin{pmatrix} 2 & 1 \\ 4 & 3 \\ 3 & 5 \\ 7 & 3 \end{pmatrix}.$$

   (a) Spočtěte $\bar{\boldsymbol{x}} = n^{-1}\mathcal{X}^T\mathbf{1}_n$ a matici $n^{-1}\mathcal{X}^T\mathcal{X}$.

   (b) Spočtěte $S_0 = n^{-1}\mathcal{X}^T\mathcal{X} - \bar{\boldsymbol{x}}\bar{\boldsymbol{x}}^T$, S a korelační matici R.

   (c) Spočtěte zobecněný rozptyl $|S|$ a celkový rozptyl $\operatorname{tr} S$.

   Výsledky: a) $\bar{\boldsymbol{x}} = (4;\ 3)^T$, $n^{-1}\mathcal{X}^T\mathcal{X} = \begin{pmatrix} 19{,}5 & 12{,}5 \\ 12{,}5 & 11 \end{pmatrix}$. b) $S_0 = \begin{pmatrix} 19{,}5-16 & 12{,}5-12 \\ 12{,}5-12 & 11-9 \end{pmatrix} = \begin{pmatrix} 3{,}5 & 0{,}5 \\ 0{,}5 & 2 \end{pmatrix}$, $S = \frac{4}{3}S_0 = \begin{pmatrix} 4{,}667 & 0{,}667 \\ 0{,}667 & 2{,}667 \end{pmatrix}$, $r_{12} = \frac{0{,}5}{\sqrt{3{,}5\cdot 2}} = 0{,}189$ (korelace na děliteli nezávisí). c) $|S| = 12$, $\operatorname{tr} S = 7{,}33$.

2. **Standardizace a normalizace.** Pro data z úlohy 1:

   (a) standardizujte sloupce ($z = (x-\bar{x})/s$) a normalizujte je do intervalu $\langle 0, 1\rangle$,

   (b) normalizujte první řádek na jednotkovou délku,

   (c) ukažte, že korelační matice se standardizací po sloupcích nezmění. Co se stane s varianční maticí?

   Výsledky: a) $s_1 = 2{,}160$, $s_2 = 1{,}633$; $Z = \begin{pmatrix} -0{,}926 & -1{,}225 \\ 0 & 0 \\ -0{,}463 & 1{,}225 \\ 1{,}389 & 0 \end{pmatrix}$; min–max: $\begin{pmatrix} 0 & 0 \\ 0{,}4 & 0{,}5 \\ 0{,}2 & 1 \\ 1 & 0{,}5 \end{pmatrix}$. b) $(2;\ 1)/\sqrt{5} = (0{,}894;\ 0{,}447)$. c) Standardizace je lineární transformace $\boldsymbol{z} = D^{-1/2}(\boldsymbol{x}-\bar{\boldsymbol{x}})$ s $D = \operatorname{diag}(S)$, varianční matice standardizovaných dat je $D^{-1/2}SD^{-1/2} = R$ – tedy korelační matice původních dat. Korelace se nemění.

3. **Vícerozměrná standardizace.** Výběrová varianční matice je $S = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$.

   (a) Najděte vlastní čísla a vlastní vektory S a symetrické matice $S^{1/2}$ a $S^{-1/2}$.

   (b) Transformujte odchylky $\boldsymbol{x}-\bar{\boldsymbol{x}} = (3;\ 3)^T$ a $(3;\ -3)^T$ na $\boldsymbol{z} = S^{-1/2}(\boldsymbol{x}-\bar{\boldsymbol{x}})$ a spočtěte jejich Mahalanobisovy vzdálenosti. Porovnejte s Eukleidovskou vzdáleností a vysvětlete rozdíl.

Výsledky: a) $\lambda_1 = 9$, $\boldsymbol{v}_1 = \frac{1}{\sqrt{2}}(1;\ 1)$; $\lambda_2 = 1$, $\boldsymbol{v}_2 = \frac{1}{\sqrt{2}}(1;\ -1)$. $S^{1/2} = V\Lambda^{1/2}V^T = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, $S^{-1/2} = \frac{1}{3}\begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$. b) $(3;\ 3) \mapsto (1;\ 1)$, $d^2 = 2$; $(3;\ -3) \mapsto (3;\ -3)$, $d^2 = 18$. Eukleidovská vzdálenost je v obou případech $\sqrt{18}$. První odchylka leží ve směru největší variability ($\lambda_1 = 9$), druhá ve směru nejmenší ($\lambda_2 = 1$) – proto je druhý bod v Mahalanobisově smyslu devětkrát „dál“.

4. **Vychýlení odhadu varianční matice.** Ukažte, že pro náhodný výběr s $\mathrm{E}\,\boldsymbol{X}_i = \boldsymbol{\mu}$, $\mathbf{Var}\,\boldsymbol{X}_i = \boldsymbol{\Sigma}$ platí $\mathrm{E}\,S_0 = \frac{n-1}{n}\boldsymbol{\Sigma}$. Jak velké je vychýlení pro $n = 5$ a pro $n = 150$? Proč nezáleží na volbě dělitele u korelační matice?

   Výsledky: $\sum_i (\boldsymbol{X}_i - \bar{\boldsymbol{X}})(\boldsymbol{X}_i - \bar{\boldsymbol{X}})^T = \sum_i \boldsymbol{X}_i\boldsymbol{X}_i^T - n\bar{\boldsymbol{X}}\,\bar{\boldsymbol{X}}^T$; $\mathrm{E}\,\boldsymbol{X}_i\boldsymbol{X}_i^T = \boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^T$, $\mathrm{E}\,\bar{\boldsymbol{X}}\,\bar{\boldsymbol{X}}^T = \frac{1}{n}\boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^T$, tedy $\mathrm{E}\,nS_0 = n\boldsymbol{\Sigma} - \boldsymbol{\Sigma} = (n-1)\boldsymbol{\Sigma}$. Pro $n = 5$ je $\mathrm{E}\,S_0 = 0{,}8\,\boldsymbol{\Sigma}$ (podhodnocení o 20 %), pro $n = 150$ o 0,67 %. V korelaci $r_{ij} = s_{ij}/\sqrt{s_{ii}s_{jj}}$ se dělitel zkrátí.

B. Rozdělení odvozená od normálního rozdělení

5. **Hotellingovo rozdělení.** Pro náhodný výběr rozsahu $n = 20$ z $N_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ vyšlo $T^2 = n(\bar{\boldsymbol{x}} - \boldsymbol{\mu}_0)^T S^{-1}(\bar{\boldsymbol{x}} - \boldsymbol{\mu}_0) = 10{,}5$.

   (a) Převeďte T^2 na statistiku s F-rozdělením a rozhodněte o $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ ($F_{0,95}(3; 17) = 3{,}20$).

   (b) Jaký závěr bychom dostali, kdybychom T^2 nesprávně porovnali s χ^2_3 ($\chi^2_{0,95}(3) = 7{,}81$)? Proč?

   Výsledky: a) $F = \frac{n-k}{k(n-1)}T^2 = \frac{17}{57} \cdot 10{,}5 = 3{,}13 < 3{,}20$, $p = 0{,}053$ – nezamítáme. Kritická hodnota pro T^2 je $\frac{57}{17} \cdot 3{,}20 = 10{,}72$. b) $10{,}5 > 7{,}81$, $p = 0{,}015$ – zamítli bychom. Rozdělení χ^2_k platí jen při známé $\boldsymbol{\Sigma}$ (nebo asymptoticky); odhad S přidává variabilitu, Hotellingovo rozdělení má těžší chvost. Při $n = 20$ je rozdíl podstatný.

6. **Konfidenční oblast pro $\boldsymbol{\mu}$ a oblast pro pozorování.** Z výběru rozsahu $n = 25$ dvourozměrných dat vyšlo $\bar{\boldsymbol{x}} = (10;\ 20)^T$ a $S = \begin{pmatrix} 4 & 2 \\ 2 & 9 \end{pmatrix}$.

   (a) Leží bod $\boldsymbol{\mu}_0 = (11;\ 19)^T$ v 95% konfidenční oblasti pro $\boldsymbol{\mu}$? ($F_{0,95}(2; 23) = 3{,}42$)

   (b) Leží pozorování $\boldsymbol{x} = (14;\ 26)^T$ uvnitř elipsy $d^2 \le \chi^2_2(0{,}95) = 5{,}99$, v níž leží přibližně 95 % pozorování?

   (c) Proč jsou obě elipsy tak rozdílně velké?

   Výsledky: $S^{-1} = \frac{1}{32}\begin{pmatrix} 9 & -2 \\ -2 & 4 \end{pmatrix}$. a) $\bar{\boldsymbol{x}} - \boldsymbol{\mu}_0 = (-1;\ 1)$, $T^2 = 25 \cdot \frac{9+4+4}{32} = 13{,}28 > \frac{24 \cdot 2}{23} \cdot 3{,}42 = 7{,}14$ – bod $\boldsymbol{\mu}_0$ v konfidenční oblasti neleží (i když se od $\bar{\boldsymbol{x}}$ liší jen o jednotku v každé složce). b) $\boldsymbol{x} - \bar{\boldsymbol{x}} = (4;\ 6)$, $d^2 = \frac{9 \cdot 16 - 2 \cdot 2 \cdot 24 + 4 \cdot 36}{32} = 6{,}0 > 5{,}99$ – těsně vně. c) $\mathbf{Var}\,\bar{\boldsymbol{X}} = \boldsymbol{\Sigma}/n$: konfidenční oblast pro $\boldsymbol{\mu}$ je zhruba $\sqrt{n}$-krát menší než oblast pro jednotlivá pozorování.

7. **Wishartovo rozdělení.** Nechť $M \sim W_k(\boldsymbol{\Sigma}, m)$.

   (a) Jaká je $\mathrm{E}\,M$? Jaké rozdělení má M pro $k = 1$?

(b) Pro výběr rozsahu $n = 11$ z $N(\mu, \sigma^2)$ určete $\mathcal{P}(s^2 > 1{,}5\,\sigma^2)$ a interval, ve kterém leží s^2/σ^2 s pravděpodobností 0,95.

Výsledky: a) $\mathrm{E}\,M = m\boldsymbol{\Sigma}$; pro $k = 1$ je $W_1(\sigma^2, m) = \sigma^2\chi^2_m$. b) $(n-1)s^2/\sigma^2 \sim \chi^2_{10}$: $\mathcal{P}(s^2 > 1{,}5\sigma^2) = \mathcal{P}(\chi^2_{10} > 15) = 0{,}132$. Interval: χ^2_{10} má kvantily 3,25 a 20,48, tedy $s^2/\sigma^2 \in (0{,}325;\ 2{,}048)$ – odhad rozptylu z 11 pozorování je velmi nepřesný.

8. **Rozdělení Mahalanobisových vzdáleností.** Pro výběr rozsahu $n = 20$ z N_2 jsou $d_i^2 = (\boldsymbol{x}_i - \bar{\boldsymbol{x}})^T S^{-1} (\boldsymbol{x}_i - \bar{\boldsymbol{x}})$.

   (a) Ukažte, že $\sum_i d_i^2 = (n-1)k$ (nápověda: d_i^2 je skalár, použijte stopu). Jaký je průměr d_i^2?

   (b) Maximální možná hodnota je $d_i^2 \le \frac{(n-1)^2}{n}$. Kolik to je pro $n = 20$?

   (c) Pozorování má $d^2 = 12$. Spočtěte pravděpodobnost $\mathcal{P}(d^2 \ge 12)$ podle přesného rozdělení $\frac{n}{(n-1)^2} d^2 \sim Beta\left(\frac{k}{2}, \frac{n-k-1}{2}\right)$ a podle aproximace χ^2_2.

Výsledky: a) $\sum_i d_i^2 = \sum_i \mathrm{tr}\,(S^{-1}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})(\boldsymbol{x}_i - \bar{\boldsymbol{x}})^T) = \mathrm{tr}\,(S^{-1}(n-1)S) = (n-1)k = 38$, průměr 1,9. b) $\frac{19^2}{20} = 18{,}05$ – rozdělení χ^2_2 s neomezeným nosičem proto u malých n nevystihuje horní chvost. c) $\frac{20}{361} \cdot 12 = 0{,}665$; pro $Beta(1;\ 8{,}5)$ je $\mathcal{P}(B \ge b) = (1-b)^{8{,}5} = 9{,}2 \cdot 10^{-5}$. Aproximace: $\mathcal{P}(\chi^2_2 \ge 12) = \mathrm{e}^{-6} = 0{,}0025$ – liší se o více než řád.

C. Vizualizace

9. **Počet tříd histogramu.** Pro $n = 200$ hodnot je rozpětí $R = 14$, výběrová směrodatná odchylka $s = 2{,}5$ a kvartilové rozpětí $R_Q = 3{,}2$. Určete počet tříd podle Sturgesova pravidla a šířku intervalu (a odpovídající počet tříd) podle Scottova a Freedmanova–Diaconisova pravidla. Kdy se FD pravidlo hodí více než Scottovo?

   Výsledky: Sturges: $m = \lceil 1 + \log_2 200 \rceil = \lceil 8{,}64 \rceil = 9$. Scott: $h = 3{,}5 \cdot 2{,}5/200^{1/3} = 1{,}50$, $m = \lceil 14/1{,}50 \rceil = 10$. FD: $h = 2 \cdot 3{,}2/200^{1/3} = 1{,}09$, $m = \lceil 12{,}8 \rceil = 13$. FD používá kvartilové rozpětí, je proto robustní vůči odlehlým hodnotám a těžkým chvostům (zde s je relativně velké vůči R_Q, což ukazuje na těžší chvosty – pro normální rozdělení je $R_Q \approx 1{,}35\,s$).

D. Počítačové úlohy

10. **Data Iris v Pythonu** (`sklearn.datasets.load_iris`).

    (a) Spočtěte $\bar{\boldsymbol{x}}$, S_0 a S maticovými vzorci a ověřte proti `np.cov`. Ověřte, že po standardizaci pomocí `StandardScaler` mají sloupce výběrový rozptyl (s dělitelem $n-1$) roven $\frac{n}{n-1}$.

    (b) Proveďte vícerozměrnou standardizaci (whitening) a ověřte, že výběrová varianční matice transformovaných dat je $\boldsymbol{I}$ a že Mahalanobisova vzdálenost je rovna Eukleidovské vzdálenosti transformovaných dat od počátku.

    (c) Nakreslete Q-Q graf Mahalanobisových vzdáleností (Beta i χ^2 kvantily) pro samotný druh setosa a pro všechny tři druhy dohromady. Proč je odchylka od diagonály u všech druhů mnohem větší?

(d) Pro proměnnou *petal length* porovnejte počet tříd podle pravidel `"sturges"`, `"scott"` a `"fd"` a jádrový odhad hustoty s různou šířkou pásma. Které nastavení nejlépe zachytí bimodalitu?

(e) Pro setosu porovnejte průměr, medián po složkách a polohu odhadu MCD. Přidejte 5 odlehlých bodů a sledujte, jak se odhady posunou.

Výsledky: a) $\bar{\boldsymbol{x}} = (5{,}843;\ 3{,}057;\ 3{,}758;\ 1{,}199)$; poměr směrodatných odchylek je $\sqrt{150/149} = 1{,}0034$. c) Data všech tří druhů jsou směsí tří rozdělení s různými průměry – nejde o jedno vícerozměrné normální rozdělení, Q-Q graf se od diagonály výrazně odchyluje. Pro setosu leží body zhruba na diagonále. d) *Petal length*: Sturges 9 tříd (šířka 0,66), Scott 6 tříd (0,98), FD 5 tříd (1,18) – u bimodálních dat dávají Scott i FD příliš široké třídy, mezera mezi setosou ($< 2\,\text{cm}$) a ostatními druhy je nejlépe vidět při Sturgesově pravidle nebo jemnějším dělení. Jádrový odhad se Scottovou šířkou pásma i s `bw_method=0.3` má dva vrcholy (asi 1,5 a 4,8 cm), s `bw_method=1` jen jeden – bimodalitu přehladí. e) Pět odlehlých bodů posune průměr délky kališního lístku o 0,23 cm, medián se nezmění, MCD se posune nejvýše o 0,05.