KMA/MSM – Přednáška 4: Vícerozměrná data

Kontrolní otázky (uzavřené) – verze s řešením

U otázek označených (*jedna odpověď*) je správná právě jedna možnost, u otázek označených (*více odpovědí*) může být správných více možností.

Otázka 1 (jedna odpověď)

Který odhad varianční matice $\boldsymbol{\Sigma}$ je nestranný?

a) $S_0 = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})(\boldsymbol{x}_i - \bar{\boldsymbol{x}})^T$

b) $S = \frac{1}{n-1}\sum_{i=1}^{n}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})(\boldsymbol{x}_i - \bar{\boldsymbol{x}})^T$ **[správně]**

c) $\frac{1}{n}\mathcal{X}^T\mathcal{X}$

d) $\frac{1}{n-1}\mathcal{X}^T\mathcal{X}$

Řešení: $\mathrm{E}\, S_0 = \frac{n-1}{n}\boldsymbol{\Sigma}$, proto $S = \frac{n}{n-1}S_0$ je nestranný. Matice $\frac{1}{n}\mathcal{X}^T\mathcal{X}$ je matice druhých momentů – bez odečtení $\bar{\boldsymbol{x}}\bar{\boldsymbol{x}}^T$ odhaduje $\boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^T$. S_0 je maximálně věrohodný odhad v normálním modelu.

Otázka 2 (více odpovědí)

Která tvrzení o standardizaci a normalizaci dat jsou pravdivá?

a) Standardizace po sloupcích nemění korelační matici dat. **[správně]**

b) Standardizace po sloupcích odstraní korelace mezi proměnnými.

c) Normalizace min–max do intervalu $\langle 0, 1\rangle$ je citlivá na odlehlé hodnoty. **[správně]**

d) Po vícerozměrné standardizaci $\boldsymbol{z}_i = S^{-1/2}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})$ je výběrová varianční matice jednotková. **[správně]**

e) `StandardScaler` ze `sklearn` dělí výběrovou směrodatnou odchylkou s dělitelem $n - 1$.

Řešení: Správně a), c), d). Standardizace po sloupcích je změna měřítka jednotlivých proměnných – varianční matice se změní na korelační, korelace zůstanou; odstraní je až vícerozměrná standardizace (whitening). `StandardScaler` používá dělitel n (`ddof=0`).

Otázka 3 (jedna odpověď)

Pro náhodný výběr rozsahu $n = 20$ z $N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ má statistika $T^2 = n(\bar{\boldsymbol{X}} - \boldsymbol{\mu})^T S^{-1}(\bar{\boldsymbol{X}} - \boldsymbol{\mu})$ rozdělení $T^2(2, 19)$. Kterému rozdělení odpovídá?

a) χ^2_2

b) $\frac{38}{18}F(2, 18)$ **[správně]**

c) $F(2, 19)$

d) $\frac{18}{38}F(2, 18)$

Řešení: $T^2(k, m) = \frac{mk}{m-k+1}F(k, m-k+1)$, pro $k = 2$, $m = n - 1 = 19$: $\frac{38}{18}F(2, 18)$. Ekvivalentně $\frac{n-k}{k(n-1)}T^2 \sim F(k, n-k)$. Rozdělení χ^2_2 platí jen při známé $\boldsymbol{\Sigma}$ nebo asymptoticky.

Otázka 4 (více odpovědí)

Která tvrzení o vizualizaci jednorozměrných dat jsou pravdivá?

a) Q-Q graf je citlivý zejména na odchylky v chvostech rozdělení. **[správně]**

b) Freedmanovo–Diaconisovo pravidlo pro šířku intervalu histogramu používá kvartilové rozpětí, a je proto robustní vůči odlehlým hodnotám. **[správně]**

c) Sturgesovo pravidlo pro počet tříd závisí na variabilitě dat.

d) Při větší šířce pásma h je jádrový odhad hustoty hladší. **[správně]**

e) Pokud intervaly histogramu nemají stejnou šířku, odpovídá četnosti výška sloupce.

Řešení: Správně a), b), d). Sturgesovo pravidlo $m = \lceil 1 + \log_2 n \rceil$ závisí jen na rozsahu výběru. Při nestejných šířkách musí četnosti odpovídat *ploše* sloupce (výška = četnost / šířka intervalu).

Otázka 5 (jedna odpověď)

Jaký předpoklad stačí k tomu, aby podle vícerozměrné centrální limitní věty platilo $\sqrt{n}(\bar{\boldsymbol{X}} - \boldsymbol{\mu}) \to N_k(\mathbf{0}, \boldsymbol{\Sigma})$?

a) Složky vektoru $\boldsymbol{X}$ jsou nezávislé.

b) $\boldsymbol{X}$ má vícerozměrné normální rozdělení.

c) Náhodný výběr z rozdělení s konečnou varianční maticí $\boldsymbol{\Sigma}$. **[správně]**

d) Složky vektoru $\boldsymbol{X}$ mají stejné rozptyly.

Řešení: Stačí náhodný výběr (nezávislé, stejně rozdělené vektory) s konečnou varianční maticí; složky mohou být libovolně závislé a rozdělení nemusí být normální. Při normálním rozdělení platí $\bar{\boldsymbol{X}} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma}/n)$ přesně pro každé n.