

Přednáška 5: Vícerozměrná data

KMA/MSM Blanka Šedivá

verze 2025/2026
29. září 2026

Obsah

- 1 Datová matice
 - Normalizace a standardizace dat
 - Výběrové statistiky
 - Odhady výběrových statistik
 - Centrální limitní věta ve více dimenzích
 - Rozdělení odvozená od vícerozměrného normálního rozdělení
- 2 Vizualizace dat
 - Jednorozměrná data $p = 1$
 - Vícerozměrná data $p = 2, 3$

Datová matice

- Normalizace a standardizace dat
- Výběrové statistiky
- Odhady výběrových statistik
- Rozdělení odvozená od normálního rozdělení

Datová matice

- Předpokládejme, že máme k dispozici vzorek $\{\mathbf{x}_i\}_{i=1}^n$ pozorovaných hodnoty vícerozměrné náhodné proměnné $\mathbf{X}$.
- Tyto hodnoty budeme považovat za realizace posloupnosti z i.i.d. náhodné veličiny $\mathbf{X}_1, \dots, \mathbf{X}_n$, kde každá $\mathbf{X}_i$ je p -rozměrná náhodná veličina, která se replikuje z populace náhodné proměnné $\mathbf{X}$.
- Data $\{\mathbf{x}_i\}_{i=1}^n$ budeme značit $\mathcal{X}$.

$$\mathcal{X} = \begin{pmatrix} x_{11} & & x_{1p} \\ & \ddots & \\ x_{n1} & & x_{np} \end{pmatrix}$$

- Řádky odpovídají jednotlivým vzorkům a sloupce jednotlivým znakům.
- Z pohledu statistické terminologie se jedná o **náhodný výběr**.

Iris dataset

- **Popis:** Iris je klasická datová sada obsahující 150 pozorování tří druhů kosatců: *Setosa*, *Versicolor*, *Virginica*.
- https://en.wikipedia.org/wiki/Iris_flower_data_set
- Každé pozorování obsahuje 4 numerické proměnné:
 - délka kališního lístku (sepal length)
 - šířka kališního lístku (sepal width)
 - délka okvětního lístku (petal length)
 - šířka okvětního lístku (petal width)
- Počet vzorků: 150 (50 od každého druhu)
- Formát: tabulka s 5 sloupci (4 proměnné + druh)

Náhled datové tabulky Iris

sepal length (cm)	sepal width (cm)	petal length (cm)	petal width	species
5.1	3.5	1.4	0.2	setosa
5.0	3.0	1.4	0.3	setosa
5.1	3.0	1.4	0.2	setosa
5.4	3.5	1.5	0.2	setosa
5.0	3.4	1.4	0.2	setosa



Rozdíl mezi standardizací a normalizací

- **Standardizace:** transformace dat tak, aby měla nulový průměr a jednotkovou směrodatnou odchylku.
 - $z = \frac{x - \mu}{\sigma}$
 - Odstraňuje měřítko mezi proměnnými. Cílem je nulová střední hodnota (průměr) a jednotkový rozptyl (výběrový rozptyl).
 - Vhodné pro normálně rozdělená data.
 - Využitelné např. pro statistické metody jako PCA (metoda hlavních komponent), regresní analýzu, klasifikace.
- **Normalizace:** škálování dat do určitého rozsahu, obvykle mezi 0 a 1.
 - $x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$
 - Upravuje rozsah dat.
 - Velmi citlivé na odlehlé hodnoty.
 - Vhodné pro neuronové sítě, vizualizace.
- Transformace stabilizující rozptyl (odvozeny z Taylorova rozvoje)
- Mocninné transformace a Box -Cox transformace
https://en.wikipedia.org/wiki/Power_transform

Standardizace a normalizace po sloupcích a po řádcích

- Standardizace po sloupcích: typická situace (regresní analýza, PCA, ...)
- Standardizace po řádcích: méně běžná, ale užitečná např. v bioinformatice nebo při porovnávání profilů, normalizace plochy pod křivkou atd.
- Normalizace po sloupcích: vhodné pro algoritmy citlivé na měřítko (např. kNN, neuronové sítě).
- Normalizace po řádcích: $x'_{ij} = \frac{x_{ij}}{\|x_i\|}$ např. když chceme porovnávat směr vektorů (např. v kosinové podobnosti), v textové analýze.

Vícerozměrná standardizace

Lineární transformace kovariance pro normální rozdělení

Pokud $\mathbf{X}$ tak, že $\mathbf{Z} \sim N_p(0, \mathbf{I})$. Pak standardizovaný vektorem lze ho získat jako

$$\mathbf{Z} = (\boldsymbol{\Sigma}^{\frac{1}{2}})^{-1} \cdot (\mathbf{x} - \boldsymbol{\mu}),$$

kde $\boldsymbol{\Sigma}^{\frac{1}{2}}$ je symetrická matice splňující

$$\boldsymbol{\Sigma} = \boldsymbol{\Sigma}^{\frac{1}{2}} \cdot \boldsymbol{\Sigma}^{\frac{1}{2}}.$$

Výběrový průměr

$$\bar{\mathbf{x}} = n^{-1} \cdot \begin{pmatrix} x_{11} & & x_{n1} \\ & \ddots & \\ x_{1p} & & x_{np} \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = n^{-1} \mathbf{x}^T \mathbf{1}_n.$$

$$\mathbb{E}(\bar{\mathbf{x}}) = \frac{1}{n} \sum \mathbb{E}(\mathbf{x}_i) = \mu$$

$$\text{Var}(\bar{\mathbf{x}}) = \frac{1}{n^2} \sum \text{Var}(\mathbf{x}_i) = \frac{1}{n} \Sigma = \mathbb{E}(\bar{\mathbf{x}} \bar{\mathbf{x}}^T) - \mu \mu^T$$

Výběrová kovariance $S_0 = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$.

$$S_0 = n^{-1} \mathcal{X}^T \mathcal{X} - \bar{\mathbf{x}} \bar{\mathbf{x}}^T = n^{-1} \left(\mathcal{X}^T \mathcal{X} - n^{-1} \mathcal{X}^T \mathbf{1}_n \mathbf{1}_n^T \mathcal{X} \right)$$

$$\begin{aligned} \mathbb{E}(S_0) &= \frac{1}{n} \mathbb{E} \left(\sum (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T \right) = \\ &= \frac{1}{n} \mathbb{E} \left(\sum (\mathbf{x}_i \mathbf{x}_i^T - n \bar{\mathbf{x}} \bar{\mathbf{x}}^T) \right) = \\ &= \frac{1}{n} \left(n \left(\Sigma + \mu \mu^T \right) - n \left(\frac{\Sigma}{n} + \mu \mu^T \right) \right) = \\ &= \frac{n-1}{n} \Sigma \end{aligned}$$

Výběrová korigovaná kovarianční matice $S = \frac{n}{n-1} S_0$

Odhady vektoru středních hodnoty

- odhad průměru může být zatížen chybou vyplývající z existence outliers
- James Steinův odhad
`https://en.wikipedia.org/wiki/James-Stein\_estimator`
- robustní odhady jsou založeny na useknutých průměrech, cross-validačních technikách a podobně

Odhady kovarianční matice

- odhad kovarinace může být zatížen chybou vyplývající z existence outliers nebo chybnými odhady průměrů
- robustní odhady kovariance jsou k dispozici v jednotlivých sw

https:

[//www.mathworks.com/help/stats/robustcov.html](https://www.mathworks.com/help/stats/robustcov.html),
<https://scikit-learn.org/stable/modules/covariance.html>

Centrální limitní věta

Věta

Nechť $\mathbf{X}_1, \dots, \mathbf{X}_n$ je náhodný výběr, kde $\mathbf{X}_i \sim N_p(\mu, \Sigma)$ pak

$$\bar{\mathbf{x}} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$$

.

Věta

Nechť $\mathbf{X}_1, \dots, \mathbf{X}_n$ je náhodný výběr, kde $\mathbf{X}_i \sim (\mu, \Sigma)$ pak rozdělení veličiny $\sqrt{n}(\bar{\mathbf{x}} - \mu)$ má asymptoticky normální rozdělení

$$\sqrt{n}(\bar{\mathbf{x}} - \mu) \longrightarrow N_p(0, \Sigma)$$

.

Rozdělení odvozená od normálního rozdělení I

- rozdělení související s rozptylem

- v jednorozměrném případě $p = 1$ zavádíme χ^2 rozdělení se stupni volnosti n , které vznikne jako součet $U^2 + U^2 + \dots + U^2$.
- Wishartovo rozdělení** pravděpodobnosti je rozdělení náhodné matice $M = \mathcal{X}^T \cdot \mathcal{X}$. značení $M \sim W_p(\Sigma, n)$.
pak M je náhodná matice $p \times p$, Σ je varianční matice normálních rozdělení a n je počet dat, která máme k dispozici.
- Když $p = 1$, pak $M = \sum_{i=1}^n x_i^2$ a Wishartovo rozdělení odpovídá χ^2 rozdělení se stupni volnosti n , přesněji $W_p(\sigma^2, n) = \sigma^2 \cdot \chi_n^2$.
- Pokud $\mathcal{X}$ je datová matice, kde každý řádek $\mathbf{X}_i \sim N(0, \Sigma)$ pro $i = 1, 2, \dots, n$ a řádky jsou nezávislé, pak pro výběrovou korigovanou kovarianční matici platí

$$nS \sim W_p(\Sigma, n-1).$$

Rozdělení odvozená od normálního rozdělení II

- rozdělení související s odhadem střední hodnoty
 - pro $p = 1$ zavádíme Studentovo t-rozdělení jako rozdělení statistiky $T = \frac{\bar{X} - \mu}{s/\sqrt{n}}$, kde vycházíme z náhodného výběru z normálního rozdělení $N(\mu, \sigma^2)$ a $\bar{X}$ je výběrový průměr a s je výběrový rozptyl.
 - Zobecněním t-rozdělení je **Hotellingovo T^2 rozdělení**, které odpovídá statistice $T^2 = n \cdot \mathbf{b}^\top \mathbf{W}^{-1} \mathbf{b}$ $\mathbf{b} \sim N_p(\mu, \Sigma)$, $\mathbf{W} \sim \text{Wishart}(\Sigma, n)$
 - Vztah Hotellingova rozdělení k Fisherovu rozdělení:

$$T^2(p, m) = \frac{np}{n - p + 1} \cdot F(p, n - p + 1)$$

- Pro $p = 1$ se Hotellingovo T^2 rozdělení redukuje na t-rozdělení.

$$\left(\frac{\bar{x} - \mu}{\sqrt{s/n}} \right)^2 \sim T^2(1, n - 1) = F_{1, n-1} = t_{n-1}^2$$


Vizualizace vícerozměrných dat

- Vizualizace jednorozměrných dat
- Vizualizace vícerozměrných dat

Jednorozměrná vizualizace $p = 1$

- Boxplot: zobrazuje medián, kvartily, průměr, případně i rozsah nebo hranice pro odlehlé hodnoty.
- Histogramy: ukazuje četnost výskytu hodnot v jednotlivých intervalech,
- Kernelovský histogram – odhad hustoty pravděpodobnosti: hladká křivka odhadující pravděpodobnostní rozdělení dat.
- Violin graf: spojuje boxplot s hustotním odhadem, vhodný pro porovnání rozdělení.
- Empirická distribuční funkce.
- P-P graf: porovnává kumulativní pravděpodobnosti (CDF) empirického a teoretického rozdělení.
- Q-Q graf: porovnává kvantily empirického a teoretického rozdělení.

Boxplot









Histogram

- 1 Sloupce v histogramu jsou vertikální. Jejich výška odpovídá četnosti (absolutní nebo relativní).
- 2 Stupnice na vodorovné ose grafu je vždy ve stejných jednotkách
- 3 V případě konstantně dlouhých intervalů, má význam i šířka sloupců v histogramu - základna každého sloupce zahrnuje třídu hodnot veličiny. Četnost tedy odpovídá ploše sloupce (tj. šířce sloupce $\times$ výšce).

Pokud budeme předpokládat, že délka intervalu je konstantní h , pak při určování počtu tříd k použijeme


- Sturgesovo pravidlo - $h = \frac{R}{k}$, kde R je $x_{max} - x_{min}$ a $k = 1 + \log_2 n$;
- Modifikované Sturgesovo pravidlo - $k = 1 + 3.3 \cdot \ln n$;
- Scottovo pravidlo - $h = 3.5 \cdot \frac{s}{n^{1/3}}$, kde s je (výběrová) standardní odchylka;
- Freedman, Diaconisovo pravidlo - $h = 2 \cdot \frac{R_Q}{n^{1/3}}$, kde $R_Q = Q_{75} - Q_{25}$ je kvartilové rozpětí ;

Porovnání boxplot a histogramy





Kernelovský (jádrový) odhad hustoty

- Zvolíme jádrovou funkci (kernel). Nejčastěji se používá Gaussovská funkce, ale lze použít i jiné (Epanechnikov, uniformní, trojúhelníkové, ...).
- Zvolíme šířku pásma (bandwidth, označuje se jako h). Parametr h určuje „rozmazání“ každého jádra.
- Na každý datový bod aplikujeme jádrovou funkci, sečteme všechny jádrové funkce.
- KDE je hladká křivka, která odhaduje, jak jsou data rozložena.




Violin graf



Porovnání boxplot a violin plot





Empirická distribuční funkce



P-P grafy a Q-Q graf

- **P–P graf (Probability–Probability):** Porovnává empirické a teoretické pravděpodobnosti.
- Citlivý na odchylky ve střední části rozdělení.
- Body by měly ležet blízko diagonály.
- **Q–Q graf (Quantile–Quantile):** Porovnává empirické a teoretické kvantily.
- Citlivý na odchylky v chvostech rozdělení.
- Odchylky od diagonály ukazují na šikmost nebo těžké chvosty.


P-P grafy a Q-Q graf



Vícerozměrná vizualizace

- Elipsy odpovídající vícerozměrnému normálnímu rozdělení: zobrazují izočáry hustoty pravděpodobnosti, umožňují vizuálně posoudit kovarianci a orientaci dat.
- Vícerozměrný Q-Q graf pro normální rozdělení
- Vícerozměrný boxplot. Generalizace klasického boxplotu pro více proměnných.
- Bagploty: dvourozměrná obdoba boxplotu, založená na hloubce dat. Dobré pro detekci odlehlých hodnot a vizuální analýzu rozložení.
- Vícerozměrný histogram.
- Heatmapy odvozené od histogramů.

Dvourozměrné normální rozdělení



1

¹https://en.wikipedia.org/wiki/Multivariate_normal_distribution

Mahalanobisova vzdálenost

- **Mahalanobisova vzdálenost** bodu $\mathbf{x}$ od průměru $\bar{\mathbf{x}}$.



$$\eta_i^2 = (\mathbf{X}_i - \bar{\mathbf{x}})^T \cdot \mathbf{S}^{-1} \cdot (\mathbf{X}_i - \bar{\mathbf{x}})$$

- Pokud $\mathbf{S}$ je jednotková matice odpovídá Mahalanobisova vzdálenost vzdálenosti Eukleidovské.
- Body se stejnou Mahalanobisovou vzdáleností od $\bar{\mathbf{x}}$ odpovídají v případě normálního rozdělení bodům na elipse.
- Pomocí Mahalanobisovy vzdálenosti a vlastností Hotellingova rozdělení, lze určit pro vícedimensionální data vícerozměrnou konfidenční množinu.
- Konfidenční oblast

$$(\mathbf{X} - \mu)^T \cdot \mathbf{S}^{-1} \cdot (\mathbf{X} - \mu) \leq \frac{(n-1)p}{(n-p)} F_{1-\alpha}(p, n-p).$$



Mahalanobisova konfidenční množina




Q-Q graf pro vícerozměrné normální rozdělení

- Mahalanobisova vzdálenost je míra vzdálenosti bodu od středu vícerozměrného rozdělení, která zohledňuje kovarianci mezi proměnnými.
- Při testování vícerozměrné normality lze škálované Mahalanobisovy vzdálenosti porovnat s kvantily F-rozdělení (nebo chi2 rozdělení, pokud známe kovarianční matici): $F_{p, n-p} \cdot \frac{(n-1) \cdot p}{n-p}$.
- py skript


```
nd = len(df_sorted) # počet pozorování
p = 2 # počet proměnných
quantiles_f = chi2.ppf((np.arange(1, nd+1) - 0.5) / nd, df=p)
quantiles_f = f.ppf((np.arange(1, nd+1) - 0.5) / nd, dfn=2, dfd=nd-2) * (nd-1)*2/(nd-2)
sns.scatterplot(x=quantiles_f, y=df_sorted["Mahalanobis"], color="blue")
```

- Q-Q plot porovnává empirické Mahalanobisovy vzdálenosti s teoretickými kvantily F-rozdělení. Pokud body leží blízko diagonály, lze předpokládat vícerozměrnou normalitu.



Q-Q graf





Dvourozměrný boxplot



Bagplot



Dvourozměrný histogram



Heat mapy

