Přednáška 4: Vícerozměrná data

KMA/MSM Blanka Šedivá

verze 2026/2027
6. října 2026

Obsah

1. Datová matice
   - Normalizace a standardizace dat
   - Výběrové statistiky
   - Odhady vektoru středních hodnot a varianční matice
   - Centrální limitní věta ve více dimenzích
   - Rozdělení odvozená od vícerozměrného normálního rozdělení
2. Vizualizace dat
   - Jednorozměrná data $k = 1$
   - Vícerozměrná data $k = 2, 3$

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Datová matice

- Normalizace a standardizace dat
- Výběrové statistiky
- Odhady vektoru středních hodnot a varianční matice
- Centrální limitní věta ve více dimenzích
- Rozdělení odvozená od normálního rozdělení

Datová matice

- Předpokládejme, že máme k dispozici vzorek $\{\boldsymbol{x}_i\}_{i=1}^n$ pozorovaných hodnot vícerozměrné náhodné veličiny $\boldsymbol{X}$.
- Tyto hodnoty budeme považovat za realizace posloupnosti nezávislých stejně rozdělených (i.i.d.) náhodných vektorů $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_n$, kde každý $\boldsymbol{X}_i$ je k-rozměrný náhodný vektor se stejným rozdělením jako $\boldsymbol{X}$.
- Data uspořádáme do datové matice $\mathcal{X}$ typu $n \times k$

$$\mathcal{X} = \begin{pmatrix} x_{11} & \cdots & x_{1k} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nk} \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^T \\ \vdots \\ \boldsymbol{x}_n^T \end{pmatrix}.$$

- Řádky odpovídají pozorováním (objektům), sloupce proměnným (znakům). Statisticky jde o náhodný výběr rozsahu n.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Iris dataset

- **Popis:** Iris je klasická datová sada obsahující 150 pozorování tří druhů kosatců: *Setosa*, *Versicolor*, *Virginica*.
- `https://en.wikipedia.org/wiki/Iris_flower_data_set`
- Každé pozorování obsahuje 4 numerické proměnné ($k = 4$):
  - délka kališního lístku (sepal length),
  - šířka kališního lístku (sepal width),
  - délka okvětního lístku (petal length),
  - šířka okvětního lístku (petal width).
- Počet pozorování: $n = 150$ (50 od každého druhu).
- Formát: tabulka s 5 sloupci (4 proměnné + druh).

Náhled datové tabulky Iris

sepal length (cm)	sepal width (cm)	petal length (cm)	petal width	**species**
5.1	3.5	1.4	0.2	setosa
5.0	3.0	1.4	0.3	setosa
5.1	3.0	1.4	0.2	setosa
5.4	3.5	1.5	0.2	setosa
5.0	3.4	1.4	0.2	setosa



FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Datová matice Iris v Pythonu

```
https://scikit-learn.org/stable/modules/generated/sklearn.
datasets.load_iris.html

import numpy as np
from sklearn.datasets import load_iris

iris = load_iris(as_frame=True)
df = iris.frame              # 4 proměnné + target
X = iris.data.to_numpy()     # datová matice n x k
n, k = X.shape               # 150, 4

print(df.head())
print(df.groupby("target").mean())  # průměry druhů
```

Rozdíl mezi standardizací a normalizací

- Standardizace: transformace dat tak, aby měla nulový průměr a jednotkovou směrodatnou odchylku.
  - $z = \frac{x-\mu}{\sigma}$, v praxi $z = \frac{x-\bar{x}}{s}$ (výběrový průměr a výběrová směrodatná odchylka).
  - Odstraňuje rozdíly v měřítku mezi proměnnými, nemění tvar rozdělení.
  - Využitelné např. pro statistické metody jako PCA (metoda hlavních komponent), regresní analýzu, klasifikaci.
- Normalizace: škálování dat do určitého rozsahu, obvykle mezi 0 a 1.
  - $x' = \frac{x-x_{\min}}{x_{\max}-x_{\min}}$
  - Upravuje rozsah dat, je velmi citlivá na odlehlé hodnoty.
  - Vhodné pro neuronové sítě, vizualizace.
- Transformace stabilizující rozptyl (odvozené z Taylorova rozvoje, tzv. delta metoda).
- Mocninné transformace a Box-Coxova transformace `https://en.wikipedia.org/wiki/Power_transform`.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Standardizace a normalizace po sloupcích a po řádcích

- Standardizace po sloupcích: typická situace (regresní analýza, PCA, ...).
- Standardizace po řádcích: méně běžná, ale užitečná např. v bioinformatice nebo při porovnávání profilů, normalizace plochy pod křivkou atd.
- Normalizace po sloupcích: vhodné pro algoritmy citlivé na měřítko (např. kNN, neuronové sítě).
- Normalizace po řádcích: $x'_{ij} = \frac{x_{ij}}{\|\boldsymbol{X}_i\|}$, např. když chceme porovnávat směr vektorů (kosinová podobnost), v textové analýze.

Standardizace a normalizace v Pythonu

```
https://scikit-learn.org/stable/modules/preprocessing.html

from sklearn.preprocessing import (StandardScaler,
                                   MinMaxScaler, normalize)

# standardizace po sloupcích: (x - průměr) / s
Z = (X - X.mean(axis=0)) / X.std(axis=0, ddof=1)
Z2 = StandardScaler().fit_transform(X)    # používá ddof=0

# normalizace po sloupcích do <0,1>
N = (X - X.min(axis=0)) / (X.max(axis=0) - X.min(axis=0))
N2 = MinMaxScaler().fit_transform(X)

# normalizace po řádcích na jednotkovou délku
R = normalize(X, norm="l2")
```

Vícerozměrná standardizace

Standardizace po sloupcích odstraní rozdíly v měřítku, ale ne korelace mezi proměnnými. Vícerozměrná standardizace odstraní i korelace.

Pokud $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, pak standardizovaný vektor $\boldsymbol{Z} \sim N_k(\boldsymbol{0}, \boldsymbol{I})$ lze získat jako (P02b)

$$\boldsymbol{Z} = \left(\boldsymbol{\Sigma}^{\frac{1}{2}}\right)^{-1} \cdot (\boldsymbol{X} - \boldsymbol{\mu}),$$

kde $\boldsymbol{\Sigma}^{\frac{1}{2}}$ je symetrická matice splňující

$$\boldsymbol{\Sigma} = \boldsymbol{\Sigma}^{\frac{1}{2}} \cdot \boldsymbol{\Sigma}^{\frac{1}{2}}.$$

Pro data nahradíme $\boldsymbol{\mu}$ a $\boldsymbol{\Sigma}$ odhady $\overline{\boldsymbol{x}}$ a S: $\boldsymbol{z}_i = S^{-\frac{1}{2}}(\boldsymbol{x}_i - \overline{\boldsymbol{x}})$ (tzv. whitening). Transformovaná data mají výběrovou varianční matici rovnu $\boldsymbol{I}$.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Výběrový průměr

$$\overline{\boldsymbol{x}} = \frac{1}{n}\sum_{i=1}^{n}\boldsymbol{x}_i = n^{-1}\cdot\begin{pmatrix} x_{11} & \cdots & x_{n1} \\ \vdots & \ddots & \vdots \\ x_{1k} & \cdots & x_{nk} \end{pmatrix}\cdot\begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = n^{-1}\mathcal{X}^T\mathbf{1}_n.$$

Pro náhodný výběr $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_n$ s $\mathbb{E}\boldsymbol{X}_i = \boldsymbol{\mu}$ a $\mathbf{Var}\,\boldsymbol{X}_i = \boldsymbol{\Sigma}$ platí

$$\begin{aligned} \mathbb{E}(\overline{\boldsymbol{X}}) &= \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(\boldsymbol{X}_i) = \boldsymbol{\mu}, \\ \mathbf{Var}\,(\overline{\boldsymbol{X}}) &= \frac{1}{n^2}\sum_{i=1}^{n}\mathbf{Var}\,(\boldsymbol{X}_i) = \frac{1}{n}\boldsymbol{\Sigma} = \mathbb{E}(\overline{\boldsymbol{X}}\,\overline{\boldsymbol{X}}^T) - \boldsymbol{\mu}\boldsymbol{\mu}^T. \end{aligned}$$

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Výběrová varianční matice

$$\begin{aligned} S_0 &= \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{x}_i - \overline{\boldsymbol{x}})(\boldsymbol{x}_i - \overline{\boldsymbol{x}})^T = n^{-1}\mathcal{X}^T\mathcal{X} - \overline{\boldsymbol{x}}\,\overline{\boldsymbol{x}}^T \\ &= n^{-1}\left(\mathcal{X}^T\mathcal{X} - n^{-1}\mathcal{X}^T\mathbf{1}_n\mathbf{1}_n^T\mathcal{X}\right). \end{aligned}$$

$$\begin{aligned} \mathbb{E}(S_0) &= \frac{1}{n}\mathbb{E}\left(\sum_{i=1}^{n}(\boldsymbol{X}_i - \overline{\boldsymbol{X}})(\boldsymbol{X}_i - \overline{\boldsymbol{X}})^T\right) = \frac{1}{n}\mathbb{E}\left(\sum_{i=1}^{n}\boldsymbol{X}_i\boldsymbol{X}_i^T - n\overline{\boldsymbol{X}}\,\overline{\boldsymbol{X}}^T\right) = \\ &= \frac{1}{n}\left(n\left(\boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^T\right) - n\left(\frac{\boldsymbol{\Sigma}}{n} + \boldsymbol{\mu}\boldsymbol{\mu}^T\right)\right) = \frac{n-1}{n}\boldsymbol{\Sigma}. \end{aligned}$$

Odhad S_0 je tedy vychýlený. Nestranným odhadem je **výběrová korigovaná varianční matice**

$$S = \frac{n}{n-1}S_0 = \frac{1}{n-1}\sum_{i=1}^{n}(\boldsymbol{x}_i - \overline{\boldsymbol{x}})(\boldsymbol{x}_i - \overline{\boldsymbol{x}})^T, \qquad \mathbb{E}S = \boldsymbol{\Sigma}.$$

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Výběrové statistiky v Pythonu

https://numpy.org/doc/stable/reference/generated/numpy.cov.html

```
import numpy as np

n, k = X.shape
one = np.ones(n)

xbar = X.T @ one / n                    # n^{-1} X^T 1_n
S0 = X.T @ X / n - np.outer(xbar, xbar)  # vychýlený
S = n / (n - 1) * S0                    # korigovaný

print(np.allclose(S, np.cov(X, rowvar=False)))   # True
print(np.allclose(S0, np.cov(X, rowvar=False, ddof=0)))
R = np.corrcoef(X, rowvar=False)        # korelační matice
```

Pozor: `np.cov` předpokládá proměnné v řádcích, proto `rowvar=False`.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Odhady vektoru středních hodnot

- Výběrový průměr může být zatížen chybou vyplývající z existence odlehlých hodnot (outliers).
- James-Steinův odhad: pro $k \geq 3$ má menší střední kvadratickou chybu než $\overline{\boldsymbol{x}}$ (průměr „stahuje“ směrem k zvolenému bodu) `https://en.wikipedia.org/wiki/James-Stein_estimator`.
- Robustní odhady: medián po složkách, prostorový (geometrický) medián, useknuté průměry, střed odhadu MCD (Minimum Covariance Determinant) a podobně.

Odhady varianční matice

- Odhad varianční matice může být zatížen chybou vyplývající z existence odlehlých hodnot nebo chybným odhadem průměru.
- Robustní odhady: MCD (Minimum Covariance Determinant) – odhad z podmnožiny h pozorování s nejmenším determinantem varianční matice.
- Při velkém počtu proměnných vzhledem k n (pro $k \geq n$ je S singulární) se používají regularizované odhady (shrinkage, např. Ledoit-Wolf).
- Robustní odhady kovariance jsou k dispozici v jednotlivých SW `https://www.mathworks.com/help/stats/robustcov.html`, `https://scikit-learn.org/stable/modules/covariance.html`.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Robustní a regularizované odhady v Pythonu

https://scikit-learn.org/stable/modules/covariance.html

```
import numpy as np
from sklearn.covariance import MinCovDet, LedoitWolf

mcd = MinCovDet(random_state=0).fit(X)
print(mcd.location_)          # robustní odhad střední hodnoty
print(mcd.covariance_)        # robustní odhad varianční matice
d2 = mcd.mahalanobis(X)       # robustní Mahalanobis^2

lw = LedoitWolf().fit(X)
print(lw.covariance_, lw.shrinkage_)     # shrinkage odhad

med = np.median(X, axis=0)   # medián po složkách
```

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Výběrový průměr a centrální limitní věta

Věta

Nechť $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_n$ je náhodný výběr, kde $\boldsymbol{X}_i \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Pak

$$\overline{\boldsymbol{X}} \sim N_k\left(\boldsymbol{\mu}, \frac{1}{n}\boldsymbol{\Sigma}\right).$$

Věta (centrální limitní věta)

Nechť $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_n$ je náhodný výběr z rozdělení se střední hodnotou $\boldsymbol{\mu}$ a konečnou varianční maticí $\boldsymbol{\Sigma}$. Pak má veličina $\sqrt{n}\left(\overline{\boldsymbol{X}} - \boldsymbol{\mu}\right)$ asymptoticky normální rozdělení,

$$\sqrt{n}\left(\overline{\boldsymbol{X}} - \boldsymbol{\mu}\right) \xrightarrow{d} N_k(\boldsymbol{0}, \boldsymbol{\Sigma}) \quad \text{pro } n \to \infty.$$

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Rozdělení odvozená od normálního rozdělení – rozptyl

- V jednorozměrném případě $k = 1$ zavádíme χ^2 rozdělení s n stupni volnosti jako rozdělení součtu $U_1^2 + U_2^2 + \cdots + U_n^2$, kde $U_i \sim N(0, 1)$ jsou nezávislé.
- **Wishartovo rozdělení** je rozdělení náhodné matice $M = \mathcal{X}^T \cdot \mathcal{X} = \sum_{i=1}^{n} \boldsymbol{X}_i \boldsymbol{X}_i^T$, kde řádky $\boldsymbol{X}_i \sim N_k(\boldsymbol{0}, \boldsymbol{\Sigma})$ jsou nezávislé. Značíme $M \sim W_k(\boldsymbol{\Sigma}, n)$,

  kde M je náhodná matice $k \times k$, $\boldsymbol{\Sigma}$ je varianční matice normálního rozdělení a n je počet stupňů volnosti (počet pozorování).
- Když $k = 1$, pak $M = \sum_{i=1}^{n} X_i^2$ a Wishartovo rozdělení odpovídá χ^2 rozdělení s n stupni volnosti, přesněji $W_1(\sigma^2, n) = \sigma^2 \cdot \chi_n^2$. Platí $\mathbb{E}M = n\boldsymbol{\Sigma}$.
- Pokud $\mathcal{X}$ je datová matice, jejíž řádky $\boldsymbol{X}_i \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $i = 1, 2, \ldots, n$, jsou nezávislé, pak pro výběrovou korigovanou varianční matici platí

$$(n-1)\,S = n\,S_0 \sim W_k(\boldsymbol{\Sigma}, n-1)$$

  a S je nezávislá s $\overline{\boldsymbol{X}}$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Rozdělení odvozená od normálního rozdělení – střední hodnota

- Pro $k = 1$ zavádíme Studentovo t-rozdělení jako rozdělení statistiky $T = \frac{\bar{X}-\mu}{s/\sqrt{n}}$, kde vycházíme z náhodného výběru z normálního rozdělení $N(\mu, \sigma^2)$, $\bar{X}$ je výběrový průměr a s je výběrová směrodatná odchylka.
- Zobecněním t-rozdělení je **Hotellingovo T^2 rozdělení**: jsou-li $\boldsymbol{b} \sim N_k(\mathbf{0}, \boldsymbol{\Sigma})$ a $W \sim W_k(\boldsymbol{\Sigma}, m)$ nezávislé, pak

$$T^2 = m \cdot \boldsymbol{b}^T W^{-1} \boldsymbol{b} \sim T^2(k, m).$$

- Vztah Hotellingova rozdělení k Fisherovu rozdělení:

$$T^2(k, m) = \frac{mk}{m - k + 1} \cdot F(k, m - k + 1).$$

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Hotellingovo rozdělení a výběrový průměr

- Pro náhodný výběr z $N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ platí

$$n\left(\overline{\boldsymbol{X}} - \boldsymbol{\mu}\right)^T S^{-1}\left(\overline{\boldsymbol{X}} - \boldsymbol{\mu}\right) \sim T^2(k, n-1) = \frac{(n-1)k}{n-k} F(k, n-k).$$

- Pro $k = 1$ se Hotellingovo T^2 rozdělení redukuje na kvadrát t-rozdělení:

$$\left(\frac{\bar{x} - \mu}{s/\sqrt{n}}\right)^2 \sim T^2\left(1, n-1\right) = F_{1,n-1} = t^2_{n-1}.$$

Vizualizace vícerozměrných dat

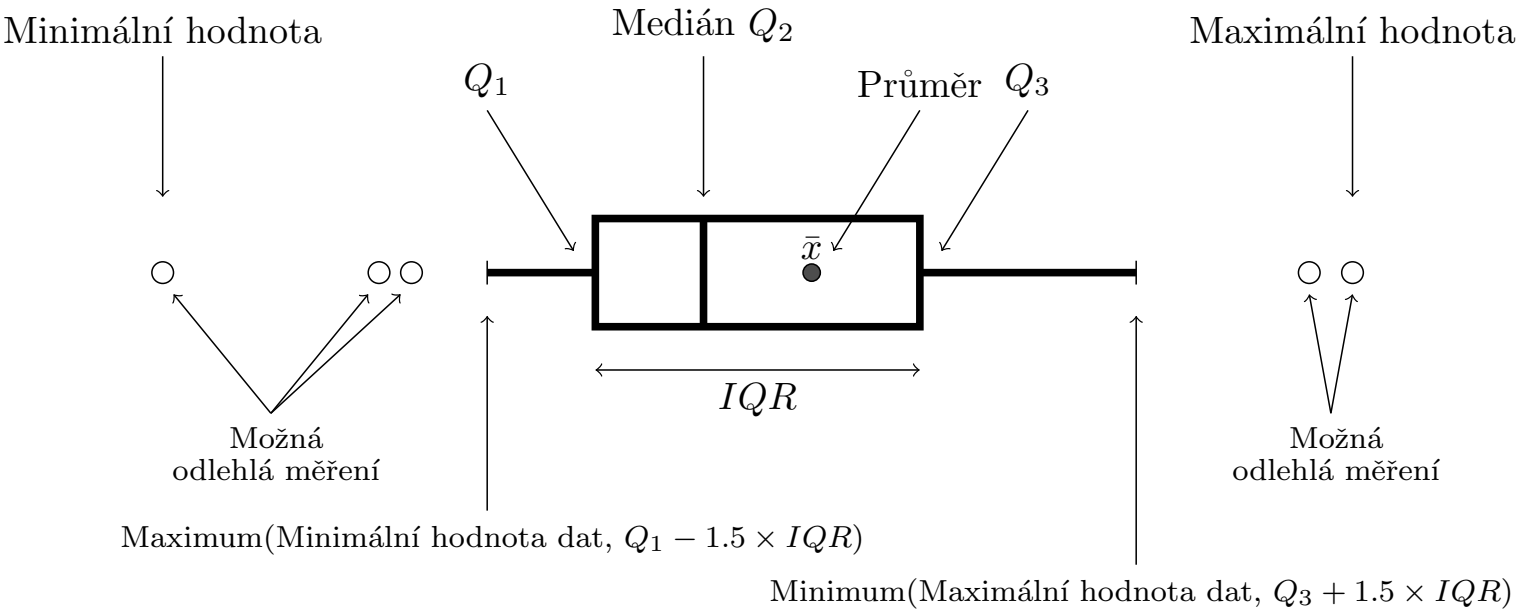
- Vizualizace jednorozměrných dat
- Vizualizace vícerozměrných dat

Jednorozměrná vizualizace $k = 1$

- Boxplot: zobrazuje medián, kvartily, případně průměr a hranice pro odlehlé hodnoty.
- Histogram: ukazuje četnost výskytu hodnot v jednotlivých intervalech.
- Jádrový (kernelový) odhad hustoty: hladká křivka odhadující hustotu rozdělení dat.
- Violin graf: spojuje boxplot s jádrovým odhadem hustoty, vhodný pro porovnání rozdělení.
- Empirická distribuční funkce.
- P-P graf: porovnává empirickou a teoretickou distribuční funkci (pravděpodobnosti).
- Q-Q graf: porovnává kvantily empirického a teoretického rozdělení.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Boxplot


Minimální hodnota
Medián Q_2
Q_1
Průměr
Q_3
Maximální hodnota
$\bar{x}$
IQR
Možná odlehlá měření
Možná odlehlá měření
Maximum(Minimální hodnota dat, $Q_1 - 1.5 \times IQR$)
Minimum(Maximální hodnota dat, $Q_3 + 1.5 \times IQR$)

Histogram

1. Sloupce v histogramu jsou vertikální. Jejich výška odpovídá četnosti (absolutní nebo relativní).
2. Stupnice na vodorovné ose grafu je vždy ve stejných jednotkách.
3. Základna každého sloupce odpovídá intervalu (třídě) hodnot veličiny. Pokud intervaly nemají stejnou délku, musí četnosti odpovídat **ploše** sloupce (výška = četnost / šířka intervalu).

Pokud budeme předpokládat, že délka intervalu je konstantní h, pak při určování počtu tříd m a šířky intervalu $h = \frac{R}{m}$, kde $R = x_{max} - x_{min}$, použijeme např.

- Sturgesovo pravidlo: $m = \lceil 1 + \log_2 n \rceil$, ekvivalentně $m \approx 1 + 3{,}3 \cdot \log_{10} n$;
- Scottovo pravidlo: $h = 3{,}5 \cdot \frac{s}{n^{1/3}}$, kde s je výběrová směrodatná odchylka;
- Freedmanovo-Diaconisovo pravidlo: $h = 2 \cdot \frac{R_Q}{n^{1/3}}$, kde $R_Q = Q_{75} - Q_{25}$ je kvartilové rozpětí.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Histogram v Pythonu

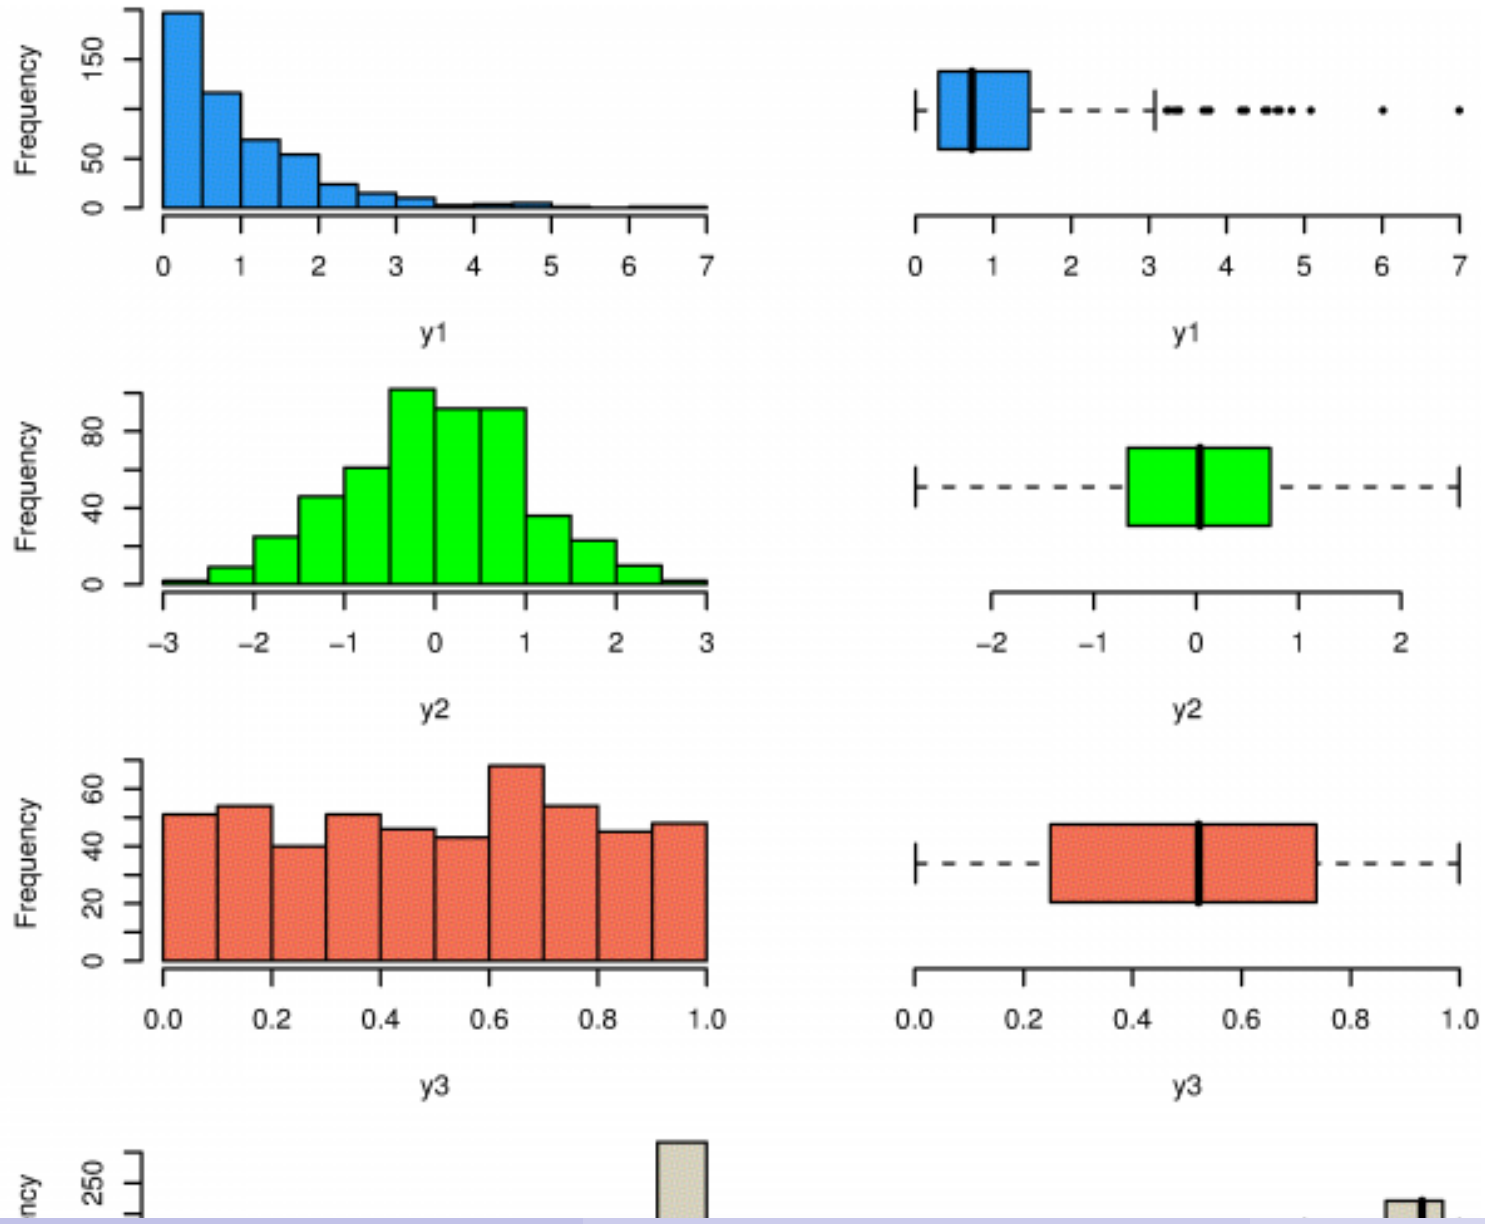
```
https://numpy.org/doc/stable/reference/generated/numpy.
histogram_bin_edges.html

import numpy as np
import matplotlib.pyplot as plt

x = X[:, 0]                              # sepal length
for pravidlo in ["sturges", "scott", "fd"]:
    hrany = np.histogram_bin_edges(x, bins=pravidlo)
    print(pravidlo, len(hrany) - 1)  # počet tříd

plt.hist(x, bins="fd", density=True) # plocha = 1
plt.show()
```

Porovnání boxplot a histogramy

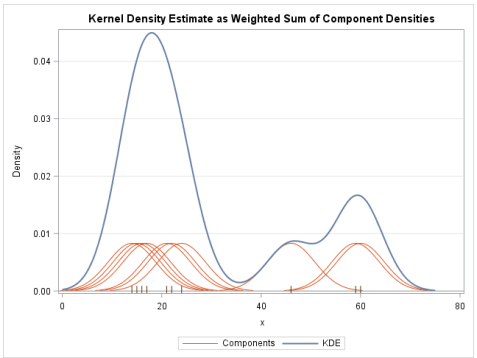


Jádrový (kernelový) odhad hustoty

- Zvolíme jádrovou funkci (kernel) K. Nejčastěji se používá Gaussovská funkce, ale lze použít i jiné (Epanechnikovo, rovnoměrné, trojúhelníkové, . . .).
- Zvolíme šířku pásma (bandwidth), označuje se jako h. Parametr h určuje „rozmazání“ každého jádra.
- Na každý datový bod aplikujeme jádrovou funkci a všechny jádrové funkce sečteme:

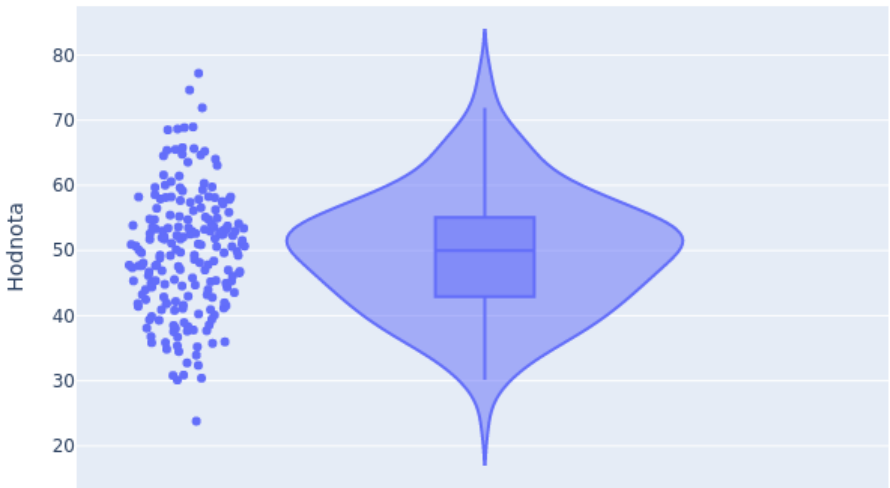
$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right).$$

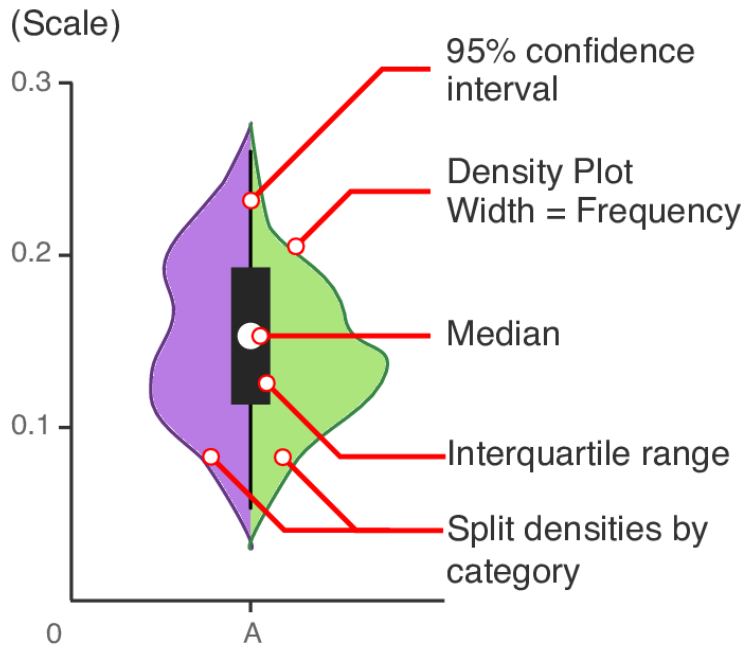
- Jádrový odhad je hladká křivka, která odhaduje, jak jsou data rozložena.



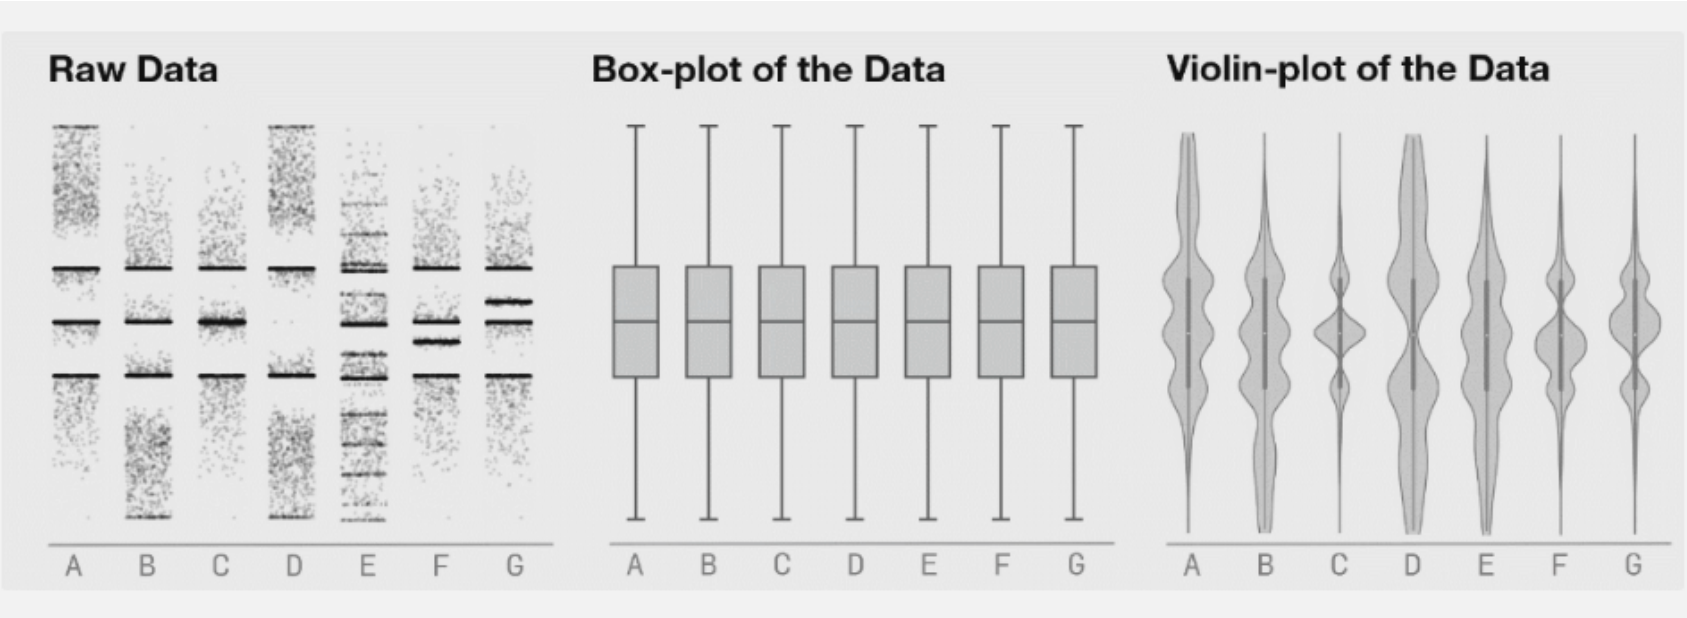
FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Violin graf

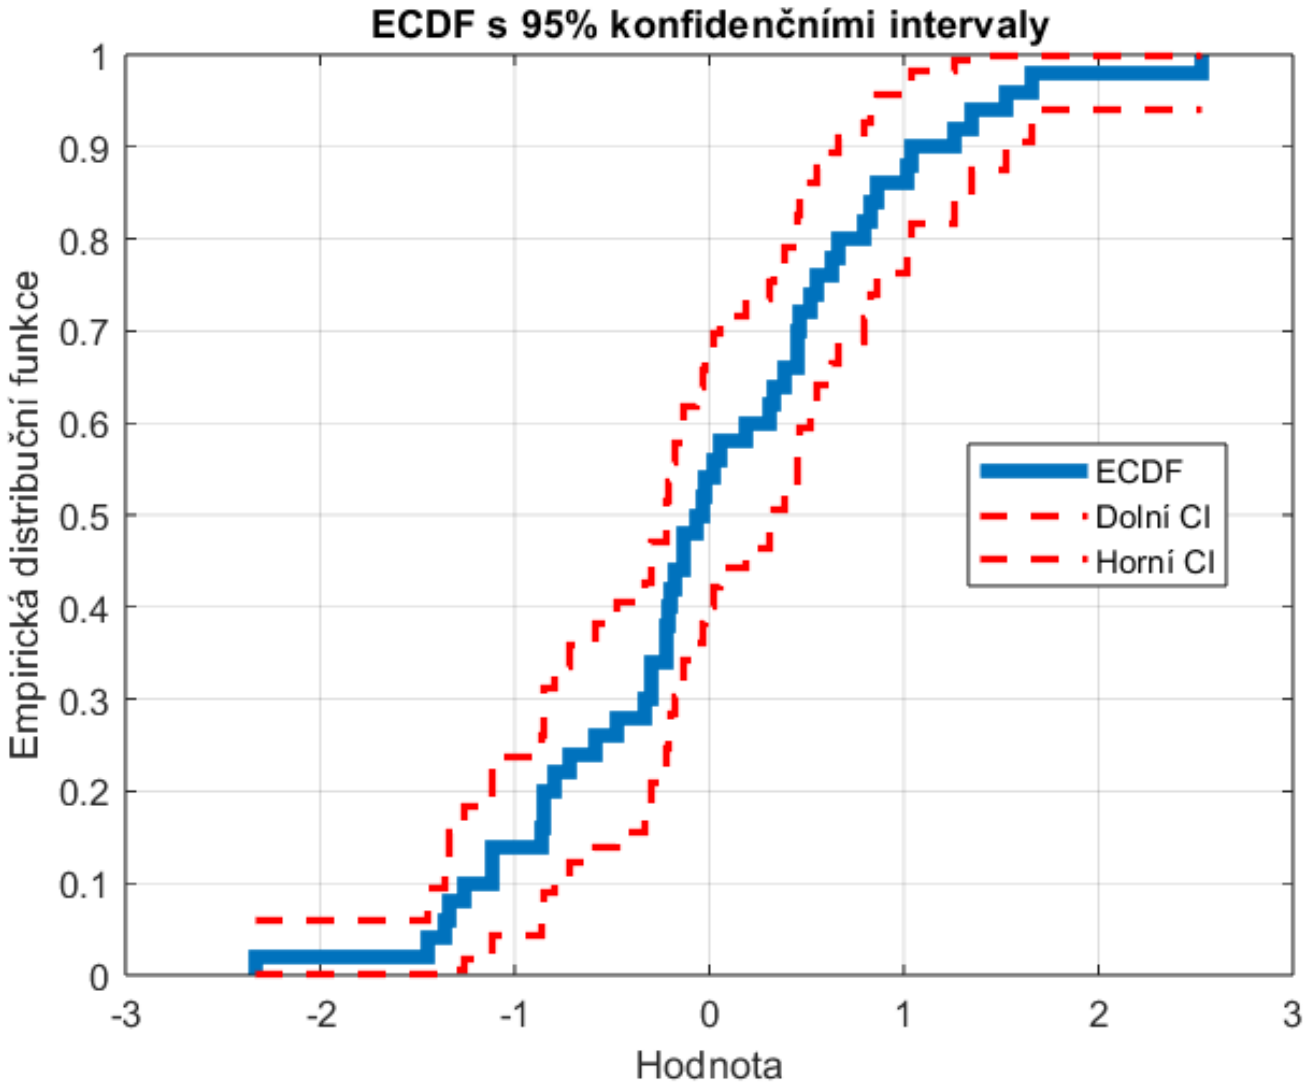

Hodnota
80
70
60
50
40
30
20


(Scale)
0.3
0.2
0.1
0
A
95% confidence interval
Density Plot
Width = Frequency
Median
Interquartile range
Split densities by category

Porovnání boxplot a violin plot



Empirická distribuční funkce

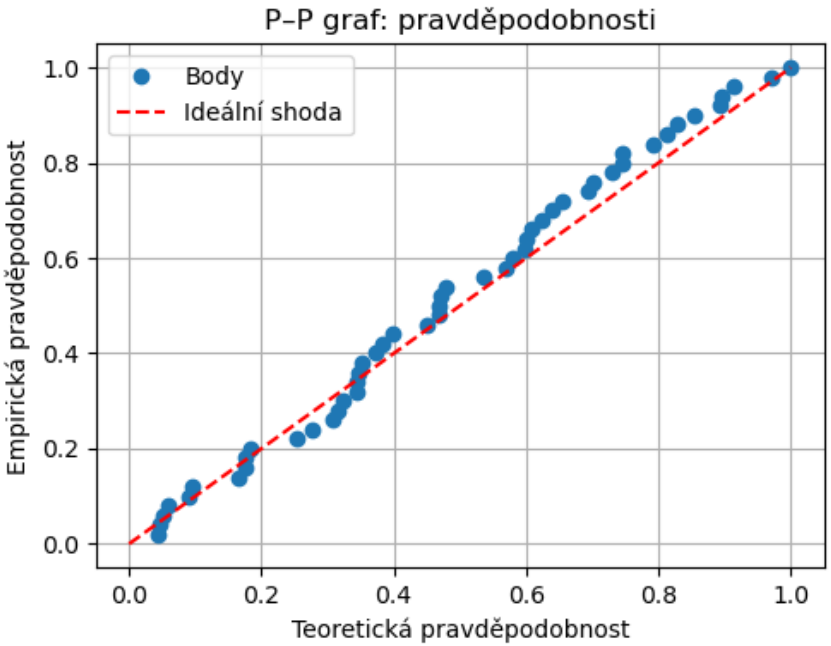


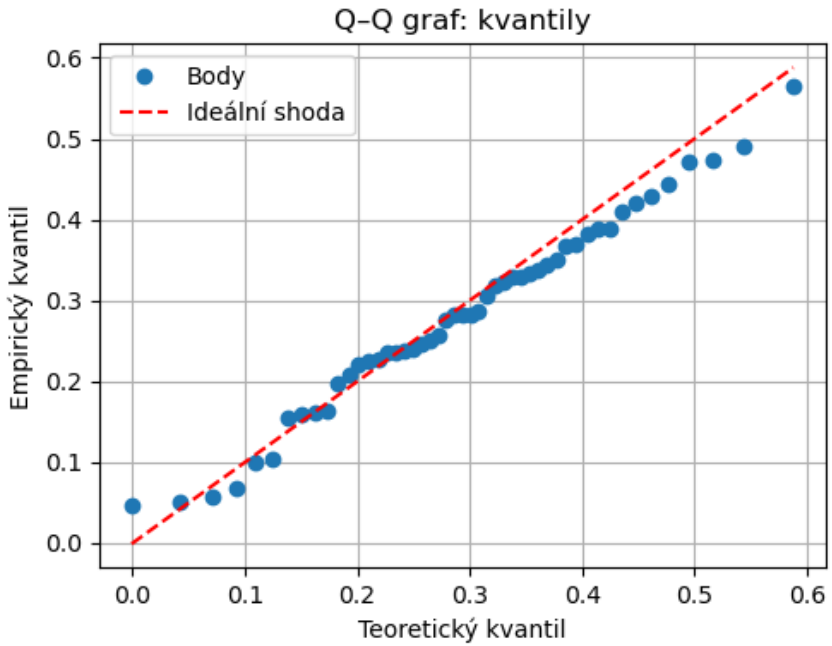
P-P graf a Q-Q graf

- **P-P graf (Probability-Probability):** porovnává empirické a teoretické pravděpodobnosti, tj. body $\left(F(x_{(i)}), \frac{i-0,5}{n}\right)$.
- Citlivý na odchylky ve střední části rozdělení.
- Body by měly ležet blízko diagonály.
- **Q-Q graf (Quantile-Quantile):** porovnává empirické a teoretické kvantily, tj. body $\left(F^{-1}\left(\frac{i-0,5}{n}\right), x_{(i)}\right)$.
- Citlivý na odchylky v chvostech rozdělení.
- Odchylky od přímky ukazují na šikmost nebo těžké chvosty.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

P-P graf a Q-Q graf





FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Jednorozměrné grafy v Pythonu

```
https://seaborn.pydata.org/api.html

import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

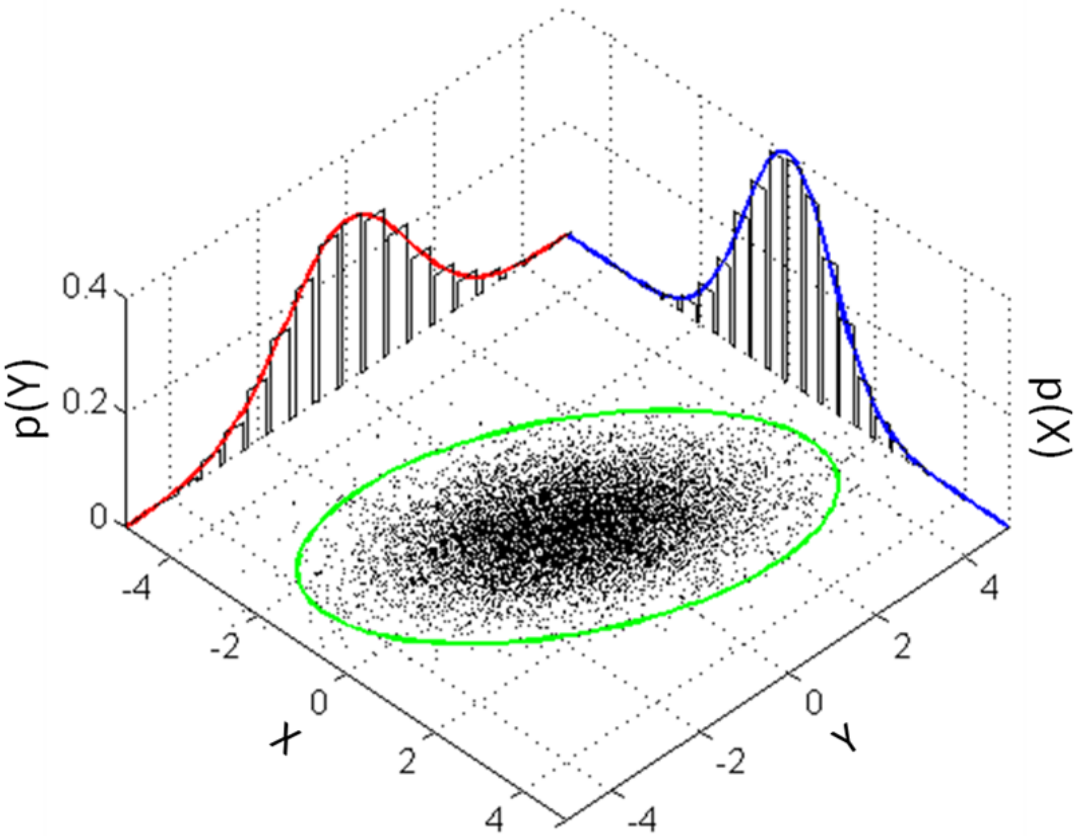
fig, ax = plt.subplots(2, 3, figsize=(12, 7))
sns.boxplot(data=df, x="target", y="sepal length (cm)",
            ax=ax[0, 0])
sns.histplot(df["sepal length (cm)"], bins="fd", kde=True,
             ax=ax[0, 1])                        # histogram + KDE
sns.violinplot(data=df, x="target",
               y="sepal length (cm)", ax=ax[0, 2])
sns.ecdfplot(df["sepal length (cm)"], ax=ax[1, 0])  # EDF
stats.probplot(df["sepal length (cm)"], dist="norm",
               plot=ax[1, 1])                      # Q-Q graf
plt.tight_layout(); plt.show()
```

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Vícerozměrná vizualizace

- Elipsy odpovídající vícerozměrnému normálnímu rozdělení: zobrazují vrstevnice hustoty, umožňují vizuálně posoudit kovarianci a orientaci dat.
- Vícerozměrný Q-Q graf pro normální rozdělení.
- Vícerozměrný boxplot: zobecnění klasického boxplotu pro více proměnných.
- Bagplot: dvourozměrná obdoba boxplotu založená na hloubce dat. Vhodný pro detekci odlehlých hodnot a vizuální analýzu rozložení.
- Vícerozměrný histogram.
- Heatmapy odvozené od histogramů.

Dvourozměrné normální rozdělení



1

[1] https://en.wikipedia.org/wiki/Multivariate_normal_distribution

Mahalanobisova vzdálenost

- **Mahalanobisova vzdálenost** pozorování $\boldsymbol{x}_i$ od průměru $\overline{\boldsymbol{x}}$:

$$d_i^2 = (\boldsymbol{x}_i - \overline{\boldsymbol{x}})^T \cdot S^{-1} \cdot (\boldsymbol{x}_i - \overline{\boldsymbol{x}}).$$

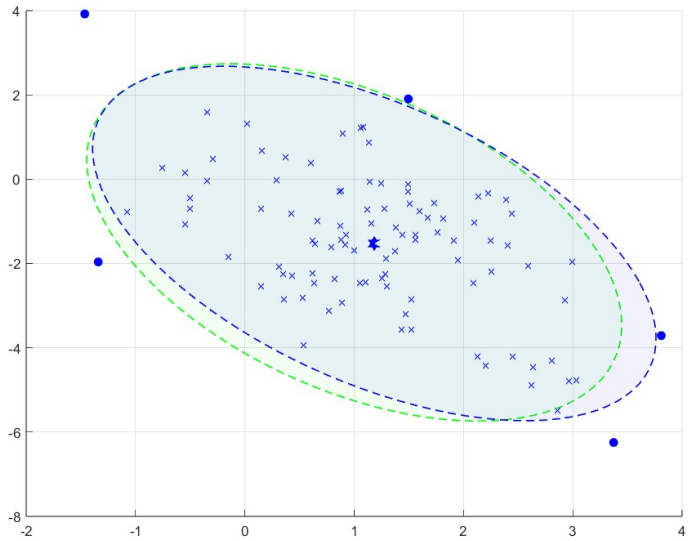
- Pokud S je jednotková matice, odpovídá Mahalanobisova vzdálenost vzdálenosti eukleidovské.
- Body se stejnou Mahalanobisovou vzdáleností od $\overline{\boldsymbol{x}}$ leží na elipse (elipsoidu), která v případě normálního rozdělení odpovídá vrstevnici hustoty.
- Pomocí vlastností Hotellingova rozdělení lze pro vícerozměrná data určit **konfidenční oblast pro μ**:

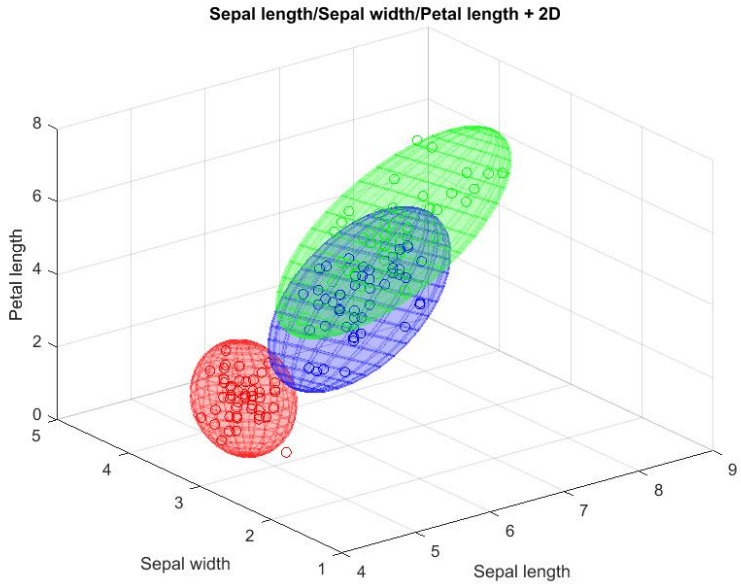
$$n\,(\overline{\boldsymbol{x}} - \boldsymbol{\mu})^T \cdot S^{-1} \cdot (\overline{\boldsymbol{x}} - \boldsymbol{\mu}) \leq \frac{(n-1)k}{n-k} F_{1-\alpha}\,(k, n-k)\,.$$

- Oblast, ve které leží přibližně $100(1-\alpha)$ % pozorování: $d^2 \leq \chi^2_k(1-\alpha)$.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Mahalanobisova konfidenční množina





FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Q-Q graf pro vícerozměrné normální rozdělení

- Mahalanobisova vzdálenost je míra vzdálenosti bodu od středu vícerozměrného rozdělení, která zohledňuje kovarianci mezi proměnnými.
- Při testování vícerozměrné normality porovnáváme seřazené vzdálenosti $d^2_{(1)} \leq \cdots \leq d^2_{(n)}$ s kvantily jejich rozdělení:
  - přesně: $\frac{n}{(n-1)^2}\, d_i^2 \sim Beta\left(\frac{k}{2}, \frac{n-k-1}{2}\right)$,
  - asymptoticky (nebo při známých $\boldsymbol{\mu}$, $\boldsymbol{\Sigma}$): $d_i^2 \approx \chi^2_k$.
- Q-Q graf porovnává empirické Mahalanobisovy vzdálenosti s teoretickými kvantily. Pokud body leží blízko diagonály, lze předpokládat vícerozměrnou normalitu.
- Odlehlé hodnoty se projeví jako body vpravo nahoře výrazně nad diagonálou.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Q-Q graf pro vícerozměrné normální rozdělení v Pythonu

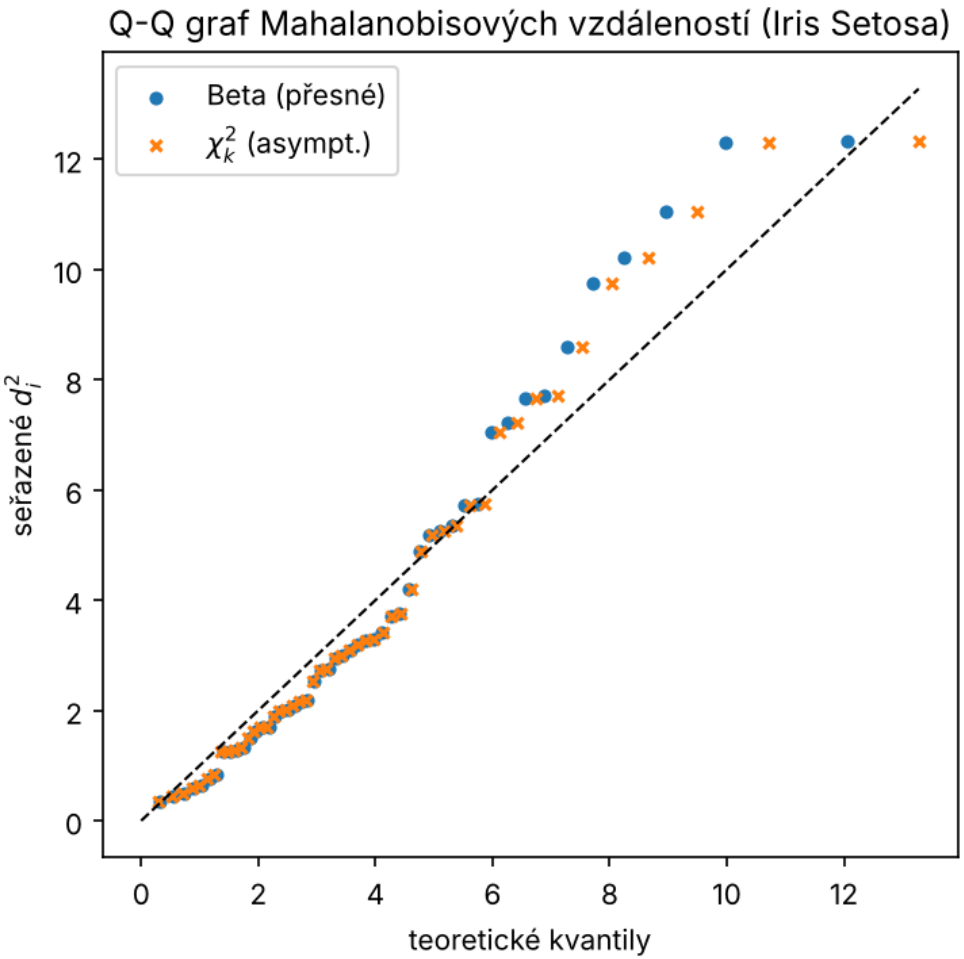
```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
from sklearn.datasets import load_iris

X = load_iris().data[:50]          # Setosa, n = 50, k = 4
n, k = X.shape
D = X - X.mean(axis=0)
S = np.cov(X, rowvar=False)
d2 = np.einsum("ij,jk,ik->i", D, np.linalg.inv(S), D)

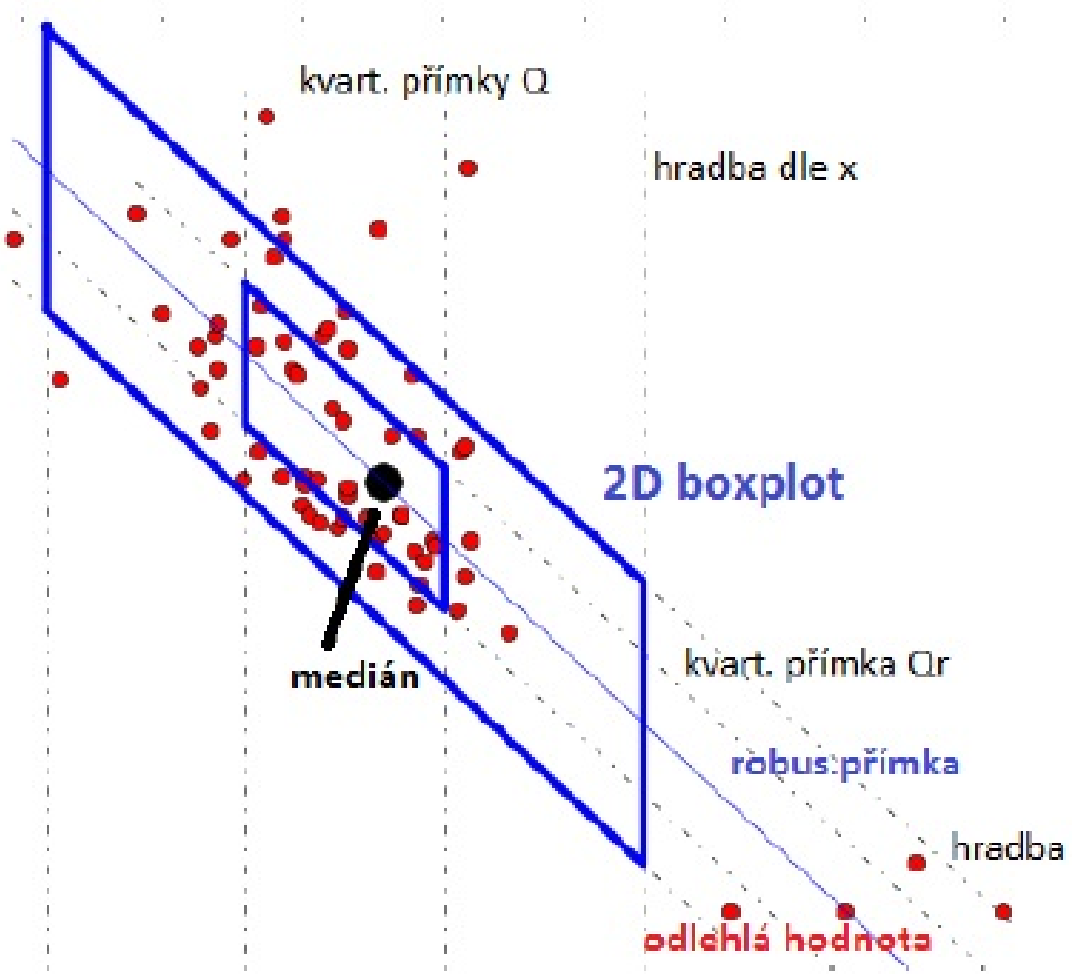
p = (np.arange(1, n + 1) - 0.5) / n
q_beta = (n-1)**2 / n * stats.beta.ppf(p, k/2, (n-k-1)/2)
q_chi2 = stats.chi2.ppf(p, df=k)
plt.scatter(q_beta, np.sort(d2), label="Beta (přesné)")
plt.scatter(q_chi2, np.sort(d2), marker="x", label="chi2")
plt.axline((0, 0), slope=1, color="k", ls="--")
plt.legend(); plt.show()
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

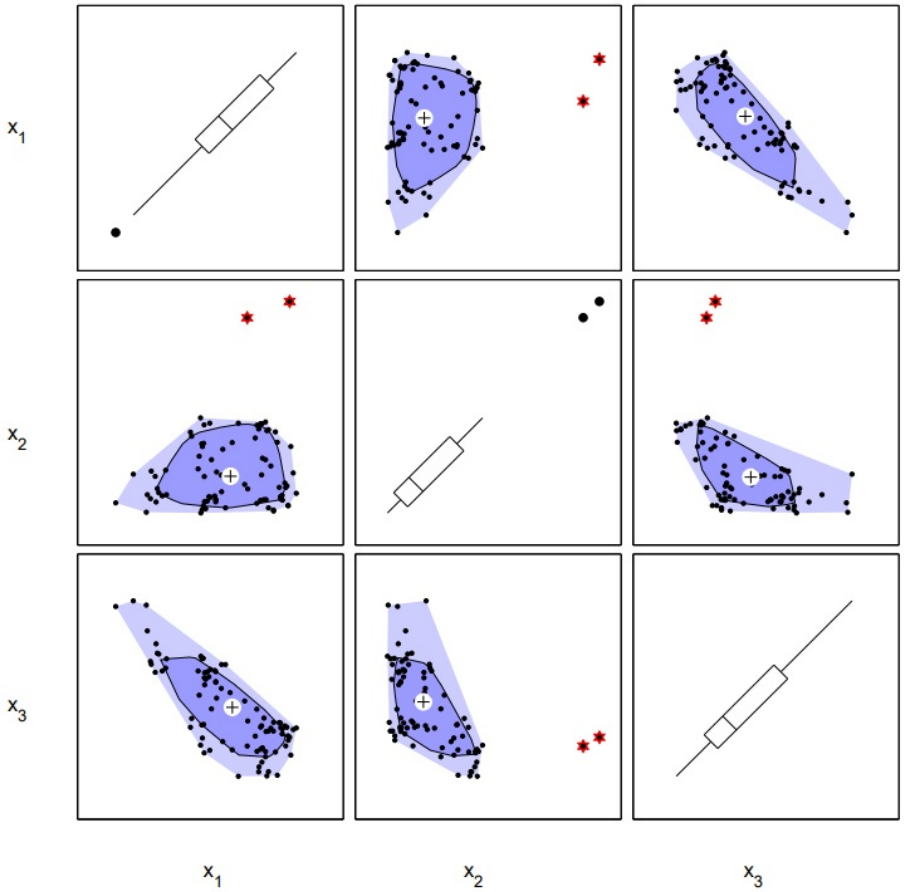
Q-Q graf

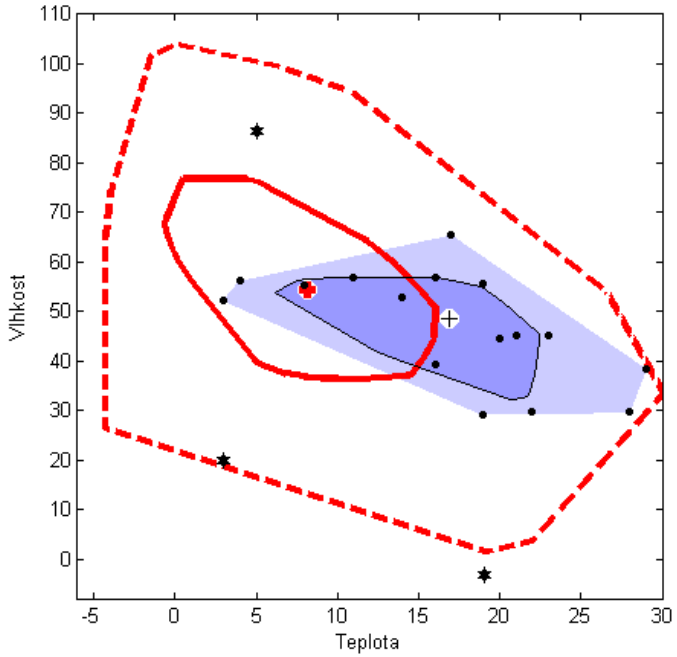

Q-Q graf Mahalanobisových vzdáleností (Iris Setosa)
Beta (přesné)
χ^2_k (asympt.)
seřazené d_i^2
teoretické kvantily
0
2
4
6
8
10
12

Dvourozměrný boxplot

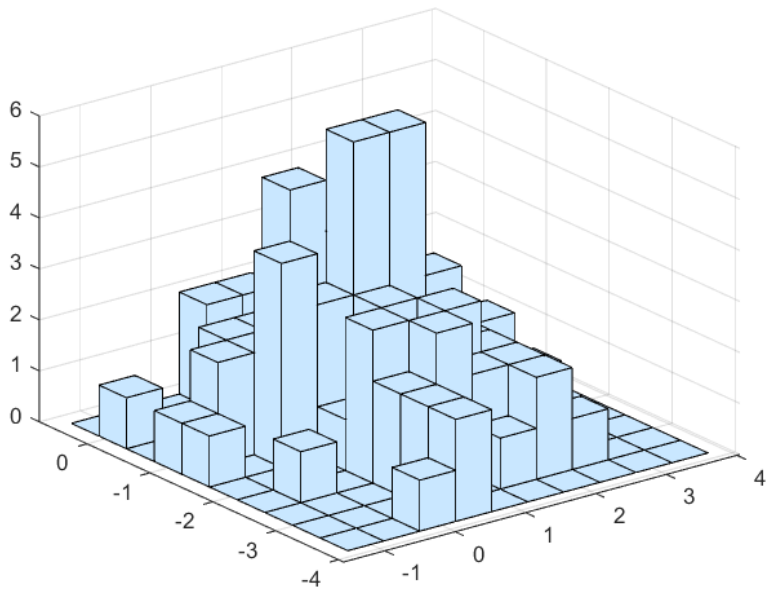


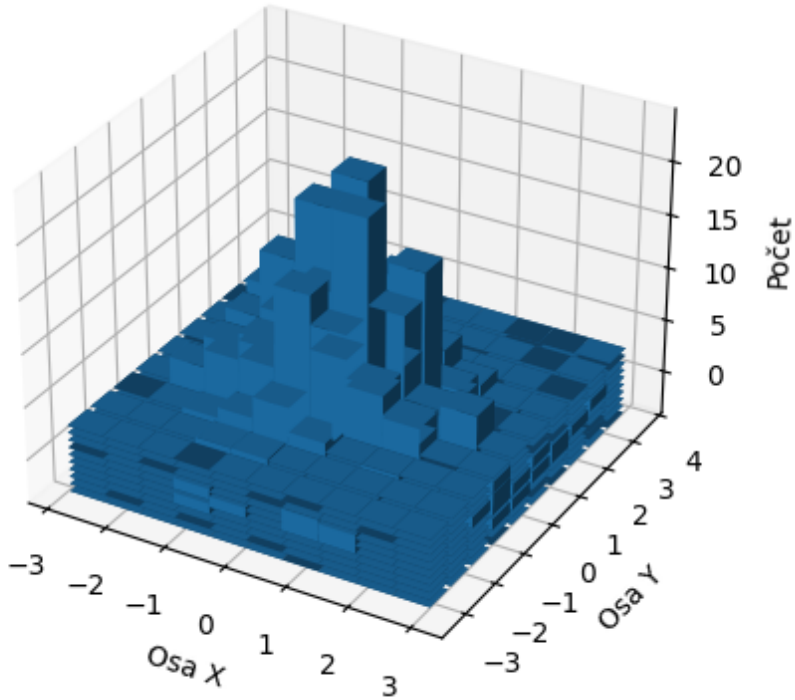
Bagplot


x1
x2
x3
x1
x2
x3


Vlhkost
Teplota
110
100
90
80
70
60
50
40
30
20
10
0
-5
0
5
10
15
20
25
30

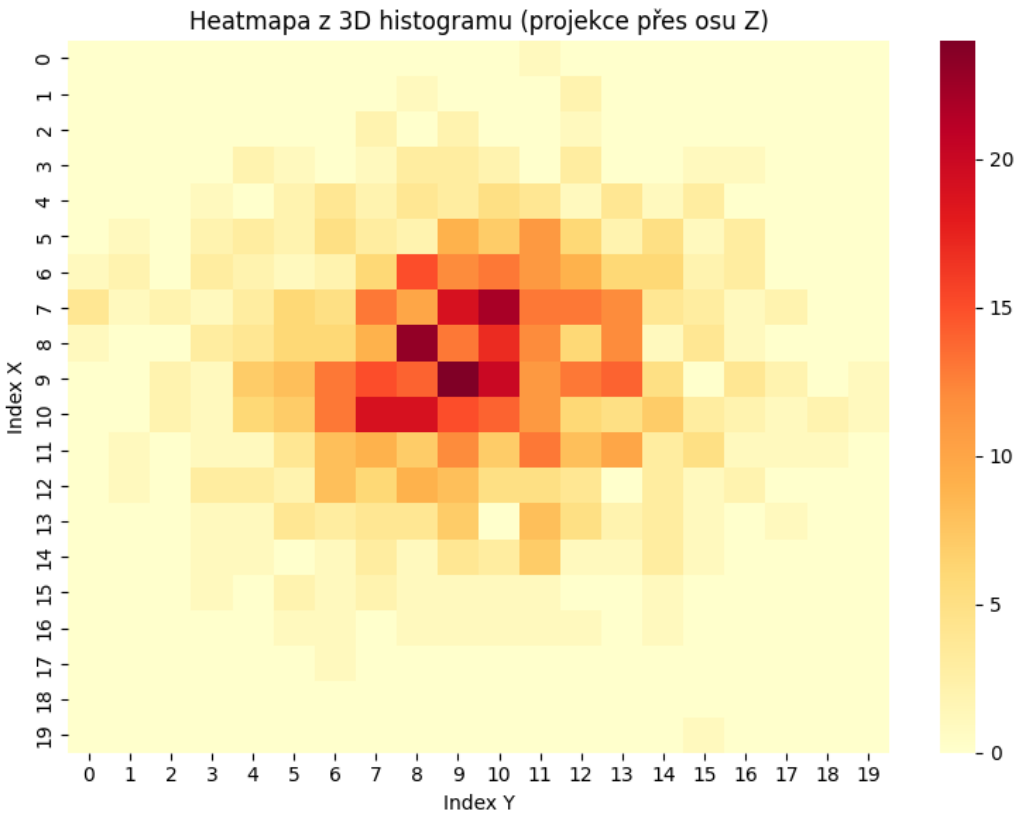
Dvourozměrný histogram





FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Heat mapy


Heatmapa z 3D histogramu (projekce přes osu Z)
Index X
Index Y
0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19
0 5 10 15 20

Vícerozměrné grafy v Pythonu

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.pairplot(df, hue="target")     # matice bodových grafů
plt.show()

x, y = X[:, 2], X[:, 3]            # petal length, width
fig, ax = plt.subplots(1, 2, figsize=(10, 4))
ax[0].hist2d(x, y, bins=20)        # heatmapa z histogramu
sns.kdeplot(x=x, y=y, fill=True, ax=ax[1])  # 2D jádrový odhad
plt.show()
```

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI