# KMA/MSM – cvičení 5: Odlehlá pozorování

(verze s výsledky)

---

Úlohy v částech A a B řešte nejprve „ručně“, výsledky ověřte v Pythonu; úlohy v části C jsou počítačové. Viz notebooky `P05a_odlehla_jednorozmerna.ipynb` a `P05b_odlehla_vicerozmerna.ipynb`. Pokud není řečeno jinak, volte hladinu $\alpha = 0{,}05$; $k$ značí dimenzi dat, $K$ počet sousedů.

## A. Jednorozměrná data

1. **Srovnání jednorozměrných metod.** Při kalibraci přístroje bylo naměřeno 10 hodnot:

   $$12{,}1;\ 12{,}4;\ 11{,}9;\ 12{,}3;\ 12{,}0;\ 12{,}2;\ 11{,}8;\ 12{,}5;\ 12{,}1;\ 14{,}0.$$

   (a) Spočtěte Z-skóre a rozhodněte podle pravidla $3\sigma$. Ukažte, že pro $n = 10$ nemůže pravidlo $3\sigma$ označit žádnou hodnotu. (Nápověda: $\max_i |z_i| \le \frac{n-1}{\sqrt{n}}$.)

   (b) Použijte Chauvenetovo kritérium.

   (c) Proveďte Grubbsův test. Kritická hodnota je $G_{krit} = \frac{n-1}{\sqrt{n}} \sqrt{\frac{t^2}{n-2+t^2}}$, kde $t = t_{\alpha/(2n),\,n-2} = 3{,}833$.

   (d) Proveďte Dixonův test ($Q_{krit} = 0{,}466$ pro $n = 10$, $\alpha = 0{,}05$).

   (e) Spočtěte modifikované Z-skóre (medián, MAD) a Tukeyho hradby $Q_{25} - 1{,}5\,IQR$, $Q_{75} + 1{,}5\,IQR$.

   (f) Porovnejte průměr, medián, 10% useknutý průměr a Tukeyho trimean. Jak se změní průměr a směrodatná odchylka po vyřazení podezřelé hodnoty?

   **Výsledky:** a) $\bar{x} = 12{,}33$, $s = 0{,}625$; největší $z = \frac{14{,}0-12{,}33}{0{,}625} = 2{,}67 < 3$. Pro $n = 10$ je $\max|z_i| \le \frac{9}{\sqrt{10}} = 2{,}85 < 3$ – pravidlo $3\sigma$ je u malých výběrů nepoužitelné. b) $n \cdot \mathcal{P}(|Z| > 2{,}67) = 10 \cdot 0{,}0076 = 0{,}076 < 0{,}5$ – hodnotu 14,0 vyřadíme. c) $G = 2{,}67 > G_{krit} = 2{,}29$ – 14,0 je odlehlá. d) $Q = \frac{14{,}0-12{,}5}{14{,}0-11{,}8} = 0{,}682 > 0{,}466$ – odlehlá. e) medián 12,15, $MAD = 0{,}20$; pro 14,0 je $z^* = \frac{0{,}6745 \cdot 1{,}85}{0{,}20} = 6{,}24 > 3{,}5$ (ostatní $|z^*| \le 1{,}18$). $Q_{25} = 12{,}025$, $Q_{75} = 12{,}375$, $IQR = 0{,}35$, hradby $(11{,}5;\ 12{,}9)$ – mimo je jen 14,0. f) průměr 12,33, medián 12,15, useknutý průměr 12,19, trimean 12,175. Bez hodnoty 14,0: $\bar{x} = 12{,}14$, $s = 0{,}230$ – jediná hodnota zvětšila $s$ téměř třikrát.

2. **Maskování.** Data obsahují dvě podobné podezřelé hodnoty:

   $$10{,}2;\ 9{,}8;\ 10{,}1;\ 9{,}9;\ 10{,}0;\ 10{,}3;\ 9{,}7;\ 10{,}1;\ 9{,}9;\ 10{,}0;\ 13{,}5;\ 13{,}6.$$

   (a) Proveďte Grubbsův test (pro $n = 12$ je $G_{krit} = 2{,}41$). Proč selže?

   (b) Proveďte GESD test s nejvýše $r = 3$ odlehlými hodnotami (v Pythonu) a určete počet odlehlých hodnot.

   (c) Jak dopadne modifikované Z-skóre a Tukeyho pravidlo?

   **Výsledky:** a) $G = 2{,}16 < 2{,}41$ – Grubbsův test nic neodhalí. Druhá odlehlá hodnota zvětší $s$ a posune průměr, takže první hodnota se „schová“ (maskování). b) GESD: $R_1 = 2{,}16 < \lambda_1 = 2{,}41$, $R_2 = 2{,}98 > \lambda_2 = 2{,}36$, $R_3 = 1{,}64 < \lambda_3 = 2{,}29$. Počet odlehlých hodnot je největší $i$ s $R_i > \lambda_i$, tj. 2 – obě hodnoty 13,5 a 13,6. c) Modifikované Z-skóre 15,5 a 16,0, hradby $(9{,}41;\ 10{,}71)$ – obě robustní metody označí obě hodnoty, protože medián a MAD (kvartily) odlehlé hodnoty neovlivní.

# B. Vícerozměrná data

3. **Mahalanobisova vzdálenost.** Data pocházejí z rozdělení $N_2(\mathbf{0}, \mathbf{\Sigma})$, $\mathbf{\Sigma} = \begin{pmatrix} 1 & 0{,}9 \\ 0{,}9 & 1 \end{pmatrix}$ (parametry považujte za známé). Posuďte body $\boldsymbol{a} = (-2{,}1;\ 2{,}1)^T$ a $\boldsymbol{b} = (2{,}5;\ 2{,}5)^T$.

   (a) Spočtěte Eukleidovské vzdálenosti od středu a Z-skóre jednotlivých složek.

   (b) Spočtěte $d_M^2$ a porovnejte s $\chi^2_2(0{,}95) = 5{,}99$ a $\chi^2_2(0{,}999) = 13{,}82$.

   (c) Vysvětlete, proč je pořadí bodů podle Eukleidovské a Mahalanobisovy vzdálenosti opačné.

   **Výsledky:** a) $\|\boldsymbol{a}\| = 2{,}97$, $\|\boldsymbol{b}\| = 3{,}54$; $|z| = 2{,}1$ resp. $2{,}5$ – žádná složka není nápadná, $\boldsymbol{b}$ je dál od středu. b) $\mathbf{\Sigma}^{-1} = \frac{1}{0{,}19}\begin{pmatrix} 1 & -0{,}9 \\ -0{,}9 & 1 \end{pmatrix}$; $d_M^2(\boldsymbol{a}) = \frac{2{\cdot}2{,}1^2(1+0{,}9)}{0{,}19} = 88{,}2$ ($p \approx 10^{-19}$, výrazně odlehlý); $d_M^2(\boldsymbol{b}) = \frac{2{\cdot}2{,}5^2(1-0{,}9)}{0{,}19} = 6{,}58$ ($p = 0{,}037$, mírně nad mezí 0,95, ale pod mezí 0,999). c) Bod $\boldsymbol{b}$ leží ve směru hlavní osy elipsy (souhlasí s kladnou korelací), bod $\boldsymbol{a}$ „proti“ korelaci, kde je rozptyl velmi malý ($1 - \rho = 0{,}1$).

4. **LOF ručně.** Pro jednorozměrná data 1; 2; 3; 4; 8 a $K = 2$ spočtěte pro každý bod $K$-dist, dosažitelné vzdálenosti, lokální dosažitelnou hustotu lrd a LOF. Výsledek ověřte pomocí `sklearn.neighbors.LocalOutlierFactor`.

   **Výsledky:** $K$-dist: $1 \to 2$, $2 \to 1$, $3 \to 1$, $4 \to 2$, $8 \to 5$. Např. pro bod 8: $N_2(8) = \{4, 3\}$, $\mathrm{rd}(8,4) = \max\{2,4\} = 4$, $\mathrm{rd}(8,3) = \max\{1,5\} = 5$, $\mathrm{lrd}(8) = 1/4{,}5 = 0{,}222$. Pro body 1–4 vychází vždy průměrná dosažitelná vzdálenost 1,5, tj. lrd = 0,667. LOF = 1 pro body 1–4, $\mathrm{LOF}(8) = \frac{0{,}667}{0{,}222} = 3$ – bod 8 je třikrát „řidší“ než jeho sousedé.

5. **Mardiův test.** Pro $n = 100$ pozorování dimenze $k = 3$ vyšla vícerozměrná šikmost $b_{1,3} = 1{,}2$ a špičatost $b_{2,3} = 17{,}5$. Otestujte vícerozměrnou normalitu ($\chi^2_{0,95}(10) = 18{,}31$). Proč může jediné odlehlé pozorování vést k zamítnutí normality?

   **Výsledky:** Šikmost: $\frac{n\,b_{1,3}}{6} = 20{,}0 > 18{,}31$ ($\mathrm{df} = \frac{3{\cdot}4{\cdot}5}{6} = 10$), $p = 0{,}029$. Špičatost: $\mathrm{E}\,b_{2,3} = k(k+2) = 15$, $\frac{17{,}5-15}{\sqrt{8{\cdot}15/100}} = 2{,}28$, $p = 0{,}022$. Normalitu zamítáme. Obě statistiky jsou založené na třetích a čtvrtých mocninách $m_{ij}$, resp. $d_i^2$; jediné velké $d_i^2$ je proto výrazně zvětší.

6. **$\chi^2$-test dobré shody.** Dvourozměrná data chceme testovat na normalitu $\chi^2$-testem dobré shody, každou proměnnou rozdělíme na 4 intervaly. Kolik má test stupňů volnosti? Kolik pozorování potřebujeme alespoň, má-li být $o_g \geq 5$ ve všech buňkách (předpokládejte stejné pravděpodobnosti buněk)? Jak by to vypadalo pro $k = 5$?

   **Výsledky:** $G = 4^2 = 16$ buněk; odhadujeme 2 střední hodnoty, 2 rozptyly a 1 kovarianci: $\nu = 16 - 1 - 4 - 1 = 10$. Při stejných $p_g = 1/16$ potřebujeme $n \geq 80$. Pro $k = 5$: $G = 4^5 = 1024$ buněk, $n \geq 5120$, $\nu = 1024 - 1 - 10 - 10 = 1003$ – test rychle ztrácí použitelnost.

# C. Počítačové úlohy

7. **Simulace – vlastnosti testů** (navazuje na notebook P05a).

   (a) Simulací ověřte, že Grubbsův test dodržuje hladinu $\alpha = 0{,}05$ pro $n = 10$ a $n = 100$ (podíl zamítnutí na čistě normálních datech).

(b) Zjistěte skutečnou hladinu *opakovaného* Grubbsova testu, pokud jej provedeme nejvýše třikrát (po každém zamítnutí hodnotu vyřadíme a test zopakujeme).

(c) Kolik hodnot označí Tukeyho pravidlo na výběru rozsahu 1000 z exponenciálního rozdělení? Proč jich je tolik? Jak by vypadalo pravidlo pro zešikmená data?

**Výsledky:** a) Podíl zamítnutí $\approx 0{,}048$ pro $n = 10$ i $n = 100$ (20 000 opakování) – hladina je dodržena. b) Opakovaný test zamítne alespoň jednou zhruba stejně často jako první krok (další kroky se provádějí jen po zamítnutí), skutečná hladina „alespoň jedné odlehlé hodnoty“ je proto přibližně $\alpha$; počet chybně označených hodnot ale roste. c) Průměrně asi 48 hodnot (4,8 %). Teoreticky: horní hradba $Q_{75} + 1{,}5\,IQR = \ln 4 + 1{,}5 \ln 3 = 3{,}03$, $\mathcal{P}(X > 3{,}03) = \mathrm{e}^{-3{,}03} = 0{,}048$. Pravidlo předpokládá symetrické rozdělení; pro zešikmená data je vhodné použít ho po transformaci (např. logaritmické) nebo použít upravený boxplot pro zešikmená data (medcouple, Hubert–Vandervieren).

8. **Vícerozměrné metody na datech `wine`** (navazuje na notebook P05b). Data načtěte funkcí `load_wine` z modulu `sklearn.datasets` ($n = 178$, $k = 13$) a standardizujte.

(a) Spočtěte klasickou a robustní (MCD) Mahalanobisovu vzdálenost a označte body s $d^2 > \chi^2_{13}(0{,}975)$. Kolik bodů označí každá metoda? Proč MCD označí tolik bodů?

(b) Proveďte Mardiův test vícerozměrné normality.

(c) Každou z metod Mahalanobis, MCD, LOF ($K = 20$) a Isolation Forest použijte k označení 5 % bodů s nejvyšším skóre. Spočtěte Jaccardovy indexy shody a najděte body, které označily všechny čtyři metody.

**Výsledky:** a) Mez $\chi^2_{13}(0{,}975) = 24{,}74$. Klasický odhad označí 12 bodů, MCD 48 bodů (všech 12 klasicky označených mezi nimi). Data tvoří tři odrůdy vína; MCD odhadne polohu a rozptyl z nejkompaktnější podmnožiny (převážně jedné odrůdy), takže velká část ostatních bodů vypadá odlehle – předpoklad jednoho eliptického rozdělení není splněn. b) $b_{1,13} = 43{,}5$, $\frac{nb_1}{6} = 1291$ (df = 455), $b_{2,13} = 225{,}1$ (očekávaná hodnota 195), $z = 10{,}2$ – normalitu jednoznačně zamítáme. c) Jaccardovy indexy (9 bodů na metodu) se pohybují mezi 0,29 (MCD–IF) a 0,64 (LOF s Mahalanobisem i s MCD). Všechny čtyři metody shodně označily 4 body (indexy 69, 95, 110, 121). Výsledky závisí na náhodném stavu Isolation Forestu.