KMA/MSM – Přednáška 5: Odlehlá pozorování

Kontrolní otázky (uzavřené) – verze s řešením

U otázek označených (*jedna odpověď*) je správná právě jedna možnost, u otázek označených (*více odpovědí*) může být správných více možností.

Otázka 1 (jedna odpověď)

Z kterých charakteristik se počítá modifikované Z-skóre (Iglewicz, Hoaglin)?

a) z průměru a výběrové směrodatné odchylky

b) z mediánu a mediánové absolutní odchylky (MAD) **[správně]**

c) z dolního a horního kvartilu

d) z useknutého průměru a mezikvartilového rozpětí

Řešení: $z_i^* = \frac{0{,}6745\,(x_i - \text{med})}{MAD}$, $MAD = \text{med}|x_i - \text{med}|$; konstanta 0,6745 zajistí srovnatelnost se Z-skóre u normálních dat. Medián i MAD odlehlé hodnoty téměř neovlivní, proto metoda netrpí maskováním. Kvartily používá Tukeyho pravidlo.

Otázka 2 (více odpovědí)

Která tvrzení o Mahalanobisově vzdálenosti $d_M^2(\boldsymbol{x}) = (\boldsymbol{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})$ jsou pravdivá?

a) Pro $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ se známými parametry má d_M^2 rozdělení χ_k^2. **[správně]**

b) Je invariantní vůči regulárním lineárním transformacím dat (nezáleží na měřítku proměnných). **[správně]**

c) S klasickými odhady $\bar{\boldsymbol{x}}$ a S je robustní vůči odlehlým pozorováním.

d) U dat tvořených dvěma oddělenými shluky může bod ležící mezi shluky mít malou Mahalanobisovu vzdálenost. **[správně]**

e) Bod, který není odlehlý v žádné jednotlivé proměnné, nemůže mít velkou Mahalanobisovu vzdálenost.

Řešení: Správně a), b), d). Klasické odhady jsou ovlivněny samotnými odlehlými body (maskování, zahlcení) – proto robustní odhad MCD. Bod porušující korelační strukturu může mít velkou d_M^2, i když je každá jeho složka nenápadná (např. $(-2{,}1;\ 2{,}1)$ při korelaci 0,9 má $d_M^2 \doteq 88$).

Otázka 3 (jedna odpověď)

Metoda LOF přiřadila bodu hodnotu $\text{LOF}_K(A) \approx 1$. Co to znamená?

a) Bod A je odlehlý s pravděpodobností přibližně 1.

b) Bod A má podobnou lokální hustotu jako jeho K nejbližších sousedů – není lokálně odlehlý. **[správně]**

c) Bod A leží ve vzdálenosti 1 od svého K-tého souseda.

d) Bod A leží blízko globálního průměru dat.

Řešení: LOF je poměr průměrné lokální dosažitelné hustoty sousedů a hustoty bodu. Hodnota kolem 1 znamená stejnou hustotu jako okolí, LOF $\gg 1$ bod řidší než sousedé. LOF není pravděpodobnost a nesouvisí s globálním středem dat (to je pohled Mahalanobisovy vzdálenosti).

Otázka 4 (více odpovědí)

Která tvrzení o maskování, zahlcení a odhadu MCD jsou pravdivá?

a) Maskování nastává, když skupina odlehlých pozorování ovlivní odhad průměru a varianční matice natolik, že sama není odhalena. **[správně]**

b) Zahlcení (swamping) znamená, že kvůli zkresleným odhadům jsou jako odlehlá označena regulérní pozorování. **[správně]**

c) MCD hledá podmnožinu h pozorování, jejíž výběrová varianční matice má nejmenší determinant. **[správně]**

d) Klasický výběrový průměr má bod zvratu (breakdown point) 50 %.

e) Opakované použití Grubbsova testu spolehlivě odhalí i dvě podobné odlehlé hodnoty.

Řešení: Správně a), b), c). Klasický průměr má bod zvratu $1/n \to 0$ (jediná hodnota jej může libovolně posunout); MCD s $h \approx n/2$ snese téměř 50 % kontaminace. Opakovaný Grubbsův test je náchylný k maskování – první krok druhou hodnotou „schovanou“ první neodhalí a postup se zastaví; vhodnější je GESD test.

Otázka 5 (jedna odpověď)

Mardiovým testem ověřujeme vícerozměrnou normalitu dat dimenze $k = 3$. Kolik stupňů volnosti má asymptotické rozdělení χ^2 statistiky $n\, b_{1,k}/6$ (test vícerozměrné šikmosti)?

a) 3

b) 6

c) 10 **[správně]**

d) 15

Řešení: $\nu = \frac{k(k+1)(k+2)}{6} = \frac{3 \cdot 4 \cdot 5}{6} = 10$. Hodnota $15 = k(k+2)$ je asymptotická střední hodnota vícerozměrné špičatosti $b_{2,k}$, hodnota 6 je počet různých prvků varianční matice.