

Odlehlá pozorování

Jednorozměrné a vícerozměrné metody, Mahalanobis, LOF a spol.

KMA/MSM Blanka Šedivá

verze 2026/2027

29. září 2026

Obsah

- 1 Odlehlá pozorování
 - Jednorozměrné metody
 - Vícerozměrné metody – přehled
- 2 Mahalanobisova vzdálenost, LOF a další metody – podrobný pohled
 - Motivace
 - Mahalanobisova vzdálenost
 - Kdy Mahalanobis selhává
 - Local Outlier Factor (LOF)
 - Další přístupy
 - Prokletí dimenzionality
 - Reálná data
 - Shrnutí podrobného pohledu
- 3 Testy normality pro vícerozměrná normální rozdělení

Odlehlá pozorování - outliers

- Jednorozměrné statistické metody
- Vícerozměrné statistické metody
- Podrobný pohled: Mahalanobisova vzdálenost, LOF a další metody na konkrétních datech

Odlehlá pozorování - outliers

- "An outlier is an observation which deviates so much from the other observations as to arouse suspicions that it was generated by a different mechanism"(Hawkins 1980)
- "An observation (or subset of observation) which appears to be inconsistent with the remainder of that set of data"(Barnett 1978)
- Normální (běžná) data jsou výsledkem jednotného mechanismu (jsou generována podle jednotného modelu) × Abnormální data jsou generována jiným mechanismem.
- Příklady aplikací
 - identifikace abnormálního chování (platby kartou, výsledky vyšetření pacienta, ...)
 - identifikace chyb v záznamech, měřeních ...
 - identifikace anomálií, potenciálních příležitostí, ...

Problémy identifikace

- data mají obvykle vícedimensionální charakter, modely jsou často jednodimensionální;
- data mohou být generována více než jedním obecným modelem;
- abnormality mohou být generovány více než jedním typem mechanismu;
- předpokládáme, že abnormality jsou méně četné.

Podle dat, která máme k dispozici, lze rozlišovat metody

- supervised - máme k dispozici data normálního i abnormálního typu;
- semi-supervised - máme k dispozici data normálního typu;
- unsupervised - nevíme jaká data máme.

Klasifikace metod identifikace outlierů podle předpokladu o základním modelu dat

- metody založené na konkrétním pravděpodobnostním modelu
předpoklad: je k dispozici model pro "běžná" data;
outliers: jsou data, která jsou málo pravděpodobná
 - metody využívající pravděpodobnostní testy
 - metody využívající "hloubku" dat
 - metody využívající "odlišnost" dat
- metody založené na "prostorové" blízkosti
předpoklad: zkoumáme "prostorové" vzdálenosti dat
outliers: body, které mají odlišnou "prostorovou" vzdálenost od ostatních
 - metody využívající vzdálenosti dat
 - metody využívající hustotu dat v okolí
- metody založené na "úhlové" blízkosti
předpoklad: zabýváme se směry spojníc mezi jednotlivými body
outliers: body, jejich systém směrů je odlišný od ostatních

Jednorozměrné statistické metody I

http://www.statistics4u.com/fundstat_eng/cc_outlier_tests.html <https://contchart.com/outliers.aspx>

Parametrické testy (předpokládají normální rozdělení)

- Z- skóre $z = \frac{x - \mu}{\sigma}$ (Chauvenet's criterion)

https://en.wikipedia.org/wiki/Chauvenet's_criterion

- test 3-sigma $x_i \in (\bar{x} \pm 3s)$

- Grubbs' test $G = \frac{\max_i |x_i - \bar{x}|}{s}$

Kritické hodnoty $G > \frac{n-1}{\sqrt{n}} \sqrt{\frac{t_{\alpha/2n, \nu=n-2}^2}{n-2+t_{\alpha/2n, \nu=n-2}^2}}$

https://en.wikipedia.org/wiki/Grubbs's_test_for_outliers

- useknuté průměry (trimmed mean)
- Tukey's trimean $Q = \frac{Q_{25\%} + 2Q_{50\%} + Q_{75\%}}{4}$

Jednorozměrné statistické metody II

Neparametrické testy

- modifikované Z-skóre $z_i = \frac{0.6745(x_i - \text{median}(x))}{MAD}$, kde $MAD = \text{median}(|x_i - \text{median}(x)|)$
(protože $\mathbb{E}(MAD) = 0.6745\sigma$ asymptoticky pro normální data)
- kvartilové porovnání (Tukeyho pravidlo, tzv. *fences*)
 $x_i \in (x_{25\%} - 1.5(x_{75\%} - x_{25\%}), x_{75\%} + 1.5(x_{75\%} - x_{25\%}))$
- Dean - Dixon test $Q = \frac{|x_{(2)} - x_{(1)}|}{|x_{(n)} - x_{(1)}|}$ resp. $Q = \frac{|x_{(n)} - x_{(n-1)}|}{|x_{(n)} - x_{(1)}|}$
(je třeba použít speciální tabulku kritických hodnot)
https://en.wikipedia.org/wiki/Dixon's_Q_test
- Peirce's criterion
https://en.wikipedia.org/wiki/Peirce's_criterion

Jednorozměrné statistické metody III

- **Walsh's Outlier Test**

https://vsp.pnnl.gov/help/vsample/Walshs_Outlier_Test.htm

- **Tietjen-Moore test**

<https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h2.htm>

- **GESD - Generalized Extreme Studentized Deviate Test**

<https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h3.htm>

- **Rosner's test** https://vsp.pnnl.gov/help/vsample/rosners_outlier_test.htm

- ...

Jednorozměrné statistické metody IV

Funkce v MATLAB:

*isoutlier (method: median, mean, quartiles, grubbs, gesd),
filloutliers(method: center, clip, previous,
next, nearest, linear, spline, pchip)*

Vícerozměrné metody I

- vícerozměrné boxploty
- Mahalanobisova vzdálenost $MDist(x, \mu) = (x - \mu)^T \Sigma^{-1} (x - \mu)$
Problémy:
 - odhad střední hodnoty a variance je citlivý na odlehlá pozorování
 - nevhodná pro modely s daty se smíšenými distribucemi (mixture models)
- metody založené na hloubce dat (depth based approaches)
 - vytvoříme konvexní obal dat a body ležící na hraně konvexního obalu mají hloubku 1
 - odstraníme body s hloubkou 1 a vytvoříme nový konvexní obal ...
 - lze porovnávat objemy konvexních obalů

Vícerozměrné metody II

- metody využívající "odlišnosti" dat
 - odlehlá pozorování ve smyslu charakteristik
počítáme charakteristiky (průměry, směrodatné odchylky, mediány , atd) pro data BEZ konkrétních pozorování a porovnáváme například směrodatnou odchylku vypočtenou ze všech dat a směrodatnou odchylku vypočtenou bez vybrané podmnožiny dat
 - odlehlá pozorování ve smyslu korelací, regresních vztahů
 - metody křížové validace (cross validation)
[https://en.wikipedia.org/wiki/Cross-validation_\(statistics\)](https://en.wikipedia.org/wiki/Cross-validation_(statistics))

Vícerozměrné metody III

- metody založené na prostorové vzdálenosti pro dané poloměr ϵ a stanovené π jsou za odlehlá pozorování považované takové body x_i , pro které platí, že nejvýše π procent všech bodů má vzdálenost menší než ϵ


Možné algoritmy

- počítáme vzdálenost všech bodů navzájem
- rozdělíme data do dvou skupin a počítáme vzdálenosti jenom od druhé skupiny
- rozdělíme datový prostor mřížkou na buňky a porovnáváme odlehlost se vzdáleností pouze v sousedních buňkách
- metody využívající kNN vzdálenost (k-nearest neighbor distances) vzdálenost počítáme pro k nejbližších sousedů
- metody využívající shlukování $ROF(x_i) = \frac{\text{počet shluků z dat bez } x_i - 1}{\text{počet shluků ze všech dat}}$

Vícerozměrné metody IV

- metody využívající "hustotu" dat

Obrázek: Hustota dat




– Model

- Reachability distance

– Introduces a smoothing factor

$$reach-dist_k(p, o) = \max\{k-distance(o), dist(p, o)\}$$



- Local reachability distance (lrd) of point p

– Inverse of the average reach-dists of the kNN s of p

$$lrd_k(p) = 1 / \left(\frac{\sum_{o \in kNN(p)} reach-dist_k(p, o)}{Card(kNN(p))} \right)$$

- Local outlier factor (LOF) of point p



– Average ratio of lrd's of neighbors of p and lrd of p

$$LOF_k(p) = \frac{\sum_{o \in kNN(p)} \frac{lrd_k(o)}{lrd_k(p)}}{Card(kNN(p))}$$

Vícerozměrné metody V

- metody využívající shlukování "úhlové" blízkosti
Pokud je bod odlehlý, pak ostatní body jsou "stejným" směrem.

Obrázek: Úhlové míry



Proč nestačí dívat se na proměnné zvlášť

- Odlehlá pozorování mohou představovat chyby měření, nestandardní procesy i zajímavé a potenciálně významné jevy.
- Zatímco v jednorozměrných datech bývá odhalení odlehlých hodnot relativně přímočaré, ve vícerozměrném prostoru se situace výrazně komplikuje.
- Pozorování může být nenápadné při pohledu na jednotlivé proměnné, ale po zohlednění jejich vzájemných vztahů se ukáže jako výrazně odlehlé.
- S rostoucí dimenzionalitou navíc selhávají intuitivní představy i některé tradiční postupy.

Cíl této části


Neexistuje univerzálně nejlepší metoda – cílem je ukázat výhody a omezení jednotlivých vybraných přístupů a to, že volba vhodné metody závisí na charakteru dat i na cíli analýzy.

Silně korelovaná data



Bod, který porušuje **vztah** mezi proměnnými, leží v marginálních rozděleních zcela nenápadně.

```
# Simulace: 300 bodu ze silne korelovaného 2D normalního rozdělení (  
    korelace 0.9)  
n = 300  
cov_true = np.array([[1.0, 0.9], [0.9, 1.0]])  
X_mot = RNG.multivariate_normal([0, 0], cov_true, n)  
suspect = np.array([-2.1, 2.1])    # bod "proti" korelaci  
...
```

Jednorozměrný pohled odlehlost neodhalí



Jednorozměrný pohled odlehlost neodhalí




Mahalanobisova vzdálenost

$$d_M^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

- Euklidovská vzdálenost **standardizovaná kovarianční strukturou** – vrstevnice jsou elipsy.
- Pro vícerozměrné normální rozdělení platí $d_M^2 \sim \chi_p^2 \rightarrow$ přirozená mez $\chi_p^2(1 - \alpha)$.
- Invariantní vůči lineárním transformacím (na měřítku nezáleží).

```
p = 2
alpha = 0.05
thr = chi2.ppf(1 - alpha, df=p)
emp = EmpiricalCovariance().fit(X_mot)
d2 = emp.mahalanobis(X_mot)
flags_m = d2 > thr
...
```

Vrstevnice d_M a rozdělení d_M^2



Maskování (masking) a zahlcení (swamping)




- Průměr i kovarianční matice se počítají **ze všech dat včetně odlehlých hodnot**.
- Skupina odlehlých pozorování si „natáhne“ elipsu k sobě a tím se sama zamaskuje.
- **Řešení:** robustní odhad polohy a rozptylu – *Minimum Covariance Determinant* (MCD), Rousseeuw (1984).

Princip MCD

Z n pozorování hledáme podmnožinu h bodů, pro kterou má výběrová kovarianční matice **nejmenší determinant** – nejkompaktnější elipsoid, jaký lze z dat vybrat. Odlehlé body leží mimo toto jádro, a proto se do odhadu μ, Σ vůbec nepromítnou.

- Výpočet: algoritmus **FastMCD** (Rousseeuw & Van Driessen, 1999) – iterativní *C-step*.
- Klasický odhad: breakdown point 0 %. MCD toleruje kontaminaci až do cca 50 % dat

Klasický vs. robustní (MCD) odhad





Kdy Mahalanobis selhává

Mahalanobisova vzdálenost implicitně předpokládá **jedno unimodální, přibližně eliptické rozdělení**. Pokud data tvoří více shluků nebo nelineární strukturu, je „střed dat“ často místo, kde žádná data nejsou.

```
def ds_two_clusters(rng):  
    a = rng.multivariate_normal([-3, 0], 0.35 * np.eye(2), 150)  
    b = rng.multivariate_normal([3, 0], 1.4 * np.eye(2), 150)  
    o = np.array([[0.0, 0.2], [-1.4, 0.6], [0.6, -0.4]])  
    ...
```

Eliptický pohled na neeliptická data

Eliptický pohled na neeliptická data



Co z toho plyne

- Body ležící **mezi shluky** (evidentně netypické) mají malou Mahalanobisovu vzdálenost – jsou blízko globálního průměru.
- Naopak zcela regulérní okrajová pozorování hustého shluku jsou označena jako odlehlá.

→ Potřebujeme kritérium založené na **lokální** struktuře dat.

Local Outlier Factor (LOF)

Breunig et al. (2000). Myšlenka: porovnej **lokální hustotu bodu** s lokální hustotou jeho k nejbližších sousedů.


- ❶ k -distance(A) – vzdálenost k k -tému nejbližšímu sousedovi
- ❷ $N_k(A)$ – množina k nejbližších sousedů bodu A
- ❸ reachability distance: $rd_k(A, B) = \max\{k\text{-dist}(B), d(A, B)\}$
- ❹ local reachability density: $lrd_k(A) = \left(\frac{1}{|N_k(A)|} \sum_{B \in N_k(A)} rd_k(A, B) \right)^{-1}$
- ❺ $LOF_k(A) = \frac{1}{k} \sum_{B \in N_k(A)} \frac{lrd_k(B)}{lrd_k(A)}$

Interpretace


$LOF \approx 1 \rightarrow$ stejná hustota jako okolí; $LOF \gg 1 \rightarrow$ bod je řidší než sousedé $\rightarrow$ lokálně odlehlý.

Řídké vs. husté okolí

```
k_demo = 4
nn = NearestNeighbors(
    n_neighbors=k_demo + 1
).fit(X_2c)
dist, idx = nn.kneighbors(X_2c)
...
```




LOF zachytí lokální odlehlost, Mahalanobis pouze globální



Citlivost LOF na volbu k

Výsledek LOF podstatně závisí na volbě k



Další často používané přístupy

Metoda	Princip	Předpoklad / parametr
Mahalanobis (klasický)	vzdálenost od průměru vážená Σ^{-1}	eliptické rozdělení; není robustní
Mahalanobis (MCD)	robustní odhad μ, Σ	eliptické rozdělení; <code>support_fraction</code>
k -NN vzdálenost	vzdálenost ke k -tému sousedovi	globální hustota; k
LOF	poměr lokálních hustot	lokální hustota; k
Isolation Forest	snadnost izolace náhodnými řezy	bez předpokladu tvaru; počet stromů
One-Class SVM	obálka nosiče rozdělení	jádro, ν, γ

Isolation Forest

Liu, Ting, Zhou (2008). Odlehlé body jsou „few and different“ – dají se izolovat od zbytku dat velmi rychle náhodným dělením prostoru.



$$s(x, n) = 2^{-E[h(x)]/c(n)}, \quad c(n) = 2H(n-1) - \frac{2(n-1)}{n}$$

- $s \rightarrow 1 \rightarrow$ bod izolován velmi mělko $\rightarrow$ odlehlý; $s \approx 0.5 \rightarrow$ typický bod.
- Časová složitost $O(n \log n)$, prakticky nezávislá na počtu příznaků.
- Citlivé na náhodnost a na osově (axis-parallel) řezy.

```
iso = IsolationForest(n_estimators=300, random_state=0)
score = -iso.fit(Xd).score_samples(Xd)
...
```

Isolation Forest – ukázka

Isolation Forest označuje body, které lze snadno izolovat náhodnými řezy



One-Class SVM

Schölkopf et al. (2001). Najdi v prostoru příznaků nejmenší možnou oblast, která obsahuje většinu dat – vše mimo ni je odlehlé.


$$\min_{\mathbf{w}, \xi, \rho} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{1}{\nu n} \sum_i \xi_i - \rho \quad \text{s.t. } (\mathbf{w} \cdot \phi(x_i)) \geq \rho - \xi_i, \xi_i \geq 0$$

- $\nu \in (0, 1]$ řídí horní mez podílu odlehlých bodů v trénovacích datech.
- jádro (RBF), parametr γ : malé $\gamma \rightarrow$ hladká hranice, velké $\gamma \rightarrow$ členitá hranice (riziko přeučení).
- Vyžaduje standardizaci vstupních dat (`StandardScaler`).

```
def s_maha(X):  
    return EmpiricalCovariance().fit(X).mahalanobis(X)
```

```
def s_mcd(X):  
    return MinCovDet(random_state=0, support...
```

Stejná data, stejný podíl označených bodů – různé výsledky



Co si odnést z přehledové mřížky


- Na eliptických datech se metody shodují – tam je volba téměř lhostejná.
- Při rozdílné hustotě shluků označí globální metody celý řidší shluk; LOF nikoli.
- U nelineárních struktur eliptické metody selhávají systematicky.
- Isolation Forest je kompromis: bez předpokladů, ale s tendencí preferovat okraje dat.

Výpočetní náročnost metod

Volba metody není jen otázka přesnosti – u větších datových souborů hraje roli i **rychlost**. Porovnáme škálování všech šesti metod se vzrůstajícím počtem pozorování n .

```
n_values = [200, 500, 1000, 2000, 4000, 8000, 15000]
p_bench = 6
for n_ in n_values:
    Xb = RNG.normal(size=(n_, p_bench))
    for mname, fn in METHODS.items():
        ...
```

Škálování výpočetní náročnosti



Mahalanobis a k -NN/LOF škálují dobře; MCD a One-Class SVM rostou rychleji s n ; Isolation Forest je téměř konstantní.

Prokletí dimenzionality

S rostoucím p se vzdálenosti mezi body **koncentrují** – poměr nejvzdálenějšího a nejbližšího souseda jde k 1. Pojem „blízkosti“ ztrácí rozlišovací schopnost a s ním i metody založené na vzdálenostech.



$$d(X, Y)^2 = \sum_{i=1}^p (X_i - Y_i)^2, \quad \text{CV}(d^2) = \frac{\sqrt{\text{Var}[d^2]}}{E[d^2]} \xrightarrow{p \rightarrow \infty} 0$$

Formálně (Beyer et al., 1999)

Pokud relativní rozptyl jde k nule s rostoucím p , pak $\frac{D_{\max}}{D_{\min}} \xrightarrow{P} 1$.

Kontrast vzdáleností v rostoucí dimenzi

```
dims = [2, 5, 10, 20, 50, 100, 200, 500]
n_pts = 300
for d in dims:
    Xd = RNG.normal(size=(n_pts, d))
    dist, _ = NearestNeighbors(n_neighbors=n_pts).fit(Xd).kneighbors(Xd)
    ...
```



Reálná data

Doposud jsme metody srovnávali na simulovaných datech, kde jsme znali „pravdu“ o tom, co je a co není odlehlé. V praxi to tak často nebývá. Ukážeme obě situace:


- **7.1 – data bez ground truth** (*wine*): metody lze srovnat jen mezi sebou (shoda/konsensus).
- **7.2 – data s ground truth** (mamografie): můžeme spočítat, která metoda je skutečně blíž pravdě.

Bez ground truth: `wine` (178 vzorků, 13 proměnných)



Dataset **Wine Recognition** z UCI Machine Learning Repository, načtený přes `sklearn.datasets.load_wine`. Nevíme, co je „skutečně“ odlehlé – sledujeme jen, **nakolik se metody shodují**.

```
wine = load_wine()
Xw = StandardScaler().fit_transform(wine.data)
CONTAM_W = 0.05
res_w = {name: flag_top(fn(Xw), CONTAM_W) for name, ...}
```

Shoda metod – Jaccardův index (wine)



Konsensus metod – PCA projekce (wine)



Praktické doporučení (bez ground truth)


Místo hledání „té správné“ metody se vyplatí sledovat **konsensus**.
Pozorování označená většinou metod jsou robustní kandidáti; body
označené jen jednou metodou vypovídají spíše o vlastnostech metody
než o datech.

S ground truth: mamografie – detekce mikrokalcifikací

Dataset **Mammography** z katalogu ODDS (Woods et al. 1993, Rayana 2016). 11 183 objektů, 6 obrazových příznaků. 260 objektů (2,32 %) je radiologicky potvrzeno jako mikrokalcifikace.



```
mammo = pd.read_csv('mammography.csv')  
y_true = mammo['odlehly'].values  
Xm = mammo.drop(columns='odlehly').values  
...
```

Shoda metod – Jaccardův index (mamografie)



Kvantitativní srovnání (ROC-AUC)

```
from sklearn.metrics import roc_auc_score
for name, s in scores_m.items():
    auc = roc_auc_score(y_true, s)
    ...
```



Praktické doporučení a shrnutí sekce 7

- Na mamografických datech mají **globální** metody (Mahalanobis, Isolation Forest, k -NN) vyšší ROC-AUC než LOF a One-Class SVM.
- Pěkný protipól k předchozím sekcím, kde naopak LOF vítězilo nad Mahalanobisem.
- **Žádná metoda není univerzálně nejlepší** – výsledek závisí na charakteru konkrétních dat.
- Bez ground truth (wine) lze posoudit jen shodu metod mezi sebou; s ground truth (mamografie) lze přímo změřit, která metoda je blíže pravdě.

Shrnutí

Metoda	Typ pohledu	Silné stránky	Omezení
Mahalanobis	globální, elip- tická	interpretovatelná mez χ^2 , rychlý	není robustní, selže u shluků
MCD- Mahalanobis	globální, elip- tická	robustní, statisticky podložený	vyžaduje $n \gg p$
k -NN	globální hus- tota	bez předpokladů tvaru	citlivý na měřítko
vzdálenost LOF	lokální hus- tota	zachytí lokální od- lehlost	citlivý na k
Isolation Fo- rest	izolovatelnost	škáluje do vyšších dimenzí	osové řezy
One-Class SVM	nosič rozdělení	flexibilní hranice	citlivý na ν, γ

Závěry

- 1 **Vícerozměrná odlehlost není součtem jednorozměrných.**
- 2 **Mahalanobisova vzdálenost** – dobrá první volba, ale jen v robustní variantě (MCD).
- 3 **LOF** odhalí lokálně odlehlá pozorování; cenou je volba k .
- 4 **S rostoucí dimenzí** slábne kontrast vzdáleností – nutná redukce dimenze či regularizace.
- 5 **Neexistuje univerzálně nejlepší metoda.**
- 6 V praxi se osvědčuje **kombinace metod a sledování konsensu.**
- 7 **Máte-li ground truth**, vždy validujte kvantitativně.

Statistické testy normality

Testy normality pro vícerozměrná normální rozdělení

Testy založené na momentech Mardia's test

- $b_{1d} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \eta_{ij}^3 \dots$ nazýváme **vícerozměrnou šikmostí**
- Pro lineární případy $n \rightarrow +\infty$ platí, že za předpokladu normálního rozdělení vektoru $\mathbf{X}$ je

$$\frac{n \cdot b_{1d}}{6} \sim \chi^2 \text{ se stupni volnosti } \nu = \frac{p \cdot (p+1) \cdot (p+2)}{6}.$$

- **vícerozměrná špičatost** $b_{2d} = \frac{1}{n} \sum_{i=1}^n \eta_i^2$
- za předpokladu normálního rozdělení vektoru $\mathbf{X}$ je

$$\sqrt{n} \frac{(b_{2d} - p \cdot (p+2))}{\sqrt{8 \cdot p \cdot (p+2)}} \sim N(0, 1).$$

Testy normality pro vícerozměrná normální rozdělení

Vícerozměrný χ^2 -test dobré shody

Rozdělíme definiční obor $\mathbb{R}^p$ na jednotlivé sektory Ω_g . Spočteme očekávané pravděpodobnosti v těchto sektorech podle vztahu $p_g = \int_{\Omega_g} f(\mathbf{x}) d\mathbf{x}$ a očekávané počty hodnot podle vztahu $o_g = p_g \cdot n$. Pak statistika

$$\chi^2 = \frac{\sum (o_g - n_g)^2}{o_g},$$

kde n_g je skutečný počet hodnot v sektoru Ω_g , má χ^2 rozdělení se stupni volnosti $\nu = \left(\prod_{e=1}^p c_e \right) - 2 \cdot p - p_{cov} - 1$, kde c_e je počet sektorů e -té proměnné a p_{cov} zachycuje kovarianci počtu sektorů vzhledem k jednotlivým proměnným, obvykle volíme $p_{cov} = \binom{p}{2}$.