# Přednáška 5: Odlehlá pozorování

## Jednorozměrné a vícerozměrné metody, Mahalanobis, LOF a další

KMA/MSM Blanka Šedivá

verze 2026/2027

6. října 2026

# Obsah


1. Odlehlá pozorování
2. Jednorozměrná data
   - Parametrické metody
   - Robustní a neparametrické metody
3. Vícerozměrná data
   - Motivace
   - Mahalanobisova vzdálenost
   - Kdy Mahalanobis selhává
   - Metody založené na vzdálenosti a hustotě, LOF
   - Další přístupy
   - Srovnání metod
   - Prokletí dimenzionality
   - Reálná data
   - Shrnutí
4. Testy vícerozměrné normality


FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Odlehlá pozorování – outliers

- Odlehlá pozorování – definice a problémy identifikace
- Identifikace odlehlých pozorování v jednorozměrných datech
- Identifikace odlehlých pozorování ve vícerozměrných datech
- Testy vícerozměrné normality

# Odlehlá pozorování – outliers

- „An outlier is an observation which deviates so much from the other observations as to arouse suspicions that it was generated by a different mechanism“ (Hawkins, 1980).
- „An observation (or subset of observations) which appears to be inconsistent with the remainder of that set of data“ (Barnett, Lewis, 1978).
- Normální (běžná) data jsou výsledkem jednotného mechanismu (jsou generována podle jednotného modelu) $\times$ abnormální data jsou generována jiným mechanismem.
- Příklady aplikací
  - identifikace abnormálního chování (platby kartou, výsledky vyšetření pacienta, . . . ),
  - identifikace chyb v záznamech, měřeních, . . .
  - identifikace anomálií, potenciálních příležitostí, . . .

# Problémy identifikace

- data mají obvykle vícerozměrný charakter, modely jsou často jednorozměrné;
- data mohou být generována více než jedním obecným modelem;
- abnormality mohou být generovány více než jedním typem mechanismu;
- předpokládáme, že abnormality jsou méně četné.

Podle dat, která máme k dispozici, lze rozlišovat metody

- supervised – máme k dispozici označená data normálního i abnormálního typu;
- semi-supervised – máme k dispozici pouze data normálního typu;
- unsupervised – nemáme informaci o tom, která data jsou odlehlá.

# Klasifikace metod identifikace outlierů podle předpokladu o základním modelu dat

- metody založené na konkrétním pravděpodobnostním modelu
  předpoklad: je k dispozici model pro „běžná“ data;
  outliers: jsou data, která jsou v rámci modelu málo pravděpodobná
  - metody využívající pravděpodobnostní testy
  - metody využívající „hloubku“ dat
  - metody využívající „odlišnost“ dat
- metody založené na „prostorové“ blízkosti
  předpoklad: zkoumáme „prostorové“ vzdálenosti dat
  outliers: body, které mají odlišnou „prostorovou“ vzdálenost od ostatních
  - metody využívající vzdálenosti dat
  - metody využívající hustotu dat v okolí
- metody založené na „úhlové“ blízkosti
  předpoklad: zabýváme se směry spojnic mezi jednotlivými body
  outliers: body, jejichž systém směrů je odlišný od ostatních

# Jednorozměrná data

- Parametrické metody (předpoklad normality): Z-skóre, Chauvenetovo kritérium, Grubbsův, Dixonův a GESD test
- Robustní a neparametrické metody: modifikované Z-skóre (MAD), Tukeyho pravidlo
- Robustní odhady polohy

Ukázky v Pythonu: notebook `P05a_odlehla_jednorozmerna.ipynb`.

# Jednorozměrné metody – parametrické (normální rozdělení)

- Z-skóre $z_i = \frac{x_i - \overline{x}}{s}$, pravidlo 3 sigma: za odlehlé považujeme $x_i \notin (\overline{x} \pm 3s)$.
- Chauvenetovo kritérium: $x_i$ vyřadíme, pokud $n \cdot \mathcal{P}(|Z| > |z_i|) < 0{,}5$
  https://en.wikipedia.org/wiki/Chauvenet's_criterion
- Grubbsův test (jedno odlehlé pozorování) $G = \frac{\max_i |x_i - \overline{x}|}{s}$, kritická hodnota

$$G > \frac{n-1}{\sqrt{n}} \sqrt{\frac{t^2_{\alpha/(2n),\, n-2}}{n-2+t^2_{\alpha/(2n),\, n-2}}},$$

  kde $t_{\alpha/(2n),\, n-2}$ je horní kritická hodnota $t$-rozdělení.
  https://en.wikipedia.org/wiki/Grubbs's_test_for_outliers
- Dixonův test $Q = \frac{|x_{(2)} - x_{(1)}|}{|x_{(n)} - x_{(1)}|}$, resp. $Q = \frac{|x_{(n)} - x_{(n-1)}|}{|x_{(n)} - x_{(1)}|}$ (malé výběry, speciální tabulka kritických hodnot).
- Tietjen-Mooreův test (předem daný počet odlehlých hodnot), GESD – Generalized Extreme Studentized Deviate test (Rosnerův test, neznámý počet odlehlých hodnot), Peirceovo kritérium. https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h.htm

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

# Jednorozměrné metody – robustní a neparametrické

- Modifikované Z-skóre (Iglewicz, Hoaglin) $z_i = \frac{0{,}6745\,(x_i - \text{median}(x))}{MAD}$, kde $MAD = \text{median}(|x_i - \text{median}(x)|)$; za odlehlé se obvykle považují $|z_i| > 3{,}5$ (protože pro normální data $MAD \to 0{,}6745\,\sigma$).
- Kvartilové pravidlo (Tukeyho pravidlo, tzv. *fences*): za odlehlé považujeme $x_i \notin (x_{25\%} - 1{,}5\,IQR,\ x_{75\%} + 1{,}5\,IQR)$, kde $IQR = x_{75\%} - x_{25\%}$ (hranice v boxplotu).
- Walshův test (neparametrický, pro velké výběry) `https://vsp.pnnl.gov/help/vsample/Walshs_Outlier_Test.htm`
- Robustní odhady polohy, které odlehlé hodnoty jen tlumí: medián, useknutý průměr (trimmed mean), Tukeyho trimean $\frac{Q_{25\%} + 2Q_{50\%} + Q_{75\%}}{4}$.

***Funkce v MATLAB:***
*isoutlier (method: median, mean, quartiles, grubbs, gesd),*
*filloutliers (method: center, clip, previous, next, nearest, linear, spline, pchip)*

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Jednorozměrné metody v Pythonu

```
import numpy as np
from scipy import stats

rng = np.random.default_rng(1)
x = np.append(rng.normal(10, 1, 30), 14.5)        # 1 podezrely bod
n = len(x)

z = (x - x.mean()) / x.std(ddof=1)                # Z-skore, |z| > 3
med = np.median(x)
mad = np.median(np.abs(x - med))
z_mod = 0.6745 * (x - med) / mad                  # modifikovane Z-skore
    , |z| > 3.5
q1, q3 = np.percentile(x, [25, 75])
iqr = q3 - q1
tukey = (x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)

G = np.max(np.abs(x - x.mean())) / x.std(ddof=1) # Grubbsuv test
alpha = 0.05
t = stats.t.ppf(1 - alpha / (2 * n), n - 2)
G_crit = (n - 1) / np.sqrt(n) * np.sqrt(t**2 / (n - 2 + t**2))
print(G, G_crit, G > G_crit)
```

# Vícerozměrná data

- Motivace – proč nestačí dívat se na proměnné zvlášť
- Mahalanobisova vzdálenost, maskování a robustní odhad MCD
- Metody založené na vzdálenosti a hustotě: $K$-NN vzdálenost, LOF
- Další přístupy: Isolation Forest, One-Class SVM, hloubka dat, shlukování, úhlové metody
- Prokletí dimenzionality, reálná data, shrnutí

Grafické nástroje viz P04 (matice bodových grafů, bagplot, Q-Q graf Mahalanobisových vzdáleností). Ukázky v Pythonu: notebook `P05b_odlehla_vicerozmerna.ipynb`.

# Proč nestačí dívat se na proměnné zvlášť

- Odlehlá pozorování mohou představovat chyby měření, nestandardní procesy i zajímavé a potenciálně významné jevy.
- Zatímco v jednorozměrných datech bývá odhalení odlehlých hodnot relativně přímočaré, ve vícerozměrném prostoru se situace výrazně komplikuje.
- Pozorování může být nenápadné při pohledu na jednotlivé proměnné, ale po zohlednění jejich vzájemných vztahů se ukáže jako výrazně odlehlé.
- S rostoucí dimenzí navíc selhávají intuitivní představy i některé tradiční postupy.

## Cíl této části

Neexistuje univerzálně nejlepší metoda – cílem je ukázat výhody a omezení jednotlivých vybraných přístupů a to, že volba vhodné metody závisí na charakteru dat i na cíli analýzy.

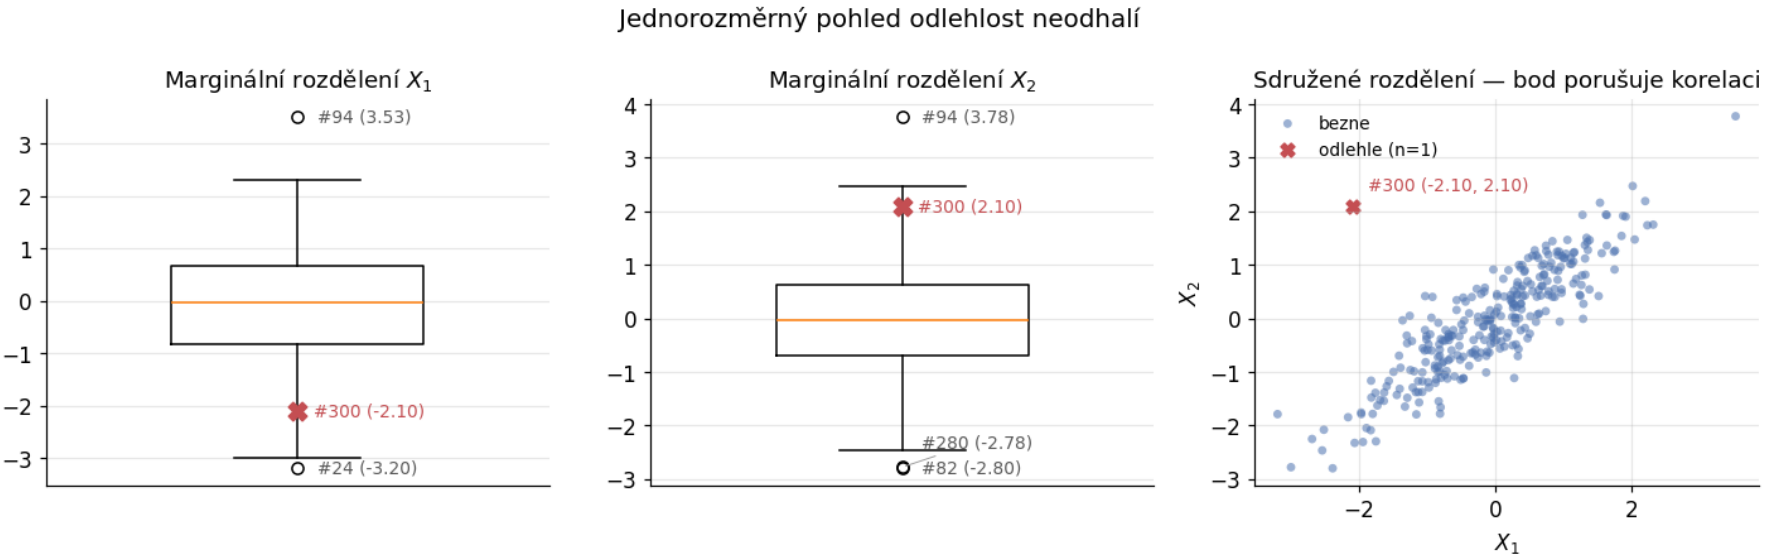
# Silně korelovaná data

Bod, který porušuje **vztah** mezi proměnnými, leží v marginálních rozděleních zcela nenápadně.

```
# Simulace: 300 bodu ze silne korelovaneho 2D normalniho rozdeleni (
    korelace 0.9)
n = 300
cov_true = np.array([[1.0, 0.9], [0.9, 1.0]])
X_mot = RNG.multivariate_normal([0, 0], cov_true, n)
suspect = np.array([-2.1, 2.1])   # bod "proti" korelaci
...
```

Pro bod $(-2{,}1;\ 2{,}1)$ je $|z| = 2{,}1$ v obou proměnných, ale $d^2 = \frac{2 \cdot 2{,}1^2}{1-0{,}9} \doteq 88$, zatímco $\chi^2_2(0{,}999) \doteq 13{,}8$.

# Jednorozměrný pohled odlehlost neodhalí



# Mahalanobisova vzdálenost

$$d_M^2(\boldsymbol{x}) = (\boldsymbol{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})$$

- Eukleidovská vzdálenost **standardizovaná varianční maticí** – vrstevnice jsou elipsy (elipsoidy).
- Pro $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ se známými parametry platí $d_M^2 \sim \chi_k^2 \rightarrow$ přirozená mez $\chi_k^2(1-\alpha)$. Při odhadnutých $\overline{\boldsymbol{x}}$, $S$ platí rozdělení $\chi_k^2$ jen přibližně (přesně je to škálované rozdělení Beta, viz P04).
- Invariantní vůči regulárním lineárním transformacím (na měřítku proměnných nezáleží).

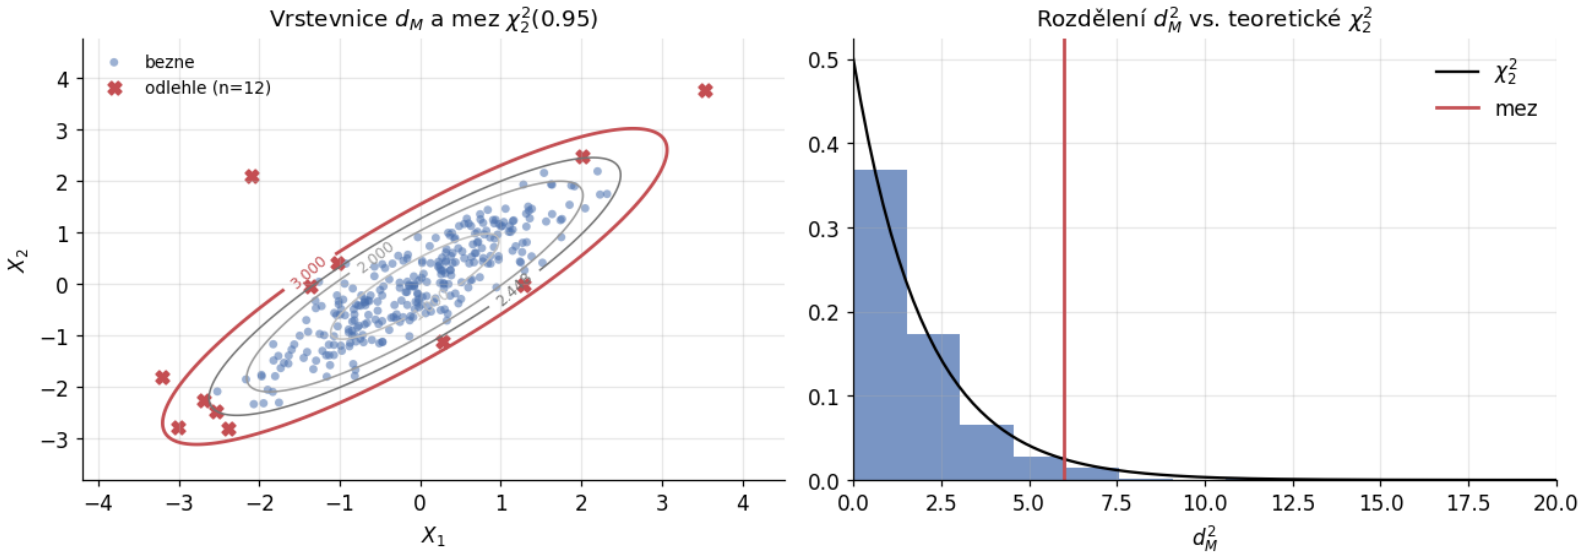
FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Mahalanobisova vzdálenost v Pythonu

```
from scipy.stats import chi2
from sklearn.covariance import EmpiricalCovariance

k = 2                                          # dimenze
alpha = 0.05
thr = chi2.ppf(1 - alpha, df=k)
emp = EmpiricalCovariance().fit(X_mot)
d2 = emp.mahalanobis(X_mot)                    # vraci ctverec vzdalenosti
flags_m = d2 > thr
```

# Vrstevnice $d_M$ a rozdělení $d_M^2$



# Maskování (masking) a zahlcení (swamping)

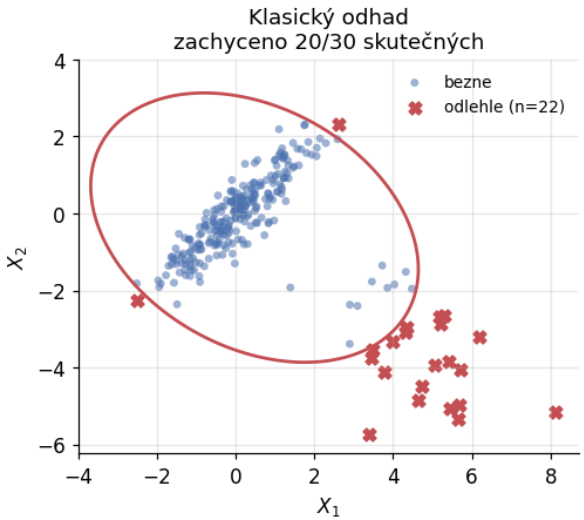
- Průměr i varianční matice se počítají **ze všech dat včetně odlehlých hodnot**.
- **Maskování:** skupina odlehlých pozorování si „natáhne“ elipsu k sobě a tím se sama zamaskuje.
- **Zahlcení:** zkreslená elipsa naopak označí jako odlehlá i regulérní pozorování.
- **Řešení:** robustní odhad polohy a rozptylu – *Minimum Covariance Determinant* (MCD), Rousseeuw (1984).

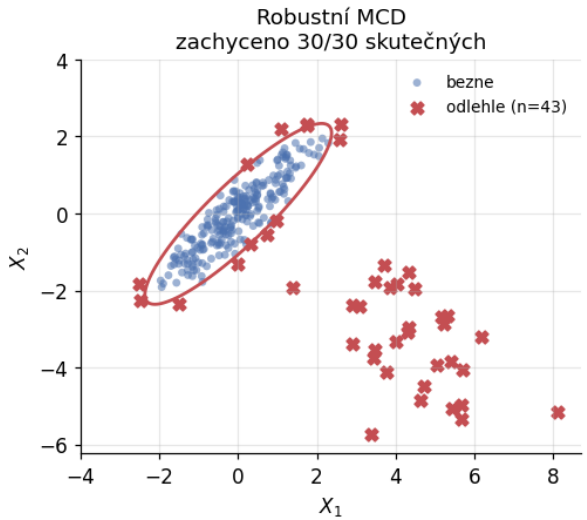
### Princip MCD

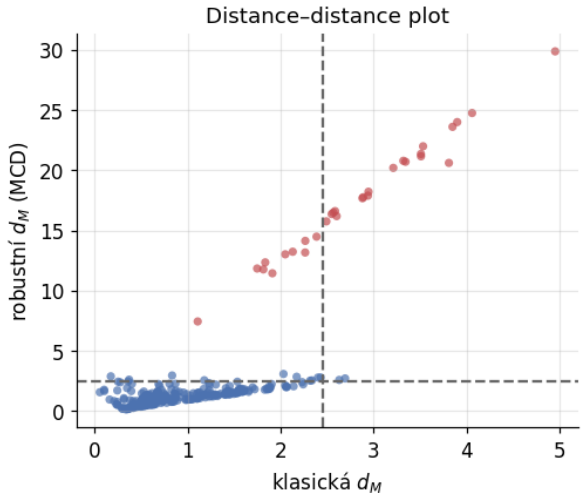
Z $n$ pozorování hledáme podmnožinu $h$ bodů, $\frac{n+k+1}{2} \leq h \leq n$, pro kterou má výběrová varianční matice **nejmenší determinant** – nejkompaktnější elipsoid, jaký lze z dat vybrat. Odlehlé body leží mimo toto jádro, a proto se do odhadu $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ nepromítnou.

- Výpočet: algoritmus **FastMCD** (Rousseeuw, Van Driessen, 1999) – iterativní *C-step*.
- Klasický odhad: bod zvratu (breakdown point) $1/n \to 0\,\%$. MCD s $h \approx n/2$ toleruje kontaminaci téměř 50 % dat.

# Klasický vs. robustní (MCD) odhad



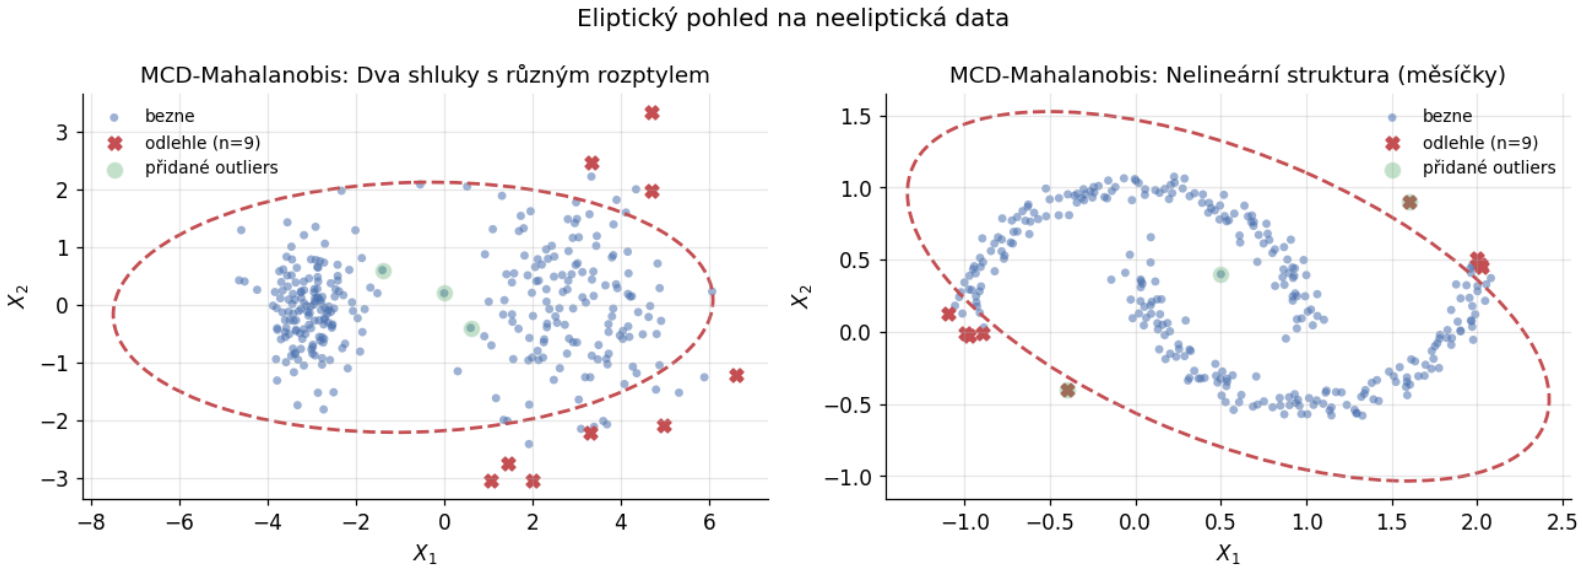



# Kdy Mahalanobis selhává

Mahalanobisova vzdálenost implicitně předpokládá **jedno unimodální, přibližně eliptické rozdělení**. Pokud data tvoří více shluků nebo nelineární strukturu, je „střed dat“ často místo, kde žádná data nejsou.

```
def ds_two_clusters(rng):
    a = rng.multivariate_normal([-3, 0], 0.35 * np.eye(2), 150)
    b = rng.multivariate_normal([3, 0], 1.4 * np.eye(2), 150)
    o = np.array([[0.0, 0.2], [-1.4, 0.6], [0.6, -0.4]])
    ...
```

# Eliptický pohled na neeliptická data



# Co z toho plyne

- Body ležící **mezi shluky** (evidentně netypické) mají malou Mahalanobisovu vzdálenost – jsou blízko globálního průměru.
- Naopak zcela regulérní okrajová pozorování řidšího shluku jsou označena jako odlehlá.

$\rightarrow$ Potřebujeme kritérium založené na **lokální** struktuře dat.

# Metody založené na vzdálenosti

- **Vzdálenostní odlehlost** (Knorr, Ng 1998): pro daný poloměr $\varepsilon$ a podíl $\pi$ je bod $\boldsymbol{x}_i$ odlehlý, pokud nejvýše $\pi$ procent všech bodů má od $\boldsymbol{x}_i$ vzdálenost menší než $\varepsilon$.

  Možné algoritmy

  - počítáme vzdálenosti všech bodů navzájem,
  - rozdělíme data do dvou skupin a počítáme vzdálenosti jenom od druhé skupiny,
  - rozdělíme datový prostor mřížkou na buňky a vzdálenosti počítáme pouze v sousedních buňkách.

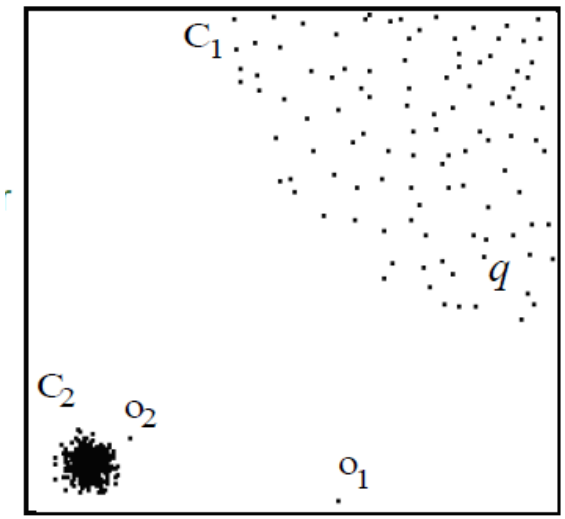
- $K$**-NN vzdálenost**: skóre bodu je vzdálenost k jeho $K$-tému nejbližšímu sousedovi (nebo průměrná vzdálenost ke $K$ sousedům).

- Obě metody měří **globální** hustotu – jeden práh platí pro celý prostor. Pokud mají shluky různou hustotu, označí celý řidší shluk.

- Počet sousedů značíme $K$, abychom jej odlišili od dimenze dat $k$.

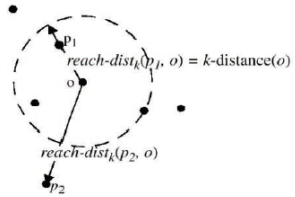
# Metody založené na hustotě

Odlehlost posuzujeme vzhledem k **lokální** hustotě dat v okolí bodu, ne vzhledem ke globálnímu středu.




- Model
  - Reachability distance
    - Introduces a smoothing factor

$$reach-dist_k(p,o) = \max\{k-\text{distance}(o), dist(p,o)\}$$




  - Local reachability distance (lrd) of point *p*
    - Inverse of the average reach-dists of the *k*NNs of *p*

$$lrd_k(p) = 1/\left(\frac{\sum_{o\in kNN(p)} reach-dist_k(p,o)}{Card(kNN(p))}\right)$$

  - Local outlier factor (LOF) of point *p*
    - Average ratio of lrds of neighbors of *p* and lrd of *p*

$$LOF_k(p) = \frac{\sum_{o\in kNN(p)} \frac{lrd_k(o)}{lrd_k(p)}}{Card(kNN(p))}$$

Bod může být blízko hustého shluku, a přesto v porovnání se svými sousedy výrazně izolovaný. Nejznámější metodou je Local Outlier Factor.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

# Local Outlier Factor (LOF)

Breunig et al. (2000). Myšlenka: porovnej **lokální hustotu bodu** s lokální hustotou jeho $K$ nejbližších sousedů.

1. $K$-dist($A$) – vzdálenost bodu $A$ k jeho $K$-tému nejbližšímu sousedovi,
2. $N_K(A)$ – množina $K$ nejbližších sousedů bodu $A$,
3. dosažitelná vzdálenost (reachability distance): $\mathrm{rd}_K(A,B) = \max\{K\text{-dist}(B),\ d(A,B)\}$,
4. lokální dosažitelná hustota: $\mathrm{lrd}_K(A) = \left(\frac{1}{|N_K(A)|}\sum_{B\in N_K(A)} \mathrm{rd}_K(A,B)\right)^{-1}$,
5. $\mathrm{LOF}_K(A) = \dfrac{1}{|N_K(A)|}\displaystyle\sum_{B\in N_K(A)} \dfrac{\mathrm{lrd}_K(B)}{\mathrm{lrd}_K(A)}$.

## Interpretace

$\mathrm{LOF} \approx 1 \rightarrow$ stejná hustota jako okolí; $\mathrm{LOF} \gg 1 \rightarrow$ bod je řidší než sousedé $\rightarrow$ lokálně odlehlý.

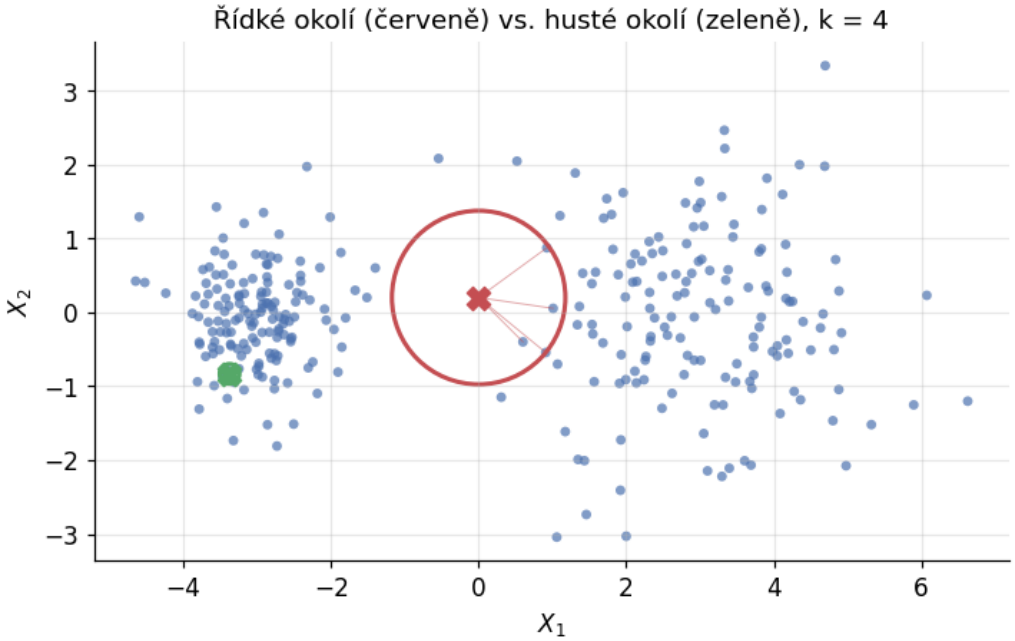
Počet sousedů značíme $K$, abychom jej odlišili od dimenze dat $k$.

# Řídké vs. husté okolí

```
from sklearn.neighbors import (
    NearestNeighbors,
        LocalOutlierFactor)

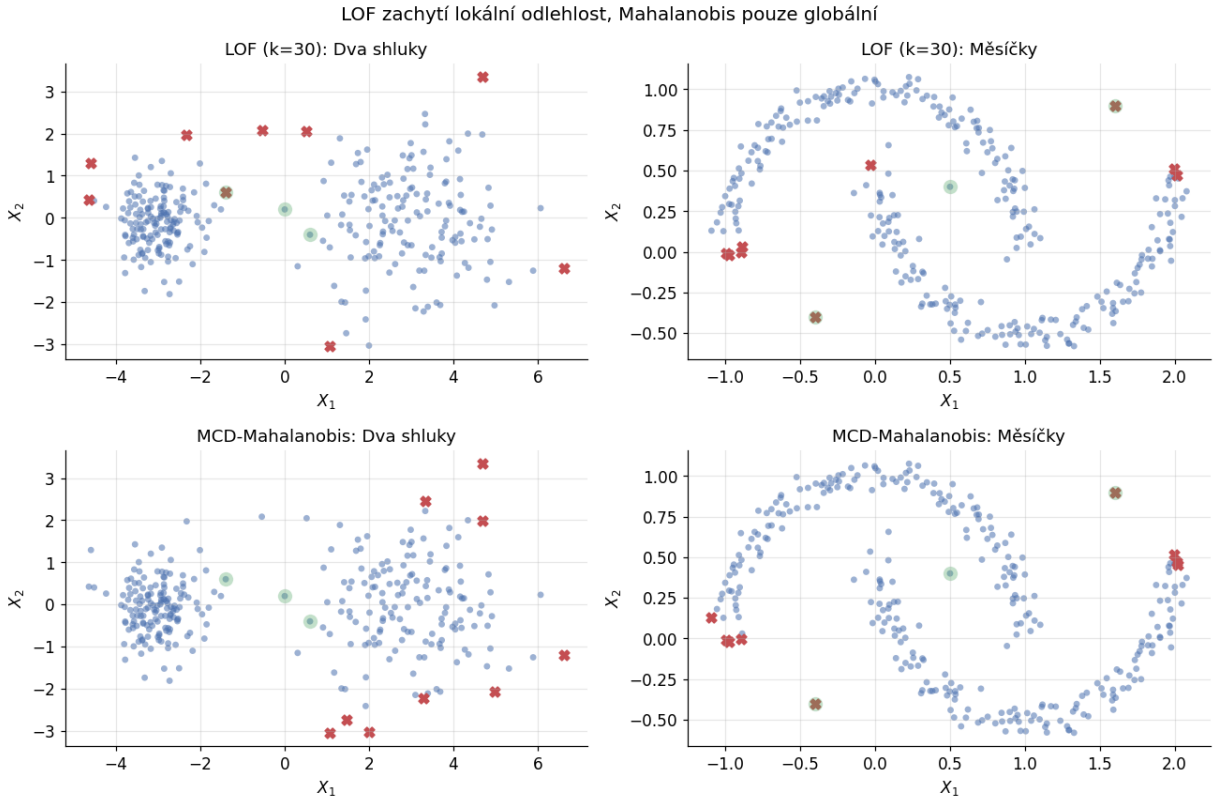
K = 4
nn = NearestNeighbors(
    n_neighbors=K + 1       # +1:
         bod sam
).fit(X_2c)
dist, idx = nn.kneighbors(X_2c)
k_dist = dist[:, K]         # K-
    dist

lof = LocalOutlierFactor(
    n_neighbors=K)
lof.fit_predict(X_2c)
score = -lof.
    negative_outlier_factor_
```

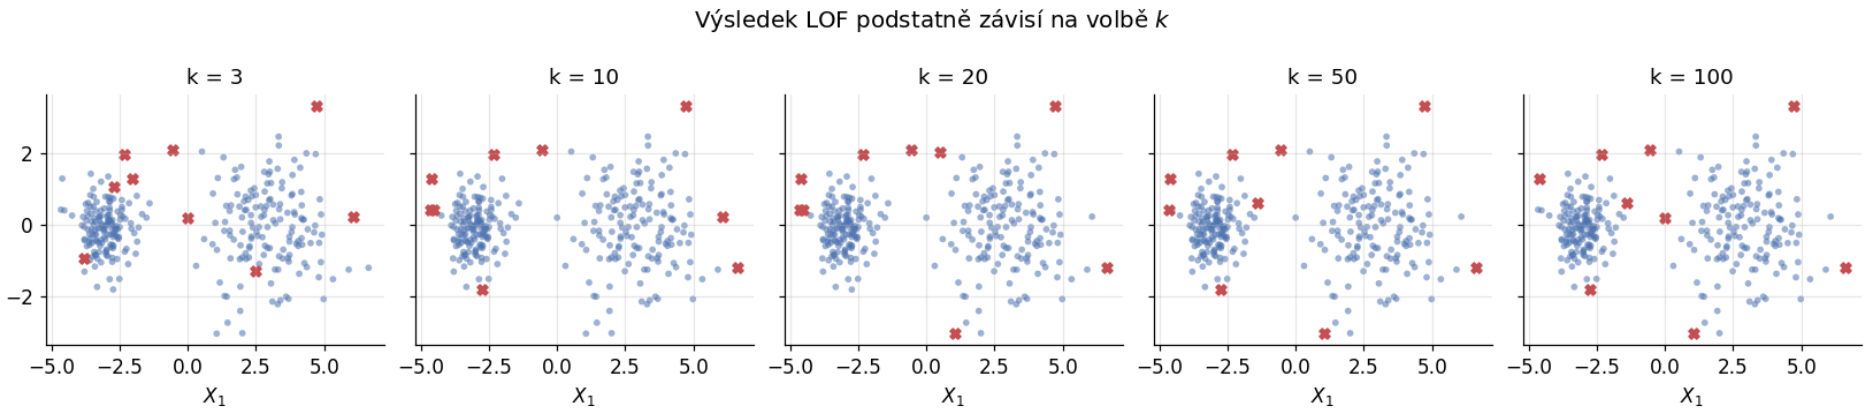



FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# LOF zachytí lokální odlehlost, Mahalanobis pouze globální



# Citlivost LOF na volbu *K*



# Isolation Forest

Liu, Ting, Zhou (2008). Odlehlé body jsou „few and different“ – dají se izolovat od zbytku dat velmi rychle náhodným dělením prostoru.

$$s(\boldsymbol{x}, \psi) = 2^{-\mathbb{E}[h(\boldsymbol{x})]/c(\psi)}, \qquad c(\psi) = 2H(\psi - 1) - \frac{2(\psi - 1)}{\psi},$$

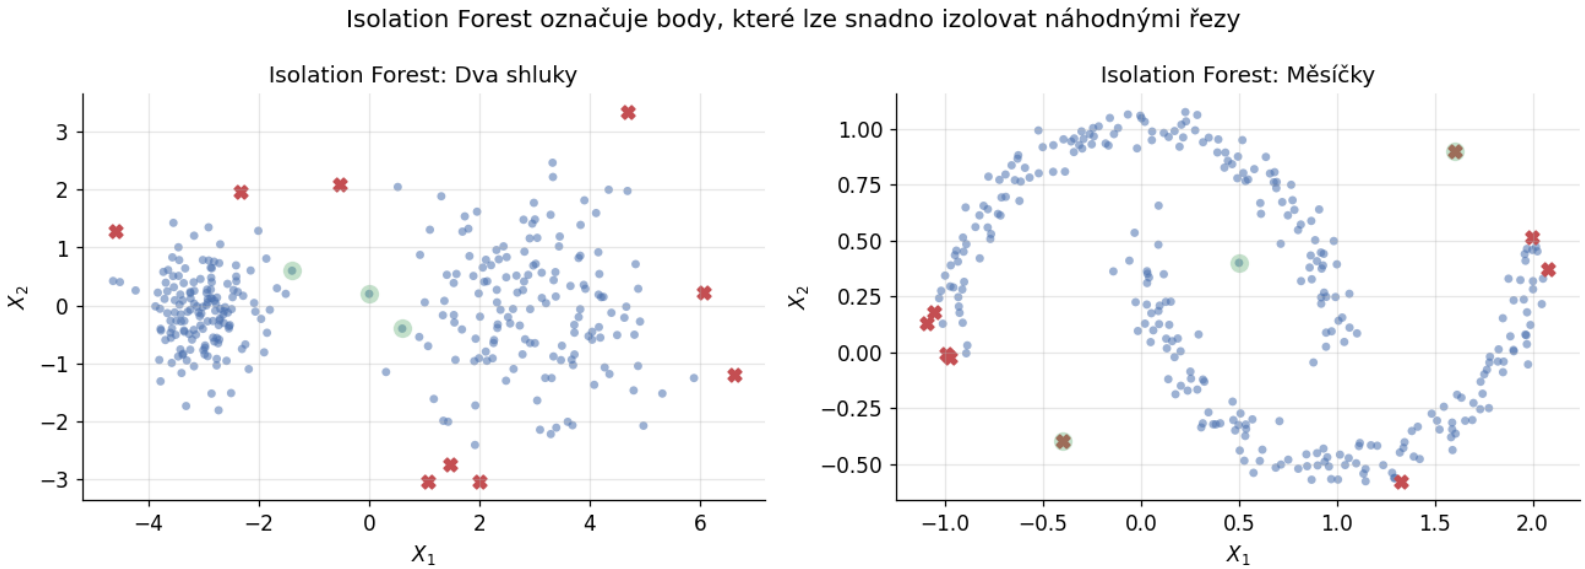
kde $h(\boldsymbol{x})$ je délka cesty k listu, $\psi$ velikost podvýběru pro jeden strom a $H(i) \approx \ln i + 0{,}5772$ harmonické číslo.

- $s \to 1 \to$ bod izolován velmi mělko $\to$ odlehlý; $s \approx 0{,}5$ a méně $\to$ typický bod.
- Stromy se stavějí z malých podvýběrů (typicky $\psi = 256$), výpočet je proto lineární v $n$ a málo závislý na počtu proměnných.
- Citlivé na náhodnost a na osové (axis-parallel) řezy.

```
from sklearn.ensemble import IsolationForest
iso = IsolationForest(n_estimators=300, random_state=0)
score = -iso.fit(Xd).score_samples(Xd)   # vetsi = odlehlejsi
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

# Isolation Forest – ukázka



# One-Class SVM

Schölkopf et al. (2001). Najdi v prostoru příznaků nejmenší možnou oblast, která obsahuje většinu dat – vše mimo ni je odlehlé.

$$\min_{w,\xi,\rho} \ \frac{1}{2}\|w\|^2 + \frac{1}{\nu n}\sum_i \xi_i - \rho \quad \text{za podmínek } \langle w, \phi(\boldsymbol{x}_i)\rangle \geq \rho - \xi_i, \ \xi_i \geq 0$$

- $\nu \in (0, 1]$ je horní mez podílu odlehlých bodů v trénovacích datech.
- Jádro (RBF), parametr $\gamma$: malé $\gamma \to$ hladká hranice, velké $\gamma \to$ členitá hranice (riziko přeučení).
- Vyžaduje standardizaci vstupních dat (`StandardScaler`).

```
from sklearn.svm import OneClassSVM
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

oc = make_pipeline(StandardScaler(),
                   OneClassSVM(kernel="rbf", nu=0.05, gamma="scale"))
pred = oc.fit_predict(X)              # -1 = odlehly, +1 = bezny
score = -oc.decision_function(X)      # vetsi = odlehlejsi
```

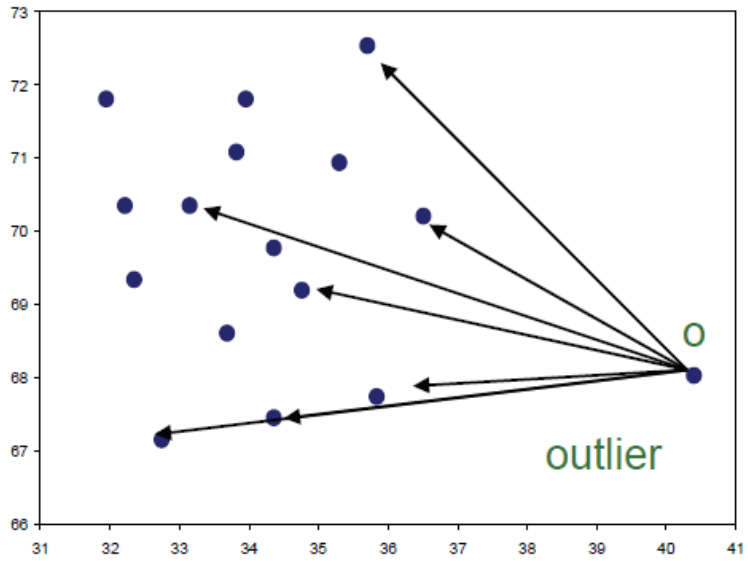
FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

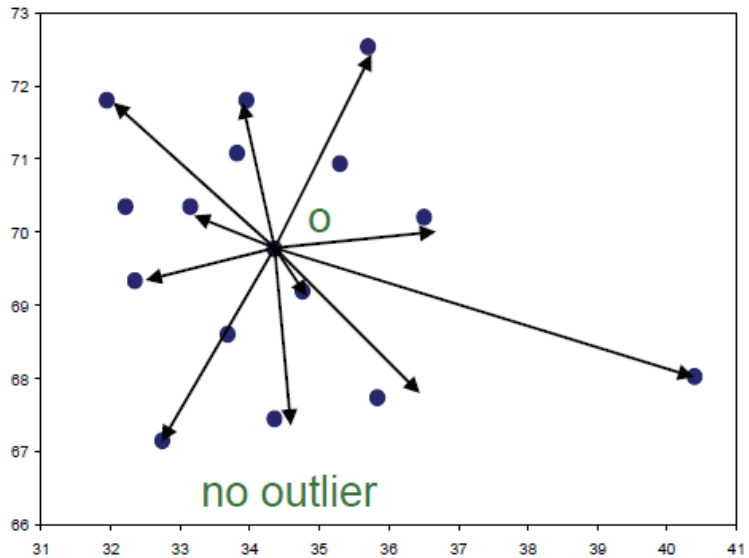
# Metody založené na hloubce dat a na odlišnosti

- **Hloubka dat** (depth based approaches)
  - vytvoříme konvexní obal dat, body ležící na jeho hranici mají hloubku 1,
  - odstraníme je a vytvoříme nový konvexní obal (body na něm mají hloubku 2), ...
  - za odlehlé považujeme body s malou hloubkou; vícerozměrný boxplot a bagplot (P04) jsou založené na stejné myšlence,
  - výpočetně náročné, prakticky jen pro $k = 2, 3$.
- **Odlišnost** (vliv vyřazení pozorování)
  - počítáme charakteristiky (průměry, směrodatné odchylky, mediány, ...) pro data BEZ vybraných pozorování a porovnáváme je s charakteristikami ze všech dat,
  - odlehlá pozorování ve smyslu korelací a regresních vztahů (vlivná pozorování, Cookova vzdálenost),
  - princip křížové validace (cross-validation).

# Metody založené na shlukování a na úhlech

- **Shlukování**: odlehlé jsou body, které nepatří do žádného shluku nebo tvoří velmi malé shluky (např. šumové body metody DBSCAN).
- **Úhlové metody** (ABOD, Angle-Based Outlier Detection, Kriegel et al. 2008): pokud je bod odlehlý, ostatní body leží přibližně „stejným“ směrem a rozptyl úhlů ke dvojicím ostatních bodů je malý. Pro bod uvnitř dat je rozptyl úhlů velký. Úhly jsou méně citlivé na prokletí dimenzionality než vzdálenosti.



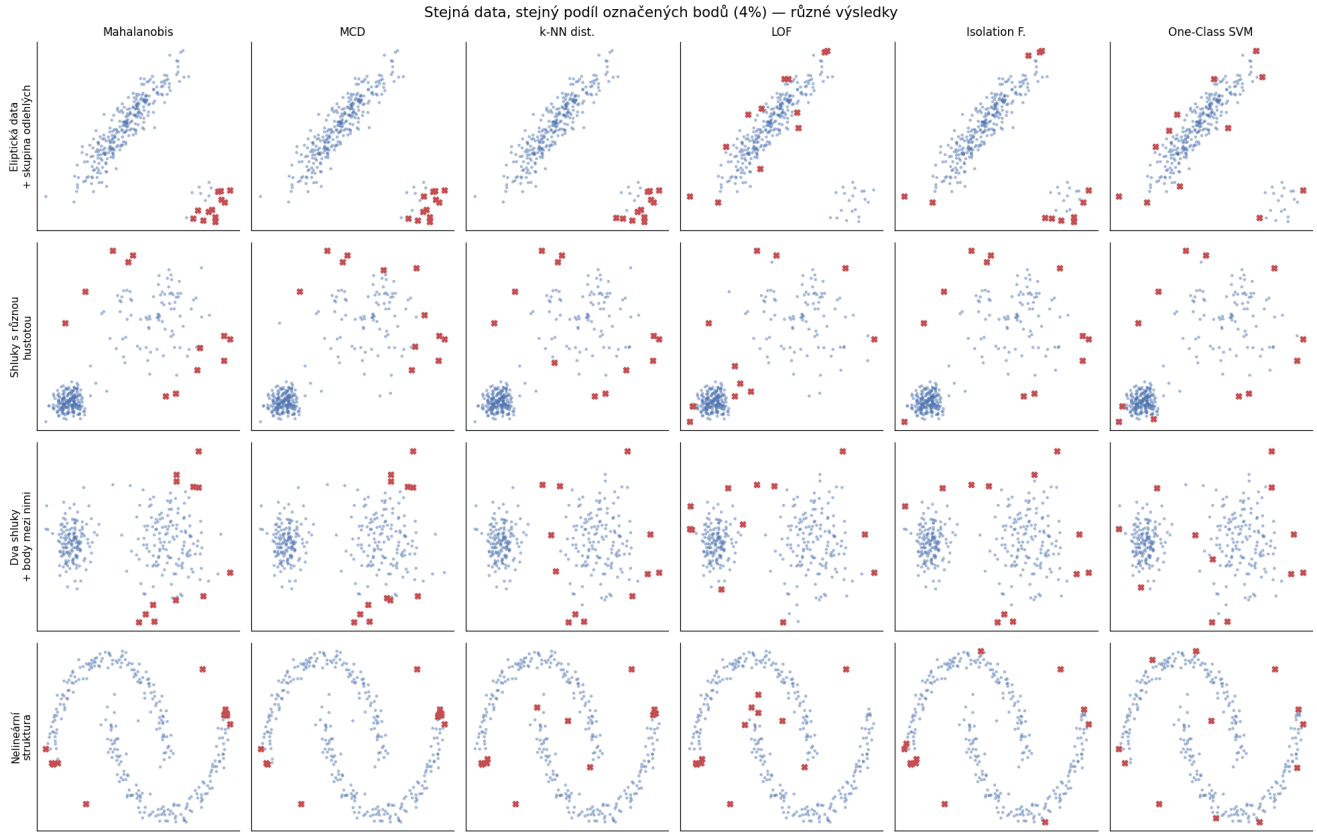



# Přehled metod pro vícerozměrná data

| **Metoda** | **Princip** | **Předpoklad / parametr** |
|---|---|---|
| Mahalanobis (klasický) | vzdálenost od průměru vážená $\boldsymbol{\Sigma}^{-1}$ | eliptické rozdělení; není robustní |
| Mahalanobis (MCD) | robustní odhad $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ | eliptické rozdělení; `support_fraction` |
| $K$-NN vzdálenost | vzdálenost ke $K$-tému sousedovi | globální hustota; $K$ |
| LOF | poměr lokálních hustot | lokální hustota; $K$ |
| Isolation Forest | snadnost izolace náhodnými řezy | bez předpokladu tvaru; počet stromů |
| One-Class SVM | obálka nosiče rozdělení | jádro, $\nu$, $\gamma$ |

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

# Stejná data, stejný podíl označených bodů – různé výsledky




FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Co si odnést z přehledové mřížky

- Na eliptických datech se metody shodují – tam je volba téměř lhostejná.
- Při rozdílné hustotě shluků označí globální metody celý řidší shluk; LOF nikoli.
- U nelineárních struktur eliptické metody selhávají systematicky.
- Isolation Forest je kompromis: bez předpokladů, ale s tendencí preferovat okraje dat.

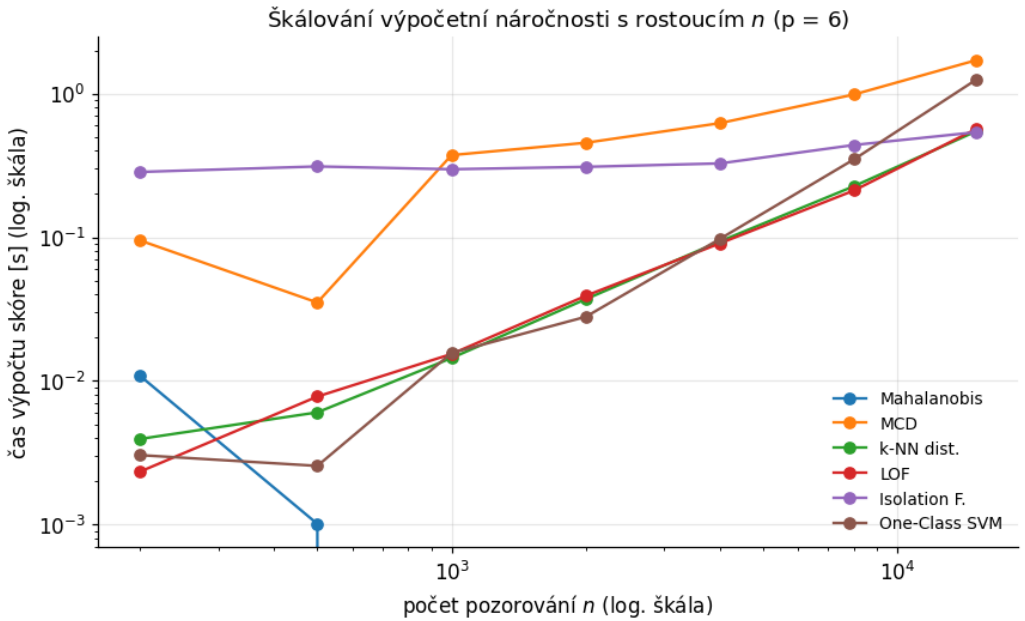
# Výpočetní náročnost metod

Volba metody není jen otázka přesnosti – u větších datových souborů hraje roli i **rychlost**. Porovnáme škálování všech šesti metod se vzrůstajícím počtem pozorování $n$.

```
n_values = [200, 500, 1000, 2000, 4000, 8000, 15000]
k_bench = 6                              # dimenze
for n_ in n_values:
    Xb = RNG.normal(size=(n_, k_bench))
    for mname, fn in METHODS.items():
        ...
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

# Škálování výpočetní náročnosti




Mahalanobis a $K$-NN/LOF škálují dobře; MCD a One-Class SVM (složitost až $O(n^2)$–$O(n^3)$) rostou s $n$ rychleji; Isolation Forest roste jen pomalu, protože stromy staví z podvýběrů pevné velikosti.

# Prokletí dimenzionality

S rostoucí dimenzí $k$ se vzdálenosti mezi body **koncentrují** – poměr vzdálenosti k nejvzdálenějšímu a k nejbližšímu bodu jde k 1. Pojem „blízkosti“ ztrácí rozlišovací schopnost a s ním i metody založené na vzdálenostech.

$$d(\boldsymbol{X}, \boldsymbol{Y})^2 = \sum_{i=1}^{k} (X_i - Y_i)^2, \qquad \mathrm{CV}(d^2) = \frac{\sqrt{\mathrm{var}\,(d^2)}}{\mathbb{E}(d^2)} \xrightarrow[k\to\infty]{} 0$$

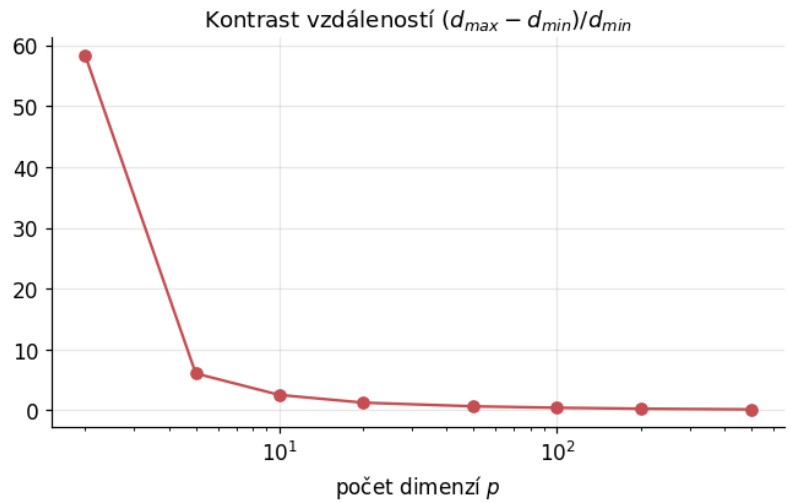
(pro nezávislé stejně rozdělené složky je $\mathrm{CV}(d^2)$ řádu $1/\sqrt{k}$).

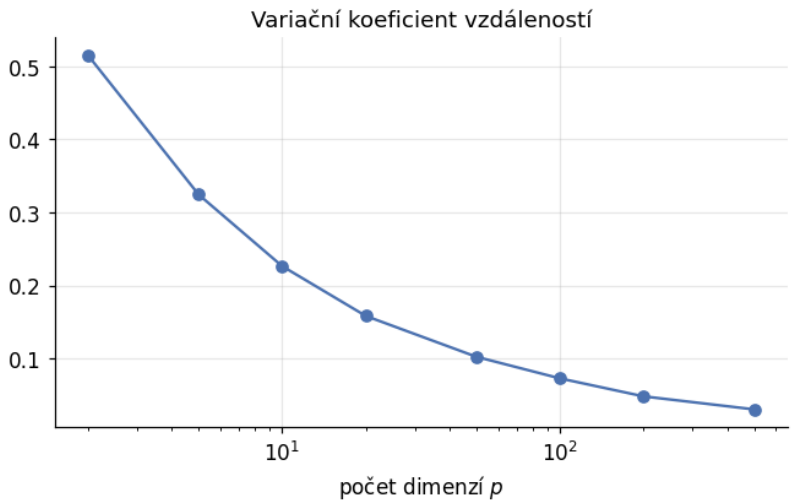
Formálně (Beyer et al., 1999)

Pokud relativní rozptyl vzdáleností jde k nule s rostoucím $k$, pak $\frac{D_{max}}{D_{min}} \xrightarrow{P} 1$.

# Kontrast vzdáleností v rostoucí dimenzi

```
dims = [2, 5, 10, 20, 50, 100, 200, 500]
n_pts = 300
for k in dims:
    Xd = RNG.normal(size=(n_pts, k))
    dist, _ = NearestNeighbors(n_neighbors=n_pts).fit(Xd).kneighbors(Xd
        )
    ...
```




FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Reálná data

Doposud jsme metody srovnávali na simulovaných datech, kde jsme znali „pravdu“ o tom, co je a co není odlehlé. V praxi to tak často nebývá. Ukážeme obě situace:

- data **bez ground truth** (`wine`): metody lze srovnat jen mezi sebou (shoda/konsensus),
- data **s ground truth** (mamografie): můžeme spočítat, která metoda je skutečně blíž pravdě.

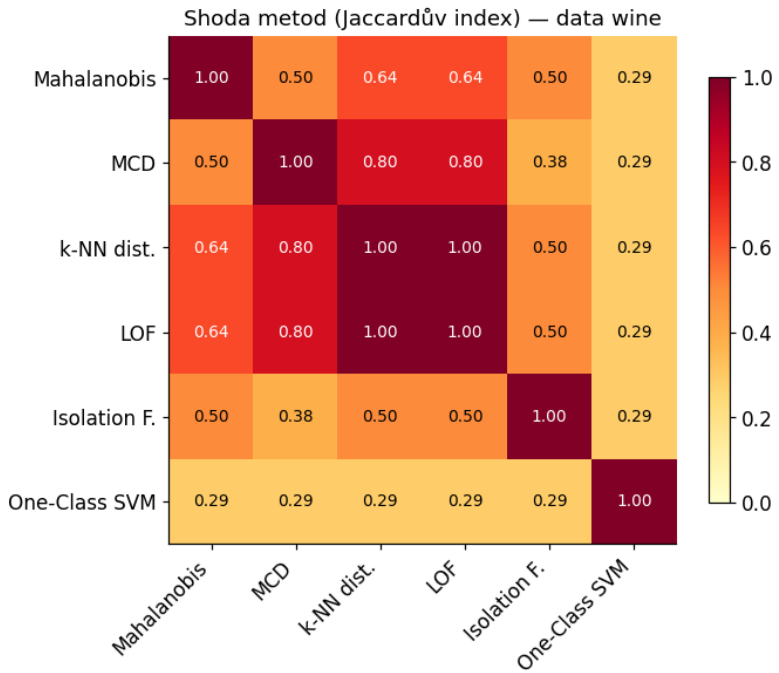
# Bez ground truth: `wine` (178 vzorků, 13 proměnných)

Dataset **Wine Recognition** z UCI Machine Learning Repository, načtený přes `sklearn.datasets.load_wine`. Nevíme, co je „skutečně“ odlehlé – sledujeme jen, **nakolik se metody shodují**.

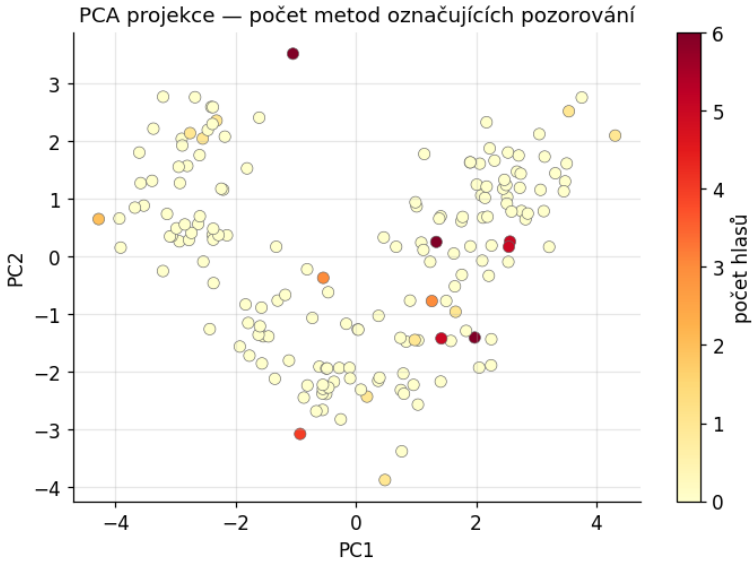
```
wine = load_wine()
Xw = StandardScaler().fit_transform(wine.data)
CONTAM_W = 0.05                          # oznacime 5 % bodu s nejvyssim
    skore
res_w = {name: flag_top(fn(Xw), CONTAM_W) for name, ...}
```

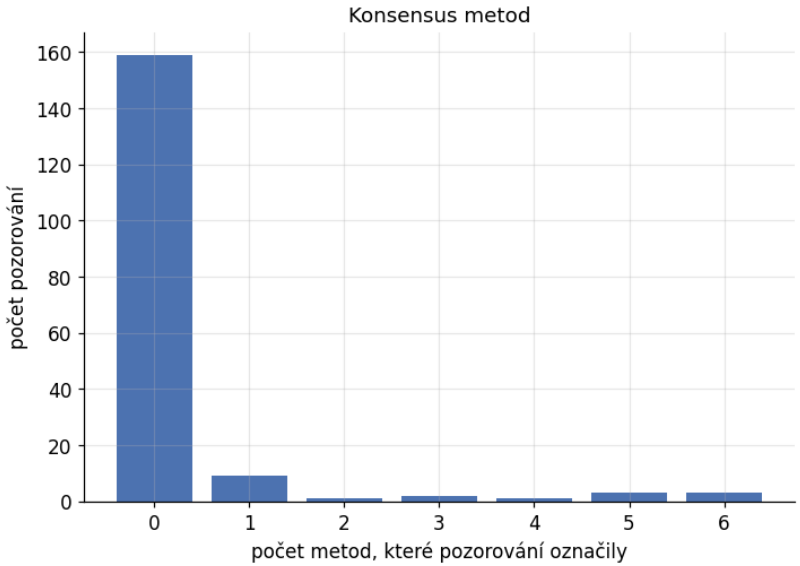
Shodu dvou metod měříme Jaccardovým indexem $J(A, B) = \frac{|A \cap B|}{|A \cup B|}$, kde $A$, $B$ jsou množiny označených bodů.

# Shoda metod – Jaccardův index (wine)



# Konsensus metod – PCA projekce (wine)



# Praktické doporučení (bez ground truth)

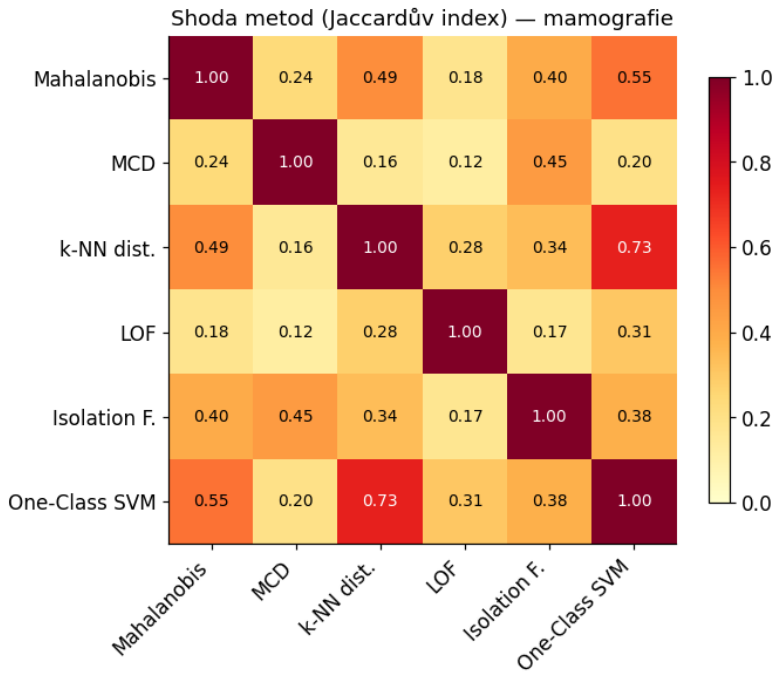
Místo hledání „té správné“ metody se vyplatí sledovat **konsensus**. Pozorování označená většinou metod jsou robustní kandidáti; body označené jen jednou metodou vypovídají spíše o vlastnostech metody než o datech.

# S ground truth: mamografie – detekce mikrokalcifikací

Dataset **Mammography** z katalogu ODDS (Woods et al. 1993, Rayana 2016). 11 183 objektů, 6 obrazových příznaků. 260 objektů (2,32 %) je radiologicky potvrzeno jako mikrokalcifikace.

```
mammo = pd.read_csv('mammography.csv')
y_true = mammo['odlehly'].values
Xm = mammo.drop(columns='odlehly').values
...
```

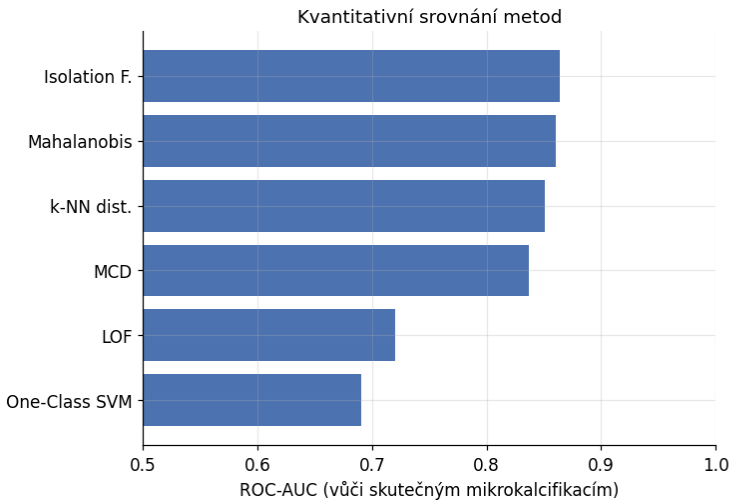
# Shoda metod – Jaccardův index (mamografie)

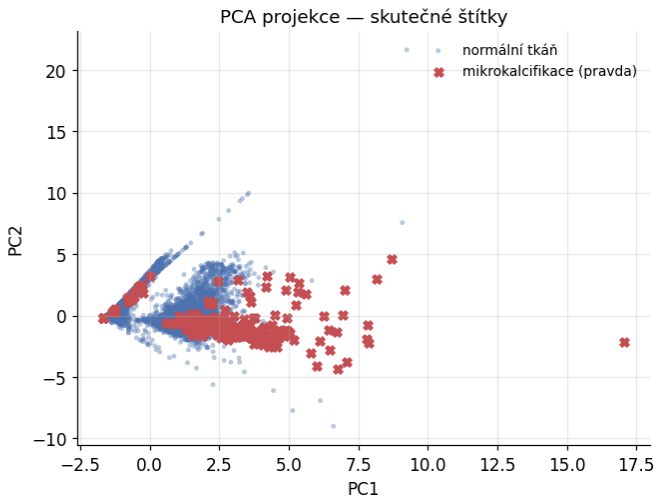



FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Kvantitativní srovnání (ROC-AUC)

```
from sklearn.metrics import roc_auc_score
for name, s in scores_m.items():
    auc = roc_auc_score(y_true, s)    # s: vetsi skore = odlehlejsi
    ...
```




FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Praktické doporučení a shrnutí – reálná data

- Na mamografických datech mají **globální** metody (Mahalanobis, Isolation Forest, $K$-NN) vyšší ROC-AUC než LOF a One-Class SVM.
- Pěkný protipól k předchozím ukázkám, kde naopak LOF vítězilo nad Mahalanobisem.
- **Žádná metoda není univerzálně nejlepší** – výsledek závisí na charakteru konkrétních dat.
- Bez ground truth (wine) lze posoudit jen shodu metod mezi sebou; s ground truth (mamografie) lze přímo změřit, která metoda je blíž pravdě.

# Shrnutí

| **Metoda** | **Typ pohledu** | **Silné stránky** | **Omezení** |
|---|---|---|---|
| Mahalanobis | globální, eliptická | interpretovatelná mez $\chi^2$, rychlý | není robustní, selže u shluků |
| MCD-Mahalanobis | globální, eliptická | robustní, statisticky podložený | vyžaduje $n \gg k$ |
| $K$-NN vzdálenost | globální hustota | bez předpokladů tvaru | citlivý na měřítko |
| LOF | lokální hustota | zachytí lokální odlehlost | citlivý na $K$ a měřítko |
| Isolation Forest | izolovatelnost | škáluje do vyšších dimenzí | osové řezy |
| One-Class SVM | nosič rozdělení | flexibilní hranice | citlivý na $\nu, \gamma$ |

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

# Závěry

1. **Vícerozměrná odlehlost není součtem jednorozměrných.**
2. **Mahalanobisova vzdálenost** – dobrá první volba, ale jen v robustní variantě (MCD).
3. **LOF** odhalí lokálně odlehlá pozorování; cenou je volba $K$.
4. **S rostoucí dimenzí** slábne kontrast vzdáleností – nutná redukce dimenze či regularizace.
5. **Neexistuje univerzálně nejlepší metoda.**
6. V praxi se osvědčuje **kombinace metod a sledování konsensu**.
7. **Máte-li ground truth**, vždy validujte kvantitativně.

# Testy vícerozměrné normality

- Mardiův test (vícerozměrná šikmost a špičatost)
- Vícerozměrný $\chi^2$-test dobré shody
- Další testy: Henze-Zirklerův, Roystonův, Q-Q graf Mahalanobisových vzdáleností (P04)

Metody založené na Mahalanobisově vzdálenosti s mezí $\chi^2_k(1-\alpha)$ předpokládají, že „běžná“ data mají přibližně vícerozměrné normální rozdělení. Testy normality jsou ale samy citlivé na odlehlé hodnoty – jediný odlehlý bod může vést k zamítnutí normality.

# Testy normality pro vícerozměrná normální rozdělení

## Testy založené na momentech – Mardiův test

Označme $m_{ij} = (\boldsymbol{x}_i - \overline{\boldsymbol{x}})^T S_0^{-1} (\boldsymbol{x}_j - \overline{\boldsymbol{x}})$, kde $S_0$ je výběrová varianční matice s dělitelem $n$ (P04). Pak $m_{ii} = d_i^2$ jsou Mahalanobisovy vzdálenosti.

- $b_{1,k} = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} m_{ij}^3$ nazýváme **vícerozměrnou šikmostí**.
- Za předpokladu normálního rozdělení vektoru $\boldsymbol{X}$ asymptoticky pro $n \to \infty$ platí

$$\frac{n \cdot b_{1,k}}{6} \sim \chi^2_\nu \text{ se stupni volnosti } \nu = \frac{k \cdot (k+1) \cdot (k+2)}{6}.$$

- **Vícerozměrná špičatost** $b_{2,k} = \frac{1}{n} \sum_{i=1}^{n} m_{ii}^2$.
- Za předpokladu normálního rozdělení vektoru $\boldsymbol{X}$ je $\mathbb{E} b_{2,k} \approx k(k+2)$ a asymptoticky

$$\sqrt{n} \, \frac{b_{2,k} - k \cdot (k+2)}{\sqrt{8 \cdot k \cdot (k+2)}} \sim N(0,1).$$

- Pro $k = 1$ jde o kvadrát výběrové šikmosti a o výběrovou špičatost.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

# Mardiův test v Pythonu

```
import numpy as np
from scipy import stats

def mardia(X):
    n, k = X.shape
    D = X - X.mean(axis=0)
    S0 = D.T @ D / n                          # odhad s delitelem n
    M = D @ np.linalg.inv(S0) @ D.T           # matice m_ij
    b1 = (M**3).sum() / n**2                  # vicerozmerna sikmost
    b2 = (np.diag(M)**2).mean()               # vicerozmerna spicatost
    A = n * b1 / 6
    df = k * (k + 1) * (k + 2) / 6
    B = (b2 - k * (k + 2)) / np.sqrt(8 * k * (k + 2) / n)
    p_skew = stats.chi2.sf(A, df)
    p_kurt = 2 * stats.norm.sf(abs(B))
    return b1, b2, p_skew, p_kurt

rng = np.random.default_rng(0)
print(mardia(rng.multivariate_normal(np.zeros(3), np.eye(3), 500)))
print(mardia(rng.exponential(size=(500, 3))))   # zamitne normalitu
```

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Henze-Zirklerův test: `pingouin.multivariate_normality(X)`.

# Testy normality pro vícerozměrná normální rozdělení

## Vícerozměrný $\chi^2$-test dobré shody

Rozdělíme definiční obor $\mathbb{R}^k$ na jednotlivé sektory (buňky) $\Omega_g$, $g = 1, \ldots, G$. Spočteme pravděpodobnosti v těchto sektorech podle vztahu $p_g = \int_{\Omega_g} f(\boldsymbol{x})\, \mathrm{d}\boldsymbol{x}$ a očekávané počty hodnot podle vztahu $o_g = p_g \cdot n$. Pak statistika

$$\chi^2 = \sum_{g=1}^{G} \frac{(n_g - o_g)^2}{o_g},$$

kde $n_g$ je skutečný počet hodnot v sektoru $\Omega_g$, má asymptoticky $\chi^2$ rozdělení se stupni volnosti

$$\nu = \left( \prod_{e=1}^{k} c_e \right) - 1 - 2 \cdot k - k_{cov},$$

kde $c_e$ je počet intervalů $e$-té proměnné (tedy $G = \prod c_e$) a $k_{cov}$ je počet odhadnutých kovariancí, obvykle $k_{cov} = \binom{k}{2}$ (odhadujeme $k$ středních hodnot, $k$ rozptylů a $\binom{k}{2}$ kovariancí).

Test vyžaduje dostatečný počet dat, očekávané počty by měly splňovat $o_g \geq 5$; s rostoucí dimenzí proto rychle ztrácí použitelnost.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI