Přednáška 5: Odlehlá pozorování

Jednorozměrné a vícerozměrné metody, Mahalanobis, LOF a další

KMA/MSM Blanka Šedivá

verze 2026/2027

8. října 2026

Obsah

1. Odlehlá pozorování
2. Jednorozměrná data
   - Parametrické metody
   - Robustní a neparametrické metody
3. Vícerozměrná data
   - Motivace
   - Mahalanobisova vzdálenost
   - Kdy Mahalanobis selhává
   - Metody založené na vzdálenosti a hustotě, LOF
   - Další přístupy
   - Srovnání metod
   - Prokletí dimenzionality
   - Reálná data
   - Shrnutí
4. Testy vícerozměrné normality

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Odlehlá pozorování – outliers

- Odlehlá pozorování – definice a problémy identifikace
- Identifikace odlehlých pozorování v jednorozměrných datech
- Identifikace odlehlých pozorování ve vícerozměrných datech
- Testy vícerozměrné normality

Odlehlá pozorování – outliers

- „An outlier is an observation which deviates so much from the other observations as to arouse suspicions that it was generated by a different mechanism“ (Hawkins, 1980).
- „An observation (or subset of observations) which appears to be inconsistent with the remainder of that set of data“ (Barnett, Lewis, 1978).
- Normální (běžná) data jsou výsledkem jednotného mechanismu (jsou generována podle jednotného modelu) $\times$ abnormální data jsou generována jiným mechanismem.
- Příklady aplikací
  - identifikace abnormálního chování (platby kartou, výsledky vyšetření pacienta, . . .),
  - identifikace chyb v záznamech, měřeních, . . .
  - identifikace anomálií, potenciálních příležitostí, . . .

Problémy identifikace

- data mají obvykle vícerozměrný charakter, modely jsou často jednorozměrné;
- data mohou být generována více než jedním obecným modelem;
- abnormality mohou být generovány více než jedním typem mechanismu;
- předpokládáme, že abnormality jsou méně četné.

Podle dat, která máme k dispozici, lze rozlišovat metody

- supervised – máme k dispozici označená data normálního i abnormálního typu;
- semi-supervised – máme k dispozici pouze data normálního typu;
- unsupervised – nemáme informaci o tom, která data jsou odlehlá.

Klasifikace metod identifikace outlierů podle předpokladu o základním modelu dat

- metody založené na konkrétním pravděpodobnostním modelu
  předpoklad: je k dispozici model pro „běžná“ data;
  outliers: jsou data, která jsou v rámci modelu málo pravděpodobná
  - metody využívající pravděpodobnostní testy
  - metody využívající „hloubku“ dat
  - metody využívající „odlišnost“ dat
- metody založené na „prostorové“ blízkosti
  předpoklad: zkoumáme „prostorové“ vzdálenosti dat
  outliers: body, které mají odlišnou „prostorovou“ vzdálenost od ostatních
  - metody využívající vzdálenosti dat
  - metody využívající hustotu dat v okolí
- metody založené na „úhlové“ blízkosti
  předpoklad: zabýváme se směry spojnic mezi jednotlivými body
  outliers: body, jejichž systém směrů je odlišný od ostatních

Jednorozměrná data

- Parametrické metody (předpoklad normality): Z-skóre, Chauvenetovo kritérium, Grubbsův, Dixonův a GESD test
- Robustní a neparametrické metody: modifikované Z-skóre (MAD), Tukeyho pravidlo
- Robustní odhady polohy

Ukázky v Pythonu: notebook `P05a_odlehla_jednorozmerna.ipynb`.

Jednorozměrné metody – parametrické (normální rozdělení)

- Z-skóre $z_i = \frac{x_i - \overline{x}}{s}$, pravidlo 3 sigma: za odlehlé považujeme $x_i \notin (\overline{x} \pm 3s)$.
- Chauvenetovo kritérium: x_i vyřadíme, pokud $n \cdot \mathcal{P}(|Z| > |z_i|) < 0{,}5$
  https://en.wikipedia.org/wiki/Chauvenet's_criterion
- Grubbsův test (jedno odlehlé pozorování) $G = \frac{\max_i |x_i - \overline{x}|}{s}$, kritická hodnota

$$G > \frac{n-1}{\sqrt{n}} \sqrt{\frac{t^2_{\alpha/(2n),\, n-2}}{n-2+t^2_{\alpha/(2n),\, n-2}}},$$

  kde $t_{\alpha/(2n),\, n-2}$ je horní kritická hodnota t-rozdělení.
  https://en.wikipedia.org/wiki/Grubbs's_test_for_outliers
- Dixonův test $Q = \frac{|x_{(2)} - x_{(1)}|}{|x_{(n)} - x_{(1)}|}$, resp. $Q = \frac{|x_{(n)} - x_{(n-1)}|}{|x_{(n)} - x_{(1)}|}$ (malé výběry, speciální tabulka kritických hodnot).
- Tietjen-Mooreův test (předem daný počet odlehlých hodnot), GESD – Generalized Extreme Studentized Deviate test (Rosnerův test, neznámý počet odlehlých hodnot), Peirceovo kritérium. https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h.htm

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Jednorozměrné metody – robustní a neparametrické

- Modifikované Z-skóre (Iglewicz, Hoaglin) $z_i = \frac{0{,}6745\,(x_i - \text{median}(x))}{MAD}$, kde $MAD = \text{median}(|x_i - \text{median}(x)|)$; za odlehlé se obvykle považují $|z_i| > 3{,}5$ (protože pro normální data $MAD \to 0{,}6745\,\sigma$).
- Kvartilové pravidlo (Tukeyho pravidlo, tzv. *fences*): za odlehlé považujeme $x_i \notin (x_{25\%} - 1{,}5\,IQR,\ x_{75\%} + 1{,}5\,IQR)$, kde $IQR = x_{75\%} - x_{25\%}$ (hranice v boxplotu).
- Walshův test (neparametrický, pro velké výběry) `https://vsp.pnnl.gov/help/vsample/Walshs_Outlier_Test.htm`
- Robustní odhady polohy, které odlehlé hodnoty jen tlumí: medián, useknutý průměr (trimmed mean), Tukeyho trimean $\frac{Q_{25\%} + 2Q_{50\%} + Q_{75\%}}{4}$.

Funkce v MATLAB:
isoutlier (method: median, mean, quartiles, grubbs, gesd),
filloutliers (method: center, clip, previous, next, nearest, linear, spline, pchip)

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Jednorozměrné metody v Pythonu

```
import numpy as np
from scipy import stats

rng = np.random.default_rng(1)
x = np.append(rng.normal(10, 1, 30), 14.5)        # 1 podezrely bod
n = len(x)

z = (x - x.mean()) / x.std(ddof=1)                # Z-skore, |z| > 3
med = np.median(x)
mad = np.median(np.abs(x - med))
z_mod = 0.6745 * (x - med) / mad                  # modifikovane Z-skore
    , |z| > 3.5
q1, q3 = np.percentile(x, [25, 75])
iqr = q3 - q1
tukey = (x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)

G = np.max(np.abs(x - x.mean())) / x.std(ddof=1) # Grubbsuv test
alpha = 0.05
t = stats.t.ppf(1 - alpha / (2 * n), n - 2)
G_crit = (n - 1) / np.sqrt(n) * np.sqrt(t**2 / (n - 2 + t**2))
print(G, G_crit, G > G_crit)
```

Vícerozměrná data

- Motivace – proč nestačí dívat se na proměnné zvlášť
- Mahalanobisova vzdálenost, maskování a robustní odhad MCD
- Metody založené na vzdálenosti a hustotě: K-NN vzdálenost, LOF
- Další přístupy: Isolation Forest, One-Class SVM, hloubka dat, shlukování, úhlové metody
- Prokletí dimenzionality, reálná data, shrnutí

Grafické nástroje viz P04 (matice bodových grafů, bagplot, Q-Q graf Mahalanobisových vzdáleností). Ukázky v Pythonu: notebook `P05b_odlehla_vicerozmerna.ipynb`.

Proč nestačí dívat se na proměnné zvlášť

- Odlehlá pozorování mohou představovat chyby měření, nestandardní procesy i zajímavé a potenciálně významné jevy.
- Zatímco v jednorozměrných datech bývá odhalení odlehlých hodnot relativně přímočaré, ve vícerozměrném prostoru se situace výrazně komplikuje.
- Pozorování může být nenápadné při pohledu na jednotlivé proměnné, ale po zohlednění jejich vzájemných vztahů se ukáže jako výrazně odlehlé.
- S rostoucí dimenzí navíc selhávají intuitivní představy i některé tradiční postupy.

Cíl této části

Neexistuje univerzálně nejlepší metoda – cílem je ukázat výhody a omezení jednotlivých vybraných přístupů a to, že volba vhodné metody závisí na charakteru dat i na cíli analýzy.

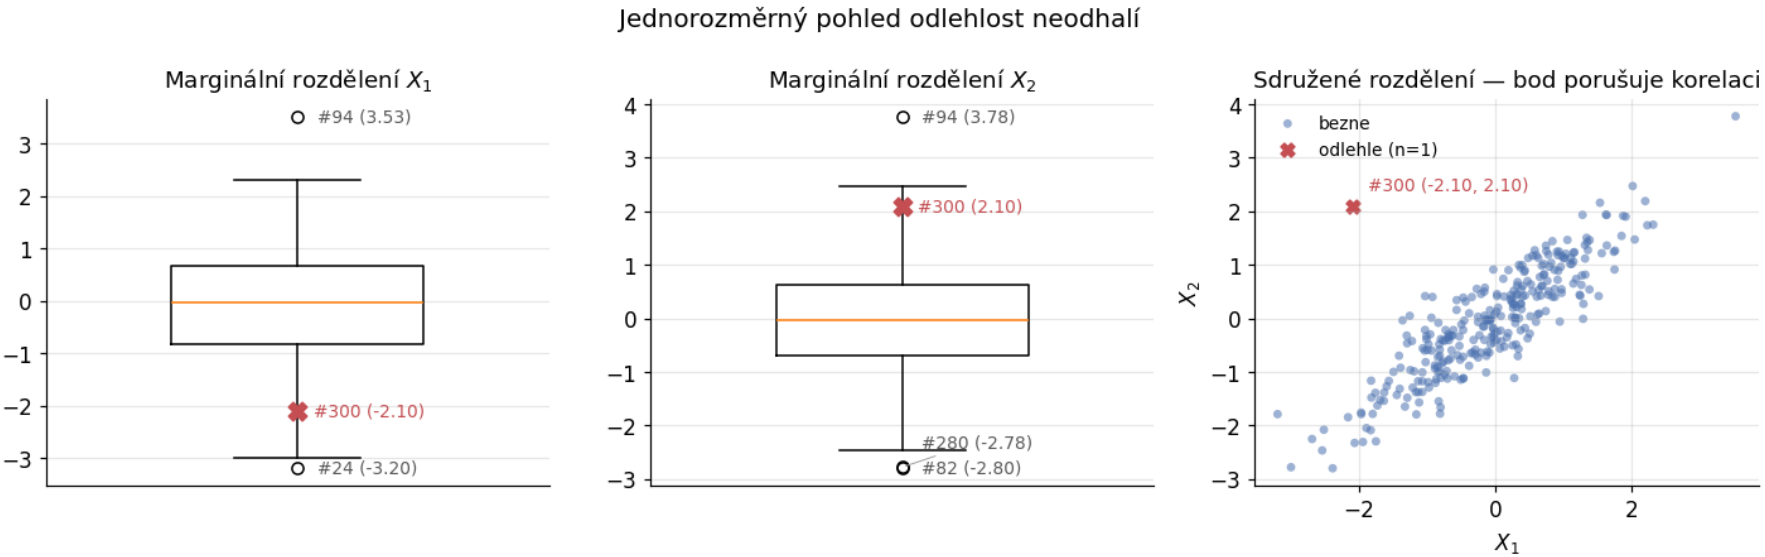
Silně korelovaná data

Bod, který porušuje **vztah** mezi proměnnými, leží v marginálních rozděleních zcela nenápadně.

```
# Simulace: 300 bodu ze silne korelovaneho 2D normalniho rozdeleni (
    korelace 0.9)
n = 300
cov_true = np.array([[1.0, 0.9], [0.9, 1.0]])
X_mot = RNG.multivariate_normal([0, 0], cov_true, n)
suspect = np.array([-2.1, 2.1])   # bod "proti" korelaci
...
```

Pro bod $(-2{,}1;\ 2{,}1)$ je $|z| = 2{,}1$ v obou proměnných, ale $d^2 = \frac{2 \cdot 2{,}1^2}{1-0{,}9} \doteq 88$, zatímco $\chi^2_2(0{,}999) \doteq 13{,}8$.

Jednorozměrný pohled odlehlost neodhalí



Mahalanobisova vzdálenost

$$d_M^2(\boldsymbol{x}) = (\boldsymbol{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})$$

- Eukleidovská vzdálenost **standardizovaná varianční maticí** – vrstevnice jsou elipsy (elipsoidy).
- Pro $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ se známými parametry platí $d_M^2 \sim \chi_k^2 \rightarrow$ přirozená mez $\chi_k^2(1-\alpha)$. Při odhadnutých $\overline{\boldsymbol{x}}$, S platí rozdělení χ_k^2 jen přibližně (přesně je to škálované rozdělení Beta, viz P04).
- Invariantní vůči regulárním lineárním transformacím (na měřítku proměnných nezáleží).

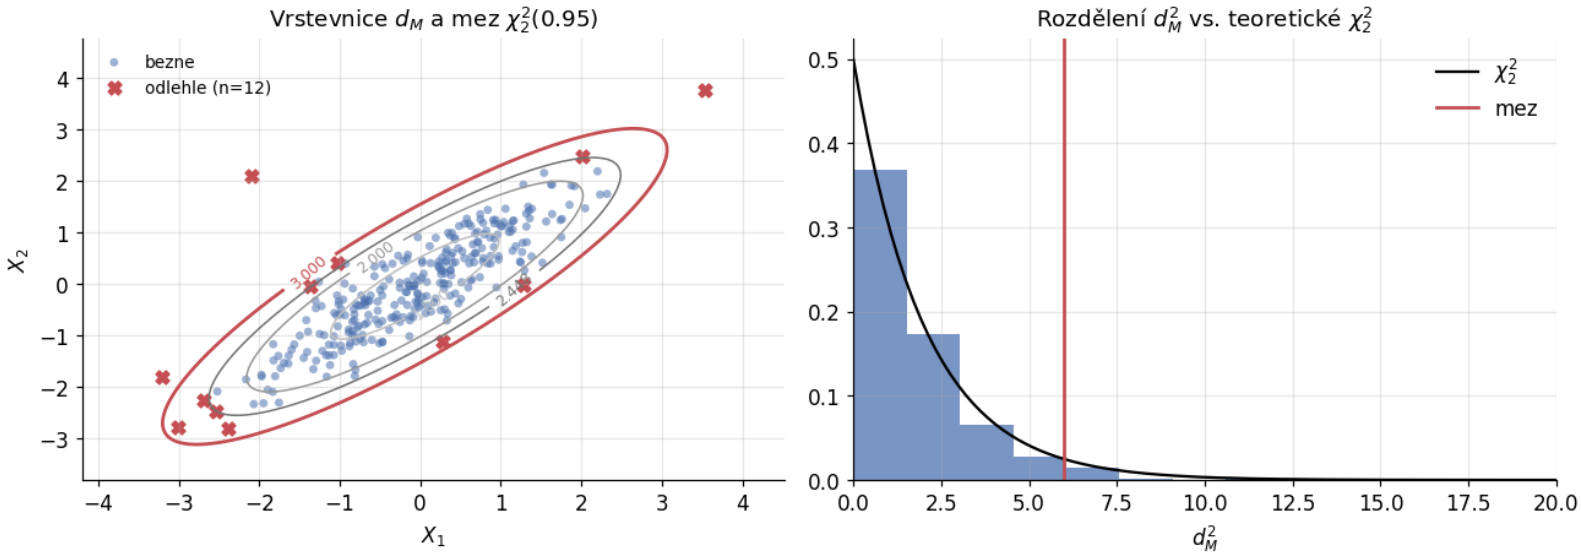
FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Mahalanobisova vzdálenost v Pythonu

```
from scipy.stats import chi2
from sklearn.covariance import EmpiricalCovariance

k = 2                                          # dimenze
alpha = 0.05
thr = chi2.ppf(1 - alpha, df=k)
emp = EmpiricalCovariance().fit(X_mot)
d2 = emp.mahalanobis(X_mot)                    # vraci ctverec vzdalenosti
flags_m = d2 > thr
```

Vrstevnice d_M a rozdělení d_M^2



Maskování (masking) a zahlcení (swamping)

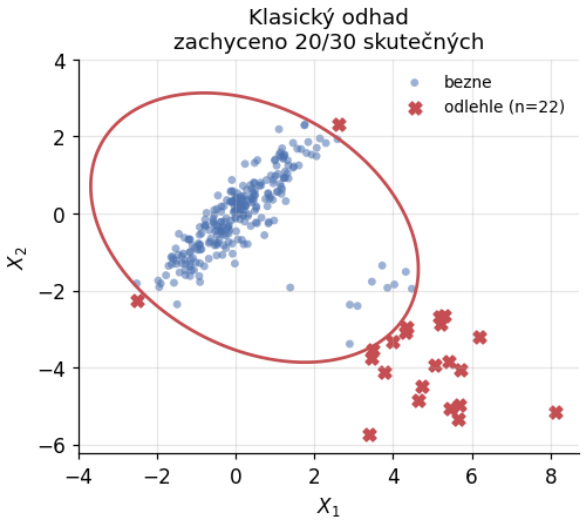
- Průměr i varianční matice se počítají **ze všech dat včetně odlehlých hodnot**.
- **Maskování:** skupina odlehlých pozorování si „natáhne“ elipsu k sobě a tím se sama zamaskuje.
- **Zahlcení:** zkreslená elipsa naopak označí jako odlehlá i regulérní pozorování.
- **Řešení:** robustní odhad polohy a rozptylu – *Minimum Covariance Determinant* (MCD), Rousseeuw (1984).

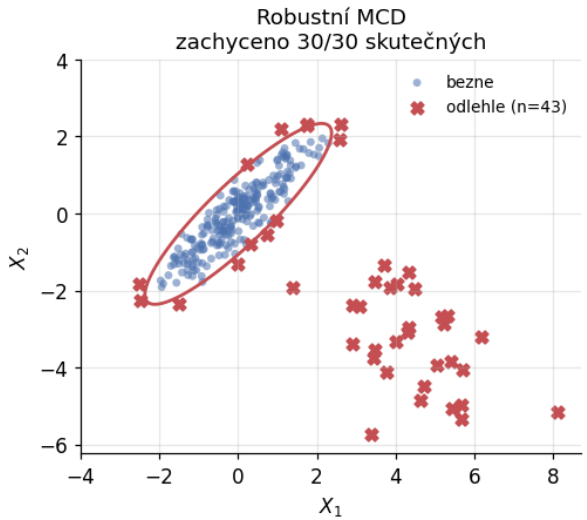
Princip MCD

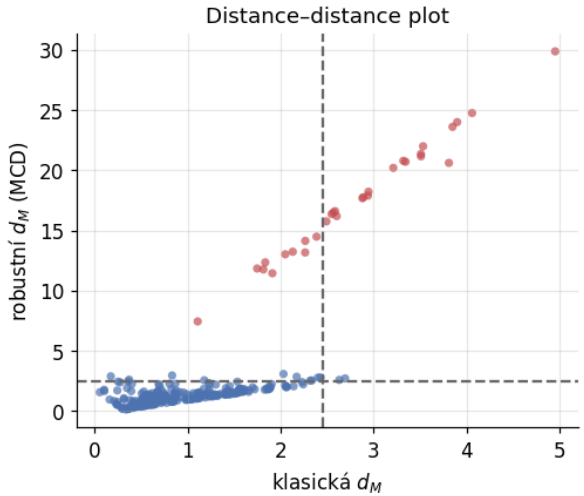
Z n pozorování hledáme podmnožinu h bodů, $\frac{n+k+1}{2} \leq h \leq n$, pro kterou má výběrová varianční matice **nejmenší determinant** – nejkompaktnější elipsoid, jaký lze z dat vybrat. Odlehlé body leží mimo toto jádro, a proto se do odhadu $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ nepromítnou.

- Výpočet: algoritmus **FastMCD** (Rousseeuw, Van Driessen, 1999) – iterativní *C-step*.
- Klasický odhad: bod zvratu (breakdown point) $1/n \to 0\,\%$. MCD s $h \approx n/2$ toleruje kontaminaci téměř 50 % dat.

Klasický vs. robustní (MCD) odhad





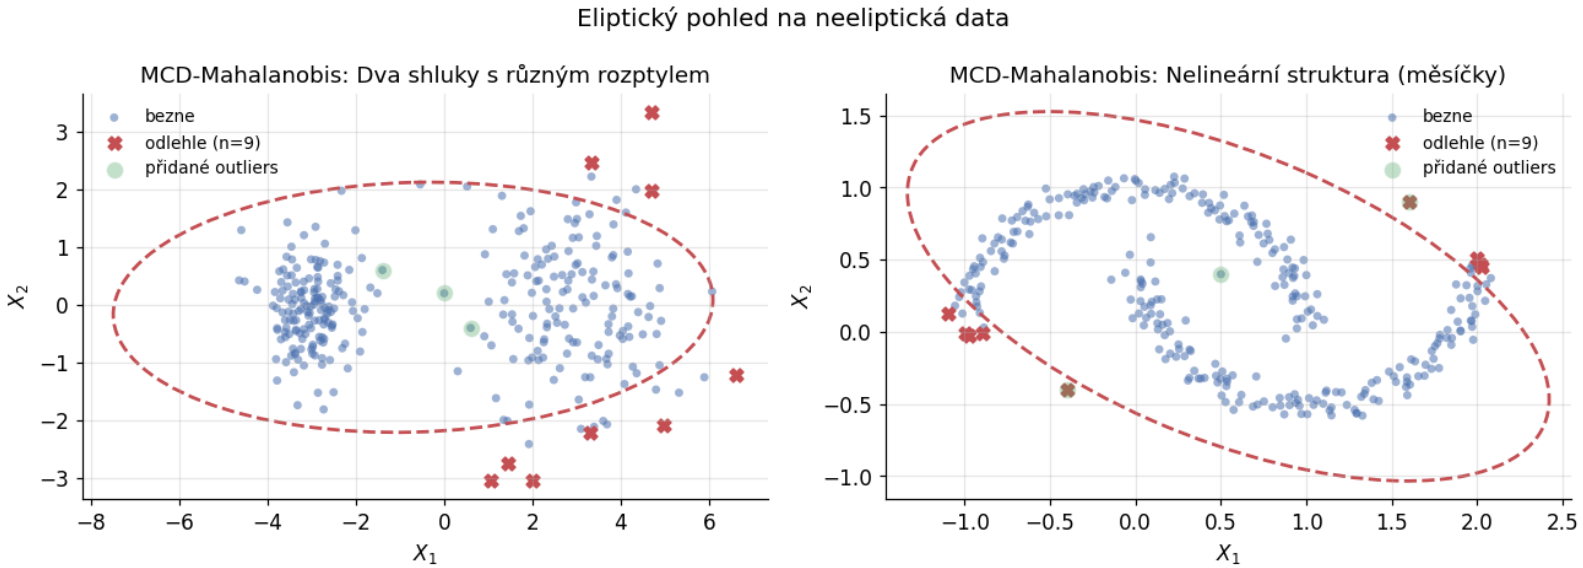


Kdy Mahalanobis selhává

Mahalanobisova vzdálenost implicitně předpokládá **jedno unimodální, přibližně eliptické rozdělení**. Pokud data tvoří více shluků nebo nelineární strukturu, je „střed dat“ často místo, kde žádná data nejsou.

```
def ds_two_clusters(rng):
    a = rng.multivariate_normal([-3, 0], 0.35 * np.eye(2), 150)
    b = rng.multivariate_normal([3, 0], 1.4 * np.eye(2), 150)
    o = np.array([[0.0, 0.2], [-1.4, 0.6], [0.6, -0.4]])
    ...
```

Eliptický pohled na neeliptická data



Co z toho plyne

- Body ležící **mezi shluky** (evidentně netypické) mají malou Mahalanobisovu vzdálenost – jsou blízko globálního průměru.
- Naopak zcela regulérní okrajová pozorování řidšího shluku jsou označena jako odlehlá.

$\rightarrow$ Potřebujeme kritérium založené na **lokální** struktuře dat.

Metody založené na vzdálenosti

- **Vzdálenostní odlehlost** (Knorr, Ng 1998): pro daný poloměr ε a podíl π je bod $\boldsymbol{x}_i$ odlehlý, pokud nejvýše π procent všech bodů má od $\boldsymbol{x}_i$ vzdálenost menší než ε.

  Možné algoritmy

  - počítáme vzdálenosti všech bodů navzájem,
  - rozdělíme data do dvou skupin a počítáme vzdálenosti jenom od druhé skupiny,
  - rozdělíme datový prostor mřížkou na buňky a vzdálenosti počítáme pouze v sousedních buňkách.

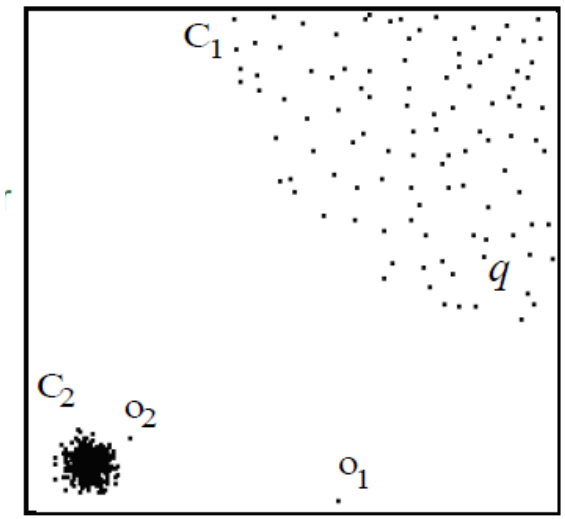
- K**-NN vzdálenost**: skóre bodu je vzdálenost k jeho K-tému nejbližšímu sousedovi (nebo průměrná vzdálenost ke K sousedům).

- Obě metody měří **globální** hustotu – jeden práh platí pro celý prostor. Pokud mají shluky různou hustotu, označí celý řidší shluk.

- Počet sousedů značíme K, abychom jej odlišili od dimenze dat k.

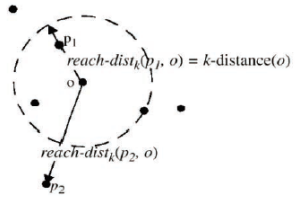
Metody založené na hustotě

Odlehlost posuzujeme vzhledem k **lokální** hustotě dat v okolí bodu, ne vzhledem ke globálnímu středu.



- Model
  - Reachability distance
    - Introduces a smoothing factor

$$reach-dist_k(p,o) = \max\{k-\text{distance}(o), dist(p,o)\}$$



  - Local reachability distance (lrd) of point *p*
    - Inverse of the average reach-dists of the *k*NNs of *p*

$$lrd_k(p) = 1/\left(\frac{\sum_{o\in kNN(p)} reach-dist_k(p,o)}{Card(kNN(p))}\right)$$

  - Local outlier factor (LOF) of point *p*
    - Average ratio of lrds of neighbors of *p* and lrd of *p*

$$LOF_k(p) = \frac{\sum_{o\in kNN(p)} \frac{lrd_k(o)}{lrd_k(p)}}{Card(kNN(p))}$$

Bod může být blízko hustého shluku, a přesto v porovnání se svými sousedy výrazně izolovaný. Nejznámější metodou je Local Outlier Factor.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Local Outlier Factor (LOF)

Breunig et al. (2000). Myšlenka: porovnej **lokální hustotu bodu** s lokální hustotou jeho K nejbližších sousedů.

1. K-dist(A) – vzdálenost bodu A k jeho K-tému nejbližšímu sousedovi,
2. $N_K(A)$ – množina K nejbližších sousedů bodu A,
3. dosažitelná vzdálenost (reachability distance): $\mathrm{rd}_K(A,B) = \max\{K\text{-dist}(B),\ d(A,B)\}$,
4. lokální dosažitelná hustota: $\mathrm{lrd}_K(A) = \left(\frac{1}{|N_K(A)|}\sum_{B\in N_K(A)} \mathrm{rd}_K(A,B)\right)^{-1}$,
5. $\mathrm{LOF}_K(A) = \dfrac{1}{|N_K(A)|}\displaystyle\sum_{B\in N_K(A)} \dfrac{\mathrm{lrd}_K(B)}{\mathrm{lrd}_K(A)}$.

Interpretace

$\mathrm{LOF} \approx 1 \rightarrow$ stejná hustota jako okolí; $\mathrm{LOF} \gg 1 \rightarrow$ bod je řidší než sousedé $\rightarrow$ lokálně odlehlý.

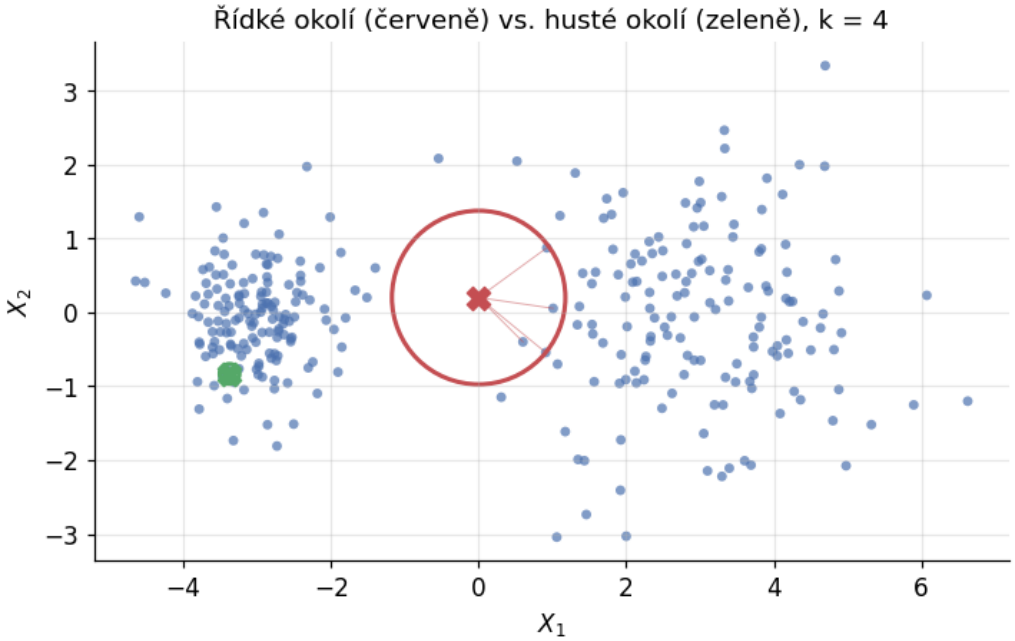
Počet sousedů značíme K, abychom jej odlišili od dimenze dat k.

Řídké vs. husté okolí

```
from sklearn.neighbors import (
    NearestNeighbors,
        LocalOutlierFactor)

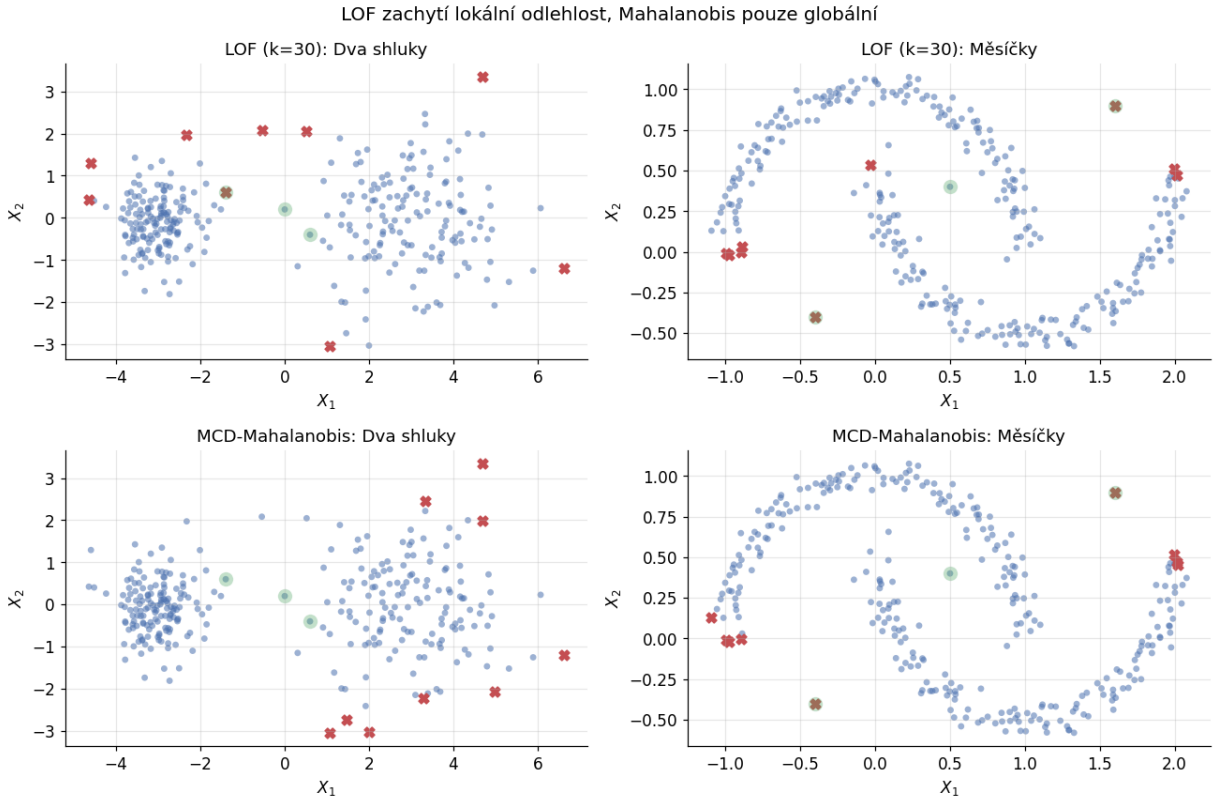
K = 4
nn = NearestNeighbors(
    n_neighbors=K + 1       # +1:
         bod sam
).fit(X_2c)
dist, idx = nn.kneighbors(X_2c)
k_dist = dist[:, K]         # K-
    dist

lof = LocalOutlierFactor(
    n_neighbors=K)
lof.fit_predict(X_2c)
score = -lof.
    negative_outlier_factor_
```

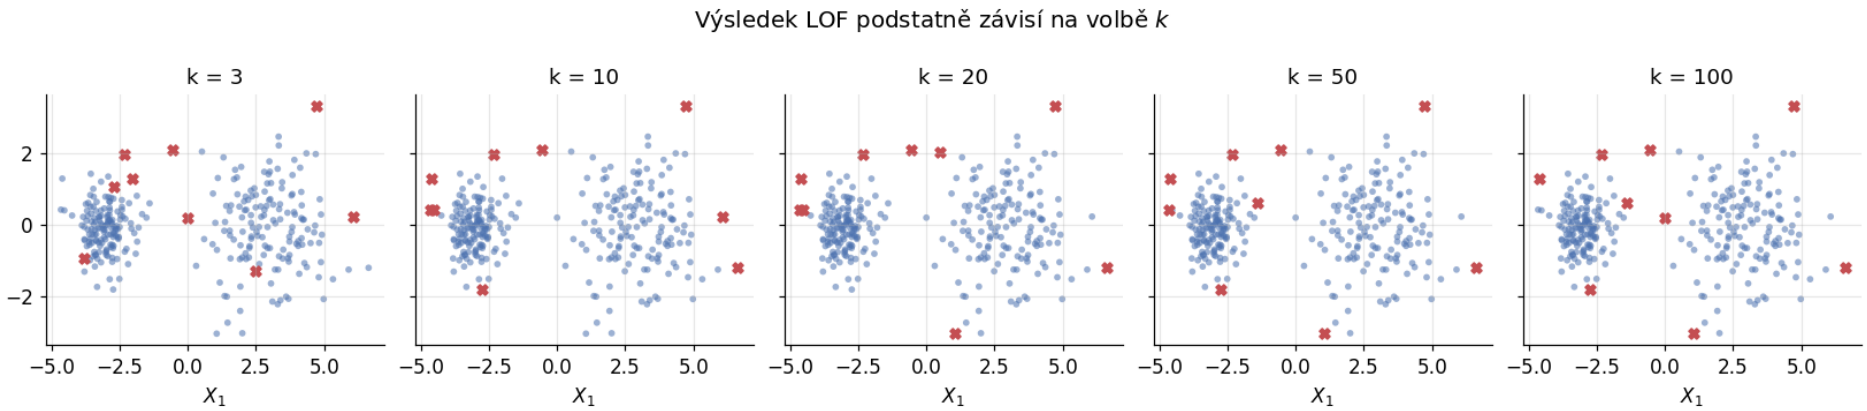


FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

LOF zachytí lokální odlehlost, Mahalanobis pouze globální



Citlivost LOF na volbu *K*



Isolation Forest

Liu, Ting, Zhou (2008). Odlehlé body jsou „few and different“ – dají se izolovat od zbytku dat velmi rychle náhodným dělením prostoru.

$$s(\boldsymbol{x}, \psi) = 2^{-\mathbb{E}[h(\boldsymbol{x})]/c(\psi)}, \qquad c(\psi) = 2H(\psi - 1) - \frac{2(\psi - 1)}{\psi},$$

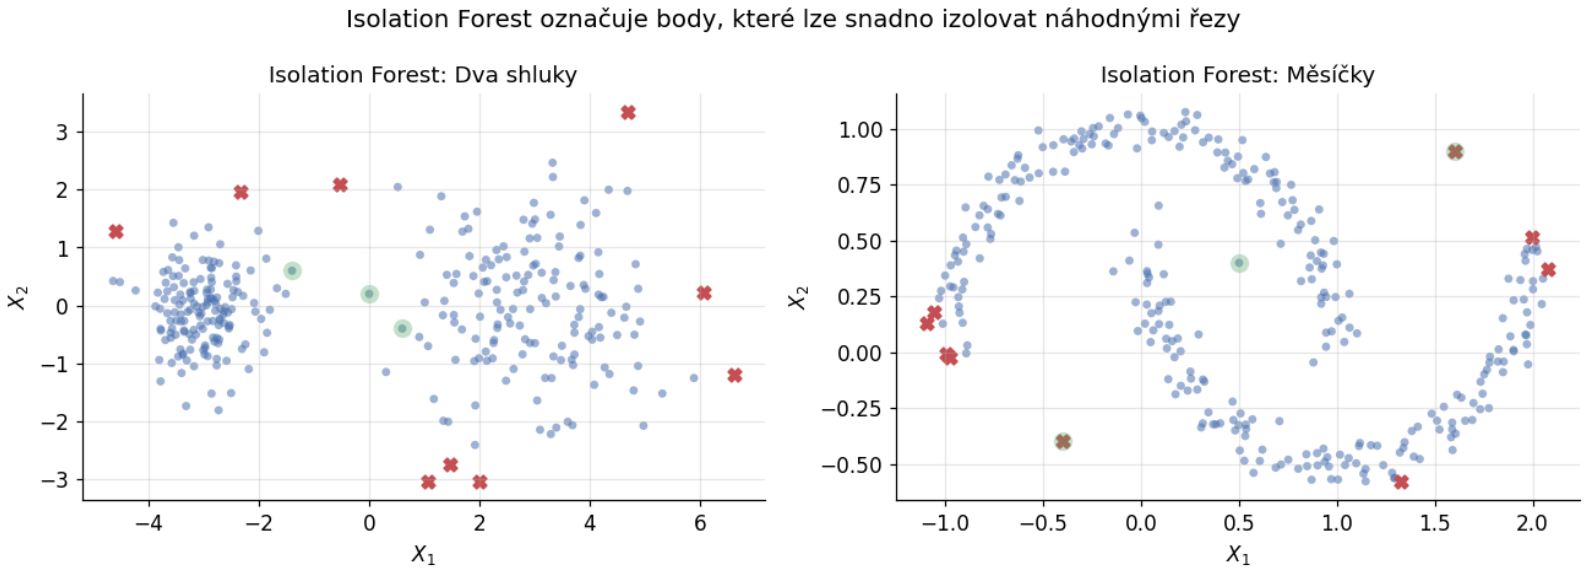
kde $h(\boldsymbol{x})$ je délka cesty k listu, ψ velikost podvýběru pro jeden strom a $H(i) \approx \ln i + 0{,}5772$ harmonické číslo.

- $s \to 1 \to$ bod izolován velmi mělko $\to$ odlehlý; $s \approx 0{,}5$ a méně $\to$ typický bod.
- Stromy se stavějí z malých podvýběrů (typicky $\psi = 256$), výpočet je proto lineární v n a málo závislý na počtu proměnných.
- Citlivé na náhodnost a na osové (axis-parallel) řezy.

```
from sklearn.ensemble import IsolationForest
iso = IsolationForest(n_estimators=300, random_state=0)
score = -iso.fit(Xd).score_samples(Xd)   # vetsi = odlehlejsi
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Isolation Forest – ukázka



One-Class SVM

Schölkopf et al. (2001). Najdi v prostoru příznaků nejmenší možnou oblast, která obsahuje většinu dat – vše mimo ni je odlehlé.

$$\min_{w,\xi,\rho} \ \frac{1}{2}\|w\|^2 + \frac{1}{\nu n}\sum_i \xi_i - \rho \quad \text{za podmínek } \langle w, \phi(\boldsymbol{x}_i)\rangle \geq \rho - \xi_i, \ \xi_i \geq 0$$

- $\nu \in (0, 1]$ je horní mez podílu odlehlých bodů v trénovacích datech.
- Jádro (RBF), parametr γ: malé $\gamma \to$ hladká hranice, velké $\gamma \to$ členitá hranice (riziko přeučení).
- Vyžaduje standardizaci vstupních dat (`StandardScaler`).

```
from sklearn.svm import OneClassSVM
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

oc = make_pipeline(StandardScaler(),
                   OneClassSVM(kernel="rbf", nu=0.05, gamma="scale"))
pred = oc.fit_predict(X)              # -1 = odlehly, +1 = bezny
score = -oc.decision_function(X)      # vetsi = odlehlejsi
```

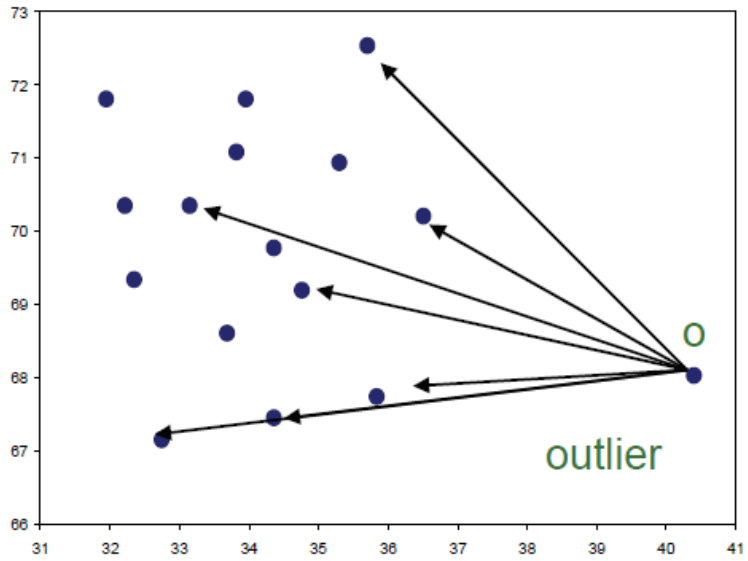
FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

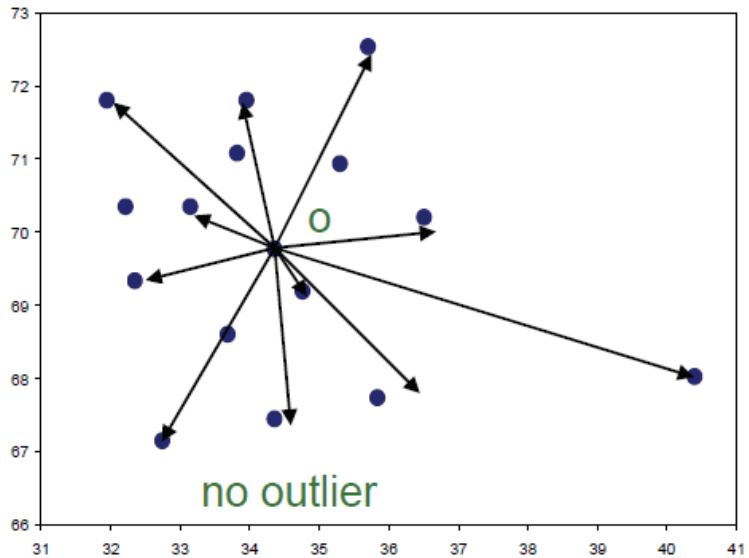
Metody založené na hloubce dat a na odlišnosti

- **Hloubka dat** (depth based approaches)
  - vytvoříme konvexní obal dat, body ležící na jeho hranici mají hloubku 1,
  - odstraníme je a vytvoříme nový konvexní obal (body na něm mají hloubku 2), ...
  - za odlehlé považujeme body s malou hloubkou; vícerozměrný boxplot a bagplot (P04) jsou založené na stejné myšlence,
  - výpočetně náročné, prakticky jen pro $k = 2, 3$.
- **Odlišnost** (vliv vyřazení pozorování)
  - počítáme charakteristiky (průměry, směrodatné odchylky, mediány, ...) pro data BEZ vybraných pozorování a porovnáváme je s charakteristikami ze všech dat,
  - odlehlá pozorování ve smyslu korelací a regresních vztahů (vlivná pozorování, Cookova vzdálenost),
  - princip křížové validace (cross-validation).

Metody založené na shlukování a na úhlech

- **Shlukování**: odlehlé jsou body, které nepatří do žádného shluku nebo tvoří velmi malé shluky (např. šumové body metody DBSCAN).
- **Úhlové metody** (ABOD, Angle-Based Outlier Detection, Kriegel et al. 2008): pokud je bod odlehlý, ostatní body leží přibližně „stejným“ směrem a rozptyl úhlů ke dvojicím ostatních bodů je malý. Pro bod uvnitř dat je rozptyl úhlů velký. Úhly jsou méně citlivé na prokletí dimenzionality než vzdálenosti.



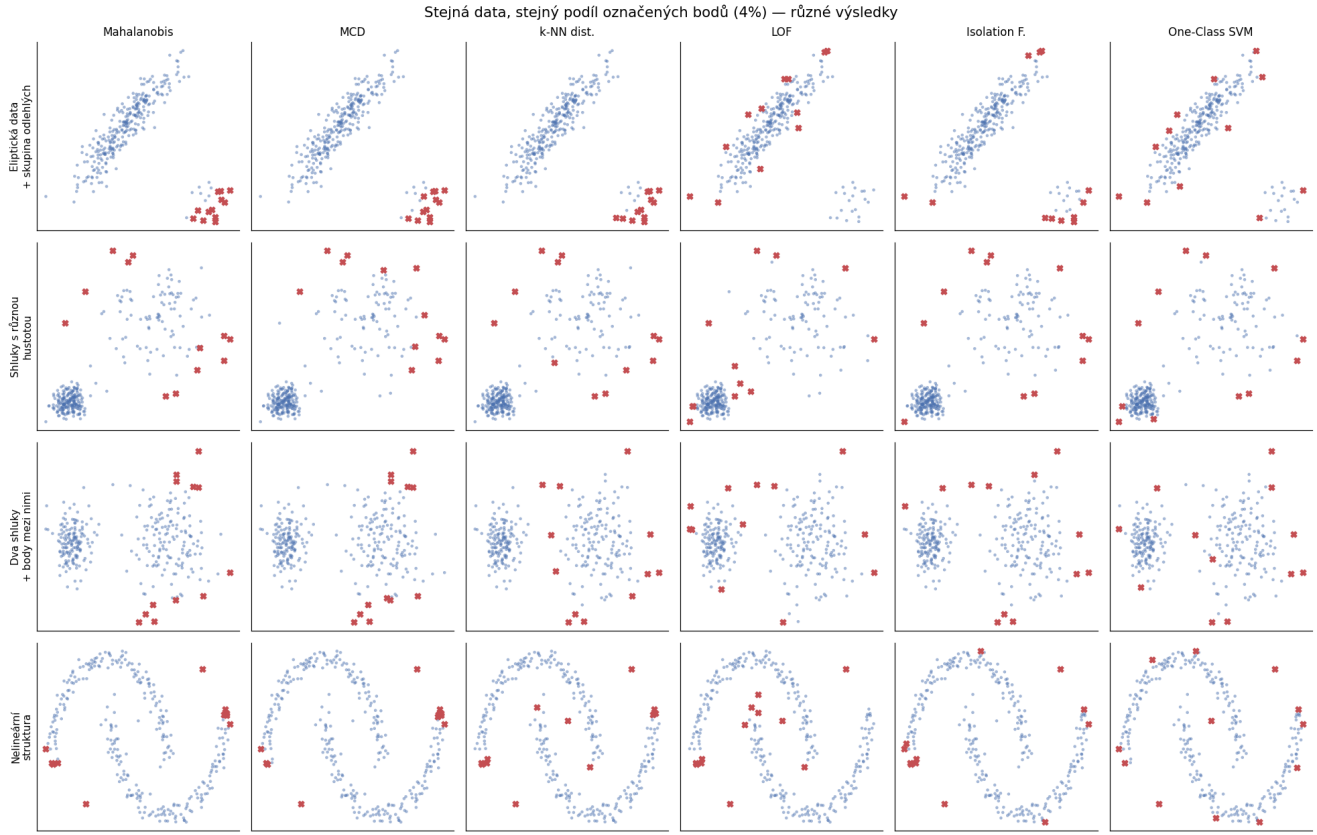


Přehled metod pro vícerozměrná data

Metoda	**Princip**	**Předpoklad / parametr**
Mahalanobis (klasický)	vzdálenost od průměru vážená $\boldsymbol{\Sigma}^{-1}$	eliptické rozdělení; není robustní
Mahalanobis (MCD)	robustní odhad $\boldsymbol{\mu}, \boldsymbol{\Sigma}$	eliptické rozdělení; `support_fraction`
K-NN vzdálenost	vzdálenost ke K-tému sousedovi	globální hustota; K
LOF	poměr lokálních hustot	lokální hustota; K
Isolation Forest	snadnost izolace náhodnými řezy	bez předpokladu tvaru; počet stromů
One-Class SVM	obálka nosiče rozdělení	jádro, ν, γ

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Stejná data, stejný podíl označených bodů – různé výsledky



FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Co si odnést z přehledové mřížky

- Na eliptických datech se metody shodují – tam je volba téměř lhostejná.
- Při rozdílné hustotě shluků označí globální metody celý řidší shluk; LOF nikoli.
- U nelineárních struktur eliptické metody selhávají systematicky.
- Isolation Forest je kompromis: bez předpokladů, ale s tendencí preferovat okraje dat.

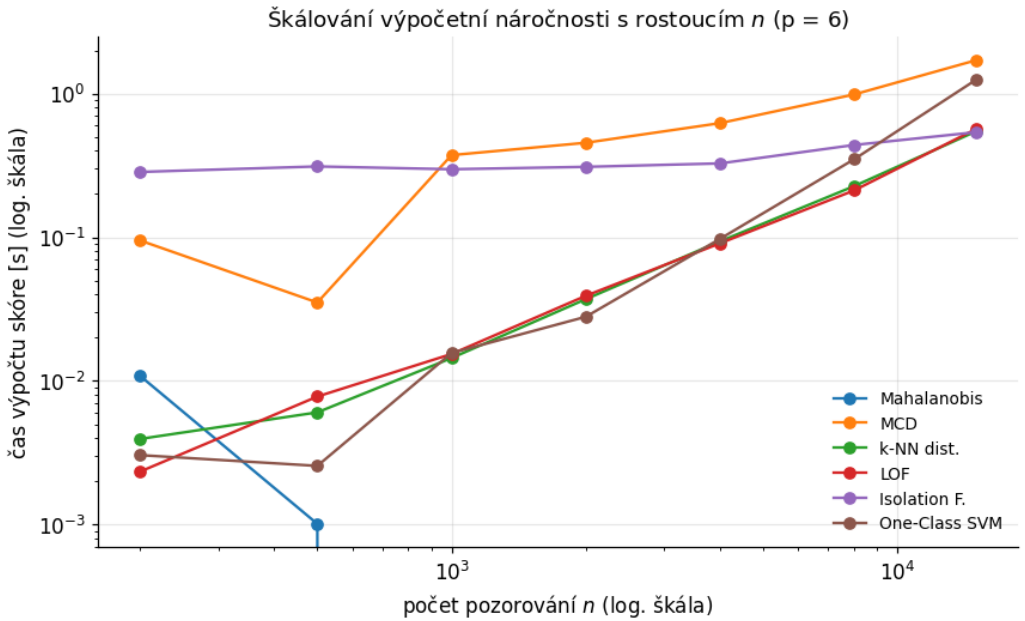
Výpočetní náročnost metod

Volba metody není jen otázka přesnosti – u větších datových souborů hraje roli i **rychlost**. Porovnáme škálování všech šesti metod se vzrůstajícím počtem pozorování n.

```
n_values = [200, 500, 1000, 2000, 4000, 8000, 15000]
k_bench = 6                              # dimenze
for n_ in n_values:
    Xb = RNG.normal(size=(n_, k_bench))
    for mname, fn in METHODS.items():
        ...
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Škálování výpočetní náročnosti



Mahalanobis a K-NN/LOF škálují dobře; MCD a One-Class SVM (složitost až $O(n^2)$–$O(n^3)$) rostou s n rychleji; Isolation Forest roste jen pomalu, protože stromy staví z podvýběrů pevné velikosti.

Prokletí dimenzionality

S rostoucí dimenzí k se vzdálenosti mezi body **koncentrují** – poměr vzdálenosti k nejvzdálenějšímu a k nejbližšímu bodu jde k 1. Pojem „blízkosti“ ztrácí rozlišovací schopnost a s ním i metody založené na vzdálenostech.

$$d(\boldsymbol{X}, \boldsymbol{Y})^2 = \sum_{i=1}^{k} (X_i - Y_i)^2, \qquad \mathrm{CV}(d^2) = \frac{\sqrt{\mathrm{var}\,(d^2)}}{\mathbb{E}(d^2)} \xrightarrow[k\to\infty]{} 0$$

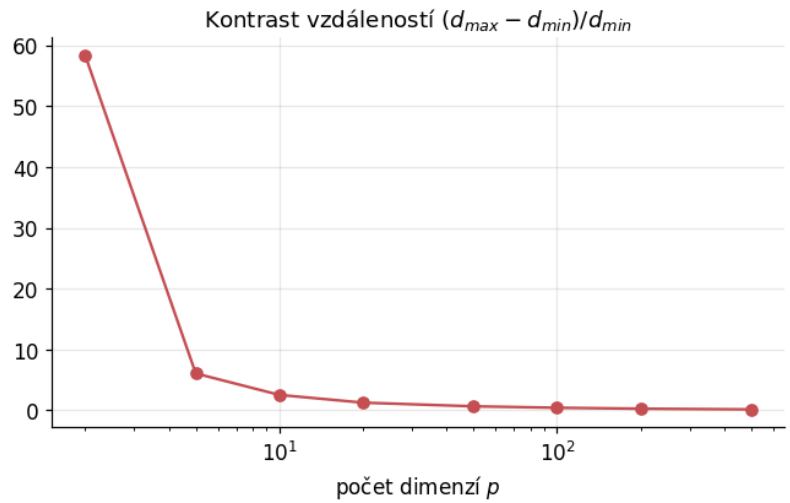
(pro nezávislé stejně rozdělené složky je $\mathrm{CV}(d^2)$ řádu $1/\sqrt{k}$).

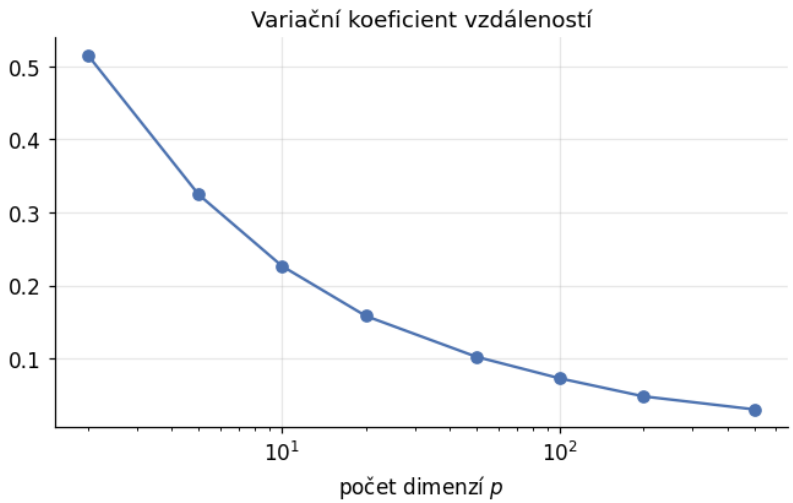
Formálně (Beyer et al., 1999)

Pokud relativní rozptyl vzdáleností jde k nule s rostoucím k, pak $\frac{D_{max}}{D_{min}} \xrightarrow{P} 1$.

Kontrast vzdáleností v rostoucí dimenzi

```
dims = [2, 5, 10, 20, 50, 100, 200, 500]
n_pts = 300
for k in dims:
    Xd = RNG.normal(size=(n_pts, k))
    dist, _ = NearestNeighbors(n_neighbors=n_pts).fit(Xd).kneighbors(Xd
        )
    ...
```





FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Reálná data

Doposud jsme metody srovnávali na simulovaných datech, kde jsme znali „pravdu“ o tom, co je a co není odlehlé. V praxi to tak často nebývá. Ukážeme obě situace:

- data **bez ground truth** (`wine`): metody lze srovnat jen mezi sebou (shoda/konsensus),
- data **s ground truth** (mamografie): můžeme spočítat, která metoda je skutečně blíž pravdě.

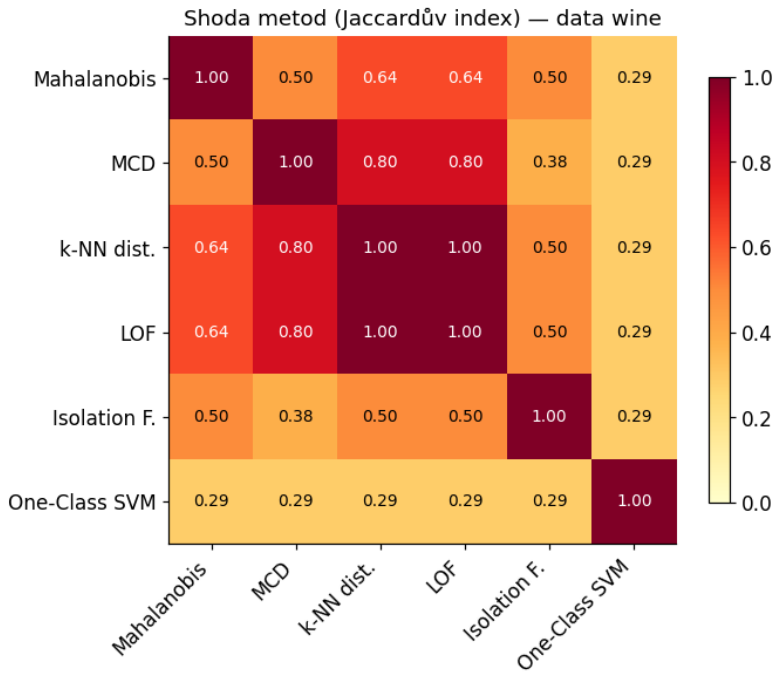
Bez ground truth: `wine` (178 vzorků, 13 proměnných)

Dataset **Wine Recognition** z UCI Machine Learning Repository, načtený přes `sklearn.datasets.load_wine`. Nevíme, co je „skutečně“ odlehlé – sledujeme jen, **nakolik se metody shodují**.

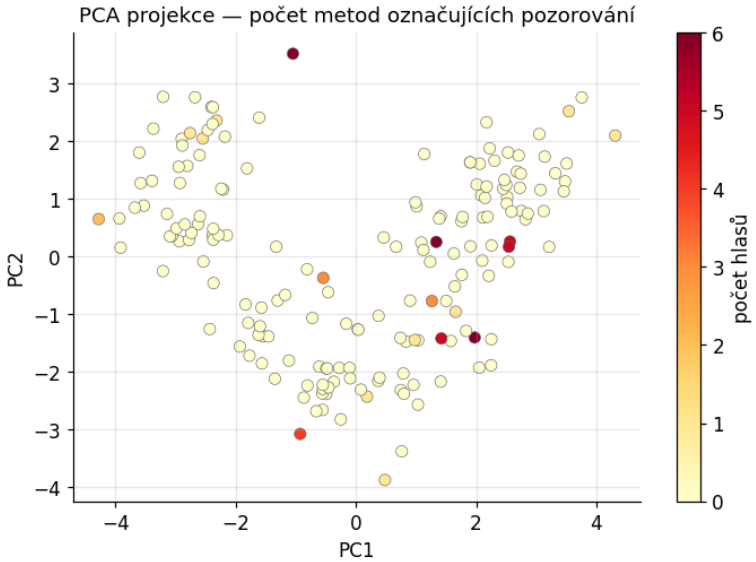
```
wine = load_wine()
Xw = StandardScaler().fit_transform(wine.data)
CONTAM_W = 0.05                          # oznacime 5 % bodu s nejvyssim
    skore
res_w = {name: flag_top(fn(Xw), CONTAM_W) for name, ...}
```

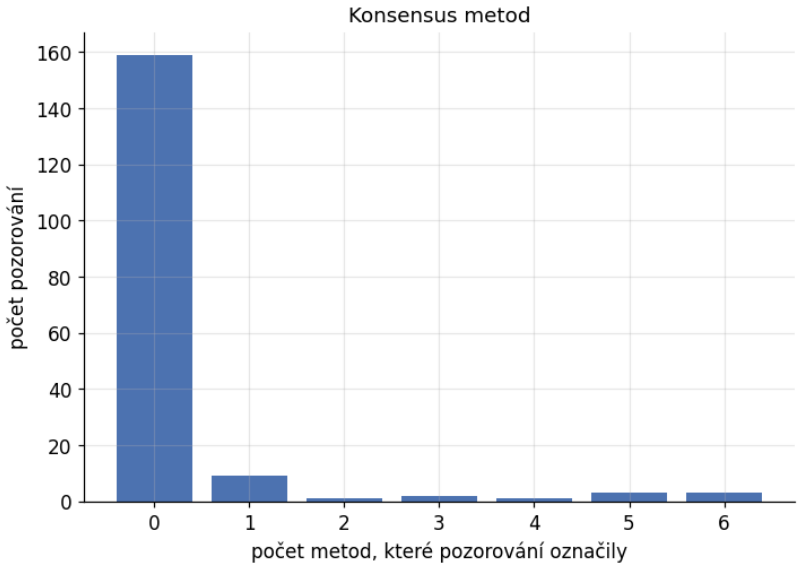
Shodu dvou metod měříme Jaccardovým indexem $J(A, B) = \frac{|A \cap B|}{|A \cup B|}$, kde A, B jsou množiny označených bodů.

Shoda metod – Jaccardův index (wine)



Konsensus metod – PCA projekce (wine)





Praktické doporučení (bez ground truth)

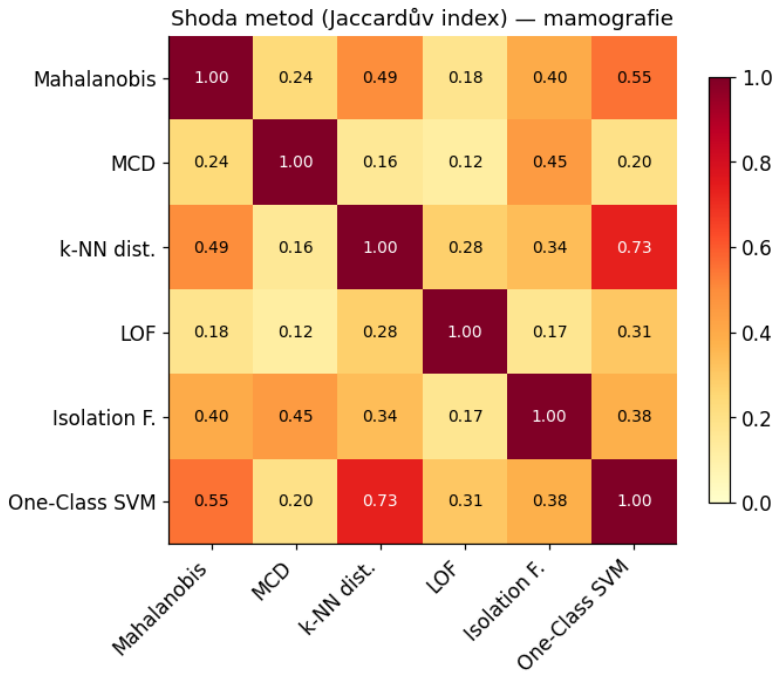
Místo hledání „té správné“ metody se vyplatí sledovat **konsensus**. Pozorování označená většinou metod jsou robustní kandidáti; body označené jen jednou metodou vypovídají spíše o vlastnostech metody než o datech.

S ground truth: mamografie – detekce mikrokalcifikací

Dataset **Mammography** z katalogu ODDS (Woods et al. 1993, Rayana 2016). 11 183 objektů, 6 obrazových příznaků. 260 objektů (2,32 %) je radiologicky potvrzeno jako mikrokalcifikace.

```
mammo = pd.read_csv('mammography.csv')
y_true = mammo['odlehly'].values
Xm = mammo.drop(columns='odlehly').values
...
```

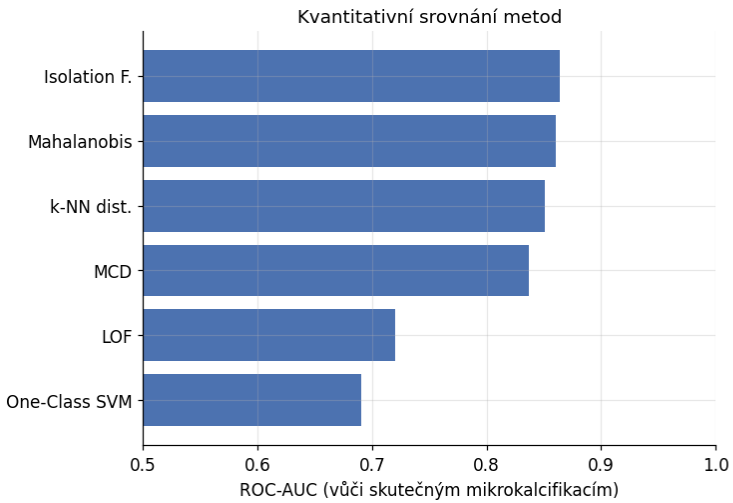
Shoda metod – Jaccardův index (mamografie)

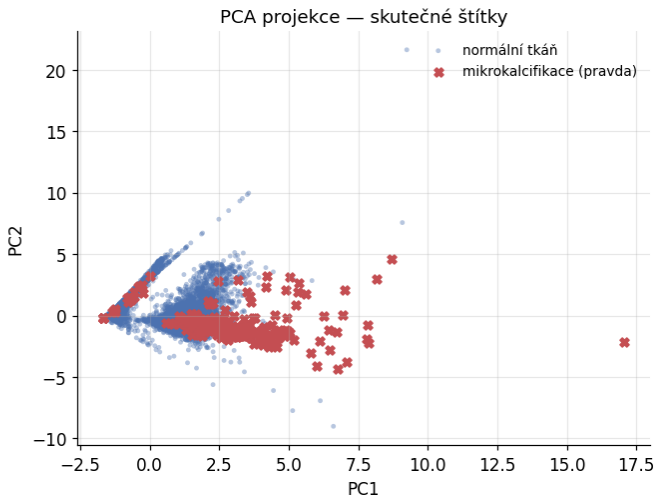


FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Kvantitativní srovnání (ROC-AUC)

```
from sklearn.metrics import roc_auc_score
for name, s in scores_m.items():
    auc = roc_auc_score(y_true, s)    # s: vetsi skore = odlehlejsi
    ...
```





FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Praktické doporučení a shrnutí – reálná data

- Na mamografických datech mají **globální** metody (Mahalanobis, Isolation Forest, K-NN) vyšší ROC-AUC než LOF a One-Class SVM.
- Pěkný protipól k předchozím ukázkám, kde naopak LOF vítězilo nad Mahalanobisem.
- **Žádná metoda není univerzálně nejlepší** – výsledek závisí na charakteru konkrétních dat.
- Bez ground truth (wine) lze posoudit jen shodu metod mezi sebou; s ground truth (mamografie) lze přímo změřit, která metoda je blíž pravdě.

Shrnutí

Metoda	**Typ pohledu**	**Silné stránky**	**Omezení**
Mahalanobis	globální, eliptická	interpretovatelná mez χ^2, rychlý	není robustní, selže u shluků
MCD-Mahalanobis	globální, eliptická	robustní, statisticky podložený	vyžaduje $n \gg k$
K-NN vzdálenost	globální hustota	bez předpokladů tvaru	citlivý na měřítko
LOF	lokální hustota	zachytí lokální odlehlost	citlivý na K a měřítko
Isolation Forest	izolovatelnost	škáluje do vyšších dimenzí	osové řezy
One-Class SVM	nosič rozdělení	flexibilní hranice	citlivý na ν, γ

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Závěry

1. **Vícerozměrná odlehlost není součtem jednorozměrných.**
2. **Mahalanobisova vzdálenost** – dobrá první volba, ale jen v robustní variantě (MCD).
3. **LOF** odhalí lokálně odlehlá pozorování; cenou je volba K.
4. **S rostoucí dimenzí** slábne kontrast vzdáleností – nutná redukce dimenze či regularizace.
5. **Neexistuje univerzálně nejlepší metoda.**
6. V praxi se osvědčuje **kombinace metod a sledování konsensu**.
7. **Máte-li ground truth**, vždy validujte kvantitativně.

Testy vícerozměrné normality

- Mardiův test (vícerozměrná šikmost a špičatost)
- Vícerozměrný χ^2-test dobré shody
- Další testy: Henze-Zirklerův, Roystonův, Q-Q graf Mahalanobisových vzdáleností (P04)

Metody založené na Mahalanobisově vzdálenosti s mezí $\chi^2_k(1-\alpha)$ předpokládají, že „běžná“ data mají přibližně vícerozměrné normální rozdělení. Testy normality jsou ale samy citlivé na odlehlé hodnoty – jediný odlehlý bod může vést k zamítnutí normality.

Testy normality pro vícerozměrná normální rozdělení

Testy založené na momentech – Mardiův test

Označme $m_{ij} = (\boldsymbol{x}_i - \overline{\boldsymbol{x}})^T S_0^{-1} (\boldsymbol{x}_j - \overline{\boldsymbol{x}})$, kde S_0 je výběrová varianční matice s dělitelem n (P04). Pak $m_{ii} = d_i^2$ jsou Mahalanobisovy vzdálenosti.

- $b_{1,k} = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} m_{ij}^3$ nazýváme **vícerozměrnou šikmostí**.
- Za předpokladu normálního rozdělení vektoru $\boldsymbol{X}$ asymptoticky pro $n \to \infty$ platí

$$\frac{n \cdot b_{1,k}}{6} \sim \chi^2_\nu \text{ se stupni volnosti } \nu = \frac{k \cdot (k+1) \cdot (k+2)}{6}.$$

- **Vícerozměrná špičatost** $b_{2,k} = \frac{1}{n} \sum_{i=1}^{n} m_{ii}^2$.
- Za předpokladu normálního rozdělení vektoru $\boldsymbol{X}$ je $\mathbb{E} b_{2,k} \approx k(k+2)$ a asymptoticky

$$\sqrt{n} \, \frac{b_{2,k} - k \cdot (k+2)}{\sqrt{8 \cdot k \cdot (k+2)}} \sim N(0,1).$$

- Pro $k = 1$ jde o kvadrát výběrové šikmosti a o výběrovou špičatost.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Mardiův test v Pythonu

```
import numpy as np
from scipy import stats

def mardia(X):
    n, k = X.shape
    D = X - X.mean(axis=0)
    S0 = D.T @ D / n                          # odhad s delitelem n
    M = D @ np.linalg.inv(S0) @ D.T           # matice m_ij
    b1 = (M**3).sum() / n**2                  # vicerozmerna sikmost
    b2 = (np.diag(M)**2).mean()               # vicerozmerna spicatost
    A = n * b1 / 6
    df = k * (k + 1) * (k + 2) / 6
    B = (b2 - k * (k + 2)) / np.sqrt(8 * k * (k + 2) / n)
    p_skew = stats.chi2.sf(A, df)
    p_kurt = 2 * stats.norm.sf(abs(B))
    return b1, b2, p_skew, p_kurt

rng = np.random.default_rng(0)
print(mardia(rng.multivariate_normal(np.zeros(3), np.eye(3), 500)))
print(mardia(rng.exponential(size=(500, 3))))   # zamitne normalitu
```

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Henze-Zirklerův test: `pingouin.multivariate_normality(X)`.

Testy normality pro vícerozměrná normální rozdělení

Vícerozměrný χ^2-test dobré shody

Rozdělíme definiční obor $\mathbb{R}^k$ na jednotlivé sektory (buňky) Ω_g, $g = 1, \ldots, G$. Spočteme pravděpodobnosti v těchto sektorech podle vztahu $p_g = \int_{\Omega_g} f(\boldsymbol{x})\, \mathrm{d}\boldsymbol{x}$ a očekávané počty hodnot podle vztahu $o_g = p_g \cdot n$. Pak statistika

$$\chi^2 = \sum_{g=1}^{G} \frac{(n_g - o_g)^2}{o_g},$$

kde n_g je skutečný počet hodnot v sektoru Ω_g, má asymptoticky χ^2 rozdělení se stupni volnosti

$$\nu = \left(\prod_{e=1}^{k} c_e \right) - 1 - 2 \cdot k - k_{cov},$$

kde c_e je počet intervalů e-té proměnné (tedy $G = \prod c_e$) a k_{cov} je počet odhadnutých kovariancí, obvykle $k_{cov} = \binom{k}{2}$ (odhadujeme k středních hodnot, k rozptylů a $\binom{k}{2}$ kovariancí).

Test vyžaduje dostatečný počet dat, očekávané počty by měly splňovat $o_g \geq 5$; s rostoucí dimenzí proto rychle ztrácí použitelnost.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI