KMA/MSM – cvičení 6: Testy o střední hodnotě

(verze s výsledky)

Úlohy řešte nejprve „ručně“ (s kalkulačkou a tabulkami kvantilů), výsledky ověřte v Pythonu (`scipy.stats`, `numpy`), viz notebook `P06_testy_o_stredni_hodnote.ipynb`. Pokud není řečeno jinak, volte hladinu $\alpha = 0{,}05$; k značí dimenzi dat.

A. Jednorozměrná data

1. **z-test.** Ve výrobní firmě se kontroluje hmotnost balíčků před expedicí. Norma stanovuje průměrnou hmotnost $\mu_0 = 500\,\text{g}$. Auditor odebral $n = 40$ balíčků, průměrná hmotnost byla $\bar{x} = 498{,}6\,\text{g}$; směrodatná odchylka procesu je známa, $\sigma = 5\,\text{g}$. Předpokládejte normální rozdělení hmotností.

   (a) Otestujte oboustrannou alternativu $H_1 : \mu \neq 500$.

   (b) Otestujte jednostrannou alternativu $H_1 : \mu < 500$ (balíčky jsou v průměru lehčí). Proč se rozhodnutí může lišit?

   Výsledky: $Z = \frac{498{,}6-500}{5/\sqrt{40}} = -1{,}771$. a) $|Z| = 1{,}771 < z_{0{,}025} = 1{,}960$, $p = 0{,}077$ – nezamítáme. b) $Z = -1{,}771 < -z_{0{,}05} = -1{,}645$, $p = 0{,}038$ – zamítáme, balíčky jsou v průměru lehčí. Jednostranný test soustředí celou hladinu α do jednoho konce rozdělení, a je proto v daném směru silnější; alternativa však musí být zvolena *před* pohledem na data.

2. **Jednovýběrový t-test.** V dílně se vyrábějí kovové součástky s cílovou délkou 50 mm. Naměřené délky (mm):

   $$49{,}8;\ 50{,}1;\ 50{,}3;\ 49{,}9;\ 50{,}2;\ 50{,}0;\ 49{,}7;\ 50{,}4.$$

   Ověřte, zda výroba splňuje požadavek na průměrnou délku. Spočtěte i 95% interval spolehlivosti pro μ a ověřte předpoklad normality.

   Výsledky: $\bar{x} = 50{,}05$, $s = 0{,}245$, $T = \frac{50{,}05-50}{0{,}245/\sqrt{8}} = 0{,}577$, $|T| < t_{0{,}025}(7) = 2{,}365$, $p = 0{,}58$ – nezamítáme. 95% IS: $(49{,}85;\ 50{,}25)$ obsahuje 50. Shapirův–Wilkův test $p = 0{,}93$.

3. **Test o mediánu.** Laboratoř sleduje tlak v potrubí. Tvrdí se, že medián tlaku je 100 jednotek. Naměřené hodnoty:

   $$98;\ 101;\ 99;\ 100;\ 102;\ 97;\ 103;\ 99.$$

   Otestujte hypotézu o mediánu jednovýběrovým Wilcoxonovým testem a znaménkovým testem. Jak naložíte s hodnotou rovnou 100? Za jakého předpokladu je Wilcoxonův test testem o mediánu?

   Výsledky: Hodnotu 100 (nulový rozdíl) vynecháme, zbývá $n = 7$ rozdílů $-2;\ 1;\ -1;\ 2;\ -3;\ 3;\ -1$. Pořadí absolutních hodnot (se shodami průměrná pořadí): $|1| \to 2$, $|2| \to 4{,}5$, $|3| \to 6{,}5$; $W^+ = 2 + 4{,}5 + 6{,}5 = 13$, $W^- = 15$; $p \approx 0{,}94$. Znaménkový test: 3 kladné z 7, $p = 1{,}00$. Hypotézu o mediánu nezamítáme (výběrový medián 99,5). Wilcoxonův test předpokládá symetrické rozdělení kolem mediánu.

4. **Dva nezávislé výběry.** Ve firmě běží dvě výrobní linky na stejný produkt. Zajímá nás, zda se liší průměrná doba cyklu. Naměřené časy (min):

   linka 1: 12,1; 11,8; 12,3; 12,0 linka 2: 11,5; 11,6; 11,4; 11,7.

   (a) F-testem ověřte shodu rozptylů. Co lze říci o síle tohoto testu při $n_1 = n_2 = 4$?

   (b) Proveďte dvouvýběrový t-test se shodnými rozptyly a Welchův test.

   (c) Proveďte Mannův–Whitneyův test. Jaká je nejmenší možná oboustranná p-hodnota tohoto testu pro $n_1 = n_2 = 4$?

   Výsledky: $\bar{x}_1 = 12{,}05$, $s_1^2 = 0{,}0433$; $\bar{x}_2 = 11{,}55$, $s_2^2 = 0{,}0167$. a) $F = 2{,}60$, $p = 0{,}45$ ($F_{0{,}975}(3;3) = 15{,}44$) – nezamítáme; při tak malých výběrech má F-test velmi malou sílu. b) $s_p^2 = 0{,}030$, $T = 4{,}08$, df $= 6$, $p = 0{,}006$; Welch: $T = 4{,}08$, df $= 5{,}0$, $p = 0{,}009$ – obě varianty zamítají. c) Všechny hodnoty linky 1 jsou větší než všechny hodnoty linky 2: $U = 16$, exaktní $p = 2/\binom{8}{4} = 0{,}029$ – to je nejmenší dosažitelná p-hodnota; na hladině 0,01 by Mannův–Whitneyův test při $n_1 = n_2 = 4$ nemohl zamítnout nikdy.

5. **Párový test.** U 8 pacientů byl změřen systolický tlak před a po čtyřtýdenní léčbě:

pacient	1	2	3	4	5	6	7	8
před	142	150	138	145	160	155	148	152
po	136	147	135	140	152	151	146	145

   (a) Párovým t-testem ověřte, zda léčba snižuje tlak. Výsledek porovnejte s Wilcoxonovým testem na rozdílech.

   (b) Analyzujte data (chybně) dvouvýběrovým t-testem. Proč je výsledek tak odlišný?

   Výsledky: a) Rozdíly 6; 3; 3; 5; 8; 4; 2; 7: $\bar{d} = 4{,}75$, $s_d = 2{,}12$, $T = 6{,}33$, df $= 7$, oboustranně $p = 0{,}0004$ (jednostranně 0,0002) – léčba tlak snižuje. Wilcoxon: všechny rozdíly kladné, $W^- = 0$, $p = 0{,}008$. b) $T = 1{,}40$, $p = 0{,}18$ – nezamítáme. Velká variabilita mezi pacienty zůstává ve jmenovateli statistiky; párový test ji odečte. Navíc výběry nejsou nezávislé.

B. Vícerozměrná data

6. **Test o vektoru středních hodnot – známá $\boldsymbol{\Sigma}$.** V klinické studii se sledují dva ukazatele. Předpokládejme, že

$$\boldsymbol{X} \sim N_2(\boldsymbol{\mu},\ \boldsymbol{\Sigma}), \qquad \boldsymbol{\Sigma} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$$

   se známou varianční maticí. Z výběru rozsahu $n = 6$ máme $\bar{\boldsymbol{x}} = (1;\ 1/2)^T$. Ověřte hypotézu $H_0 : \boldsymbol{\mu} = (2;\ 2/3)^T$. Porovnejte s výsledky dvou samostatných z-testů pro jednotlivé složky.

   Výsledky: $\boldsymbol{d} = \bar{\boldsymbol{x}} - \boldsymbol{\mu}_0 = (-1;\ -1/6)^T$, $\boldsymbol{\Sigma}^{-1} = \frac{1}{3}\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, $\chi^2 = n\,\boldsymbol{d}^T\boldsymbol{\Sigma}^{-1}\boldsymbol{d} = 6 \cdot \frac{43}{54} = 4{,}78 < \chi^2_{0{,}95}(2) = 5{,}99$, $p = 0{,}092$ – nezamítáme. Samostatně: $z_1 = \frac{-1}{\sqrt{2/6}} = -1{,}73$ ($p = 0{,}083$), $z_2 = \frac{-1/6}{\sqrt{2/6}} = -0{,}29$ ($p = 0{,}77$) – také nezamítáme; vícerozměrný test navíc zohledňuje zápornou korelaci složek.

7. **Vliv korelace.** Náhodný výběr rozsahu $n = 8$ pochází z rozdělení

$$\boldsymbol{X} \sim N_2\left(\boldsymbol{\mu}, \begin{pmatrix} 3 & \rho \\ \rho & 1 \end{pmatrix}\right)$$

se známou varianční maticí (tj. známým ρ); výběrový průměr je $\bar{\boldsymbol{x}} = (1{,}2;\ 0{,}4)^T$.

(a) Jaké hodnoty ρ jsou vůbec přípustné?

(b) Vyjádřete testovou statistiku χ^2 pro $H_0 : \boldsymbol{\mu} = (0;\ 0)^T$ jako funkci ρ a rozhodněte pro $\rho = -0{,}5;\ 0;\ 1;\ 1{,}6$.

(c) Pro které hodnoty ρ hypotézu H_0 zamítneme? Nakreslete v Pythonu graf $\chi^2(\rho)$ spolu s kritickou hodnotou.

(d) Vysvětlete, proč při kladné korelaci (do jisté meze) nezamítáme, kdežto při záporné ano.

Výsledky: a) Matice je pozitivně definitní pro $3 - \rho^2 > 0$, tj. $|\rho| < \sqrt{3} \doteq 1{,}732$. b) $\boldsymbol{\Sigma}^{-1} = \frac{1}{3-\rho^2}\begin{pmatrix} 1 & -\rho \\ -\rho & 3 \end{pmatrix}$, takže $\chi^2(\rho) = 8\,\frac{1{,}2^2 - 2\rho\cdot 1{,}2\cdot 0{,}4 + 3\cdot 0{,}4^2}{3-\rho^2} = \frac{7{,}68\,(2-\rho)}{3-\rho^2}$; kritická hodnota $\chi^2_{0{,}95}(2) = 5{,}99$. $\rho = -0{,}5$: $\chi^2 = 6{,}98$, $p = 0{,}031$ – zamítáme; $\rho = 0$: $\chi^2 = 5{,}12$, $p = 0{,}077$ – nezamítáme; $\rho = 1$: $\chi^2 = 3{,}84$, $p = 0{,}147$ – nezamítáme; $\rho = 1{,}6$: $\chi^2 = 6{,}98$, $p = 0{,}031$ – zamítáme. c) Funkce má na $(-\sqrt{3}, \sqrt{3})$ minimum v $\rho = 1$ ($\chi^2 = 3{,}84$) a roste k nekonečnu pro $\rho \to \pm\sqrt{3}$. Z nerovnice $7{,}68(2-\rho) > 5{,}99(3-\rho^2)$, tj. $5{,}99\rho^2 - 7{,}68\rho - 2{,}61 > 0$, plyne: H_0 zamítáme pro $-\sqrt{3} < \rho < -0{,}28$ a pro $1{,}56 < \rho < \sqrt{3}$; pro $-0{,}28 \le \rho \le 1{,}56$ nezamítáme. d) Obě složky $\bar{\boldsymbol{x}}$ se od nuly odchylují stejným směrem. Při kladné korelaci je takový výsledek pod H_0 „očekávaný“ (složky se pohybují spolu), a je proto slabším důkazem proti H_0. Při záporné korelaci by se složky měly odchylovat opačně, souhlasná odchylka je nepravděpodobná a vede k zamítnutí. Pro ρ blízko $\sqrt{3}$ je rozdělení téměř degenerované (soustředěné kolem přímky $x_1 = \sqrt{3}\,x_2$) a bod $(1{,}2;\ 0{,}4)$, který na ní neleží, je opět nepravděpodobný.

8. **Test o varianční matici.** V laboratoři se měří dva parametry kvality materiálu. Z výběru rozsahu $n = 25$ byla spočtena (korigovaná) výběrová varianční matice S. Ověřte, zda odpovídá referenční matici $\boldsymbol{\Sigma}_0$:

$$S = \begin{pmatrix} 166 & 124 \\ 124 & 137 \end{pmatrix}, \qquad \boldsymbol{\Sigma}_0 = \begin{pmatrix} 122 & 114 \\ 114 & 151 \end{pmatrix}.$$

Výsledky: ML odhad $S_0 = \frac{24}{25}S$; $\operatorname{tr}(\boldsymbol{\Sigma}_0^{-1}S_0) = 2{,}390$, $|\boldsymbol{\Sigma}_0^{-1}S_0| = 1{,}251$; $-2\ln\lambda = 25\cdot 2{,}390 - 25\ln 1{,}251 - 25\cdot 2 = 4{,}15 < \chi^2_{0{,}95}(3) = 7{,}81$, $p = 0{,}25$ – shodu s $\boldsymbol{\Sigma}_0$ nezamítáme.

9. **Dva vícerozměrné výběry.** Ve studii máme dvě skupiny pacientů ($n_1 = 20$, $n_2 = 25$) a sledujeme dva ukazatele. Výběrové charakteristiky:

$$\bar{\boldsymbol{x}}_1 = (2;\ 1)^T, \quad \bar{\boldsymbol{x}}_2 = (1;\ 1)^T, \qquad S_1 = \begin{pmatrix} 4 & -1 \\ -1 & 2 \end{pmatrix}, \quad S_2 = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix}.$$

(a) Otestujte shodu variančních matic.

(b) Otestujte shodu vektorů středních hodnot Hotellingovým T^2 testem se sdruženou maticí S_p a testem pro různé varianční matice. Který test je zde vhodnější?

Výsledky: a) $-2\ln\lambda = 11{,}06 > \chi^2_{0,95}(3) = 7{,}81$, $p = 0{,}011$ (Boxův M-test: 10,09, $p = 0{,}018$) – varianční matice se liší. b) $S_p = \begin{pmatrix} 2{,}884 & -1{,}558 \\ -1{,}558 & 3{,}116 \end{pmatrix}$, $T^2 = 5{,}28$, $F = \frac{42}{2\cdot 43}T^2 = 2{,}58 < F_{0,95}(2;42) = 3{,}22$, $p = 0{,}088$. Pro různé matice: $T^2 = \boldsymbol{d}^T(S_1/n_1 + S_2/n_2)^{-1}\boldsymbol{d} = 4{,}65 < 5{,}99$, $p = 0{,}098$. Vzhledem k a) je vhodnější druhý test; oba shodu vektorů středních hodnot nezamítají.

10. **Data Iris v Pythonu.** Použijte data `sklearn.datasets.load_iris`.

    (a) Pro každý druh otestujte, zda je střední hodnota délky kališního lístku (*sepal length*) rovna 5,0 cm.

    (b) Pro každý druh otestujte, zda je medián délky kališního lístku roven 6,0 cm (Wilcoxonův a znaménkový test).

    (c) Pro každou dvojici druhů porovnejte vektory středních hodnot všech čtyř proměnných dvouvýběrovým Hotellingovým T^2 testem.

    (d) Pro každou dvojici druhů otestujte shodu variančních matic. Jaký to má důsledek pro volbu testu v bodě c)?

Výsledky: a) setosa $\bar{x} = 5{,}006$, $p = 0{,}90$ (nezamítáme); versicolor 5,94 a virginica 6,59, $p < 0{,}001$. b) Medián: setosa 5,0 ($p < 0{,}001$), versicolor 5,9 (Wilcoxon $p = 0{,}37$, znaménkový $p = 0{,}46$ – nezamítáme), virginica 6,5 ($p < 0{,}001$). c) F: setosa–versicolor 625,5, setosa–virginica 1182,6, versicolor–virginica 86,1 (df $4; 95$), vše $p < 0{,}001$. d) Boxův M-test: $\chi^2 = 66{,}8$; 109,3; 35,0 (df $= 10$), vše $p < 0{,}001$ – varianční matice se liší, vhodnější je test pro různé varianční matice. Při tak výrazných rozdílech průměrů se závěr nezmění.