

Přednáška 6: Testy o střední hodnotě

T-test pro jednorozměrná a vícerozměrná data. Neparametrické varianty testů.

KMA/MSM Blanka Šedivá

verze 2025/2026

29. září 2026

Obsah

1

Jednorozměrná data


- Jeden výběr (shoda střední hodnoty s konstantou)
- Dva výběry (shoda dvou středních hodnot)
 - Shoda rozptylů F-test

2

Vícerozměrná data

- Jeden výběr (shoda vektoru středních hodnot s konstantním vektorem)
- Dva výběry (shoda dvou vektorů středních hodnot)
 - Shoda kovariančních matic

Testy o poloze



¹<https://app.diagrams.net/>

Jednorozměrná data


- Jednovýběrové testy o střední hodnotě - parametrické
- Jednovýběrové testy o střední hodnotě - neparametrické
- Dvouvýběrové testy o shodě středních hodnot - parametrické
- Dvouvýběrové testy o shodě rozptylů
- Dvouvýběrové testy o shodě středních hodnot - neparametrické

$H_0 : \mu = \mu_0$ (z-test)

Cíl	Ověřit hypotézu, zda se střední hodnota náhodného výběru μ rovná předpokládané hodnotě μ_0 .
Předpoklady	Data pochází z náhodného výběru z normálního rozdělení se známým rozptylem σ^2 .
Nulová hypotéza	$H_0 : \mu = \mu_0$
Alternativní hypotézy	$H_1 : \mu \neq \mu_0$ (oboustranný test) $H_1 : \mu < \mu_0$ (levostranný test) $H_1 : \mu > \mu_0$ (pravostranný test)
Testovací statistika	$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}, \text{ kde}$ - $\bar{X}$ je výběrový průměr, σ je známá směrodatná odchylka základního souboru a n je velikost výběru.

Rozdělení testovací statistiky normální $Z \sim N(0, 1)$

Vizualizace jednovýběrového testu



Vyhodnocení z-testu (kritický obor)

- **testová statistika** je statistika vypočtená z náhodného výběru
 $T = T(X_1, X_2, \dots, X_n),$
- statistické rozhodování probíhá na základě **kritického oboru** W , kdy kritický obor volíme tak, aby při platnosti H_1 hodnota testové statistiky padla do kritického oboru co možná nejčastěji a při platnosti H_0 zřídka, pokud $T \in W \rightarrow$ zamítám nulovou hypotézu a pokud $T \notin W \rightarrow$ nezamítám nulovou hypotézu
- velikost W volíme tak, abychom platnou hypotézu H_0 zamítali nejvýše s pravděpodobností α - jedná se maximální povolenou chybu I. druhu a nazýváme ji **hladina testu**
volíme obvykle $\alpha = 5\%$ (případně 1%, nebo 10%)

Vyhodnocení z-testu (p-hodnota testu)

- velikost W volíme tak, abychom platnou hypotézu H_0 zamítali nejvýše s pravděpodobností α - jedná se maximální povolenou chybu I. druhu a nazýváme ji **hladina testu**

volíme obvykle $\alpha = 5\%$ (případně 1%, nebo 10%)

- výpočetní sw poskytují informaci o nejmenší hladině, při které bychom hypotézu H_0 zamítli, tato nejmenší hladina se nazývá **p-hodnota testu**
p-hodnota testu udává mezní hodnotu hladiny významnosti, při které zamítáme H_0

H_0 zamítáme na hladině α právě tehdy, když hodnota $p < \alpha$

nízké p-hodnoty $\rightarrow$ zamítám nulovou hypotézu, vysoké p-hodnoty $\rightarrow$ nezamítám nulovou hypotézu

Vyhodnocení z-testu — oblast přijetí a zamítnutí

Kritické hodnoty pro vyhodnocení testu z_α , resp. $z_{\alpha/2}$ najdeme v tabulkách nebo pomocí sw:

```
from scipy.stats import norm
# Hladina významnosti
alpha = 0.05
# Kritická hodnota pro oboustranný test ( $z_{\alpha/2}$ )
z_alpha_over_2 = norm.ppf(1 - alpha / 2)
# Kritická hodnota pro jednostranný test ( $z_\alpha$ )
z_alpha = norm.ppf(1 - alpha)
```

Oboustranný test Zamítáme H_0 , pokud $|Z| > z_{\alpha/2}$

Levostranný test Zamítáme H_0 , pokud $Z < -z_\alpha$


Pravostranný test Zamítáme H_0 , pokud $Z > z_\alpha$

Vyhodnocení z-testu — oblast přijetí a zamítnutí

$$\text{Prob}(z|_{H_0} \in W) = \alpha$$

z curve (probability distribution of test statistic Z when H_0 is true)

— H_0
— H_1



Rejection regions for z tests: (a) upper-tailed test; (b) lower-tailed test; (c) two-tailed test

Vyhodnocení z-testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V Pythonu:

```
import numpy as np
from scipy.stats import norm
# Vypočtená hodnota testovací statistiky (např)
z_stat = (sample_mean - mu_0) / (sigma / np.sqrt(n))
# Oboustranný test
p_value_two_sided = 2 * (1 - norm.cdf(abs(z_stat)))
# Pravostranný test
p_value_right = 1 - norm.cdf(z_stat)
# Levostranný test
p_value_left = norm.cdf(z_stat)
```

Oboustranný a jednostranný test Zamítáme H_0 , pokud p -hodnota $< \alpha$

P-hodnota vyjadřuje pravděpodobnost, že bychom získali stejně extrémní nebo extrémnější výsledek za platnosti nulové hypotézy.

$H_0 : \mu = \mu_0$ jednovýběrový t-test

Cíl	Ověřit hypotézu, zda se střední hodnota náhodného výběru μ rovná předpokládané hodnotě μ_0 .
Předpoklady	Data pochází z náhodného výběru z normálního rozdělení s neznámým rozptylem .
Nulová hypotéza	$H_0 : \mu = \mu_0$
Alternativní hypotézy	$H_1 : \mu \neq \mu_0$ (oboustranný test) $H_1 : \mu < \mu_0$ (levostranný test) $H_1 : \mu > \mu_0$ (pravostranný test)
Testovací statistika	$T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}, \text{ kde}$ - $\bar{X}$ je výběrový průměr, s je odhadnutá směrodatná odchylka a n je velikost výběru.
Rozdělení testovací statistiky	Studentovo t-rozdělení se stupni volnosti $\nu = n-1$ $T \sim t(\nu = n-1)$

Vyhodnocení t-testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_1samp.html

```
from scipy.stats import t
# Vypočtená hodnota testovací statistiky
t_stat = 2.1
# Počet stupňů volnosti (např. n - 1)
df = 24
# Oboustranný test
p_value_two_sided = 2 * (1 - t.cdf(abs(t_stat), df))
# Pravostranný test
p_value_right = 1 - t.cdf(t_stat, df)
# Levostranný test
p_value_left = t.cdf(t_stat, df)
```

Zamítáme H_0 , pokud p -hodnota $< \alpha$

Jednovýběrový Wilcoxonův test (neparametrická varianta t-testu)

Cíl	Ověřit hypotézu, zda se medián náhodného výběru rovná předpokládané hodnotě μ_0 .
Předpoklady	Data pochází z náhodného výběru, nemusí být z normálního rozdělení.
Nulová hypotéza	H_0 : medián rozdílů mezi pozorováními a μ_0 je nulový.
Alternativní hypotézy	H_1 : medián $\neq \mu_0$ (oboustranný test) H_1 : medián $< \mu_0$ (levostranný test) H_1 : medián $> \mu_0$ (pravostranný test)
Testovací statistika	Na základě pořadí absolutních rozdílů od μ_0 a jejich znamének.
Rozdělení testovacích statistik	Pro větší výběry se používá aproximace pomocí normálního rozdělení.

Vyhodnocení Wilcoxonova testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wilcoxon.html>

```
from scipy.stats import wilcoxon
# Data a hypotetická hodnota
data = [5.1, 4.9, 5.0, 5.2, 5.3]
mu_0 = 5.0
# Výpočet rozdílů
diffs = [x - mu_0 for x in data]
# Wilcoxonův test
stat, p_value = wilcoxon(diffs)
```

Zamítáme H_0 , pokud p -hodnota $< \alpha$

Wilcoxonův test je vhodný, pokud nelze předpokládat normální rozdělení dat.

Jednovýběrový známénkový test

Cíl	Ověřit hypotézu, zda se medián náhodného výběru rovná předpokládané hodnotě μ_0 .
Předpoklady	Data pochází z náhodného výběru, nemusí být z normálního rozdělení.
Nulová hypotéza	H_0 : pravděpodobnost, že hodnota je větší než μ_0 , je 0.5.
Alternativní hypotézy	H_1 : medián $\neq \mu_0$ (oboustranný test) H_1 : medián $< \mu_0$ (levostranný test) H_1 : medián $> \mu_0$ (pravostranný test)
Testovací statistika	Počet kladných a záporných znamének rozdílů od μ_0 (nulové rozdíly se ignorují).
Rozdělení testovací statistiky	Binomické rozdělení $B(n, 0.5)$, kde n je počet nenulových rozdílů.

Vyhodnocení znaménkového testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.binom.html>


```
from scipy.stats import binom
# Počet nenulových rozdílů
n = 20
# Počet kladných znamének
k = 15
# Oboustranný test
p_value_two_sided = 2 * min(binom.cdf(k, n, 0.5),
    1 - binom.cdf(k - 1, n, 0.5))
# Pravostranný test
p_value_right = 1 - binom.cdf(k - 1, n, 0.5)
# Levostranný test
p_value_left = binom.cdf(k, n, 0.5)
```

Zamítáme H_0 , pokud p -hodnota $< \alpha$


Dvouvýběrový t-test — shodné rozptyly

Cíl	Ověřit hypotézu, zda se střední hodnoty dvou nezávislých výběrů μ_1 a μ_2 rovnají.
Předpoklady	Oba výběry pochází z normálního rozdělení se shodným rozptylem . Výběry jsou nezávislé.
Nulová hypotéza	$H_0 : \mu_1 = \mu_2$
Alternativní hypotézy	$H_1 : \mu_1 \neq \mu_2$ (oboustranný test) $H_1 : \mu_1 < \mu_2$ (levostranný test) $H_1 : \mu_1 > \mu_2$ (pravostranný test)
Testovací statistika	$T = \frac{\bar{X}_1 - \bar{X}_2}{s_p \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}, \text{ kde}$ - s_p je společná směrodatná odchylka: $s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$
Rozdělení testovacích statistik	Studentovo t-rozdělení se stupni volnosti $\nu = n_1 + n_2 - 2$

Vizualizace dvouvýběrového testu



Vizualizace dvouvýběrového testu



Vyhodnocení dvouvýběrového t-testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html

```
from scipy.stats import ttest_ind
# Dva nezávislé výběry
sample1 = [5.1, 5.3, 5.0, 5.2]
sample2 = [4.8, 4.9, 5.0, 4.7]
# Dvouvýběrový t-test se shodnými rozptyly
stat, p_value = ttest_ind(sample1, sample2, equal_var=True)
```

Zamítáme H_0 , pokud p -hodnota $< \alpha$

Test je citlivý na odchylky od normality a shodnosti rozptylů — doporučuje se ověřit předpoklady.

Dvouvýběrový t-test — nestejně rozptyly (Welchův test)

Cíl

Ověřit hypotézu, zda se střední hodnoty dvou nezávislých výběrů μ_1 a μ_2 rovnají.

Předpoklady

Výběry pochází z normálního rozdělení, ale **ne-mají shodné rozptyly**. Výběry jsou nezávislé.

Nulová hypotéza

$$H_0 : \mu_1 = \mu_2$$

Alternativní hypotézy

$$H_1 : \mu_1 \neq \mu_2 \quad (\text{oboustranný test})$$

$$H_1 : \mu_1 < \mu_2 \quad (\text{levostranný test})$$

$$H_1 : \mu_1 > \mu_2 \quad (\text{pravostranný test})$$

Testovací statistika


$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Rozdělení testovací statistiky

Aproximace pomocí Studentova t-rozdělení s **efektivními stupni volnosti**:

$$\nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$$

Vizualizace dvouvýběrového testu



Vyhodnocení Welchova t-testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html

```
from scipy.stats import ttest_ind
# Dva nezávislé výběry
sample1 = [5.1, 5.3, 5.0, 5.2]
sample2 = [4.8, 4.9, 5.0, 4.7]
# Welchův t-test (equal_var=False)
stat, p_value = ttest_ind(sample1, sample2, equal_var=False)
```

Zamítáme H_0 , pokud p -hodnota $< \alpha$

Welchův test je robustnější než klasický dvouvýběrový t-test, pokud nejsou rozptyly shodné.

F-test — test shody rozptylů

Cíl	Ověřit hypotézu, zda mají dva nezávislé výběry stejný rozptyl: $\sigma_1^2 = \sigma_2^2$.
Předpoklady	Výběry pochází z normálního rozdělení. Výběry jsou nezávislé.
Nulová hypotéza	$H_0 : \sigma_1^2 = \sigma_2^2$
Alternativní hypotézy	$H_1 : \sigma_1^2 \neq \sigma_2^2$ (oboustranný test) $H_1 : \sigma_1^2 < \sigma_2^2$ (levostranný test) $H_1 : \sigma_1^2 > \sigma_2^2$ (pravostranný test)
Testovací statistika	$F = \frac{s_1^2}{s_2^2}$, kde s_1^2 a s_2^2 jsou výběrové rozptyly.
Rozdělení testovacích statistik	Fisherovo F-rozdělení se stupni volnosti $\nu_1 = n_1 - 1$, $\nu_2 = n_2 - 1$:

$$F \sim F(\nu_1, \nu_2)$$

Vyhodnocení F-testu — pomocí p-hodnoty I.

<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f.html>

```
from scipy.stats import f
# Výběrové rozptyly
s1_sq = np.var(sample1, ddof=1)
s2_sq = np.var(sample2, ddof=1)
# Velikosti výběrů
n1 = len(sample1)
n2 = len(sample2)
# Testovací statistika
F_stat = s1_sq / s2_sq
# Stupně volnosti
v1 = n1 - 1
v2 = n2 - 1
p_value_two_sided = 2 * min(f.cdf(F_stat, v1, v2),
                             1 - f.cdf(F_stat, v1, v2))
p_value_right = 1 - f.cdf(F_stat, v1, v2)
p_value_left = f.cdf(F_stat, v1, v2)
```

F-test je citlivý na odchylky od normality — doporučuje se ověřit předpoklady.

Mann–Whitneyův U test (dvouvýběrový neparametrický test)

Cíl	Ověřit hypotézu, zda se rozdělení dvou nezávislých výběrů liší — typicky testujeme rozdíl mediánů.
Předpoklady	Výběry jsou nezávislé, měření je alespoň ordinální. Není nutné předpokládat normalitu, ale předpokládáme stejné rozdělení.
Nulová hypotéza	H_0 : rozdělení obou výběrů je stejné (žádný rozdíl v mediánu).
Alternativní hypotézy	H_1 : rozdělení se liší (oboustranný test) H_1 : první výběr má menší hodnoty (levostranný test) H_1 : první výběr má větší hodnoty (pravostranný test)
Testovací statistika	Na základě součtu pořadí hodnot z obou výběrů. Výpočet U-statistiky.
Rozdělení testovacích statistik	Pro větší výběry se používá aproximace pomocí normálního rozdělení.

Vyhodnocení Mann–Whitneyova testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V Pythonu: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html>

```
from scipy.stats import mannwhitneyu
# Dva nezávislé výběry
sample1 = [5.1, 5.3, 5.0, 5.2]
sample2 = [4.8, 4.9, 5.0, 4.7]
# Mann{Whitneyův test (oboustranný)
stat, p_value = mannwhitneyu(sample1, sample2,
                             alternative='two-sided')
```

Zamítáme H_0 , pokud $p\text{-hodnota} < \alpha$

Test je vhodný pro data, která nejsou normálně rozdělená nebo mají odlehlé hodnoty.

Další dvouvýběrové neparametrické testy


Test	Použití	Python funkce
Kolmogo- rov–Smirnovův test	Porovnání celých rozdělení dvou výběrů.	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ks_2samp.html
Median test	Test shody mediánů, méně citlivý než Mann–Whitney.	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.median_test.html
Permutační test	Obecný test rozdílu mezi skupinami bez předpokladů.	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.permutation_test.html
Brunner–Munzelův test	Alternativa k Mann–Whitney, nevyžaduje shodné rozptyly.	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.brunnermunzel.html

Neparametrické testy jsou vhodné, pokud nejsou splněny předpoklady normality nebo shodnosti rozptylů.

Párový t-test (test závislých výběrů)

Cíl	Ověřit hypotézu, zda se průměrný rozdíl mezi dvěma závislými měřeními rovná hodnotě δ .
Předpoklady	Rozdíly mezi páry jsou z normálního rozdělení. Výběry jsou závislé (např. měření před a po).
Nulová hypotéza	$H_0: \mu_D = \delta$, kde μ_D je střední hodnota rozdílů.
Alternativní hypotézy	$H_1: \mu_D \neq \delta$ (oboustranný test) $H_1: \mu_D < \delta$ (levostranný test) $H_1: \mu_D > \delta$ (pravostranný test)
Testovací statistika	$T = \frac{\bar{D} - \delta}{s_D / \sqrt{n}}, \text{ kde}$ - $\bar{D}$ je průměr rozdílů, s_D je směrodatná odchylka rozdílů, n je počet párů.
Rozdělení testovacích statistik	Studentovo t-rozdělení se stupni volnosti $\nu = n - 1$

Vizualizace párového t-testu



Vyhodnocení párového t-testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_1samp.html

```
from scipy.stats import ttest_1samp
# Dva závislé výběry (např. před a po)
before = [5.1, 5.3, 5.0, 5.2]
after  = [5.0, 5.1, 4.9, 5.0]
# Rozdíly mezi páry
diffs = [b - a for b, a in zip(before, after)]
# Testujeme, zda průměr rozdílů = delta
delta = 0.2
adjusted_diffs = [d - delta for d in diffs]
# Párový t-test pomocí jednovýběrového testu
stat, p_value = ttest_1samp(adjusted_diffs, popmean=0)
```

Zamítáme H_0 , pokud $p\text{-hodnota} < \alpha$

Test je vhodný pro porovnání měření na stejných objektech v různých podmínkách, i pokud očekáváme konkrétní rozdíl δ .


Vícerozměrná data

- Jednovýběrové testy o vektoru středních hodnot
- Dvouvýběrové testy o shodě vektorů středních hodnot
- Testy o shodě kovariančních matic

Test o vektoru středních hodnot — Hotellingův T^2 test

Cíl	Ověřit hypotézu, zda se vektor středních hodnot vícerozměrného výběru μ rovná hypotetickému vektoru μ_0 .
Předpoklady	Data pochází z vícerozměrného normálního rozdělení. Kovarianční matice Σ je známa.
Nulová hypotéza	$H_0 : \mu = \mu_0$
Alternativní hypotéza	$H_1 : \mu \neq \mu_0$ (oboustranný test)
Testovací statistika	$T^2 = n(\bar{\mathbf{x}} - \mu_0)^\top \Sigma^{-1}(\bar{\mathbf{x}} - \mu_0)$
Rozdělení testovací statistiky	χ^2 -rozdělení: $T^2 \sim \chi_p^2$, kde p je počet proměnných.

Vizualizace 2D shoda s konstantním vektorem (jeden výběr)



Test o vektoru středních hodnot — Hotellingův T^2 test

```
from scipy.stats import chi2
import numpy as np

# Parametry
n = 30
mu_0 = np.array([5.0, 3.0])
sample_mean = np.array([5.2, 3.1])
# známá kovarianční matice
Sigma = np.array([[0.04, 0.01], [0.01, 0.03]])

# Výpočet  $T^2$ 
diff = sample_mean - mu_0
T2 = n * diff.T @ np.linalg.inv(Sigma) @ diff

# p-hodnota
p_value = 1 - chi2.cdf(T2, df=2)
```

Test o vektoru středních hodnot — Hotellingův T^2 test (neznámá Σ , asymptotická verze)

Cíl	Ověřit hypotézu, zda se vektor středních hodnot vícerozměrného výběru μ rovná hypotetickému vektoru μ_0 .
Předpoklady	Data pochází z vícerozměrného normálního rozdělení. Kovarianční matice Σ je neznámá.
Nulová hypotéza	$H_0 : \mu = \mu_0$
Alternativní hypotéza	$H_1 : \mu \neq \mu_0$ (oboustranný test)
Testovací statistika	$-2 \log \lambda = n \cdot \log (1 + (\bar{\mathbf{x}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0))$
Rozdělení testovacích statistik	Asymptoticky: $-2 \log \lambda \sim \chi_p^2$, kde p je počet proměnných.

Hotellingův T^2 test (neznámá Σ , asymptotická verze)

```
import numpy as np
from scipy.stats import chi2

# Parametry
n = 50
mu_0 = np.array([5.0, 3.0])
sample_mean = np.array([5.2, 3.1])
# Odhadnutá kovarianční matice ze vzorku
S = np.array([[0.05, 0.01], [0.01, 0.04]])

# Výpočet testovací statistiky
diff = sample_mean - mu_0
T2 = n * np.log(1 + diff.T @ np.linalg.inv(S) @ diff)

# p-hodnota
p_value = 1 - chi2.cdf(T2, df=2)
```

Test o vektoru středních hodnot — Hotellingův T^2 test (neznámá Σ , exaktní verze)

Cíl	Ověřit hypotézu, zda se vektor středních hodnot vícerozměrného výběru μ rovná hypotetickému vektoru μ_0 .
Předpoklady	Data pochází z vícerozměrného normálního rozdělení. Kovarianční matice Σ je neznámá.
Nulová hypotéza	$H_0 : \mu = \mu_0$
Alternativní hypotéza	$H_1 : \mu \neq \mu_0$ (oboustranný test)
Testovací statistika	$T^2 = n(\bar{\mathbf{x}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \mu_0)$
Rozdělení statistiky	$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$, kde n je počet pozorování, p počet proměnných.

Hotellingův T^2 test (neznámá Σ , exaktní verze)

```
import numpy as np
from scipy.stats import f

# Parametry
n = 30
p = 2
mu_0 = np.array([5.0, 3.0])
sample_mean = np.array([5.2, 3.1])
# Odhadnutá kovarianční matice ze vzorku
S = np.array([[0.05, 0.01], [0.01, 0.04]])
# Výpočet  $T^2$ 
diff = sample_mean - mu_0
T2 = n * diff.T @ np.linalg.inv(S) @ diff
# Přepočet na F-statistiku
F_stat = (n - p) * T2 / (p * (n - 1))
# p-hodnota
p_value = 1 - f.cdf(F_stat, dfn=p, dfd=n - p)
```

Test o kovarianční matici Σ (asymptotický test)

Cíl	Ověřit hypotézu, zda kovarianční matice Σ vícerozměrného normálního rozdělení odpovídá předem dané matici Σ_0 .
Předpoklady	Náhodný výběr $X_1, X_2, \dots, X_n$ z $N_p(\mu, \Sigma)$, μ neznámá.
Nulová hypotéza	$H_0 : \Sigma = \Sigma_0$
Alternativní hypotéza	$H_1 : \Sigma \neq \Sigma_0$
Testovací statistika	$-2 \log \lambda = n \cdot \text{tr}(\Sigma_0^{-1} S) - n \cdot \log \Sigma_0^{-1} S - np$
Rozdělení testovacích statistik	Asymptoticky: $-2 \log \lambda \sim \chi_m^2$, kde $m = \frac{p(p+1)}{2}$ je počet parametrů matice Σ .

Test o kovarianční matici Σ (asymptotický test)

```
import numpy as np
from scipy.stats import chi2
n = 50 # Parametry
p = 3
# Hypotetická kovarianční matice
Sigma_0 = np.array([[1.0, 0.2, 0.1],
                    [0.2, 1.5, 0.3],
                    [0.1, 0.3, 2.0]])
# Odhadnutá kovarianční matice ze vzorku
S = np.cov(data, rowvar=False)
# Výpočet testovací statistiky
inv_Sigma0 = np.linalg.inv(Sigma_0)
term1 = n * np.trace(inv_Sigma0 @ S)
term2 = n * np.log(np.linalg.det(inv_Sigma0 @ S))
T_stat = term1 - term2 - n * p
m = int(p * (p + 1) / 2)
p_value = 1 - chi2.cdf(T_stat, df=m) # p-hodnota
```

Dva vícerozměrné výběry

Uvažujeme náhodný výběr $X_{11}, X_{12}, \dots, X_{1n_1}$ z $N_p(\mu_1, \Sigma)$ a náhodný výběr $X_{21}, X_{22}, \dots, X_{2n_2}$ z $N_p(\mu_2, \Sigma)$ a uvažujeme nulovou hypotézu $H_0 : \mu_1 = \mu_2$, pak pro výběrové statistiky platí

$$\begin{aligned}(\bar{X}_1 - \bar{X}_2) &\sim N_p\left(\mu_1 - \mu_2, \frac{n_1 + n_2}{n_1 n_2} \Sigma\right) \\(n_1 S_1 + n_2 S_2) &\sim W_p(\Sigma, n_1 + n_2 - 2)\end{aligned}$$

a z vlastností normálního a Wishartova rozdělení platí

$$\frac{n_1 n_2 (n_1 + n_2 - 2)}{(n_1 + n_2)^2} ((\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2))^T S^{-1} ((\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)) \sim$$

$$T^2_{(p, n_1 + n_2 - 2)} \text{ a}$$

ze vztahu mezi Hotellingovým a F- rozdělením dostáváme


$$\frac{(n_1 + n_2 - p - 1) n_1 n_2}{p(n_1 + n_2)^2} ((\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2))^T S^{-1} ((\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)) \sim$$

$$F_{p, n_1 + n_2 - p - 1}$$

Test o shodě dvou středních vektorů — Hotellingův T^2 test (známá Σ)

Cíl	Ověřit hypotézu, zda se střední hodnoty dvou vícerozměrných výběrů μ_1 a μ_2 rovnají.
Předpoklady	Dva nezávislé výběry z $N_p(\mu_1, \Sigma)$ a $N_p(\mu_2, \Sigma)$ se stejnou známou kovarianční maticí Σ .
Nulová hypotéza	$H_0 : \mu_1 = \mu_2$
Alternativní hypotéza	$H_1 : \mu_1 \neq \mu_2$ (oboustranný test)
Testovací statistika	$T^2 = \frac{n_1 n_2}{n_1 + n_2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \Sigma^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$
Rozdělení testovacích statistik	$T^2 \sim \chi_p^2$, kde p je počet proměnných.

Vizualizace dvoubýběrový 2D shodná kovariance



Test o shodě dvou středních vektorů — Hotellingův T^2 test (známá Σ)

```
import numpy as np
from scipy.stats import chi2

# Výpočet středních hodnot
x1_bar = np.mean(data1, axis=0)
x2_bar = np.mean(data2, axis=0)

# Známa kovarianční matice
Sigma = np.array([[0.2, 0.05],
                  [0.05, 0.3]])


# Výpočet  $T^2$ 
diff = x1_bar - x2_bar
T2 = (n1 * n2) / (n1 + n2) * diff.T @ np.linalg.inv(Sigma) @ diff

# p-hodnota
p_value = 1 - chi2.cdf(T2, df=p)
```

Test o shodě dvou středních vektorů — neznámé Σ_1 , Σ_2 (asymptotický test)

Cíl	Ověřit hypotézu, zda se střední hodnoty dvou vícerozměrných výběrů μ_1 a μ_2 rovnají.
Předpoklady	Dva nezávislé výběry z $N_p(\mu_1, \Sigma_1)$ a $N_p(\mu_2, \Sigma_2)$, kovarianční matice Σ_1 , Σ_2 jsou neznámé.
Nulová hypotéza	$H_0 : \mu_1 = \mu_2$
Alternativní hypotéza	$H_1 : \mu_1 \neq \mu_2$ (oboustranný test)
Testovací statistika	$T^2 = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \left(\frac{\mathbf{S}_1}{n_1} + \frac{\mathbf{S}_2}{n_2} \right)^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$
Rozdělení testovací statistiky	Asymptoticky: $T^2 \longrightarrow \chi_p^2$, kde p je počet proměnných.

Vizualizace dvouvýběrový 2D neznámé kovariance



Test o shodě dvou středních vektorů — neznámé Σ_1 , Σ_2 (asymptotický test)

```
import numpy as np
from scipy.stats import chi2
n1 = 40, n2 = 35, p = 3 # Parametry
# Generování náhodných vícerozměrných dat
data1 = np.random.multivariate_normal(mean=[1, 2, 3],
                                       cov=np.identity(p), size=n1)
data2 = np.random.multivariate_normal(mean=[1.2, 2.1, 3.2],
                                       cov=2 * np.identity(p), size=n2)
# Výběrové průměry
x1_bar = np.mean(data1, axis=0), x2_bar = np.mean(data2, axis=0)
# Výběrové kovarianční matice
S1 = np.cov(data1, rowvar=False), S2 = np.cov(data2, rowvar=False)
# Testovací statistika
diff = x1_bar - x2_bar
Sigma_hat = S1 / n1 + S2 / n2
T2 = diff.T @ np.linalg.inv(Sigma_hat) @ diff
# p-hodnota
p_value = 1 - chi2.cdf(T2, df=p)
```

Test o shodě dvou kovariančních matic Σ_1, Σ_2 (asymptotický test)

Cíl	Ověřit hypotézu, zda kovarianční matice dvou vícerozměrných výběrů jsou shodné: $\Sigma_1 = \Sigma_2$.
Předpoklady	Dva nezávislé výběry z $N_p(\mu_1, \Sigma_1)$ a $N_p(\mu_2, \Sigma_2)$, střední hodnoty μ_1, μ_2 mohou být různé.
Nulová hypotéza	$H_0 : \Sigma_1 = \Sigma_2$
Alternativní hypotéza	$H_1 : \Sigma_1 \neq \Sigma_2$
Testovací statistika	$-2 \log \lambda = n \log \mathbf{S} - \sum_{j=1}^2 n_j \log \mathbf{S}_j ,$ kde $\mathbf{S} = \frac{n_1 \mathbf{S}_1 + n_2 \mathbf{S}_2}{n_1 + n_2}$ je vážený průměr výběrových kovariančních matic.
Rozdělení testovacích statistik	Asymptoticky: $-2 \log \lambda \sim \chi_m^2$, kde $m = \frac{p(p+1)}{2}$ je počet parametrů kovarianční matice.

Test o shodě dvou kovariančních matic Σ_1, Σ_2 (asymptotický test)

```
import numpy as np
from scipy.stats import chi2
# Parametry
n1 = 40, n2 = 35, p = 3
# Výběrové kovarianční matice
S1 = np.cov(data1, rowvar=False)
S2 = np.cov(data2, rowvar=False)
# Vážený průměr kovariančních matic
S = (n1 * S1 + n2 * S2) / (n1 + n2)
# Testovací statistika
term1 = (n1 + n2) * np.log(np.linalg.det(S))
term2 = n1 * np.log(np.linalg.det(S1)) + n2 *
    np.log(np.linalg.det(S2))
T_stat = term1 - term2
# p-hodnota
m = int(p * (p + 1) / 2)
p_value = 1 - chi2.cdf(T_stat, df=m)
```