KMA/MSM – cvičení 7: Porovnávání středních hodnot pro více skupin

(verze s výsledky)

Výpočty provádějte v Pythonu (`scipy.stats`, `statsmodels`), viz notebook `P07_porovnavani_vice_skupin.ipynb`. Značení: g je počet skupin, n celkový počet pozorování, k počet závislých proměnných. Pokud není řečeno jinak, volte hladinu $\alpha = 0{,}05$.

A. Jednorozměrná data

1. **ANOVA ze souhrnných charakteristik.** Ve třech nezávislých skupinách po $n_j = 6$ pacientech byla změřena doba rekonvalescence (dny):

skupina	1	2	3
$\bar{x}_j$	12,0	15,0	13,0
s_j	1,8	2,1	1,5

   (a) Ručně spočtěte SSB, SSW, MSB, MSW a statistiku F; sestavte tabulku ANOVA a rozhodněte ($F_{0,95}(2, 15) = 3{,}68$).

   (b) Bartlettovým testem ověřte shodu rozptylů ($\chi^2_{0,95}(2) = 5{,}99$).

   (c) Pomocí Tukeyho metody určete, které skupiny se liší. Kritická hodnota studentizovaného rozpětí je $q_{0,95}(3; 15) = 3{,}67$, minimální významný rozdíl je $HSD = q\sqrt{MSW/n_j}$.

   Výsledky: a) $\bar{x} = 13{,}33$; $SSB = 6[(12-13{,}33)^2+(15-13{,}33)^2+(13-13{,}33)^2] = 28{,}0$, $SSW = 5(1{,}8^2 + 2{,}1^2 + 1{,}5^2) = 49{,}5$; $MSB = 14{,}0$ (df = 2), $MSW = 3{,}30$ (df = 15), $F = 4{,}24 > 3{,}68$, $p = 0{,}035$ – shodu středních hodnot zamítáme. b) $s_p^2 = MSW = 3{,}30$; $\chi^2 = 0{,}511$, $p = 0{,}77$ – shodu rozptylů nezamítáme. c) $HSD = 3{,}67\sqrt{3{,}30/6} = 2{,}72$. Rozdíly průměrů: $|1-2| = 3{,}0$ (významný), $|1-3| = 1{,}0$, $|2-3| = 2{,}0$ (nevýznamné). Liší se jen skupiny 1 a 2.

2. **Kompletní analýza tří skupin.** Na pokusných parcelách byl měřen výnos (t/ha) při použití tří hnojiv:

A	5,2	5,8	4,9	6,1	5,5	5,0	5,7	5,4
B	6,3	6,8	5,9	7,2	6,5	6,0	6,9	6,6
C	5,6	6,2	5,1	6,9	5,3	7,4	4,8	6,0

   (a) Data vizualizujte (krabicové grafy), spočtěte výběrové charakteristiky a ověřte normalitu ve skupinách.

   (b) Ověřte shodu rozptylů Bartlettovým, Leveneovým, Brownovým–Forsytheovým a Flignerovým–Killeenovým testem. Který byste zvolili a proč?

   (c) Proveďte klasickou ANOVA a Welchovu ANOVA.

   (d) Proveďte post-hoc analýzu (Tukey HSD, Games–Howell) a porovnejte s párovými t-testy bez korekce a s Holmovou korekcí.

   (e) Proveďte Kruskalův–Wallisův test a Dunnův post-hoc test s Holmovou korekcí. Shrňte, ke kterým závěrům vedou parametrické a neparametrické metody.

Výsledky: a) Průměry 5,45; 6,53; 5,91, směrodatné odchylky 0,41; 0,45; 0,90 (skupina C má výrazně větší rozptyl). Shapirův–Wilkův test: $p = 0{,}93$; 0,91; 0,76. b) Bartlett $p = 0{,}073$, Levene $p = 0{,}053$, Brown–Forsythe $p = 0{,}060$, Fligner–Killeen $p = 0{,}101$ – shodu rozptylů na hladině 5 % nezamítáme, ale těsně (malé n_j, nízká síla testů). Vhodnou výchozí volbou je Brownův–Forsytheův test (robustní). c) ANOVA: $F = 5{,}94$, df $= (2; 21)$, $p = 0{,}009$. Welch: $F = 11{,}96$, df $= (2; 13{,}2)$, $p = 0{,}001$. d) Tukey: liší se pouze A–B ($p = 0{,}007$); A–C $p = 0{,}32$, B–C $p = 0{,}15$. Games–Howell: A–B $p < 0{,}001$, ostatní nevýznamné. Párové t-testy: A–B $p = 0{,}0002$, A–C $p = 0{,}21$, B–C $p = 0{,}11$; po Holmově korekci 0,0006; 0,21; 0,21. e) Kruskal–Wallis: $H = 8{,}71$, $p = 0{,}013$. Dunn (Holm): A–B $p = 0{,}010$, A–C $p = 0{,}23$, B–C $p = 0{,}17$. Všechny přístupy shodně: hnojivo B dává vyšší výnos než A, skupina C se od ostatních průkazně neliší.

3. **Mnohonásobné testování.** Porovnáváme $g = 6$ skupin všemi párovými t-testy.

   (a) Kolik testů provedeme? Jaká je pravděpodobnost alespoň jednoho chybného zamítnutí, jsou-li testy nezávislé, každý na hladině 0,05 a platí-li všechny nulové hypotézy?

   (b) Na jaké hladině je třeba provádět jednotlivé testy při Bonferroniho korekci?

   (c) Seřazené p-hodnoty párových testů jsou

   $$0{,}001;\ 0{,}0035;\ 0{,}006;\ 0{,}012;\ 0{,}020;\ 0{,}031;\ 0{,}045;\ 0{,}08;\ 0{,}11;\ 0{,}19;\ 0{,}27;\ 0{,}35;\ 0{,}48;\ 0{,}62;\ 0{,}83.$$

   Kolik hypotéz zamítneme bez korekce, s Bonferroniho a s Holmovou korekcí?

Výsledky: a) $m = \binom{6}{2} = 15$; $1 - 0{,}95^{15} = 0{,}54$. b) $0{,}05/15 = 0{,}0033$. c) Bez korekce 7 (všechny $p < 0{,}05$). Bonferroni: 1 (pouze $0{,}001 \le 0{,}0033$). Holm: porovnáváme postupně s $0{,}05/15 = 0{,}00333$, $0{,}05/14 = 0{,}00357$, $0{,}05/13 = 0{,}00385, \ldots$: 0,001 i 0,0035 vyhovují, $0{,}006 > 0{,}00385$ – zastavíme; zamítneme 2 hypotézy. Holmova metoda je vždy alespoň tak silná jako Bonferroniho.

4. **Kruskalův–Wallisův test ručně.** Byla měřena koncentrace látky ve třech skupinách:

   $$A:\ 4{,}2;\ 5{,}1;\ 3{,}8;\ 4{,}6 \qquad B:\ 5{,}9;\ 6{,}4;\ 5{,}5;\ 6{,}8 \qquad C:\ 5{,}0;\ 4{,}9;\ 6{,}1;\ 5{,}3$$

   Přiřaďte pořadí ve spojeném výběru, spočtěte součty pořadí R_j a statistiku H a rozhodněte pomocí asymptotického rozdělení ($\chi^2_{0{,}95}(2) = 5{,}99$). Je asymptotická aproximace při $n_j = 4$ spolehlivá?

Výsledky: Pořadí: A: 2, 6, 1, 3 ($R_A = 12$); B: 9, 11, 8, 12 ($R_B = 40$); C: 5, 4, 10, 7 ($R_C = 26$). $H = \frac{12}{12 \cdot 13} \cdot \frac{12^2 + 40^2 + 26^2}{4} - 3 \cdot 13 = 7{,}54 > 5{,}99$, $p = 0{,}023$ – shodu polohy zamítáme. Pro tak malé skupiny je vhodnější exaktní rozdělení H (tabulky nebo permutační test); asymptotika je jen orientační.

5. **Two-way ANOVA – doplnění tabulky.** Byl sledován výnos tří odrůd (a_1, a_2, a_3) při dvou způsobech závlahy (b_1, b_2), v každé kombinaci 4 parcely. Průměry v buňkách:

	b_1	b_2
a_1	19,68	22,98
a_2	21,90	24,95
a_3	19,13	26,83

zdroj	SS	df	MS	F
odrůda A	19,56			
závlaha B	131,60			
interakce AB	27,36			
reziduální	22,02			

   (a) Doplňte tabulku a otestujte všechny tři hypotézy ($F_{0{,}95}(1; 18) = 4{,}41$, $F_{0{,}95}(2; 18) = 3{,}55$).

(b) Nakreslete graf interakcí (průměry v buňkách) a interpretujte. Má smysl interpretovat hlavní efekt odrůdy samostatně?

Výsledky: a) $n = 24$; df: A: 2, B: 1, AB: 2, reziduální $n - ab = 18$. MS: 9,78; 131,60; 13,68; 1,223. F: 8,00 ($p = 0{,}003$); 107,58 ($p < 0{,}001$); 11,18 ($p < 0{,}001$). Všechny tři efekty jsou významné. b) Závlaha b_2 zvyšuje výnos u všech odrůd, ale u a_3 výrazně více (+7,7) než u a_1 (+3,3) a a_2 (+3,1) – čáry v grafu nejsou rovnoběžné. Při významné interakci nemá smysl mluvit o „nejlepší odrůdě“ obecně: při závlaze b_1 je nejlepší odrůda a_2, při závlaze b_2 odrůda a_3. Hlavní efekty je třeba interpretovat po úrovních druhého faktoru.

6. **ANOVA s opakovanými měřeními.** U 6 osob byla změřena hodnota ukazatele před zahájením tréninku (T_0), po 4 týdnech (T_1) a po 8 týdnech (T_2):

osoba	1	2	3	4	5	6
T_0	51	52	54	49	49	47
T_1	53	59	57	52	53	52
T_2	56	59	58	53	53	53

(a) Ručně rozložte celkový součet čtverců na složky „čas“, „osoby“ a reziduální a otestujte vliv času ($F_{0,95}(2; 10) = 4{,}10$). Ověřte pomocí `AnovaRM`.

(b) Analyzujte stejná data chybně jako tři nezávislé skupiny (one-way ANOVA). Proč se výsledky liší?

(c) Jaký další předpoklad je třeba ověřit u ANOVA s opakovanými měřeními? Jakou neparametrickou alternativu byste mohli použít?

Výsledky: a) Celkový průměr 53,33; průměry v čase 50,33; 54,33; 55,33; průměry osob 53,33; 56,67; 56,33; 51,33; 51,67; 50,67. $SS_T = 196$, $SS_{\text{čas}} = 6\sum(\bar{x}_{\cdot t} - \bar{x})^2 = 84$, $SS_{\text{osoby}} = 3\sum(\bar{x}_{i\cdot} - \bar{x})^2 = 102$, $SS_E = 196 - 84 - 102 = 10$. $F = \frac{84/2}{10/10} = 42{,}0$, df $= (2; 10)$, $p < 0{,}001$ – vliv času je významný. b) One-way ANOVA: $F = \frac{84/2}{112/15} = 5{,}63$, $p = 0{,}015$. Variabilita mezi osobami ($SS_{\text{osoby}} = 102$) zůstává v reziduálním součtu čtverců, chyba je proto mnohem větší a test slabší; navíc porušuje předpoklad nezávislosti. c) Sféricitu (Mauchlyho test, případně Greenhouseova–Geisserova korekce). Neparametricky Friedmanův test: $\chi^2 = 11{,}27$, $p = 0{,}004$.

7. **ANCOVA.** Byly porovnány dvě metody výuky. U každého studenta je znám výsledek vstupního testu (*před*) a závěrečného testu (*po*):

metoda A								
před	62	35	53	47	47	49	38	49
po	67	41	60	52	52	58	46	53
metoda B								
před	55	80	61	58	58	56	54	58
po	59	83	70	62	62	63	56	61

(a) Porovnejte výsledky závěrečného testu obou metod pomocí ANOVA (bez kovariáty).

(b) Ověřte předpoklad shodných směrnic (model s interakcí metoda × před).

(c) Proveďte ANCOVA s kovariátou *před*. Jak se změnil závěr? Interpretujte odhad efektu metody.

Výsledky: a) Průměry *po*: A 53,6, B 64,5; $F = 6{,}87$, $p = 0{,}020$ – metoda B se zdá lepší. b) Interakce: $p = 0{,}86$ – shodné směrnice lze předpokládat. c) ANCOVA: metoda $p = 0{,}41$, kovariáta $p < 0{,}001$ (směrnice 0,96). Upravený rozdíl $B - A$ je $-1{,}1$ bodu. Skupina B měla vyšší vstupní úroveň (průměr *před* 60,0 vs. 47,5); po jejím zohlednění se metody neliší. Rozdíl v ANOVA byl způsoben rozdílnou startovní úrovní, nikoli metodou (u neznáhodněných skupin ale ANCOVA neodstraní vliv neměřených proměnných).

B. Vícerozměrná data

8. **MANOVA ručně.** Ve $g = 3$ skupinách s celkovým počtem $n = 30$ pozorování byly sledovány $k = 2$ proměnné. Matice součtů čtverců a součinů jsou

$$\boldsymbol{H} = \begin{pmatrix} 30 & 12 \\ 12 & 20 \end{pmatrix}, \qquad \boldsymbol{E} = \begin{pmatrix} 60 & 10 \\ 10 & 40 \end{pmatrix}.$$

   (a) Spočtěte Wilksovu lambdu $\Lambda = |\boldsymbol{E}|/|\boldsymbol{E} + \boldsymbol{H}|$.

   (b) Najděte vlastní čísla matice $\boldsymbol{E}^{-1}\boldsymbol{H}$ a z nich spočtěte všechny čtyři statistiky MANOVA. Ověřte, že $\Lambda = \prod_i (1 + \lambda_i)^{-1}$.

   (c) Otestujte $H_0 : \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 = \boldsymbol{\mu}_3$ pomocí Bartlettovy aproximace $-\left(n - 1 - \frac{k+g}{2}\right) \ln \Lambda \approx \chi^2_{k(g-1)}$ ($\chi^2_{0{,}95}(4) = 9{,}49$). Pro $k = 2$ je exaktní transformace $F = \frac{1-\sqrt{\Lambda}}{\sqrt{\Lambda}} \cdot \frac{n-g-1}{g-1} \sim F_{2(g-1),\,2(n-g-1)}$; spočtěte i ji.

Výsledky: a) $|\boldsymbol{E}| = 2300$, $|\boldsymbol{E} + \boldsymbol{H}| = \begin{vmatrix} 90 & 22 \\ 22 & 60 \end{vmatrix} = 4916$, $\Lambda = 0{,}468$. b) $\lambda_1 = 0{,}619$, $\lambda_2 = 0{,}320$; Wilks $\frac{1}{1{,}619 \cdot 1{,}320} = 0{,}468$; Pillai $\frac{0{,}619}{1{,}619} + \frac{0{,}320}{1{,}320} = 0{,}625$; Hotelling–Lawley 0,939; Roy 0,619. c) $-(29 - 2{,}5) \ln 0{,}468 = 20{,}13 > 9{,}49$, $p < 0{,}001$. Exaktně $F = 6{,}01$, df $= (4; 52)$, $p < 0{,}001$. Vektory středních hodnot se liší.

9. **MANOVA v Pythonu – data Iris.** Použijte data `sklearn.datasets.load_iris`.

   (a) Pro proměnné délka a šířka kališního lístku (SL, SW) proveďte MANOVA s faktorem druh a uveďte všechny čtyři statistiky.

   (b) Proveďte pro obě proměnné samostatné ANOVA. Jaký je rozdíl mezi jedním testem MANOVA a dvěma testy ANOVA?

   (c) Boxovým M-testem ověřte shodu kovariančních matic. Kterou statistiku MANOVA byste při jejím porušení preferovali?

   (d) Proveďte MANOVA pro všechny čtyři proměnné, ale jen pro druhy *versicolor* a *virginica*. Proč dávají všechny čtyři statistiky stejnou hodnotu F? Jakému testu z P06 to odpovídá?

Výsledky: a) Wilks 0,167 ($F = 105{,}9$), Pillai 0,945 ($F = 65{,}9$), Hotelling–Lawley 4,33, Roy 4,17; vše $p < 0{,}001$. b) ANOVA: SL $F = 119{,}3$, SW $F = 49{,}2$, obě $p < 0{,}001$. MANOVA je jeden test na hladině α a využívá korelaci proměnných; dvě ANOVA zvyšují celkovou chybu I. druhu a mohou přehlédnout rozdíl, který se projeví jen v kombinaci proměnných. c) Box M: $\chi^2 = 35{,}7$, df $= 6$, $p < 0{,}001$ – kovarianční matice se liší; nejrobustnější je Pillaiova stopa. d) Pro $g = 2$ je $s = \min(k, g - 1) = 1$, matice $\boldsymbol{E}^{-1}\boldsymbol{H}$ má jediné nenulové vlastní číslo a všechny statistiky jsou jeho funkcemi: $\Lambda = 0{,}216$, $F = 86{,}15$, df $= (4; 95)$, $p < 0{,}001$. Odpovídá to dvouvýběrovému Hotellingovu T^2 testu.