Přednáška 7: Porovnávání středních hodnot pro více skupin

Mnohonásobné porovnávání. ANOVA one-way a two-way. Metody multicompare analýzy. Kruskal-Wallisův test. MANOVA.

KMA/MSM Blanka Šedivá

verze 2026/2027

6. října 2026

Obsah

1. Jednorozměrná data
   - Více výběrů (shoda g středních hodnot)
     - Shoda rozptylů pro více výběrů
     - Mnohonásobné porovnávání
     - Neparametrická varianta
   - Více faktorů
2. Vícerozměrná data
   - Více výběrů (shoda vektorů středních hodnot pro více výběrů)

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Jednorozměrná data – porovnávání více skupin

- ANOVA – test o shodě středních hodnot, parametrický (one-way)
- Testy o shodě rozptylů pro více výběrů
- Post-hoc analýzy (metody multicompare)
- Kruskal-Wallisův test o shodě polohy – neparametrický
- Two-way ANOVA, ANOVA s opakovanými měřeními, three-way ANOVA, ANCOVA

Počet skupin značíme g, celkový počet pozorování $n = n_1 + \cdots + n_g$ (písmeno k je vyhrazeno pro dimenzi dat).
Ukázky v Pythonu: notebook `P07_porovnavani_vice_skupin.ipynb`.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Proč ne opakované t-testy?

- Při porovnání g skupin dvojicemi provedeme $m = \binom{g}{2}$ testů.
- Pokud každý provedeme na hladině α, je pravděpodobnost alespoň jednoho chybného zamítnutí (pro nezávislé testy)

$$1 - (1 - \alpha)^m,$$

  např. pro $g = 5$ skupin ($m = 10$ testů) a $\alpha = 0{,}05$ je to přibližně 0,40.
- Proto nejprve testujeme **jednou** společnou hypotézu $H_0 : \mu_1 = \cdots = \mu_g$ (ANOVA) a teprve po jejím zamítnutí hledáme, které skupiny se liší, pomocí metod s kontrolou celkové chyby (post-hoc testy).

One-way ANOVA – test shody středních hodnot ve více skupinách

Cíl
Ověřit, zda se střední hodnoty g nezávislých skupin rovnají.

Model
$X_{ij} = \mu + \alpha_j + \varepsilon_{ij}$, $\varepsilon_{ij} \sim N(0, \sigma^2)$ nezávislé, $i = 1, \ldots, n_j$, $j = 1, \ldots, g$.

Předpoklady
Každá skupina je tvořena nezávislým náhodným výběrem z normálního rozdělení. Všechny skupiny mají stejný rozptyl (homoskedasticita).

Nulová hypotéza
$H_0 : \mu_1 = \mu_2 = \cdots = \mu_g$

Alternativní hypotéza
Alespoň dvě střední hodnoty se liší.

Testovací statistika
$F = \dfrac{MSB}{MSW}$, kde:
MSB (meziskupinová variabilita) měří rozdíly mezi skupinovými průměry a celkovým průměrem,
MSW (vnitroskupinová variabilita) měří rozptyl uvnitř jednotlivých skupin.

Rozdělení testovací statistiky
$F \sim F_{g-1,\, n-g}$, kde n je celkový počet pozorování a g počet skupin.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

One-way ANOVA – meziskupinová variabilita (MSB)

Definice

Meziskupinová variabilita (Mean Square Between, MSB) měří rozdíly mezi průměry jednotlivých skupin a celkovým průměrem.

Význam

Pokud jsou skupinové průměry výrazně odlišné od celkového průměru, MSB bude velká. To může naznačovat, že alespoň jedna skupina má jinou střední hodnotu.

Výpočet

$$MSB = \frac{SSB}{g-1} = \frac{1}{g-1}\sum_{j=1}^{g} n_j(\bar{x}_j - \bar{x})^2,$$

kde g je počet skupin, n_j počet pozorování ve skupině j, $\bar{x}_j$ průměr skupiny j a $\bar{x}$ celkový průměr všech dat.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

One-way ANOVA – vnitroskupinová variabilita (MSW)

Definice Vnitroskupinová variabilita (Mean Square Within, MSW) měří rozptyl hodnot uvnitř jednotlivých skupin.

Význam Pokud jsou hodnoty uvnitř každé skupiny blízko svému skupinovému průměru, MSW bude malá. Vysoká MSW značí velkou variabilitu uvnitř skupin. MSW je nestranným odhadem σ^2 (sdružený rozptyl).

Výpočet

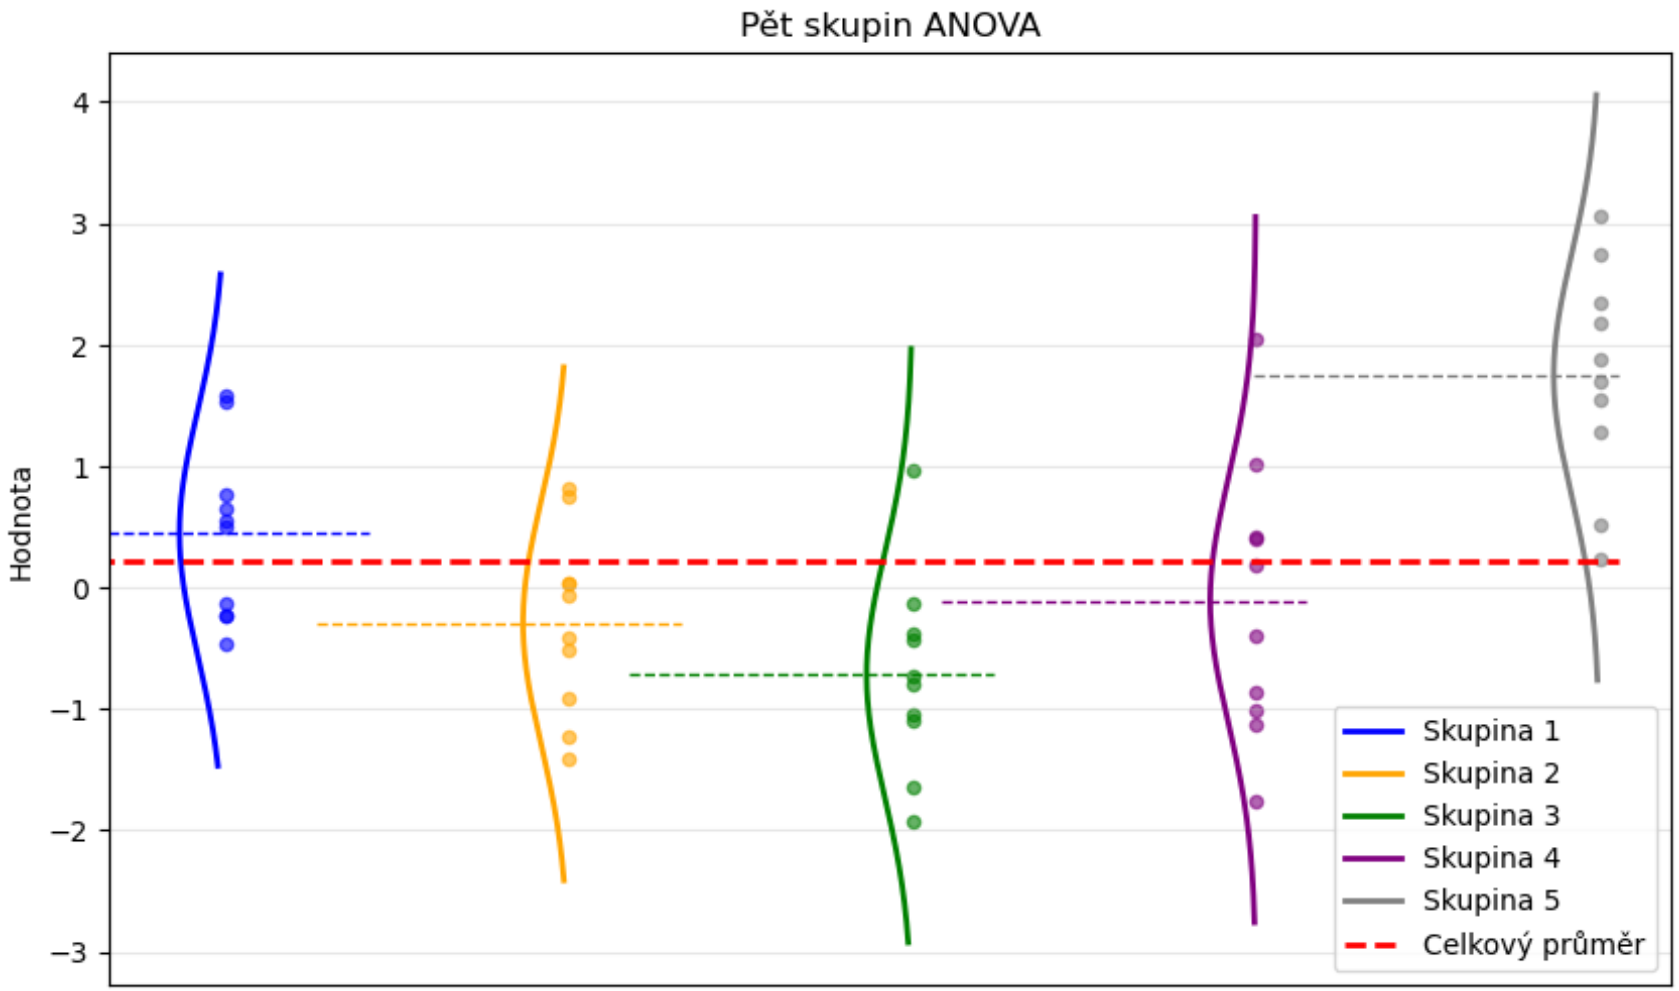
$$MSW = \frac{SSW}{n-g} = \frac{1}{n-g}\sum_{j=1}^{g}\sum_{i=1}^{n_j}(x_{ij}-\bar{x}_j)^2,$$

kde n je celkový počet pozorování, g počet skupin, x_{ij} je i-tá hodnota ve skupině j, $\bar{x}_j$ je průměr skupiny j.

Rozklad $SST = \sum_j \sum_i (x_{ij}-\bar{x})^2 = SSB + SSW$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vizualizace ANOVA



Vyhodnocení one-way ANOVA – pomocí p-hodnoty I.

P-hodnotu lze vypočítat pomocí software (např. Python, R, Excel). V Pythonu:
https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f_oneway.html
https://www.statsmodels.org/stable/anova.html

```
import numpy as np
from scipy.stats import f, f_oneway

# Tři skupiny po 10 pozorováních
rng = np.random.default_rng(42)
groups = [rng.normal(loc=m, scale=1.0, size=10)
          for m in (5.0, 5.5, 6.0)]
g = len(groups)                                  # počet skupin
n = sum(len(x) for x in groups)                  # celkový počet
means = [x.mean() for x in groups]
overall_mean = np.concatenate(groups).mean()
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vyhodnocení one-way ANOVA – pomocí p-hodnoty II.

```
# Meziskupinová variabilita (MSB)
SSB = sum(len(x) * (m - overall_mean)**2
          for x, m in zip(groups, means))
MSB = SSB / (g - 1)

# Vnitroskupinová variabilita (MSW)
SSW = sum(((x - m)**2).sum() for x, m in zip(groups, means))
MSW = SSW / (n - g)

# F-statistika a p-hodnota
F_stat = MSB / MSW
p_value = f.sf(F_stat, dfn=g - 1, dfd=n - g)

print(F_stat, p_value)
print(f_oneway(*groups))                    # kontrola
```

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Shoda rozptylů pro více výběrů – přehled testů a jejich principů I.

Bartlettův test

Parametrický test založený na porovnání logaritmu sdruženého rozptylu s_p^2 a logaritmů rozptylů jednotlivých skupin.

Testovací statistika: $\chi^2 = \frac{(n-g)\ln s_p^2 - \sum_{j=1}^{g}(n_j-1)\ln s_j^2}{1+\frac{1}{3(g-1)}\left(\sum_{j=1}^{g}\frac{1}{n_j-1}-\frac{1}{n-g}\right)}$,

kde $s_p^2 = \frac{1}{n-g}\sum_j (n_j-1)s_j^2$ je sdružený rozptyl ($= MSW$), s_j^2 rozptyl ve skupině j, n_j počet pozorování ve skupině j, $n = \sum n_j$.

Testovací statistika má asymptoticky χ^2 rozdělení s $g-1$ stupni volnosti.

Velmi citlivý na odchylky od normality – i malá odchylka může vést k chybnému zamítnutí H_0.

Vhodný pouze při splnění předpokladu normality.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Shoda rozptylů pro více výběrů – přehled testů a jejich principů II.

Leveneův test

Testuje shodu rozptylů pomocí jednofaktorové ANOVY aplikované na absolutní odchylky hodnot od skupinového průměru: $z_{ij} = |x_{ij} - \bar{x}_j|$.
Poté se testuje, zda se střední hodnoty z_{ij} ve skupinách liší.
Méně citlivý na nenormální rozdělení než Bartlettův test.

Brown-Forsytheův test

Varianta Leveneova testu, která místo průměrů používá mediány: $z_{ij} = |x_{ij} - \text{median}_j|$.
Následně se provede ANOVA nad těmito odchylkami.
Ještě robustnější vůči odlehlým hodnotám a zešikmeným rozdělením. Doporučená výchozí volba.
Pozor: `scipy.stats.levene` má výchozí `center="median"`, tj. provádí Brown-Forsytheův test; klasický Leveneův test je `center="mean"`.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Shoda rozptylů pro více výběrů – přehled testů a jejich principů III.

Fligner-Killeenův test

Neparametrický test založený na pořadích.
Nevyžaduje normalitu.
Velmi robustní vůči odlehlým hodnotám a vhodný pro široké spektrum dat, včetně silně nenormálních.
Pro každé pozorování x_{ij} ve skupině j se spočítá absolutní odchylka od mediánu skupiny: $z_{ij} = |x_{ij} - \text{median}_j|$.
Odchylky z_{ij} se seřadí, přiřadí se jim pořadí r_{ij} a ta se transformují pomocí kvantilové funkce normálního rozdělení: $a_{ij} = \Phi^{-1}\left(\frac{1}{2} + \frac{r_{ij}}{2(n+1)}\right)$.
Testovací statistika má tvar $X^2 = \frac{1}{s^2}\sum_{j=1}^{g} n_j(\bar{a}_j - \bar{a})^2$,
kde s^2 je rozptyl všech a_{ij}, $\bar{a}_j$ je průměr transformovaných hodnot ve skupině j a $\bar{a}$ celkový průměr.
Statistika má asymptoticky χ^2 rozdělení s $g - 1$ stupni volnosti.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Testy shody rozptylů v Pythonu

```
https://docs.scipy.org/doc/scipy/reference/stats.html#
hypothesis-tests

from scipy.stats import bartlett, levene, fligner

print(bartlett(*groups))                    # Bartlett
print(levene(*groups, center="mean"))       # Levene
print(levene(*groups, center="median"))     # Brown-Forsythe
print(fligner(*groups))                     # Fligner-Killeen
```

Pokud se rozptyly liší, lze místo klasické ANOVA použít Welchovu ANOVA (zobecnění Welchova t-testu), např. `statsmodels.stats.oneway.anova_oneway(..., use_var="unequal")`.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

One-way ANOVA – post-hoc testy

Účel post-hoc testů	Používají se po zamítnutí nulové hypotézy v ANOVA k určení, které skupiny se statisticky významně liší, při kontrole celkové pravděpodobnosti chyby I. druhu (family-wise error rate).
Tukey HSD	Testuje všechny párové rozdíly mezi skupinami. Předpokládá shodné rozptyly; pro nestejné velikosti skupin se používá varianta Tukey-Kramer. Dobrá rovnováha mezi chybovostí a silou.
Bonferroni	Každé z m srovnání testuje na hladině α/m. Vhodný pro předem definované hypotézy. Konzervativní, snižuje sílu testu při mnoha srovnáních.
Holm	Sekvenční korekce p-hodnot (seřazené p-hodnoty porovnáváme s $\alpha/m, \alpha/(m-1), \ldots$). Vždy alespoň tak silná jako Bonferroniho korekce.
Scheffé	Umožňuje testovat libovolné lineární kontrasty. Velmi flexibilní, ale konzervativní pro párová srovnání.
Games-Howell	Nepředpokládá shodu rozptylů ani velikostí skupin. Vhodný při porušení předpokladu homoskedasticity.
Dunnett	Porovnává všechny skupiny vůči jedné kontrolní. Efektivní pro experimenty s kontrolní skupinou.

Poznámka: Výběr testu závisí na cíli analýzy, počtu skupin, velikosti vzorků a splnění předpokladů ANOVA.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Post-hoc testy v Pythonu

```
https://www.statsmodels.org/dev/generated/statsmodels.stats.multicomp.
pairwise_tukeyhsd.html

import numpy as np
from itertools import combinations
from scipy.stats import ttest_ind, dunnett
from statsmodels.stats.multicomp import pairwise_tukeyhsd
from statsmodels.stats.multitest import multipletests

data = np.concatenate(groups)
labels = np.repeat(["Skupina 1", "Skupina 2", "Skupina 3"], 10)
tukey = pairwise_tukeyhsd(endog=data, groups=labels, alpha=0.05)
print(tukey)                                        # Tukey HSD

pairs = list(combinations(range(g), 2))             # párové t-testy
p_raw = [ttest_ind(groups[i], groups[j]).pvalue for i, j in pairs]
rej, p_holm, _, _ = multipletests(p_raw, alpha=0.05, method="holm")

print(dunnett(groups[1], groups[2], control=groups[0]))   # Dunnett
```

Kruskal-Wallisův test – test shody polohy ve více skupinách

Cíl
Ověřit, zda se rozdělení g nezávislých skupin liší polohou (zobecnění Mann-Whitneyova testu).

Předpoklady
Nezávislé výběry, měřítko alespoň ordinální. Nepředpokládá normální rozdělení. Pro interpretaci jako test o mediánech předpokládáme stejný tvar rozdělení ve skupinách.

Nulová hypotéza
H_0: všechny skupiny mají stejné rozdělení (při stejném tvaru: stejný medián).

Alternativní hypotéza
Alespoň jedna skupina má rozdělení posunuté oproti ostatním.

Testovací statistika
$$H = \frac{12}{n(n+1)} \sum_{j=1}^{g} \frac{R_j^2}{n_j} - 3(n+1), \text{ kde}$$
n je celkový počet pozorování, n_j počet pozorování ve skupině j, R_j součet pořadí ve skupině j (ve spojeném výběru). Při shodných hodnotách se použije korekce.

Rozdělení testovací statistiky
$H \sim \chi^2_{g-1}$ (asymptoticky, při dostatečně velkém n_j).

Post-hoc
Dunnův test s korekcí p-hodnot (Holm, Bonferroni).

Vyhodnocení Kruskal-Wallisova testu – pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí software (např. Python, R, Excel). V Pythonu: `https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.kruskal.html`

```
import numpy as np
from scipy.stats import kruskal

# Tři skupiny po 10 pozorováních
rng = np.random.default_rng(42)
group1 = rng.normal(loc=5.0, scale=1.0, size=10)
group2 = rng.normal(loc=5.5, scale=1.0, size=10)
group3 = rng.normal(loc=6.0, scale=1.0, size=10)

# Kruskal-Wallisův test
stat, p_value = kruskal(group1, group2, group3)
```

Two-way ANOVA – test vlivu dvou faktorů

Cíl	Ověřit vliv dvou faktorů (A s a úrovněmi a B s b úrovněmi) na závislou proměnnou, včetně interakce mezi faktory.
Model	$X_{ijl} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijl}$, $\varepsilon_{ijl} \sim N(0, \sigma^2)$ nezávislé.
Předpoklady	Nezávislá pozorování, normální rozdělení reziduí, homoskedasticita.
Nulové hypotézy	H_0^A: všechna $\alpha_i = 0$ (faktor A nemá vliv). H_0^B: všechna $\beta_j = 0$ (faktor B nemá vliv). H_0^{AB}: všechna $(\alpha\beta)_{ij} = 0$ (interakce neexistuje).
Testovací statistika	Pro každý efekt se počítá F-statistika $F = \frac{MS_{\text{efekt}}}{MS_{\text{chyba}}}$.
Rozdělení testovací statistiky	$F \sim F_{df_{\text{efekt}}, df_{\text{chyba}}}$, kde $df_A = a - 1$, $df_B = b - 1$, $df_{AB} = (a-1)(b-1)$, $df_{\text{chyba}} = n - ab$.
Interpretace	Při významné interakci nelze vliv jednoho faktoru interpretovat bez ohledu na úroveň druhého (graf interakcí).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vyhodnocení two-way ANOVA – pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:
`https://www.statsmodels.org/stable/anova.html`

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols

rng = np.random.default_rng(1)
A = np.repeat(["a1", "a2", "a3"], 20)           # faktor A, 3 úrovně
B = np.tile(np.repeat(["b1", "b2"], 10), 3)     # faktor B, 2 úrovně
y = (10 + (A == "a2") * 1.0 + (B == "b2") * 0.8
     + ((A == "a3") & (B == "b2")) * 1.5 + rng.normal(0, 1, 60))
data = pd.DataFrame({"vysledek": y, "faktor_A": A, "faktor_B": B})

# C(A) * C(B) = hlavní efekty + interakce
model = ols("vysledek ~ C(faktor_A) * C(faktor_B)", data=data).fit()
anova_table = sm.stats.anova_lm(model, typ=2)
print(anova_table)
```

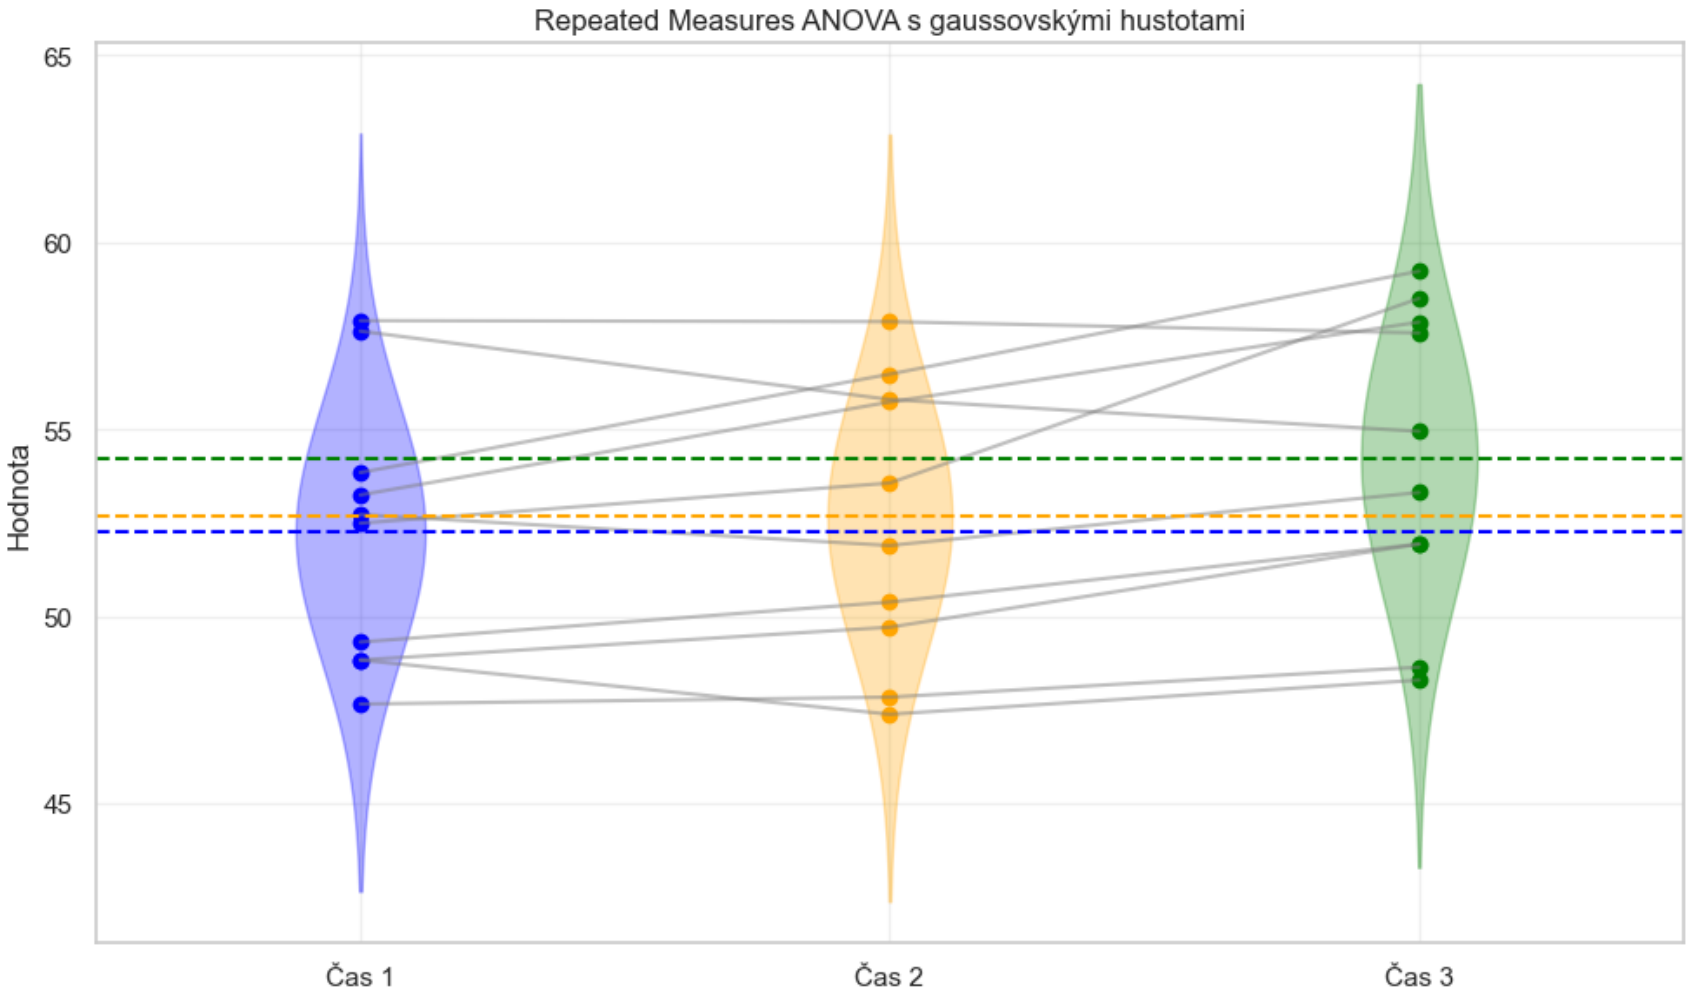
FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

ANOVA s opakovanými měřeními (repeated measures ANOVA)

Cíl	Ověřit, zda se střední hodnoty mění v čase nebo mezi podmínkami u stejných subjektů (zobecnění párového t-testu).
Předpoklady	Nezávislost subjektů, normální rozdělení, **sféricita** – rozptyly rozdílů mezi všemi dvojicemi podmínek jsou shodné. Sféricitu ověřuje Mauchlyho test; při jejím porušení se stupně volnosti opravují (Greenhouse-Geisser, Huynh-Feldt).
Nulová hypotéza	H_0: střední hodnoty ve všech podmínkách jsou stejné.
Alternativní hypotéza	Alespoň jedna podmínka má odlišnou střední hodnotu.
Testovací statistika	$F = \frac{MS_{\text{podmínka}}}{MS_{\text{chyba}}}$, kde variabilita mezi subjekty je z chyby odečtena.
Rozdělení testovací statistiky	$F \sim F_{df_{\text{podmínka}}, df_{\text{chyba}}}$, pro s subjektů a c podmínek $df_{\text{podmínka}} = c - 1$, $df_{\text{chyba}} = (s-1)(c-1)$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vizualizace ANOVA s opakovanými měřeními



Vyhodnocení ANOVA s opakovanými měřeními – pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`: `https://www.statsmodels.org/stable/generated/statsmodels.stats.anova.AnovaRM.html`

```
import numpy as np
import pandas as pd
from statsmodels.stats.anova import AnovaRM

rng = np.random.default_rng(2)
s, c = 12, 3                                    # subjekty, podmínky
osoba = rng.normal(0, 2, s)                     # efekt subjektu
rows = [{"subjekt": i, "cas": t,
         "vysledek": 10 + osoba[i] + 0.5 * t + rng.normal(0, 1)}
        for i in range(s) for t in range(c)]
data = pd.DataFrame(rows)

res = AnovaRM(data, depvar="vysledek", subject="subjekt",
              within=["cas"]).fit()
print(res)
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vyhodnocení three-way ANOVA – pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols
# data: DataFrame se sloupci vysledek, faktor_A, faktor_B,
# faktor_C (každá kombinace úrovní s více pozorováními)

# C(A) * C(B) * C(C) = hlavní efekty + všechny interakce
model = ols("vysledek ~ C(faktor_A) * C(faktor_B) * C(faktor_C)",
            data=data).fit()
anova_table = sm.stats.anova_lm(model, typ=2)
```

S rostoucím počtem faktorů rychle roste počet interakcí a potřebný počet pozorování.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

ANCOVA – analýza kovariance

Cíl
Kombinuje ANOVA a lineární regresi: testuje vliv jednoho nebo více faktorů na závislou proměnnou **při kontrole vlivu kovariát**.

Model
$Y_{ij} = \mu + \alpha_j + \beta(x_{ij} - \bar{x}) + \varepsilon_{ij}$.

Rozdíl oproti ANOVA
ANCOVA zahrnuje **kovariáty** (spojité proměnné), které vysvětlují část variability, čímž zvyšuje přesnost odhadu efektů faktorů.

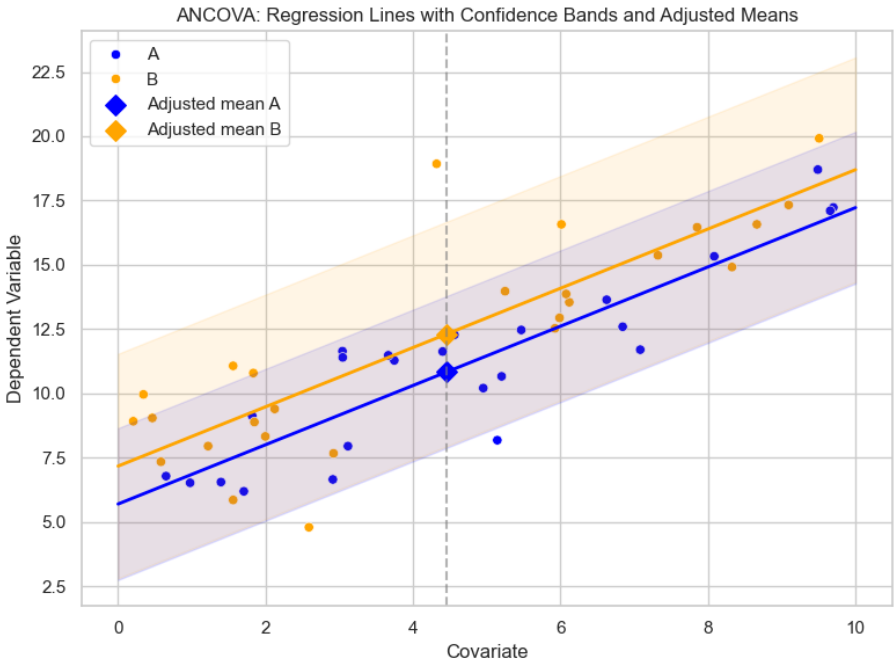
Předpoklady
Lineární vztah mezi kovariátou a závislou proměnnou, **shodné směrnice** ve všech skupinách (bez interakce faktor $\times$ kovariáta), homoskedasticita, normální rozdělení reziduí, nezávislost pozorování.

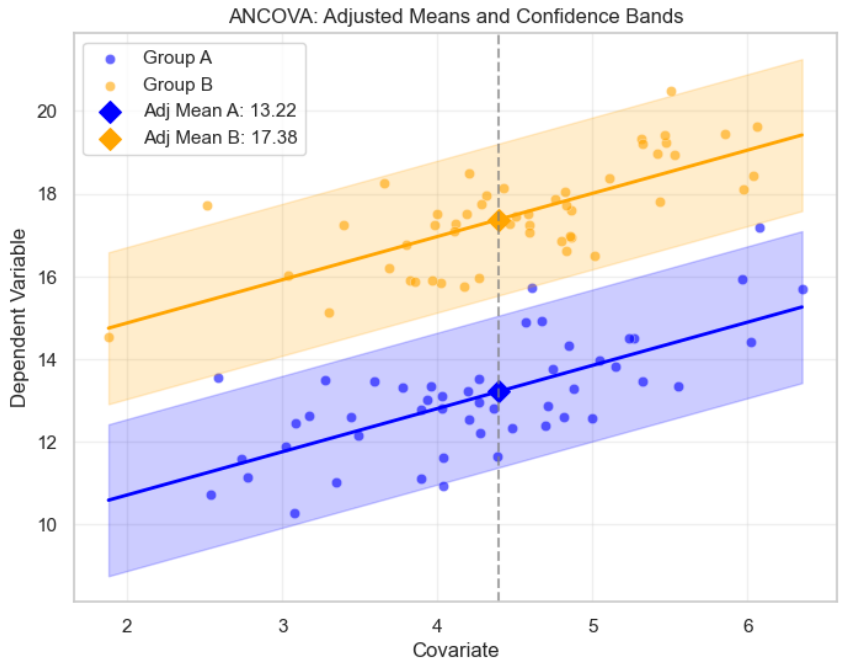
Nulová hypotéza
H_0: po zohlednění kovariát nemají faktory vliv na závislou proměnnou.

Použití
Např. porovnání účinku léčby při kontrole věku nebo počátečního stavu.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vizualizace ANCOVA





FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Vyhodnocení ANCOVA – pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols

rng = np.random.default_rng(3)
faktor = np.repeat(["A", "B"], 25)              # typ tréninku
kovariata = rng.normal(40, 5, 50)               # počáteční kondice
vysledek = (5 + 0.8 * kovariata + (faktor == "B") * 2
            + rng.normal(0, 2, 50))
data = pd.DataFrame({"vysledek": vysledek, "faktor": faktor,
                     "kovariata": kovariata})

# ověření shodných směrnic (interakce by měla být nevýznamná)
m_int = ols("vysledek ~ C(faktor) * kovariata", data=data).fit()
print(sm.stats.anova_lm(m_int, typ=2))
# model ANCOVA
model = ols("vysledek ~ C(faktor) + kovariata", data=data).fit()
print(sm.stats.anova_lm(model, typ=2))
```

ANCOVA – praktický příklad

Scénář	Porovnáváme účinek dvou typů tréninku na skóre fyzické kondice po programu.
Proměnné	**Výsledek**: skóre kondice po programu. **Faktor**: typ tréninku (A = aerobní, B = silový). **Kovariáta**: počáteční úroveň kondice (např. VO_2 max).
Proč ANCOVA?	Zohledňuje vliv počáteční kondice, aby rozdíly mezi skupinami nebyly zkresleny tím, že jedna skupina začínala s vyšší úrovní.
Interpretace	Pokud je p-hodnota pro faktor `typ tréninku` menší než 0,05 i po zohlednění kovariáty, rozdíl mezi tréninky nelze vysvětlit rozdílnou startovní úrovní. U neznáhodněných skupin ale ANCOVA neodstraní vliv jiných, neměřených proměnných.

Praktický význam: ANCOVA zvyšuje přesnost odhadu efektů tím, že odstraní část variability vysvětlenou kovariátou.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Vícerozměrná data – porovnávání více skupin

- MANOVA – test o shodě vektorů středních hodnot
- Testovací statistiky MANOVA (Wilks, Pillai, Hotelling-Lawley, Roy)
- MANCOVA – test o shodě vektorů středních hodnot s kovariátami

k je počet závislých proměnných (dimenze), g počet skupin, n celkový počet pozorování.

MANOVA – vícerozměrná analýza rozptylu

Cíl	Testovat vliv jednoho nebo více faktorů na **více závislých proměnných současně**.
Model	$\boldsymbol{X}_{ij} = \boldsymbol{\mu} + \boldsymbol{\alpha}_j + \boldsymbol{\varepsilon}_{ij}$, $\boldsymbol{\varepsilon}_{ij} \sim N_k(\mathbf{0}, \boldsymbol{\Sigma})$ nezávislé, $j = 1, \ldots, g$.
Rozdíl oproti ANOVA	ANOVA testuje jednu závislou proměnnou, zatímco MANOVA bere v úvahu korelace mezi více závislými proměnnými. Odpovídá jednomu testu místo k samostatných ANOVA.
Předpoklady	Vícerozměrná normalita, **shodné varianční matice** ve všech skupinách (Boxův M-test, P06), nezávislost pozorování.
Nulová hypotéza	H_0: $\boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 = \cdots = \boldsymbol{\mu}_g$ – vektor středních hodnot závislých proměnných je stejný ve všech skupinách.
Testovací statistiky	Wilksova lambda, Pillaiova stopa, Hotellingova-Lawleyho stopa, Royova největší vlastní hodnota.

Použití: Např. při zkoumání vlivu léčby na více fyziologických ukazatelů současně.
Pro $g = 2$ je MANOVA ekvivalentní dvouvýběrovému Hotellingovu T^2 testu (P06).

MANOVA – rozklad variability

Obdobou součtů čtverců jsou matice součtů čtverců a součinů (SSCP) typu $k \times k$:

$$\boldsymbol{H} = \sum_{j=1}^{g} n_j(\overline{\boldsymbol{x}}_j - \overline{\boldsymbol{x}})(\overline{\boldsymbol{x}}_j - \overline{\boldsymbol{x}})^T \qquad \text{(meziskupinová, hypotéza)},$$

$$\boldsymbol{E} = \sum_{j=1}^{g}\sum_{i=1}^{n_j}(\boldsymbol{x}_{ij} - \overline{\boldsymbol{x}}_j)(\boldsymbol{x}_{ij} - \overline{\boldsymbol{x}}_j)^T \qquad \text{(vnitroskupinová, chyba)},$$

$\boldsymbol{T} = \boldsymbol{H} + \boldsymbol{E}$. Statistiky jsou funkcemi vlastních čísel $\lambda_1 \geq \cdots \geq \lambda_s$ matice $\boldsymbol{E}^{-1}\boldsymbol{H}$, $s = \min(k, g-1)$:

Wilksova lambda	$\Lambda = \dfrac{\lvert\boldsymbol{E}\rvert}{\lvert\boldsymbol{E}+\boldsymbol{H}\rvert} = \prod_i \dfrac{1}{1+\lambda_i}$
Pillaiova stopa	$V = \operatorname{tr}\left(\boldsymbol{H}(\boldsymbol{H}+\boldsymbol{E})^{-1}\right) = \sum_i \dfrac{\lambda_i}{1+\lambda_i}$
Hotellingova-Lawleyho stopa	$U = \operatorname{tr}\left(\boldsymbol{H}\boldsymbol{E}^{-1}\right) = \sum_i \lambda_i$
Royova největší vlastní hodnota	λ_1

Pro $k = 1$ je $\boldsymbol{H} = SSB$, $\boldsymbol{E} = SSW$ a všechny statistiky jsou funkcemi F-statistiky ANOVA.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vyhodnocení MANOVA – pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`: https://www.statsmodels.org/stable/generated/statsmodels.multivariate.manova.MANOVA.html

```
from sklearn.datasets import load_iris
from statsmodels.multivariate.manova import MANOVA

iris = load_iris(as_frame=True)
data = iris.frame.rename(columns={
    "sepal length (cm)": "SL", "sepal width (cm)": "SW",
    "petal length (cm)": "PL", "petal width (cm)": "PW"})

# Model MANOVA: 4 závislé proměnné, faktor druh (3 úrovně)
model = MANOVA.from_formula("SL + SW + PL + PW ~ C(target)",
                            data=data)
print(model.mv_test())
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Wilksova lambda – testovací statistika v MANOVA

Co měří? Podíl zobecněného rozptylu (determinantu) uvnitř skupin na celkovém zobecněném rozptylu. Čím menší hodnota, tím větší rozdíly mezi skupinami.

Definice $\Lambda = \frac{|\boldsymbol{E}|}{|\boldsymbol{E}+\boldsymbol{H}|}$, kde $\boldsymbol{E}$ je matice chyb (vnitroskupinová SSCP), $\boldsymbol{H}$ matice hypotézy (meziskupinová SSCP).

Interpretace $\Lambda \approx 1$: skupiny se neliší (data jsou v souladu s H_0).
$\Lambda \approx 0$: skupiny se výrazně liší.

Testování Wilksova lambda se převádí na F-statistiku (Raova aproximace, pro $k \leq 2$ nebo $g \leq 3$ exaktní) nebo na χ^2 (Bartlettova aproximace $-\left(n-1-\frac{k+g}{2}\right)\ln\Lambda \approx \chi^2_{k(g-1)}$).

Výhody / nevýhody Nejčastěji používaná statistika. Při porušení předpokladů (normalita, shoda variančních matic) a malých výběrech je nejrobustnější Pillaiova stopa; Royova statistika je nejsilnější, pokud se skupiny liší jen v jednom směru.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Výpočet Wilksovy lambdy v Pythonu

Použijeme knihovnu `statsmodels` a výsledek ověříme výpočtem z matic $\boldsymbol{E}$, $\boldsymbol{H}$:

```
import numpy as np
import pandas as pd
from statsmodels.multivariate.manova import MANOVA

data = pd.DataFrame({
    "Y1": [5.1, 4.9, 4.7, 6.0, 6.2, 6.1, 7.0, 6.8, 7.1],
    "Y2": [3.5, 3.0, 3.2, 3.8, 3.9, 4.0, 4.5, 4.3, 4.6],
    "Group": ["A", "A", "A", "B", "B", "B", "C", "C", "C"]})
print(MANOVA.from_formula("Y1 + Y2 ~ Group", data=data).mv_test())

xbar = data[["Y1", "Y2"]].to_numpy().mean(axis=0)
E, H = np.zeros((2, 2)), np.zeros((2, 2))
for _, d in data.groupby("Group"):
    Yg = d[["Y1", "Y2"]].to_numpy()
    E += (Yg - Yg.mean(axis=0)).T @ (Yg - Yg.mean(axis=0))
    dm = Yg.mean(axis=0) - xbar
    H += len(Yg) * np.outer(dm, dm)
Lambda = np.linalg.det(E) / np.linalg.det(E + H)   # 0.0201
```

Výsledek: Wilksova lambda $= 0{,}0201$, $F = 15{,}15$, $p = 0{,}0003$. Pillaiova stopa ale dává $p = 0{,}055$ – u tak malých výběrů (3 pozorování ve skupině) se statistiky mohou výrazně lišit.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

MANCOVA – vícerozměrná analýza kovariance

Cíl	Testovat vliv jednoho nebo více faktorů na **více závislých proměnných současně**, přičemž kontrolujeme vliv **kovariát**.
Rozdíl oproti MANOVA	MANCOVA zahrnuje kovariáty (např. věk, BMI), které mohou ovlivnit závislé proměnné.
Předpoklady	Vícerozměrná normalita, shodné varianční matice, nezávislost pozorování, lineární vztah mezi kovariátami a závislými proměnnými se shodnými regresními koeficienty ve všech skupinách.
Nulová hypotéza	H_0: po zohlednění kovariát jsou vektory středních hodnot závislých proměnných stejné ve všech skupinách.
Testovací statistiky	Wilksova lambda, Pillaiova stopa, Hotellingova-Lawleyho stopa, Royova největší vlastní hodnota.

Použití: Např. vliv léčby na více fyziologických ukazatelů při kontrole věku.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vyhodnocení MANCOVA – pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import numpy as np
import pandas as pd
from statsmodels.multivariate.manova import MANOVA

rng = np.random.default_rng(5)
Group = np.repeat(["A", "B", "C"], 20)          # faktor
Age = rng.uniform(20, 60, 60)                   # kovariáta
Y1 = 10 + 0.1 * Age + (Group == "B") + rng.normal(0, 1, 60)
Y2 = 5 + 0.05 * Age + 0.5 * (Group == "C") + rng.normal(0, 1, 60)
data = pd.DataFrame({"Y1": Y1, "Y2": Y2, "Group": Group, "Age": Age})

# Model MANCOVA (faktor + kovariáta)
model = MANOVA.from_formula("Y1 + Y2 ~ C(Group) + Age", data=data)
print(model.mv_test())
```