

Přednáška 7: Porovnávání středních hodnot pro více skupin

Mnohonásobné porovnávání. ANOVA one-way a two-way. Metody multicompare analýzy. Kruskal-Wallisův test.

KMA/MSM Blanka Šedivá

verze 2025/2026

29. září 2026

Obsah

- 1 Jednorozměrná data
 - Více výběrů (shoda k – středních hodnot)
 - Shoda rozptylů pro více výběrů
- 2 Vícerozměrná data
 - Více výběrů (shoda vektorů středních hodnot pro více výběrů)

Jednorozměrná data — porovnávání více skupin

- ANOVA test o shodě středních hodnot - parametrické (one-way)
- Testy o shodě rozptylů pro více výběrů
- Post-hoc analýzy (metody multicompare)
- Kruskal-Wallisův test o shodě polohy - neparametrické
- Two-way ANOVA, repeated ANOVA, Three-way ANOVA, ANCOVA

One-way ANOVA — test shody středních hodnot ve více skupinách

Cíl	Ověřit, zda se střední hodnoty k nezávislých skupin rovnají.
Předpoklady	Každá skupina je tvořena nezávislým náhodným výběrem z normálního rozdělení. Všechny skupiny mají stejný rozptyl (homoskedasticita).
Nulová hypotéza	$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$
Alternativní hypotéza	Alespoň dvě střední hodnoty se liší.
Testovací statistika	$F = \frac{MSB}{MSW}$, kde: MSB (meziskupinová variabilita) měří rozdíly mezi skupinovými průměry a celkovým průměrem: MSW (vnitroskupinová variabilita) měří rozptyl uvnitř jednotlivých skupin:
Rozdělení testovacích statistik	$F \sim F_{k-1, n-k}$, kde n je celkový počet pozorování a k počet skupin.

One-way ANOVA — meziskupinová variabilita (MSB)

Definice

Meziskupinová variabilita (Mean Square Between, MSB) měří rozdíly mezi průměry jednotlivých skupin a celkovým průměrem.

Význam

Pokud jsou skupinové průměry výrazně odlišné od celkového průměru, MSB bude velká. To může naznačovat, že alespoň jedna skupina má jinou střední hodnotu.

Výpočet

$$MSB = \frac{1}{k-1} \sum_{j=1}^k n_j (\bar{x}_j - \bar{x})^2$$

kde k je počet skupin, n_j počet pozorování ve skupině j , $\bar{x}_j$ průměr skupiny j a $\bar{x}$ celkový průměr všech dat.

One-way ANOVA — vnitroskupinová variabilita (MSW)

Definice

Vnitroskupinová variabilita (Mean Square Within, MSW) měří rozptyl hodnot uvnitř jednotlivých skupin.

Význam


Pokud jsou hodnoty uvnitř každé skupiny blízko svému skupinovému průměru, MSW bude malá. Vysoká MSW značí velkou variabilitu uvnitř skupin.

Výpočet

$$MSW = \frac{1}{n - k} \sum_{j=1}^k \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2$$

kde n je celkový počet pozorování, k počet skupin, x_{ij} je i -tá hodnota ve skupině j , $\bar{x}_j$ je průměr skupiny j .

Vizualizace ANOVA



Vyhodnocení one-way ANOVA — pomocí p-hodnoty I.

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f_oneway.html

<https://www.statsmodels.org/stable/anova.html>

```
import numpy as np
from scipy.stats import f

# Tři skupiny po 10 pozorováních
np.random.seed(42)
group1 = np.random.normal(loc=5.0, scale=1.0, size=10)
group2 = np.random.normal(loc=5.5, scale=1.0, size=10)
group3 = np.random.normal(loc=6.0, scale=1.0, size=10)

# Výpočty průměrů
means = [np.mean(group1), np.mean(group2), np.mean(group3)]
overall_mean = np.mean(np.concatenate
    ([group1, group2, group3]))
```

Vyhodnocení one-way ANOVA — pomocí p-hodnoty II.

```
# Meziskupinová variabilita (MSB)
SSB = 10 * sum((m - overall_mean)**2 for m in means)
MSB = SSB / (3 - 1)

# Vnitroskupinová variabilita (MSW)
SSW = sum(((g - m)**2).sum() for g, m
          in zip([group1, group2, group3], means))
MSW = SSW / (30 - 3)

# F-statistika a p-hodnota
F_stat = MSB / MSW
p_value = 1 - f.cdf(F_stat, dfn=2, dfd=27)
```

Shoda rozptylů pro více výběrů — přehled testů a jejich principů I.

Bartlettův test

Parametrický test založený na porovnání logaritmu determinantu celkového rozptylu a součtu logaritmů rozptylů jednotlivých skupin.

$$\text{Testovací statistika: } \chi^2 = \frac{((N-k) \ln s_p^2 - \sum_{j=1}^k (n_j - 1) \ln s_j^2)}{1 + \frac{1}{3(k-1)} \left(\sum_{j=1}^k \frac{1}{n_j - 1} - \frac{1}{N-k} \right)}$$

kde s_p^2 je celkový rozptyl, s_j^2 rozptyl ve skupině j , n_j počet pozorování ve skupině j , $N = \sum n_j$.

Testovací statistika má asymptotické χ^2 rozdělení s $k - 1$ stupni volnosti.

Velmi citlivý na odchylky od normality — i malá odchylka může vést k chybnému zamítnutí H_0 .

Vhodný pouze při splnění předpokladu normality.

Shoda rozptylů pro více výběrů — přehled testů a jejich principů II.

Leveneův test

Testuje shodu rozptylů pomocí jednofaktorové ANOVY aplikované na absolutní odchylky hodnot od skupinového průměru: $z_{ij} = |x_{ij} - \bar{x}_j|$

Poté se testuje, zda se střední hodnoty z_{ij} ve skupinách liší.

Méně citlivý na odlehlé hodnoty a nenormální rozdělení. Vhodný pro běžné použití.

Brown–Forsytheův test

Varianta Leveneova testu, která místo průměrů používá mediány $z_{ij} = |x_{ij} - \text{median}_j|$

Následně se provede ANOVA nad těmito odchylkami.

Ještě robustnější vůči odlehlým hodnotám než Leveneův test. Doporučený při podezření na extrémní hodnoty v datech.

Shoda rozptylů pro více výběrů — přehled testů a jejich principů III.

Fligner–Killeenův test

Neparametrický test založený na pořadích.

Nevyžaduje normalitu ani shodný tvar rozdělení.

Velmi robustní vůči odlehlým hodnotám a vhodný pro široké spektrum dat, včetně silně nenormálních.

Pro každé pozorování x_{ij} ve skupině j se spočítá absolutní odchylka od mediánu: $z_{ij} = |x_{ij} - \text{median}_j|$

Odchylky z_{ij} se seřadí a přiřadí se jim pořadí r_{ij} , které se transformuje pomocí inverzní normální distribuční funkce: $a_{ij} = \Phi^{-1} \left(\frac{r_{ij}}{N+1} \right)$

Testovací statistika má tvar: $X^2 = \frac{1}{s^2} \sum_{j=1}^k n_j (\bar{a}_j - \bar{a})^2$

kde s^2 je rozptyl všech a_{ij} , $\bar{a}_j$ je průměr transformovaných hodnot ve skupině j , $\bar{a}$ je celkový průměr.

Statistika má asymptotické χ^2 rozdělení s $k - 1$ stupni volnosti.

One-way ANOVA — Post-hoc testy

Účel post-hoc testů

Používají se po zamítnutí nulové hypotézy v ANOVA k určení, které skupiny se statisticky významně liší.

Tukey HSD

Testuje všechny párové rozdíly mezi skupinami. Předpokládá rovnost rozptylů a velikostí vzorků. Dobrá rovnováha mezi chybovostí a výkonem.

Bonferroni

Korekce pro více srovnání. Vhodný pro předem definované hypotézy. Konzervativní, snižuje sílu testu při mnoha srovnáních.

Scheffé

Umožňuje testovat libovolné lineární kontrasty. Velmi flexibilní, ale konzervativní. Vhodný při nerovných velikostech skupin.

Games-Howell

Nepředpokládá rovnost rozptylů ani velikostí vzorků. Vhodný při porušení předpokladů ANOVA.

Holm

Sekvenční korekce p-hodnot. Vyšší síla než Bonferroni, vhodný pro párová srovnání.

Dunnett

Porovnává všechny skupiny vůči jedné kontrolní. Efektivní pro experimenty s kontrolní skupinou.

Poznámka: Výběr testu závisí na cíli analýzy, počtu skupin, velikosti vzorků a splnění

předpokladů ANOVA.

Post-hoc test — Tukey HSD v Pythonu

Ukázka výpočtu pomocí knihovny `statsmodels`:

https://www.statsmodels.org/dev/generated/statsmodels.stats.multicomp.pairwise_tukeyhsd.html

```
import numpy as np
import pandas as pd
from statsmodels.stats.multicomp import pairwise_tukeyhsd
# Data: tři skupiny
np.random.seed(42)
group1 = np.random.normal(loc=5.0, scale=1.0, size=10)
group2 = np.random.normal(loc=5.5, scale=1.0, size=10)
group3 = np.random.normal(loc=6.0, scale=1.0, size=10)
# Spojení dat do DataFrame
data = np.concatenate([group1, group2, group3])
labels = ['Skupina 1']*10 + ['Skupina 2']*10
        + ['Skupina 3']*10
# Tukey HSD test
tukey = pairwise_tukeyhsd(endog=data,
                           groups=labels, alpha=0.05)
```

Kruskal-Wallisův test — test shody mediánů ve více skupinách

Cíl	Ověřit, zda se mediány k nezávislých skupin rovnají.
Předpoklady	Nezávislé výběry, měřítko alespoň ordinální. Nepředpokládá normální rozdělení ani shodu rozptylů.
Nulová hypotéza	H_0 : Všechny skupiny mají stejný medián.
Alternativní hypotéza	Alespoň jedna skupina má odlišný medián.
Testovací statistika	$H = \frac{12}{n(n+1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(n+1), \text{ kde:}$ n je celkový počet pozorování, n_j počet pozorování ve skupině j, R_j součet pořadí ve skupině j.
Rozdělení testovacích statistik	$H \sim \chi_{k-1}^2$ (při dostatečně velkém n).

Vyhodnocení Kruskal-Wallisova testu — pomocí p-hodnoty

P-hodnotu lze vypočítat pomocí softwaru (např. Python, R, Excel). V

Pythonu: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.kruskal.html>

```
import numpy as np
from scipy.stats import kruskal

# Tři skupiny po 10 pozorováních
np.random.seed(42)
group1 = np.random.normal(loc=5.0, scale=1.0, size=10)
group2 = np.random.normal(loc=5.5, scale=1.0, size=10)
group3 = np.random.normal(loc=6.0, scale=1.0, size=10)

# Kruskal-Wallisův test
stat, p_value = kruskal(group1, group2, group3)
```

Two-way ANOVA — test vlivu dvou faktorů

Cíl	Ověřit vliv dvou nezávislých faktorů (např. A a B) na závislou proměnnou, včetně interakce mezi faktory.
Předpoklady	Nezávislé náhodné výběry, normální rozdělení reziduí, homoskedasticita.
Nulové hypotézy	H_0^A : Faktor A nemá vliv na závislou proměnnou. H_0^B : Faktor B nemá vliv na závislou proměnnou. H_0^{AB} : Neexistuje interakce mezi faktory A a B.
Testovací statistika	Pro každý efekt se počítá F-statistika: $F = \frac{MS_{\text{efekt}}}{MS_{\text{chyba}}}$
Rozdělení testovacích statistik	$F \sim F_{df_{\text{efekt}}, df_{\text{chyba}}}$

Vyhodnocení Two-way ANOVA — pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:


```
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols
# Ukázková data
data = pd.DataFrame({
    'výsledek': [...],
    'faktor_A': [...],
    'faktor_B': [...]})

# Model a ANOVA
model = ols('výsledek ~ C(faktor_A) + C(faktor_B) +
            C(faktor_A):C(faktor_B)', data=data).fit()
anova_table = sm.stats.anova_lm(model, typ=2)
```

ANOVA s opakovanými měřeními (repeated ANOVA)

Cíl	Ověřit, zda se střední hodnoty mění v čase nebo mezi podmínkami u stejných subjektů.
Předpoklady	Normální rozdělení rozdílů, sféricita (rovnost kovariancí mezi páry měření), nezávislost subjektů.
Nulová hypotéza	H_0 : Střední hodnoty ve všech podmínkách jsou stejné.
Alternativní hypotéza	Alespoň jedna podmínka má odlišnou střední hodnotu.
Testovací statistika	$F = \frac{MS_{\text{podmínka}}}{MS_{\text{chyba}}}$
Rozdělení testovací statistiky	$F \sim F_{df_{\text{podmínka}}, df_{\text{chyba}}}$

Vizualizace repeatedANOVA



Vyhodnocení repeatedANOVA — pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import pandas as pd
import statsmodels.api as sm
from statsmodels.stats.anova import AnovaRM

# Ukázková data
data = pd.DataFrame({
    'subjekt': [...],
    'čas': [...],
    'výsledek': [...]
})

# Repeated Measures ANOVA
anova = AnovaRM(data, depvar='výsledek',
                 subject='subjekt', within=['čas'])
res = anova.fit()
```

Vyhodnocení Three-way ANOVA — pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:



```
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols
# Ukázková data
data = pd.DataFrame({
    'výsledek': [...], 'faktor_A': [...],
    'faktor_B': [...], 'faktor_C': [...]}
# Model a ANOVA
model = ols('výsledek ~ C(faktor_A) + C(faktor_B) +
    C(faktor_C) + C(faktor_A):C(faktor_B) +
    C(faktor_A):C(faktor_C) + C(faktor_B):C(faktor_C) +
    C(faktor_A):C(faktor_B):C(faktor_C)',
    data=data).fit()

anova_table = sm.stats.anova_lm(model, typ=2)
```

ANCOVA — Analýza kovariance

Cíl		Kombinuje ANOVA a lineární regresi: testuje vliv jednoho nebo více faktorů na závislou proměnnou, při kontrole vlivu kovariátů .
Rozdíl ANOVA	oproti	ANCOVA zahrnuje kovariáty (kontinuální proměnné), které vysvětlují část variability, čímž zvyšuje přesnost odhadu efektů faktorů.
Předpoklady		Lineární vztah mezi kovariátem a závislou proměnnou, homoskedasticita, normální rozdělení reziduí, nezávislost pozorování.
Nulová hypotéza		H_0 : Po zohlednění kovariátů nemají faktory vliv na závislou proměnnou.
Použití		Např. porovnání účinku léčby při kontrole věku nebo počátečního stavu.

Vizualizace ANCOVA



Vyhodnocení ANCOVA — pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Ukázková data
data = pd.DataFrame({
    'výsledek': [...],          # závislá proměnná
    'faktor': [...],           # kategorický faktor
    'kovariat': [...]          # kovariát (kontinuální proměnná)
})

# Model ANCOVA
model = ols('výsledek ~ C(faktor) + kovariat', data=data).fit()
anova_table = sm.stats.anova_lm(model, typ=2)
print(anova_table)
```

ANCOVA — Praktický příklad

Scénář

Porovnáváme účinek dvou typů tréninku na skóre fyzické kondice po programu.

Proměnné

Výsledek: Skóre kondice po programu.

Faktor: Typ tréninku (A = aerobní, B = silový).

Kovariát: Počáteční úroveň kondice (např. VO_2 max).

Proč ANCOVA?

Zohledňuje vliv počáteční kondice, aby rozdíly mezi skupinami nebyly zkresleny tím, že jedna skupina začínala s vyšší úrovní.

Interpretace

Pokud p -hodnota pro faktor `typ tréninku` < 0.05 i po kontrole kovariátu, rozdíl mezi tréninky je skutečný, nikoli způsobený rozdílnou startovní úrovní.

Praktický význam: ANCOVA zvyšuje přesnost odhadu efektů tím, že eliminuje vliv rušivých proměnných.

Vícerozměrná data — porovnávání více skupin

- MANOVA test o shodě vektorů středních hodnot
- MANCOVA test o shodě středních hodnot s kovariáty

MANOVA — Multivariační analýza rozptylu

Cíl	Testovat vliv jednoho nebo více faktorů na více závislých proměnných současně .
Rozdíl ANOVA	oproti ANOVA testuje jednu závislou proměnnou, zatímco MANOVA bere v úvahu korelace mezi více závislými proměnnými.
Předpoklady	Multivariační normalita, homoskedasticita, nezávislost pozorování.
Nulová hypotéza	H_0 : Vektor středních hodnot závislých proměnných je stejný ve všech skupinách.
Testovací statistiky	Wilks' Lambda, Pillai's Trace, Hotelling-Lawley Trace, Roy's Largest Root.

Použití: Např. při zkoumání vlivu léčby na více fyziologických ukazatelů současně.

Vyhodnocení MANOVA — pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import pandas as pd
from statsmodels.multivariate.manova import MANOVA

# Ukázková data
data = pd.DataFrame({
    'Y1': [...],    # první závislá proměnná
    'Y2': [...],    # druhá závislá proměnná
    'faktor_A': [...],
    'faktor_B': [...]
})

# Model MANOVA
model = MANOVA.from_formula('Y1 + Y2 ~ faktor_A +
                             faktor_B', data=data)
```

Wilks' Lambda — Testovací statistika v MANOVA

Co měří?

Poměr rozptylu uvnitř skupin k celkovému rozptylu. Čím menší hodnota, tím větší rozdíly mezi skupinami.

Definice

$\Lambda = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}$, kde $\mathbf{E}$ = matice chyb, $\mathbf{H}$ = matice hypotézy.

Interpretace

$\Lambda \approx 1$: skupiny jsou podobné (H_0 platí). $\Lambda \approx 0$: skupiny se liší (H_0 neplatí).

Testování

Wilks' Lambda se převádí na F-statistiku pro výpočet p-hodnoty.

Výhody / Nevýhody

Běžně používaná, ale citlivá na porušení předpokladů (např. multivariační normalita).

Výpočet Wilks' Lambda v Pythonu

Použijeme knihovnu `statsmodels`:

```
import pandas as pd
from statsmodels.multivariate.manova import MANOVA

# Simulovaná data
data = pd.DataFrame({
    'Y1': [5.1, 4.9, 4.7, 6.0, 6.2, 6.1, 7.0, 6.8, 7.1],
    'Y2': [3.5, 3.0, 3.2, 3.8, 3.9, 4.0, 4.5, 4.3, 4.6],
    'Group': ['A', 'A', 'A', 'B', 'B', 'B', 'C', 'C', 'C']
})

# Model MANOVA
model = MANOVA.from_formula('Y1 + Y2 ~ Group', data=data)
result = model.mv_test()
```

Výsledek: Wilks' Lambda = 0.0201, F = 15.15, p = 0.0003

MANCOVA — Multivariační analýza kovariance

Cíl	Testovat vliv jednoho nebo více faktorů na více závislých proměnných současně , přičemž kontrolujeme vliv kovariátů .
Rozdíl oproti MANOVA	MANCOVA zahrnuje kovariáty (např. věk, BMI), které mohou ovlivnit závislé proměnné.
Předpoklady	Multivariační normalita, homoskedasticita, nezávislost pozorování, lineární vztah mezi kovariáty a závislými proměnnými.
Nulová hypotéza	H_0 : Po zohlednění kovariátů jsou vektory středních hodnot závislých proměnných stejné ve všech skupinách.
Testovací statistiky	Wilks' Lambda, Pillai's Trace, Hotelling-Lawley Trace, Roy's Largest Root.

Použití: Např. vliv léčby na více fyziologických ukazatelů při kontrole věku.

Vyhodnocení MANCOVA — pomocí Pythonu

V Pythonu lze použít knihovnu `statsmodels`:

```
import pandas as pd
from statsmodels.multivariate.manova import MANOVA

# Ukázková data
data = pd.DataFrame({
    'Y1': [...],    # první závislá proměnná
    'Y2': [...],    # druhá závislá proměnná
    'Group': [...], # faktor
    'Age': [...]    # kovariát
})

# Model MANCOVA (faktor + kovariát)
model = MANOVA.from_formula('Y1 + Y2 ~ Group + Age',
                             data=data)
result = model.mv_test()
```