KMA/MSM – cvičení 8: Kontingenční tabulky

(verze s výsledky)

Výpočty provádějte v Pythonu: `scipy.stats`, modul `contingency_tables` knihovny `statsmodels` a log-lineární modely jako Poissonův GLM ve `statsmodels` (viz notebook `P08_kontingencni_tabulky.ipynb`). Pokud není řečeno jinak, volte hladinu $\alpha = 0{,}05$.

A. Dvourozměrné tabulky

1. **Test nezávislosti a míry asociace.** V průzkumu mezi 100 respondenty byla zjištěna tabulka

	souhlasí	nesouhlasí	celkem
skupina 1	25	15	40
skupina 2	15	45	60
celkem	40	60	100

   (a) Vypočtěte (ručně) očekávané četnosti za hypotézy nezávislosti.

   (b) Spočtěte Pearsonovu statistiku X^2 bez Yatesovy korekce a rozhodněte ($\chi^2_{0{,}95}(1) = 3{,}84$).

   (c) Spočtěte Cramérovo V a poměr šancí b s 95% intervalem spolehlivosti. Interpretujte.

   (d) Výsledek ověřte v Pythonu. Co vrátí `scipy.stats.chi2_contingency(tab)` při výchozím nastavení a proč?

   Výsledky: a) $\hat{m}_{ij} = n_{i\bullet}n_{\bullet j}/n$: $\begin{pmatrix} 16 & 24 \\ 24 & 36 \end{pmatrix}$. b) Všechny odchylky mají absolutní hodnotu 9: $X^2 = 81\left(\frac{1}{16}+\frac{1}{24}+\frac{1}{24}+\frac{1}{36}\right) = 14{,}06 > 3{,}84$, $p = 0{,}00018$ – nezávislost zamítáme. c) $V = \sqrt{X^2/n} = 0{,}375$ (střední síla asociace); $b = \frac{25\cdot 45}{15\cdot 15} = 5$, $SE(\ln b) = \sqrt{\frac{1}{25}+\frac{1}{15}+\frac{1}{15}+\frac{1}{45}} = 0{,}442$, 95% IS $\exp(\ln 5 \pm 1{,}96\cdot 0{,}442) = (2{,}10;\ 11{,}90)$. Šance na souhlas je ve skupině 1 asi pětkrát vyšší. d) U tabulky s 1 stupněm volnosti scipy implicitně použije Yatesovu korekci (`correction=True`): $X^2_Y = 12{,}54$.

2. **Vrstvené tabulky 2×2 a Simpsonův paradox.** Ve studii léčby ledvinových kamenů (Charig a kol., 1986) byly porovnány dvě operační metody A (otevřená operace) a B (perkutánní nefrolitotomie). Výsledky podle velikosti kamene:

	malé kameny		velké kameny	
	úspěch	neúspěch	úspěch	neúspěch
metoda A	81	6	192	71
metoda B	234	36	55	25

   (a) Zvlášť pro malé a zvlášť pro velké kameny otestujte, zda úspěšnost závisí na metodě. Použijte Pearsonův χ^2 test (bez korekce i s Yatesovou korekcí), test založený na poměru šancí (s 95% intervalem spolehlivosti pro poměr šancí) a Fisherův exaktní test. Ověřte předpoklady asymptotických testů.

(b) Testy zopakujte pro tabulku vzniklou sečtením obou vrstev. Porovnejte úspěšnost metod a poměry šancí ve vrstvách a v sečtené tabulce. Vysvětlete, čím je rozdíl způsoben.

(c) Spočtěte Mantelův–Haenszelův odhad společného poměru šancí, CMH test a Breslowův–Dayův test homogenity poměrů šancí.

(d) Uvažujte data jako trojrozměrnou tabulku (metoda × výsledek × velikost kamene) a najděte nejjednodušší vyhovující log-lineární model.

Výsledky:

	malé	velké	sečteno
úspěšnost A / B	93,1 % / 86,7 %	73,0 % / 68,8 %	78,0 % / 82,6 %
X^2 (p)	2,63 (0,105)	0,55 (0,458)	2,31 (0,129)
X^2_Y (p)	2,04 (0,153)	0,36 (0,549)	2,03 (0,154)
b (95% IS)	2,08 (0,84; 5,11)	1,23 (0,71; 2,12)	0,75 (0,52; 1,09)
Fisher p	0,127	0,479	0,154

a) Nejmenší očekávaná četnost je 10,2 (malé kameny), asymptotické testy lze použít. V žádné vrstvě není rozdíl významný.
b) V obou vrstvách je úspěšnější metoda A ($b > 1$), v sečtené tabulce metoda B ($b = 0{,}75$) – **Simpsonův paradox**. Příčinou je matoucí proměnná „velikost kamene“: metodou A se operovaly převážně velké (obtížné) kameny (75 % případů), metodou B převážně malé (77 %).
c) $\hat{\beta}_{MH} = 1{,}45$, 95% IS (0,92; 2,29); CMH $\chi^2 = 2{,}43$, $p = 0{,}12$; Breslow–Day $p = 0{,}33$ (poměry šancí lze považovat za shodné). Po zohlednění velikosti kamene je metoda A spíše lepší, rozdíl však není významný.
d) Vyhovuje $[AC][BC]$ ($G^2 = 3{,}45$, df = 2, $p = 0{,}18$) i $[AB][AC][BC]$ ($G^2 = 1{,}01$, df = 1, $p = 0{,}32$); $\Delta G^2 = 2{,}44$, df = 1, $p = 0{,}12 \Rightarrow$ volíme $[AC][BC]$: metoda a výsledek jsou podmíněně nezávislé při dané velikosti kamene, obě souvisí s velikostí kamene. Ostatní modely jsou zamítnuty ($p < 0{,}001$).

3. **Simpsonův paradox – kouření a přežití.** Ve studii Whickham (Appleton a kol., 1996) byly ženy dotázány, zda kouří, a po 20 letech se zjišťovalo, zda žijí. Celkem zemřelo 139 z 582 kuřaček a 230 z 732 nekuřaček, poměr šancí úmrtí kuřačky vs. nekuřačky je tedy $b = 0{,}68$. Data podle věkových skupin (věk při vstupu do studie; skupiny 65–74 a 75+ jsou sloučeny) a podmíněné poměry šancí úmrtí b_k:

	kuřačky		nekuřačky		
věk	zemřela	žije	zemřela	žije	b_k
18–24	2	53	1	61	2,30
25–34	3	121	5	152	0,75
35–44	14	95	7	114	2,40
45–54	27	103	12	66	1,44
55–64	51	64	40	81	1,61
65+	42	7	165	28	1,02
celkem	139	443	230	502	0,68

(a) Vysvětlete, jak může vzniknout tento zdánlivý rozpor (kuřačky přežívají častěji). Jakou roli hraje věk?

(b) Mantelův–Haenszelův odhad společného poměru šancí je $\hat{\beta}_{MH} = 1{,}50$ s 95% IS (1,06; 2,11) a CMH test dává $p = 0{,}020$. Interpretujte.

(c) Breslowův–Dayův test homogenity poměrů šancí dává $p = 0{,}73$. Co to znamená pro interpretaci $\hat{\beta}_{MH}$?

Výsledky: a) Věk je matoucí proměnná: úmrtnost během 20 let silně roste s věkem a mezi nejstaršími ženami (65+, úmrtnost přes 85 %) je kuřaček jen 20 %, zatímco v mladších skupinách kolem poloviny. Kuřačky jsou tedy v průměru mladší, a proto v souhrnné tabulce přežívají častěji – souhrnný poměr šancí míchá vliv kouření s vlivem věku. b) Při stejném věku jsou šance na úmrtí u kuřaček zhruba 1,5krát vyšší; interval neobsahuje 1 a CMH test zamítá podmíněnou nezávislost kouření a přežití při daném věku. Směr asociace je opačný než v souhrnné tabulce. c) Hypotézu shodných poměrů šancí ve věkových skupinách nezamítáme – rozdíly mezi b_k lze přičíst náhodě (malé počty úmrtí v mladých skupinách). Společný odhad $\hat{\beta}_{MH}$ je proto smysluplným shrnutím.

B. Párová data – testy symetrie

4. **McNemarův test.** Bylo zkoumáno, zda podání určitého léku má jako vedlejší účinek změnu rychlosti srážení krve. Náhodně bylo vybráno 100 pacientů a u každého byla zjištěna rychlost srážení krve (pomalá/rychlá) před podáním a po podání léku:

	po léčbě pomalá	po léčbě rychlá	celkem
před léčbou pomalá	24	28	52
před léčbou rychlá	12	36	48
celkem	36	64	100

Formulujte nulovou hypotézu. Pomocí asymptotického McNemarova testu (bez korekce i s korekcí na spojitost) a jeho exaktní (binomické) varianty zjistěte, zda podání léku ovlivňuje rychlost srážení krve. Proč nelze použít Pearsonův χ^2 test nezávislosti?

Výsledky: H_0: $p_{12} = p_{21}$, ekvivalentně $p_{1\bullet} = p_{\bullet 1}$ (podíl pacientů s pomalým srážením je před a po léčbě stejný). Data jsou párová, test nezávislosti by odpovídal na jinou otázku (zda stav po souvisí se stavem před). Rozhodují jen nesouhlasné páry $n_{12} = 28$, $n_{21} = 12$: $\chi^2 = \frac{(28-12)^2}{40} = 6{,}40$, $p = 0{,}011$; s korekcí $\frac{(|28-12|-1)^2}{40} = 5{,}63$, $p = 0{,}018$; exaktně $n_{12} \sim Bi(40;\, 0{,}5)$, $p = 0{,}017$. Všechny varianty H_0 zamítají: podíl pacientů s rychlým srážením vzrostl z 48 % na 64 %.

5. **Asymptotická vs. exaktní varianta.** Ve studii s 60 účastníky se před a po kampani zjišťovalo, zda podporují určitý návrh. Názor změnilo 16 osob: 12 z „ano“ na „ne“ a 4 z „ne“ na „ano“.

   (a) Formulujte nulovou hypotézu a vysvětlete, proč nepotřebujeme počty osob, které názor nezměnily.

   (b) Proveďte asymptotický McNemarův test.

   (c) Proveďte exaktní (binomický) test. Liší se rozhodnutí? Kterému byste dali přednost a proč?

Výsledky: a) H_0: $p_{12} = p_{21}$ (podíl podporovatelů se kampaní nezměnil). Za H_0 je podmíněně na $n_{12}+n_{21}$ počet n_{12} binomický s $p = \frac{1}{2}$; diagonální buňky nenesou informaci o změně. b) $\chi^2 = \frac{(12-4)^2}{16} = 4{,}0 > 3{,}84$, $p = 0{,}046$ – zamítáme. c) $n_{12} \sim Bi(16;\, 0{,}5)$: $p = 2\,P(X \le 4) = 0{,}077$ – nezamítáme. Při tak malém počtu nesouhlasných párů je asymptotická aproximace nespolehlivá, přednost má exaktní test.

6. **Bowkerův a Stuartův–Maxwellův test.** Pro náhodně vybrané dvojice (dítě, rodič) bylo zjištěno nejvyšší dosažené vzdělání:

	vzdělání rodiče				
vzdělání dítěte	základní	vyučen	střední	vysokoškolské	celkem
základní	194	70	41	30	335
vyučen	83	124	41	36	284
střední	25	34	55	23	137
vysokoškolské	56	36	43	109	244
celkem	358	264	180	198	1000

(a) Slovně formulujte hypotézu o symetrii a otestujte ji Bowkerovým testem.

(b) Slovně formulujte hypotézu o homogenitě marginálních pravděpodobností a otestujte ji Stuartovým–Maxwellovým testem.

(c) Vysvětlete, proč symetrie implikuje marginální homogenitu, ale ne naopak. Sestavte příklad tabulky 3×3, která má stejné marginální četnosti, ale není symetrická.

(d) Proč ve Stuartově–Maxwellově testu stačí pracovat jen s $c-1$ rozdíly $d_i = n_{i\bullet} - n_{\bullet i}$? Které dvojice kategorií nejvíce přispívají k nesymetrii?

Výsledky: a) H_0: $p_{ij} = p_{ji}$ – např. dvojic (dítě základní, rodič VŠ) je stejně jako (dítě VŠ, rodič základní). $X^2_B = 19{,}56$, df $= 6$, $p = 0{,}003$ – symetrii zamítáme. b) H_0: $p_{i\bullet} = p_{\bullet i}$ – rozdělení vzdělání dětí je stejné jako rozdělení vzdělání rodičů. $Q = 15{,}77$, df $= 3$, $p = 0{,}001$ – zamítáme. Děti mají častěji VŠ (24,4 % vs. 19,8 %) a méně často střední vzdělání (13,7 % vs. 18,0 %). c) Ze $p_{ij} = p_{ji}$ plyne sečtením přes j rovnost $p_{i\bullet} = p_{\bullet i}$. Opačně ne – např. cyklická tabulka $\begin{pmatrix} 10 & 20 & 0 \\ 0 & 10 & 20 \\ 20 & 0 & 10 \end{pmatrix}$ má všechny řádkové i sloupcové součty 30, ale $n_{12} = 20 \neq n_{21} = 0$. d) $\sum_i d_i = n - n = 0$, poslední rozdíl je určen ostatními (kovarianční matice všech c rozdílů je singulární). Největší příspěvky k X^2_B: (základní, VŠ) $\frac{(30-56)^2}{86} = 7{,}86$, (střední, VŠ) 6,06, (základní, střední) 3,88.

C. Trojrozměrné tabulky – log-lineární modely

7. **Výběr log-lineárního modelu.** Byl zkoumán vliv pohlaví a složení maturity z matematiky na úspěšnost studentů v prvním ročníku. Uvažujeme znaky

- A: student/studentka absolvoval/a ($i = 1$) nebo neabsolvoval/a ($i = 2$) první ročník,
- B: složil/a ($j = 1$) nebo nesložil/a ($j = 2$) maturitu z matematiky,
- C: student ($k = 1$) nebo studentka ($k = 2$).

	studenti ($k = 1$)		studentky ($k = 2$)	
	mat. ano ($j = 1$)	ne ($j = 2$)	mat. ano ($j = 1$)	ne ($j = 2$)
absolvoval/a ($i = 1$)	120	20	50	20
neabsolvoval/a ($i = 2$)	30	30	10	20

Předpokládejme součinově multinomický výběr s pevnými počty studentů a studentek ($n_{\bullet\bullet 1} = 200$, $n_{\bullet\bullet 2} = 100$), takže každý uvažovaný model musí obsahovat člen $\lambda^{(C)}_k$.

(a) Odhadněte hierarchické log-lineární modely $[A][B][C]$, $[AB][C]$, $[AC][B]$, $[BC][A]$, $[AB][AC]$, $[AB][BC]$, $[AC][BC]$ a $[AB][AC][BC]$ a pro každý uveďte G^2, X^2, počet stupňů volnosti a p-hodnotu testu shody.

(b) Najděte **nejjednodušší** model, který není v rozporu s daty (saturovaný model $[ABC]$ vyhovuje vždy, ale nic nevysvětluje). Vnořené modely porovnejte pomocí rozdílu G^2.

(c) Vybraný model slovně interpretujte.

Výsledky:

model	G^2	X^2	df	p
$[A][B][C]$	46,56	47,17	4	$< 0{,}001$
$[AB][C]$	8,20	8,43	3	0,042
$[AC][B]$	46,56	47,17	3	$< 0{,}001$
$[BC][A]$	39,58	41,27	3	$< 0{,}001$
$[AB][AC]$	8,20	8,43	2	0,017
$[AB][BC]$	1,22	1,21	2	0,545
$[AC][BC]$	39,58	41,27	2	$< 0{,}001$
$[AB][AC][BC]$	0,10	0,10	1	0,757

Vyhovují pouze $[AB][BC]$ a $[AB][AC][BC]$; $\Delta G^2 = 1{,}12$, df $= 1$, $p = 0{,}29$ – člen $\lambda^{(AC)}$ není potřebný. Model $[AB][BC]$: úspěšnost (A) a pohlaví (C) jsou **podmíněně nezávislé při dané maturitě** (B). Úspěšnost závisí na maturitě z matematiky (podmíněné poměry šancí 6,0 u studentů a 5,0 u studentek), pohlaví souvisí s volbou maturity, ale při stejné maturitě se úspěšnost studentů a studentek neliší.

8. **Log-lineární modely – kouření a přežití.** Pro data z úlohy 3 (znaky $A =$ přežití po 20 letech, $B =$ kouření, $C =$ věková skupina; $I = J = 2$, $K = 6$) byly odhadnuty log-lineární modely jako Poissonův GLM:

model	G^2	df
$[A][B][C]$	704,61	16
$[AB][C]$	695,41	15
$[AB][BC]$	602,71	10
$[AB][AC]$	91,74	10
$[AC][BC]$	8,24	6
$[AB][AC][BC]$	2,77	5

(a) Ověřte stupně volnosti modelů $[AC][BC]$ a $[AB][AC][BC]$ podle obecných vzorců.

(b) Model $[AC][BC]$ vyhovuje na hladině 5 % ($p = 0{,}22$). Přesto jej porovnejte s modelem $[AB][AC][BC]$ testem poměrem věrohodností. Který model je vhodnější?

(c) Vybraný model interpretujte a porovnejte s výsledky úlohy 3. Co by znamenalo, kdyby nevyhověl ani model $[AB][AC][BC]$?

Výsledky: a) $[AC][BC]$: $K(I-1)(J-1) = 6$; $[AB][AC][BC]$: $(I-1)(J-1)(K-1) = 5$. b) $\Delta G^2 = 8{,}24 - 2{,}77 = 5{,}47$, df $= 1$, $p = 0{,}019$ – člen $\lambda^{(AB)}$ je potřebný, volíme model homogenní asociace $[AB][AC][BC]$ ($p = 0{,}74$). Samotná shoda jednoduššího modelu nestačí, vnořené modely je třeba porovnat. c) Přežití závisí na věku i na kouření, kouření souvisí s věkem a vztah kouření–přežití (poměr šancí) je ve všech věkových skupinách stejný – není potřeba trojná interakce. Odpovídá to úloze 3: $\Delta G^2 = 5{,}47$ je asymptoticky ekvivalentní CMH testu ($p = 0{,}020$) a shoda modelu $[AB][AC][BC]$ Breslowovu–Dayovu testu ($p = 0{,}73$). Kdyby model nevyhověl, poměr šancí by se mezi věkovými skupinami lišil (trojná interakce $\lambda^{(ABC)}$) a bylo by nutné interpretovat vztah po skupinách.