Přednáška 8: Vztahy diskrétních proměnných – kontingenční tabulky

KMA/MSM Blanka Šedivá

verze 2026/2027
7. října 2026

Obsah

1. Úvod
2. Dvourozměrné kontingenční tabulky
   - Kontingenční tabulka a testy nezávislosti
   - Míry asociace, rezidua a mozaikový graf
   - Čtyřpolní tabulky (2×2)
   - Testy symetrie pro párová data
3. Trojrozměrné tabulky a log-lineární modely
   - Výběrová schémata a parametrizace
   - Hierarchické modely M1–M4
   - Odhad modelů: IPF a Newton–Raphson
   - Testování shody modelu s daty
4. Příklad: přijímací řízení UC Berkeley 1973
   - Simpsonův paradox
   - Mantelův–Haenszelův test
   - Log-lineární modely pro data UCB

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Typy závislostí mezi náhodnými proměnnými

Dvě náhodné veličiny X a Y jsou **nezávislé**, pokud jejich sdružená distribuční funkce je součinem marginálních:

$$F(x, y) = F_X(x) \cdot F_Y(y) \quad \text{pro všechna } x, y.$$

Pro diskrétní veličiny s hodnotami $x_1, \ldots, x_r$ a $y_1, \ldots, y_c$ je to ekvivalentní s

$$p_{ij} = \mathcal{P}(X = x_i, Y = y_j) = \mathcal{P}(X = x_i)\,\mathcal{P}(Y = y_j) = p_{i\bullet}\, p_{\bullet j} \quad \text{pro všechna } i, j.$$

Veličiny $X_1, \ldots, X_k$ jsou (vzájemně) nezávislé, pokud $F(x_1, \ldots, x_k) = F_1(x_1) \cdots F_k(x_k)$ pro všechna $\boldsymbol{x} \in \mathbb{R}^k$. Vzájemná nezávislost **neplyne** z nezávislosti všech dvojic (párové nezávislosti).

Typy závislostí:

- **Symetrická závislost:** vztah je oboustranný, neexistuje přirozené rozlišení vstupu a výstupu (např. barva očí $\times$ barva vlasů).
- **Asymetrická závislost:** jedna proměnná je vysvětlující, druhá vysvětlovaná (např. léčba $\rightarrow$ výsledek).

Poznámka: Statistická závislost neimplikuje **kauzalitu**. Může být způsobena třetí (zavádějící) proměnnou – viz Simpsonův paradox na konci přednášky.

Typy statistických metod podle typu proměnných

	Diskrétní (závislá)	**Spojitá (závislá)**
Diskrétní (nezávislá)	kontingenční tabulky (symetrická vazba), log-lineární modely	t-test, ANOVA, ... regrese s kategoriální proměnnou
Spojitá (nezávislá)	logistická regrese multinomická regrese	korelace (symetrická vazba) regrese (nesymetrická vazba)

Tato přednáška: levý horní roh – obě proměnné diskrétní (kategoriální), data shrnutá do **tabulky četností**.

Ukázky v Pythonu: notebook `P08_kontingencni_tabulky.ipynb`.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Výpočty v Pythonu

Všechny výpočty a příklady z přednášky (včetně kódu a dalších simulací) jsou v notebooku `P08_kontingencni_tabulky.ipynb`. Použité funkce:

- χ^2 a G^2 test: `scipy.stats.chi2_contingency` (pozor: u 2×2 implicitně Yatesova korekce),
- míry asociace: `scipy.stats.contingency.association`,
- Fisherův test: `scipy.stats.fisher_exact`; McNemar: `scipy.stats.binomtest`, `contingency_tables.mcnemar`,
- rezidua, poměr šancí, testy symetrie: `statsmodels.stats.contingency_tables` (`Table`, `Table2x2`, `SquareTable`),
- Mantel–Haenszel, Breslow–Day: `StratifiedTable`,
- log-lineární modely: `statsmodels` GLM s Poissonovým rozdělením; mozaikový graf: `statsmodels.graphics.mosaicplot`.

`https://docs.scipy.org/doc/scipy/reference/stats.html`
`https://www.statsmodels.org/stable/contingency_tables.html`

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Kontingenční tabulka a matice pravděpodobností

- Řádky odpovídají r kategoriím znaku X, sloupce c kategoriím znaku Y; v buňce (i, j) je počet n_{ij} pozorování s $X = x_i$ a $Y = y_j$.
- Marginální četnosti: $n_{i\bullet} = \sum_j n_{ij}$, $n_{\bullet j} = \sum_i n_{ij}$, $n = \sum_{i,j} n_{ij}$.
- Teoretickým protějškem je matice pravděpodobností (p_{ij}) dvourozměrného diskrétního náhodného vektoru; $\hat{p}_{ij} = n_{ij}/n$.

Kontingenční tabulka $r \times c$

	1	...	c	Σ
1	n_{11}	...	n_{1c}	$n_{1\bullet}$
2	n_{21}	...	n_{2c}	$n_{2\bullet}$
...	...	...	...	...
r	n_{r1}	...	n_{rc}	$n_{r\bullet}$
Σ	$n_{\bullet 1}$	...	$n_{\bullet c}$	n

Matice pravděpodobností

	1	...	c	Σ
1	p_{11}	...	p_{1c}	$p_{1\bullet}$
2	p_{21}	...	p_{2c}	$p_{2\bullet}$
...	...	...	...	...
r	p_{r1}	...	p_{rc}	$p_{r\bullet}$
Σ	$p_{\bullet 1}$	...	$p_{\bullet c}$	1

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

χ^2 test nezávislosti (Pearsonův test)

Cíl
Ověřit, zda mezi dvěma kategoriálními znaky existuje statisticky významný vztah (symetrická závislost).

Předpoklady
Nezávislá pozorování, (n_{ij}) má multinomické rozdělení $\mathrm{Mult}(n; p_{ij})$. Očekávané četnosti dostatečně velké (obvykle všechny $\hat{m}_{ij} \geq 5$, resp. nejvýše 20 % buněk pod 5 a žádná pod 1).

Nulová hypotéza
H_0: znaky jsou nezávislé, tj. $p_{ij} = p_{i\bullet}\, p_{\bullet j}$ pro všechna i, j.

Alternativní hypotéza
H_1: $p_{ij} \neq p_{i\bullet}\, p_{\bullet j}$ pro alespoň jednu dvojici (i, j).

Očekávané četnosti
$$\hat{m}_{ij} = n\,\hat{p}_{i\bullet}\hat{p}_{\bullet j} = \frac{n_{i\bullet}\, n_{\bullet j}}{n} \quad \text{(MLE za platnosti } H_0\text{)}$$

Testovací statistika
$$X^2 = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(n_{ij} - \hat{m}_{ij})^2}{\hat{m}_{ij}}$$

Rozdělení
$X^2 \sim \chi^2\big((r-1)(c-1)\big)$ asymptoticky při platnosti H_0.

Stupně volnosti
$(rc - 1) - \big((r-1) + (c-1)\big) = (r-1)(c-1)$: počet volných parametrů bez omezení minus za H_0.

Poznámka: Jsou-li očekávané četnosti malé, slučujeme řádky/sloupce nebo použijeme Fisherův exaktní test.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

G^2 test nezávislosti (test poměrem věrohodností)

Cíl

Ověřit, zda mezi dvěma kategoriálními znaky existuje statisticky významná závislost.

Předpoklady

Stejné jako u Pearsonova χ^2 testu.

Hypotézy

H_0: $p_{ij} = p_{i\bullet}\, p_{\bullet j}$ proti H_1: $p_{ij} \neq p_{i\bullet}\, p_{\bullet j}$ pro některé i, j.

Testovací statistika

$$G^2 = 2 \sum_{i=1}^{r} \sum_{j=1}^{c} n_{ij} \ln \frac{n_{ij}}{\hat{m}_{ij}}, \qquad \hat{m}_{ij} = \frac{n_{i\bullet}\, n_{\bullet j}}{n}$$

(buňky s $n_{ij} = 0$ přispívají nulou).

Odvození

$G^2 = -2 \ln \Lambda$, kde Λ je poměr maximálních věrohodností multinomického modelu za H_0 a bez omezení ($\hat{p}_{ij} = n_{ij}/n$).

Rozdělení

$G^2 \sim \chi^2\big((r-1)(c-1)\big)$ asymptoticky při platnosti H_0.

Poznámka

X^2 a G^2 jsou asymptoticky ekvivalentní; při malých četnostech se mohou lišit (X^2 se obvykle lépe drží χ^2 aproximace). G^2 je **aditivní** při rozkladu modelů, proto je základem testování log-lineárních modelů („deviance“).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Test homogenity

- Stejná tabulka může vzniknout jiným **schématem výběru**: řádkové součty $n_{i\bullet}$ jsou **pevně stanoveny** předem (např. 100 mužů a 100 žen) a v každém řádku zjišťujeme rozdělení znaku Y.
- i-tý řádek má multinomické rozdělení $\mathrm{Mult}(n_{i\bullet};\, q_{i1}, \ldots, q_{ic})$, kde $q_{i1} + \cdots + q_{ic} = 1$; řádky jsou nezávislé (**součinově multinomický model**).
- Hypotéza **homogenity**: $H_0 : q_{1j} = q_{2j} = \cdots = q_{rj}$ pro všechna j, tj. podmíněné rozdělení Y nezávisí na řádku.
- Odhad za H_0: $\hat{q}_j = n_{\bullet j}/n$, tedy $\hat{m}_{ij} = n_{i\bullet}\hat{q}_j = n_{i\bullet}n_{\bullet j}/n$ – **stejné** jako u testu nezávislosti.
- Testovací statistiky (X^2, G^2), stupně volnosti $(r-1)(c-1)$ i kritické hodnoty jsou identické s testem nezávislosti; liší se jen interpretace („rozdělení Y je ve všech skupinách stejné“).

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Yatesova korekce na spojitost

- Statistika X^2 je diskrétní, ale aproximujeme ji spojitým rozdělením χ^2. U tabulky 2×2 s malými četnostmi je aproximace „liberální“ (p-hodnoty příliš malé).
- **Yatesova korekce** zmenšuje každou absolutní odchylku o 0,5:

$$X_Y^2 = \sum_{i,j} \frac{\left(|n_{ij} - \hat{m}_{ij}| - 0{,}5\right)^2}{\hat{m}_{ij}} = \frac{n\left(|n_{11}n_{22} - n_{12}n_{21}| - n/2\right)^2}{n_{1\bullet}n_{2\bullet}n_{\bullet 1}n_{\bullet 2}}.$$

- Korekce je **konzervativní** (p-hodnoty spíše větší); při velkém n má zanedbatelný vliv.
- Dnes se místo ní u malých tabulek doporučuje spíš exaktní (Fisherův) test.

Pozor na software: `scipy.stats.chi2_contingency` provádí Yatesovu korekci **automaticky** u tabulek s 1 stupněm volnosti (výchozí `correction=True`). Pro klasický Pearsonův test je nutné zadat `correction=False`.

Příklad $\begin{pmatrix} 30 & 10 \\ 20 & 40 \end{pmatrix}$: bez korekce $X^2 = 16{,}67$ ($p = 4{,}5 \cdot 10^{-5}$), s korekcí $X_Y^2 = 15{,}04$ ($p = 1{,}1 \cdot 10^{-4}$).

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Míry asociace (síla závislosti)

P-hodnota testu závisí na n – při velkém n je „významná“ i zanedbatelná závislost.
Sílu závislosti popisují normované míry založené na X^2:

- **Koeficient** φ (tabulka 2×2): $\varphi = \dfrac{n_{11}n_{22} - n_{12}n_{21}}{\sqrt{n_{1\bullet}n_{2\bullet}n_{\bullet 1}n_{\bullet 2}}}$, $\varphi^2 = X^2/n$, $\varphi \in \langle -1, 1\rangle$.
- **Cramérovo** V: $V = \sqrt{\dfrac{X^2}{n\,(\min(r,c) - 1)}} \in \langle 0, 1\rangle$; $V = 0$ při nezávislosti „ve výběru“, $V = 1$ při úplné závislosti.
- **Kontingenční koeficient** (Pearsonův): $C = \sqrt{\dfrac{X^2}{X^2 + n}}$; jeho maximum je < 1 a závisí na rozměru tabulky ($\sqrt{(q-1)/q}$, $q = \min(r,c)$).

Orientačně (Cohen, pro $\min(r,c) = 2$): $V \approx 0{,}1$ slabá, $0{,}3$ střední, $0{,}5$ silná asociace.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Adjustovaná standardizovaná rezidua

Zamítnutí H_0 neříká, **které buňky** se od nezávislosti odchylují. K tomu slouží rezidua:

- **Pearsonovo reziduum**: $e_{ij} = \dfrac{n_{ij} - \hat{m}_{ij}}{\sqrt{\hat{m}_{ij}}}, \quad X^2 = \sum_{i,j} e_{ij}^2.$

  Má ale za H_0 rozptyl menší než 1 (odhad $\hat{m}_{ij}$ je z týchž dat).
- **Adjustované standardizované reziduum** (Haberman):

$$r_{ij} = \frac{n_{ij} - \hat{m}_{ij}}{\sqrt{\hat{m}_{ij}\left(1 - \dfrac{n_{i\bullet}}{n}\right)\left(1 - \dfrac{n_{\bullet j}}{n}\right)}} \approx N(0,1) \text{ za } H_0.$$

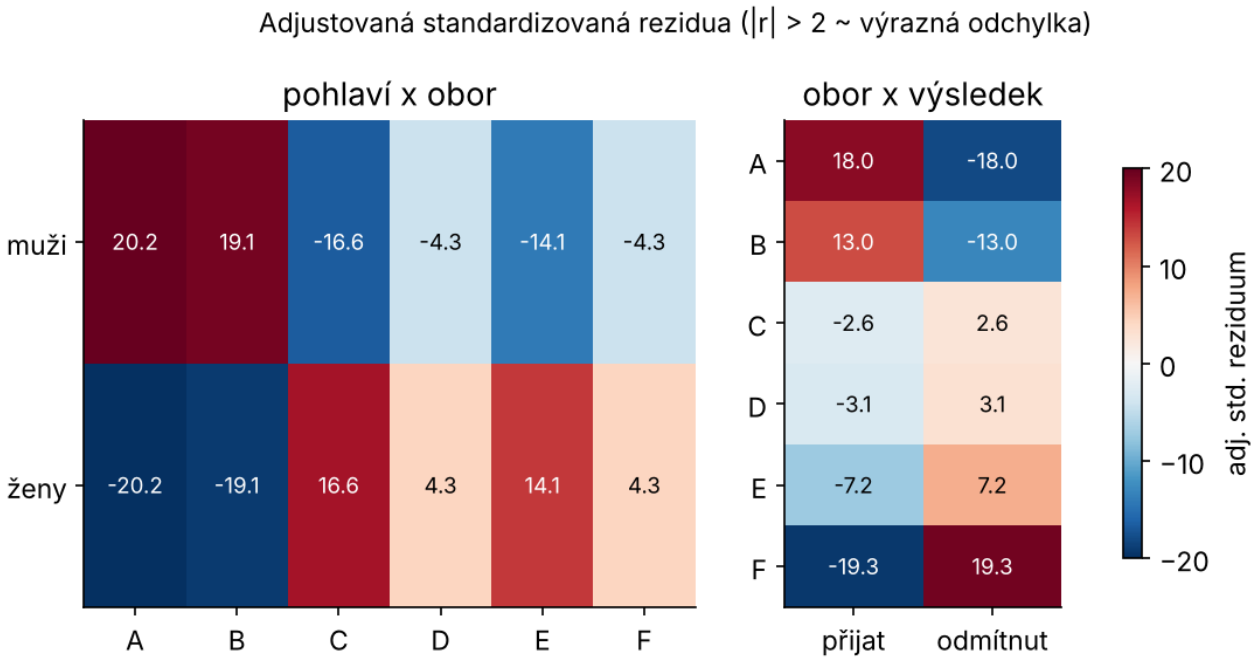
- **Interpretace:** $|r_{ij}| > 2$ (resp. $> 1{,}96$) značí buňku, kde je pozorováno výrazně víc ($r_{ij} > 0$) nebo méně ($r_{ij} < 0$) případů, než odpovídá nezávislosti.
- Při mnoha buňkách jde o mnohonásobné porovnání – hranici je vhodné zpřísnit (např. Bonferroni, $|r_{ij}| > 3$).
- V tabulce 2×2 mají všechna r_{ij} stejnou absolutní hodnotu a $r_{11}^2 = X^2$.

Python: `Table(tab).standardized_resids` ze `statsmodels.stats.contingency_tables`, `https://www.statsmodels.org/stable/contingency_tables.html`

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Rezidua – příklad (přijímací řízení Berkeley 1973)

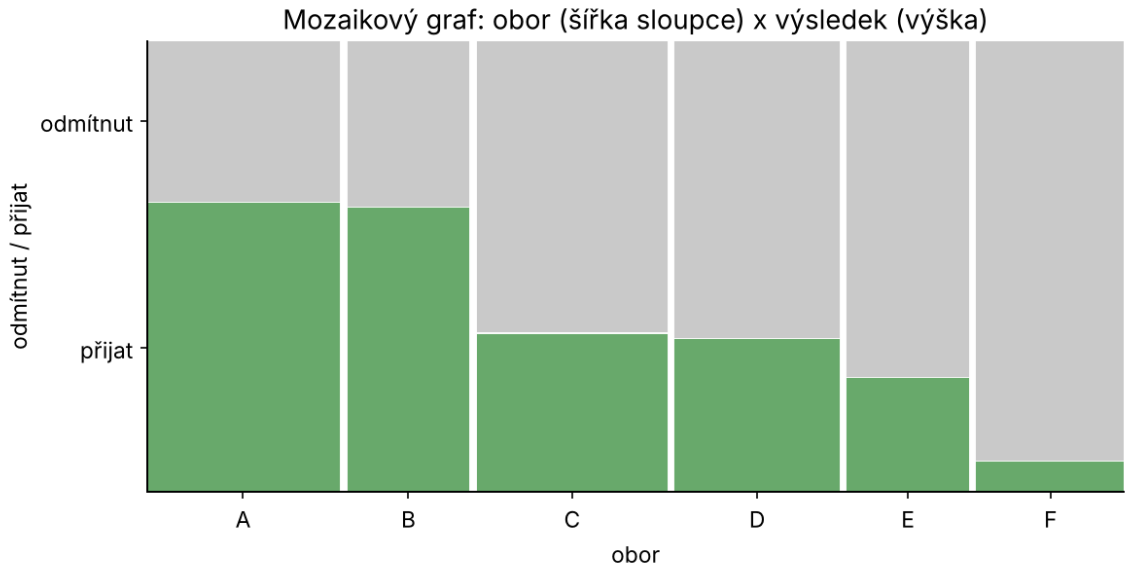
Tabulka obor (A–F) $\times$ výsledek (přijat / odmítnut), $n = 4526$: $X^2 = 778{,}9$, df $= 5$, $p < 10^{-100}$. Adjustovaná standardizovaná rezidua:



Obory A, B přijímají výrazně víc, C–F méně, než odpovídá nezávislosti; ženy se hlásily převážně na obory C–F.

Mozaikový graf

Plocha obdélníku je úměrná četnosti n_{ij}: šířka sloupce $\sim n_{\bullet j}$ (resp. $n_{i\bullet}$), výška $\sim$ podmíněné relativní četnosti. Při nezávislosti by dělicí čáry byly ve všech sloupcích ve stejné výšce.



Čtyřpolní tabulky

n_{11}	n_{12}	$n_{1\bullet}$
n_{21}	n_{22}	$n_{2\bullet}$
$n_{\bullet 1}$	$n_{\bullet 2}$	n

- Testovací statistika pro test nezávislosti i homogenity v čtyřpolní tabulce má tvar

$$X^2 = \frac{n\left(n_{11}n_{22} - n_{12}n_{21}\right)^2}{n_{\bullet 1}n_{\bullet 2}n_{1\bullet}n_{2\bullet}},$$

  kterou porovnáváme s kritickou hodnotou $\chi^2_{1-\alpha}(1)$ rozdělení χ^2 s jedním stupněm volnosti (verze s Yatesovou korekcí viz výše).
- Typické situace: expozice (ano/ne) × onemocnění (ano/ne), léčba × výsledek, pohlaví × přijetí.
- Kromě testu nás zajímá **míra účinku** – poměr šancí (odds ratio).

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Čtyřpolní tabulky: poměr šancí

- Označme $s_1 = \frac{n_{11}}{n_{12}}$ šanci (odds) $Y = y_1$ proti $Y = y_2$ při $X = x_1$ a $s_2 = \frac{n_{21}}{n_{22}}$ šanci při $X = x_2$. Jejich podíl je **výběrový poměr šancí**

$$b = \frac{s_1}{s_2} = \frac{n_{11} n_{22}}{n_{12} n_{21}}.$$

- Protože $\frac{n_{ij}}{n}$ je odhadem p_{ij}, je b odhadem teoretického poměru šancí $\beta = \frac{p_{11} p_{22}}{p_{12} p_{21}}$.
- V čtyřpolní tabulce platí $\beta = 1$ právě tehdy, když $p_{ij} = p_{i\bullet}\, p_{\bullet j}$; závislost je tím silnější, čím dál je β od 1.
- β je symetrický vůči záměně řádků a sloupců a **nezávisí na marginálních součtech** (stejný při prospektivním i retrospektivním, case–control, výběru).
- Kvůli nesymetrii kolem 1 ($\beta \in (0, \infty)$; β a $1/\beta$ vyjadřují stejně silnou závislost) se používá logaritmus $d = \ln b, \qquad \delta = \ln \beta$.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Test a interval spolehlivosti pro poměr šancí

Cíl
Ověřit, zda se poměr šancí liší od referenční hodnoty β_0 (obvykle 1), a odhadnout jej intervalem.

Předpoklady
Tabulka 2×2, všechny $n_{ij} > 0$ a dostatečně velké (asymptotická normalita d).

Hypotézy
$H_0\colon \delta = \ln \beta = \delta_0$ (obvykle 0) proti $H_1\colon \delta \neq \delta_0$.

Směrodatná chyba
$$SE(d) = \sqrt{\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}}}$$ (delta metoda)

Testovací statistika
$$D = \frac{d - \delta_0}{SE(d)}, \quad d = \ln b$$

Rozdělení
$D \sim N(0, 1)$ asymptoticky při platnosti H_0.

Interval spolehlivosti
Pro δ: $d \pm z_{1-\alpha/2}\, SE(d)$; pro β zpětnou transformací $\left(\mathrm{e}^{d - z_{1-\alpha/2} SE(d)},\ \mathrm{e}^{d + z_{1-\alpha/2} SE(d)}\right)$ – interval je nesymetrický kolem b.

Poznámka
Při nulové buňce se často přičte 0,5 ke všem buňkám (Haldaneova–Anscombeova korekce).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Fisherův exaktní test (tabulka 2 × 2)

Cíl

Otestovat nezávislost dvou dichotomických znaků i při malých četnostech.

Předpoklady

Tabulka 2×2; test je **podmíněný** pevnými marginálními četnostmi (i když je experiment nefixuje).

Hypotézy

H_0: znaky jsou nezávislé ($\beta = 1$) proti H_1: $\beta \neq 1$ (příp. jednostranně).

Rozdělení za H_0

Při pevných marginálech je n_{11} hypergeometrické:

$$\mathcal{P}(n_{11} = a) = \frac{\binom{n_{1\bullet}}{a}\binom{n_{2\bullet}}{n_{\bullet 1}-a}}{\binom{n}{n_{\bullet 1}}} = \frac{n_{1\bullet}!\, n_{2\bullet}!\, n_{\bullet 1}!\, n_{\bullet 2}!}{n!\, n_{11}!\, n_{12}!\, n_{21}!\, n_{22}!}$$

P-hodnota

Součet pravděpodobností všech tabulek se stejnými marginály, které nejsou pravděpodobnější než pozorovaná (tj. „stejně nebo více extrémní“).

Vlastnosti

P-hodnota je spočtena **exaktně**, bez asymptotických předpokladů. Kvůli diskrétnosti je test konzervativní (alternativy: Barnardův, Boschlooův test – `scipy.stats.barnard_exact`, `boschloo_exact`).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Obecný Fisherův exaktní test ($r \times c$)

- Fisherův (Freemanův–Haltonův) test lze aplikovat na libovolnou tabulku $r \times c$: za H_0 a při pevných marginálech má tabulka (vícerozměrné) hypergeometrické rozdělení
$$\mathcal{P}((n_{ij})) = \frac{\prod_i n_{i\bullet}! \prod_j n_{\bullet j}!}{n! \prod_{i,j} n_{ij}!}.$$
- P-hodnota = součet pravděpodobností všech tabulek se stejnými marginály, které nejsou pravděpodobnější než pozorovaná.
- Počet takových tabulek rychle roste – pro větší tabulky se p-hodnota odhaduje **Monte Carlo** simulací (náhodné tabulky s danými marginály), případně MCMC.
- V Pythonu (SciPy $\geq$ 1.15): `fisher_exact(table, method=MonteCarloMethod(...))` pro $r \times c$ tabulky; `scipy.stats.random_table` generuje tabulky s danými marginály.

Kdy použít exaktní test:

- **malé očekávané četnosti** – χ^2 aproximace je nepřesná,
- **tabulka** 2×2 – výpočet je triviální, exaktní test je vždy k dispozici,
- **malý výběr nebo vzácné události** – např. účinnost léčby u malého počtu pacientů.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Čtyřpolní tabulky – výsledky příkladů

Příklad 1: $\begin{pmatrix} 30 & 10 \\ 20 & 40 \end{pmatrix}$, $n = 100$, očekávané četnosti $\begin{pmatrix} 20 & 20 \\ 30 & 30 \end{pmatrix}$.

- Pearsonův test: $X^2 = 16{,}67$, df $= 1$, $p = 4{,}5 \cdot 10^{-5}$; s Yatesovou korekcí $X^2_Y = 15{,}04$ ($p = 1{,}1 \cdot 10^{-4}$); $G^2 = 17{,}26$ ($p = 3{,}3 \cdot 10^{-5}$).
- Síla závislosti: Cramérovo $V = 0{,}408$, kontingenční koeficient $C = 0{,}378$.
- Poměr šancí: $b = 6{,}0$, $SE(d) = 0{,}456$, $D = 3{,}93$, $p = 8{,}7 \cdot 10^{-5}$, 95% IS pro β: $(2{,}45;\ 14{,}68)$ – šance na $Y = y_1$ je ve skupině x_1 asi 6krát vyšší.

Příklad 2: $\begin{pmatrix} 8 & 2 \\ 1 & 5 \end{pmatrix}$, $n = 16$, očekávané četnosti $\begin{pmatrix} 5{,}6 & 4{,}4 \\ 3{,}4 & 2{,}6 \end{pmatrix}$ – podmínka pro χ^2 test není splněna, použijeme Fisherův test.

- Při pevných marginálech může být $n_{11} = 3, \ldots, 9$ s pravděpodobnostmi $0{,}0105;\ 0{,}1101;\ 0{,}3304;\ 0{,}3671;\ 0{,}1573;\ 0{,}0236;\ 0{,}0009$.
- Pozorovaná tabulka ($n_{11} = 8$) má $P = 0{,}0236$; do p-hodnoty patří tabulky s $P \leq 0{,}0236$, tj. $n_{11} \in \{3, 8, 9\}$: $p = 0{,}0105 + 0{,}0236 + 0{,}0009 = 0{,}0350 < 0{,}05$ $\Rightarrow$ nezávislost zamítáme.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

McNemarův test (párová data, tabulka 2×2)

Cíl
Ověřit, zda zákrok změnil pravděpodobnost výskytu znaku (stejný subjekt měřen dvakrát – párová data).

Data
Párová pozorování uspořádaná do čtyřpolní tabulky:
n_{11}: znak před i po zákroku, n_{22}: znak ani před, ani po,
n_{12}: znak pouze před zákrokem, n_{21}: znak pouze po zákroku.

Hypotézy
H_0: $p_{12} = p_{21}$ (symetrie $\Leftrightarrow p_{1\bullet} = p_{\bullet 1}$, marginální homogenita)
H_1: $p_{12} \neq p_{21}$ (příp. jednostranně).

Asymptotická varianta
$\chi^2 = \dfrac{(n_{12} - n_{21})^2}{n_{12} + n_{21}} \sim \chi^2(1)$ při platnosti H_0
(s korekcí na spojitost: $(|n_{12} - n_{21}| - 1)^2/(n_{12} + n_{21})$).

Exaktní varianta
Za H_0 a při daném počtu „nesouhlasných“ párů $n_d = n_{12} + n_{21}$ je $n_{12} \sim Bi(n_d, \frac{1}{2})$ – binomický test. Vhodná při malém n_d (obvykle $n_d < 25$).

Poznámka
Diagonální (souhlasné) páry n_{11}, n_{22} nenesou informaci o změně a do statistiky nevstupují.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

McNemarův test – příklad

	Po zákroku: Ano	Po zákroku: Ne	Celkem
Před zákrokem: Ano	$n_{11} = 30$	$n_{12} = 10$	40
Před zákrokem: Ne	$n_{21} = 20$	$n_{22} = 40$	60
Celkem	50	50	100

Hypotézy: $H_0 : p_{12} = p_{21}$ (symetrie), $H_1 : p_{12} \neq p_{21}$.

Asymptotická varianta:

$$\chi^2 = \frac{(n_{12} - n_{21})^2}{n_{12} + n_{21}} = \frac{(10 - 20)^2}{10 + 20} = \frac{100}{30} \approx 3{,}33,$$

p-hodnota $= \mathcal{P}(\chi^2(1) \geq 3{,}33) \approx 0{,}068$. Při $\alpha = 0{,}05$ hypotézu H_0 **nezamítáme**.

Exaktní varianta: binomický test, $n_{12} = 10$ z $n_d = 30$, $p = 0{,}5$: p-hodnota $= 2\,\mathcal{P}(Bi(30; 0{,}5) \leq 10) \approx 0{,}099$. Při $\alpha = 0{,}05$ hypotézu H_0 **nezamítáme**.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

McNemarův test – rozdílné rozhodnutí

	Po zákroku: Ano	Po zákroku: Ne	Celkem
Před zákrokem: Ano	$n_{11} = 20$	$n_{12} = 0$	20
Před zákrokem: Ne	$n_{21} = 5$	$n_{22} = 25$	30
Celkem	25	25	50

Asymptotická varianta:

$$\chi^2 = \frac{(0-5)^2}{0+5} = \frac{25}{5} = 5{,}0,$$

p-hodnota $= \mathcal{P}(\chi^2(1) \geq 5{,}0) \approx 0{,}0253$. Při $\alpha = 0{,}05$ hypotézu H_0 **zamítáme**.

Exaktní varianta: binomický test, $n_{12} = 0$ z $n_d = 5$, $p = 0{,}5$: p-hodnota $= 2 \cdot 0{,}5^5 = 0{,}0625$. Při $\alpha = 0{,}05$ hypotézu H_0 **nezamítáme**.

Při malém počtu nesouhlasných párů je asymptotická varianta příliš „optimistická“ (liberální); exaktní test je spolehlivější. S korekcí na spojitost by vyšlo $\chi^2 = 3{,}2$, $p = 0{,}074$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Bowkerův test symetrie ($c \times c$)

Cíl
Ověřit, zda párová data uspořádaná ve čtvercové tabulce $c \times c$ (stejné kategorie před a po) jsou symetrická. Zobecnění McNemarova testu.

Předpoklady
Párová data, čtvercová tabulka $c \times c$, dostatečně velké součty $n_{ij} + n_{ji}$.

Nulová hypotéza
H_0: $p_{ij} = p_{ji}$ pro všechna $i \neq j$ (symetrie).

Alternativní hypotéza
H_1: existuje dvojice (i, j), pro kterou $p_{ij} \neq p_{ji}$.

Testovací statistika
$$X_B^2 = \sum_{i<j} \frac{(n_{ij} - n_{ji})^2}{n_{ij} + n_{ji}}$$ (sčítáme přes dvojice s $n_{ij} + n_{ji} > 0$)

Rozdělení
$X_B^2 \sim \chi^2\left(\frac{c(c-1)}{2}\right)$ asymptoticky při platnosti H_0.

Poznámka
Pro $c = 2$ je to přesně McNemarův test.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Stuartův–Maxwellův test marginální homogenity

Cíl Ověřit, zda se marginální rozdělení před a po shodují.

Předpoklady Párová data ve čtvercové tabulce $c \times c$, dostatečně velké n.

Hypotézy H_0: $p_{i\bullet} = p_{\bullet i}$ pro všechna $i = 1, \ldots, c$; H_1: pro některé i $p_{i\bullet} \neq p_{\bullet i}$.

Rozdíly marginálů $d_i = n_{i\bullet} - n_{\bullet i}$, $i = 1, \ldots, c$. Platí $\sum_i d_i = 0$, proto bereme jen $\boldsymbol{d}^* = (d_1, \ldots, d_{c-1})^T$.

Kovarianční matice Odhad $\mathbf{Var}\,(\boldsymbol{d}^*)$ za H_0: $\boldsymbol{V} = (V_{ij})_{i,j=1}^{c-1}$,

$V_{ii} = n_{i\bullet} + n_{\bullet i} - 2n_{ii}$, $V_{ij} = -(n_{ij} + n_{ji})$ pro $i \neq j$.

($V_{ii} = \sum_{j \neq i}(n_{ij} + n_{ji})$ – jen mimodiagonální páry.)

Testovací statistika $Q = \boldsymbol{d}^{*T} \boldsymbol{V}^{-1} \boldsymbol{d}^*$ (nezávisí na tom, který rozdíl vynecháme).

Rozdělení $Q \sim \chi^2(c-1)$ asymptoticky při platnosti H_0.

Poznámka $\boldsymbol{d}^*$ je asymptoticky normální $N_{c-1}(\mathbf{0}, \mathbf{Var}\,(\boldsymbol{d}^*))$, proto má kvadratická forma Q rozdělení χ^2. Pro $c = 2$ je Q McNemarova statistika.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Bowker vs. Stuart–Maxwell – rozdíl v hypotézách

- **Bowkerův test symetrie**:

$$H_0 : p_{ij} = p_{ji} \text{ pro všechna } i \neq j$$

  Testuje **symetrii** čtvercové tabulky – zda pravděpodobnost přechodu z kategorie i do j je stejná jako z j do i.

- **Stuartův–Maxwellův test homogenity marginálů**:

$$H_0 : p_{i\bullet} = p_{\bullet i} \text{ pro všechny kategorie } i$$

  Testuje **rovnost marginálních rozdělení** – zda celkové rozložení kategorií před a po intervenci je stejné.

- **Vztah**: symetrie $\Rightarrow$ marginální homogenita, ale ne naopak (pro $c \geq 3$). Přechody se mohou „vyrušit“ v cyklu $1 \to 2 \to 3 \to 1$.

- **Shrnutí**:
  - Bowker: zaměřuje se na **buňky mimo diagonálu** (df $= c(c-1)/2$).
  - Stuart–Maxwell: zaměřuje se na **marginální četnosti** (df $= c - 1$).
  - Pro $c = 2$ splývají oba testy s McNemarovým testem.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Bowker a Stuart–Maxwell – příklad

Párové hodnocení před (řádky) a po (sloupce) intervenci ve třech kategoriích:

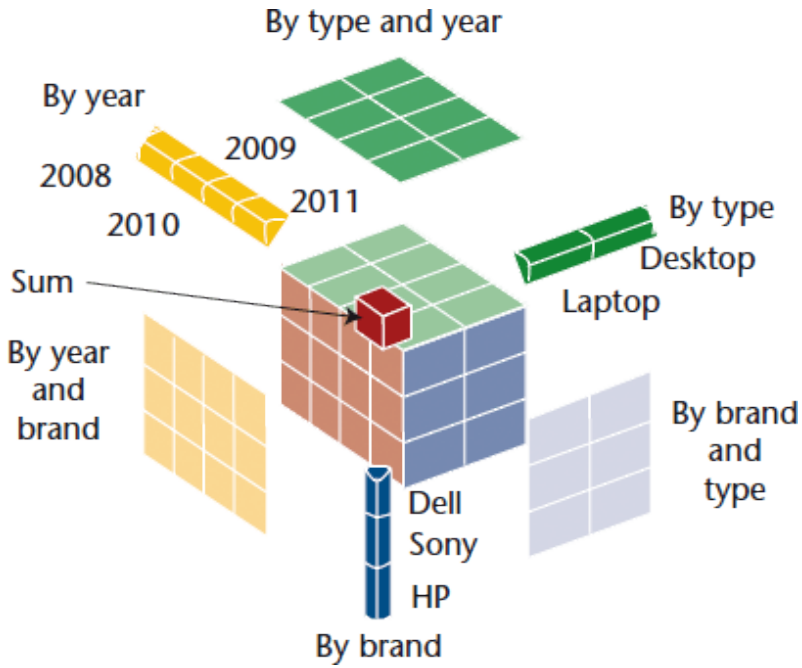
	nízké	střední	vysoké	Σ
nízké	40	8	2	50
střední	10	35	5	50
vysoké	3	7	40	50
Σ	53	50	47	150

- **Bowker:** $X_B^2 = \frac{(8-10)^2}{18} + \frac{(2-3)^2}{5} + \frac{(5-7)^2}{12} = 0{,}756$, df $= 3$, $p = 0{,}860$ – symetrii nezamítáme.
- **Stuart–Maxwell:** $\boldsymbol{d}^* = (50 - 53,\ 50 - 50) = (-3,\ 0)$, $Q = 0{,}738$, df $= 2$, $p = 0{,}692$ – marginální rozdělení před a po se významně neliší.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Trojrozměrné kontingenční tabulky

Uvažujeme tři kategoriální znaky A (I kategorií), B (J kategorií), C (K kategorií) a trojrozměrnou tabulku četností (n_{ijk}), $i = 1, \ldots, I$, $j = 1, \ldots, J$, $k = 1, \ldots, K$.



- Marginální součty: $n_{ij\bullet} = \sum_k n_{ijk}$, $n_{i\bullet k}$, $n_{\bullet jk}$, $n_{i\bullet\bullet}$, $\ldots$, $n = n_{\bullet\bullet\bullet}$.
- Očekávané četnosti $m_{ijk} = \mathbb{E}\, n_{ijk}$, jejich odhady $\hat{m}_{ijk}$.
- **Pozor na značení:** v této sekci je k index kategorie třetího znaku (nikoli dimenze dat).

Výběrová schémata: Poissonův, multinomický, součinově multinomický

- **Poissonův model**: n_{ijk} nezávislé, $n_{ijk} \sim Po(m_{ijk})$; celkový počet n není pevný (např. počty událostí za období).

$$\mathcal{P}((n_{ijk})) = \prod_{i,j,k} \frac{m_{ijk}^{n_{ijk}}}{n_{ijk}!} \mathrm{e}^{-m_{ijk}}, \qquad \ell = \sum_{i,j,k} (n_{ijk} \ln m_{ijk} - m_{ijk}) + \text{konst.}$$

- **Multinomický model**: pevné n, $(n_{ijk}) \sim \mathrm{Mult}(n;\, p_{ijk})$, $\sum p_{ijk} = 1$, $m_{ijk} = n\, p_{ijk}$:

$$\mathcal{P}((n_{ijk})) = n! \prod_{i,j,k} \frac{p_{ijk}^{n_{ijk}}}{n_{ijk}!}, \qquad \ell = \sum_{i,j,k} n_{ijk} \ln p_{ijk} + \text{konst.}$$

  Vzniká z Poissonova modelu podmíněním $\sum n_{ijk} = n$.
- **Součinově multinomický model**: pevné jsou některé marginály, např. $n_{\bullet jk}$; pro každou dvojici (j,k) je $(n_{1jk}, \ldots, n_{Ijk}) \sim \mathrm{Mult}(n_{\bullet jk};\, p_{1jk}, \ldots, p_{Ijk})$, $\sum_i p_{ijk} = 1$, nezávisle; $m_{ijk} = n_{\bullet jk}\, p_{ijk}$.
- **Ekvivalence:** MLE očekávaných četností $\hat{m}_{ijk}$ (a tedy X^2, G^2, df) jsou ve všech třech schématech **totožné** (přesně, ne jen asymptoticky), pokud log-lineární model obsahuje člen odpovídající pevným marginálům (intercept pro pevné n, člen $\lambda_{jk}^{(BC)}$ pro pevné $n_{\bullet jk}$). Proto lze vždy počítat s Poissonovým modelem (GLM).

Log-lineární parametrizace

Saturovaný (úplný) model:

$$\ln m_{ijk} = \lambda + \underbrace{\lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)}}_{\text{hlavní efekty}} + \underbrace{\lambda_{ij}^{(AB)} + \lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)}}_{\text{interakce I. řádu}} + \underbrace{\lambda_{ijk}^{(ABC)}}_{\text{interakce II. řádu}}$$

(v multinomickém modelu $\ln p_{ijk} = \ln m_{ijk} - \ln n$, liší se jen konstanta λ).

Význam parametrů:

- λ: intercept (normalizační konstanta, zajišťuje $\sum m_{ijk} = n$).
- hlavní efekty: nestejné marginální četnosti jednotlivých znaků,
- interakce I. řádu (dvojné): např. $\lambda_{ij}^{(AB)} \neq 0 \Rightarrow A$ a B jsou (podmíněně) závislé; v tabulce $2 \times 2 \times K$ je ln podmíněného poměru šancí = součet čtyř členů $\pm\lambda^{(AB)}$,
- interakce II. řádu (trojná): asociace A–B se mění s úrovní C.

Identifikační podmínky (součtové): $\sum_i \lambda_i^{(A)} = 0, \ldots, \sum_i \lambda_{ij}^{(AB)} = \sum_j \lambda_{ij}^{(AB)} = 0, \ldots,$ $\sum_i \lambda_{ijk}^{(ABC)} = \sum_j \lambda_{ijk}^{(ABC)} = \sum_k \lambda_{ijk}^{(ABC)} = 0$. Software (statsmodels, R) obvykle používá místo toho referenční kódování (první kategorie = 0) – $\hat{m}_{ijk}$ jsou stejné.

Hierarchický model: obsahuje-li interakci, obsahuje i všechny členy nižšího řádu z ní odvozené. Značíme jej „generujícími třídami“, např. $[AB][C]$.

Hierarchické log-lineární modely pro trojrozměrné tabulky

Všechny modely obsahují $\lambda + \lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)}$ (hlavní efekty); liší se interakcemi:

Model	**Značení**	**Interakční členy v** $\ln m_{ijk}$
M1: úplná nezávislost	$[A][B][C]$	–
M2: sdružená nezávislost	$[AB][C]$	$\lambda_{ij}^{(AB)}$
	$[AC][B]$	$\lambda_{ik}^{(AC)}$
	$[BC][A]$	$\lambda_{jk}^{(BC)}$
M3: podmíněná nezávislost	$[AC][BC]$	$\lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)}$
	$[AB][BC]$	$\lambda_{ij}^{(AB)} + \lambda_{jk}^{(BC)}$
	$[AB][AC]$	$\lambda_{ij}^{(AB)} + \lambda_{ik}^{(AC)}$
M4: homogenní asociace	$[AB][AC][BC]$	$\lambda_{ij}^{(AB)} + \lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)}$
saturovaný model	$[ABC]$	$\lambda_{ij}^{(AB)} + \lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)} + \lambda_{ijk}^{(ABC)}$

Modely jsou **vnořené**: M1 $\subset$ M2 $\subset$ M3 $\subset$ M4 $\subset$ saturovaný (pro vhodné varianty, např. $[A][B][C] \subset [AC][B] \subset [AC][BC]$). Postačujícími statistikami jsou marginály odpovídající generujícím třídám; MLE splňuje $\hat{m} = n$ na těchto marginálech.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Model M1 – úplná nezávislost $[A][B][C]$

Model: $\ln m_{ijk} = \lambda + \lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)}$, tj. $p_{ijk} = p_{i\bullet\bullet}\, p_{\bullet j\bullet}\, p_{\bullet\bullet k}$.

Odhad očekávaných četností $\hat{m}_{ijk} = n\,\hat{p}_{ijk}$, kde $\hat{p}_{i\bullet\bullet} = n_{i\bullet\bullet}/n$ atd.:

$$\hat{m}_{ijk} = n\,\frac{n_{i\bullet\bullet}}{n}\,\frac{n_{\bullet j\bullet}}{n}\,\frac{n_{\bullet\bullet k}}{n} = \frac{n_{i\bullet\bullet}\, n_{\bullet j\bullet}\, n_{\bullet\bullet k}}{n^2},$$

kde $n_{i\bullet\bullet}, n_{\bullet j\bullet}, n_{\bullet\bullet k}$ jsou jednorozměrné marginální součty.

Testovací statistiky:

$$X^2 = \sum_{i,j,k} \frac{(n_{ijk} - \hat{m}_{ijk})^2}{\hat{m}_{ijk}}, \qquad G^2 = 2\sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{\hat{m}_{ijk}}$$

Rozdělení za H_0 (platí M1):

$$X^2, G^2 \sim \chi^2(\mathrm{df}), \quad \mathrm{df} = (IJK - 1) - \big((I-1) + (J-1) + (K-1)\big) = IJK - I - J - K + 2.$$

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Model M2 – sdružená nezávislost

- **Varianta 1** $[AB][C]$**:** znaky A a B jsou závislé, dvojice (A, B) je nezávislá na C.

$$\ln m_{ijk} = \lambda + \lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)} + \lambda_{ij}^{(AB)}, \qquad \hat{m}_{ijk} = \frac{n_{ij\bullet}\, n_{\bullet\bullet k}}{n},$$

  kde $n_{ij\bullet}$ je marginální součet přes k pro dvojici (i, j) a $n_{\bullet\bullet k}$ součet přes i, j pro kategorii k. Stupně volnosti $\mathrm{df} = IJK - (IJ + K - 1) = (IJ - 1)(K - 1)$.

- **Varianta 2** $[AC][B]$**:** A a C jsou závislé, B je nezávislý na (A, C).

$$\ln m_{ijk} = \ldots + \lambda_{ik}^{(AC)}, \quad \hat{m}_{ijk} = \frac{n_{i\bullet k}\, n_{\bullet j\bullet}}{n}, \quad \mathrm{df} = (IK - 1)(J - 1).$$

- **Varianta 3** $[BC][A]$**:** B a C jsou závislé, A je nezávislý na (B, C).

$$\ln m_{ijk} = \ldots + \lambda_{jk}^{(BC)}, \quad \hat{m}_{ijk} = \frac{n_{i\bullet\bullet}\, n_{\bullet jk}}{n}, \quad \mathrm{df} = (JK - 1)(I - 1).$$

Model M2 je vlastně test nezávislosti v dvourozměrné tabulce, kde jeden „znak“ tvoří kombinace dvou původních.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Model M3 – podmíněná nezávislost

- **Varianta 1** $[AC][BC]$**:** A a B jsou nezávislé při každé pevné hodnotě C ($A \perp B \mid C$).

$$\ln m_{ijk} = \lambda + \lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)} + \lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)}, \qquad \hat{m}_{ijk} = \frac{n_{i\bullet k}\, n_{\bullet jk}}{n_{\bullet\bullet k}},$$

  kde $n_{i\bullet k}$ je součet přes j pro dvojici (i,k) a $n_{\bullet jk}$ součet přes i pro dvojici (j,k).
  Stupně volnosti $\mathrm{df} = IJK - (IK + JK - K) = K(I-1)(J-1)$
  (součet df testů nezávislosti v K dílčích tabulkách $I \times J$).

- **Varianta 2** $[AB][BC]$**:** $A \perp C \mid B$.

$$\hat{m}_{ijk} = \frac{n_{ij\bullet}\, n_{\bullet jk}}{n_{\bullet j\bullet}}, \qquad \mathrm{df} = J(I-1)(K-1).$$

- **Varianta 3** $[AB][AC]$**:** $B \perp C \mid A$.

$$\hat{m}_{ijk} = \frac{n_{ij\bullet}\, n_{i\bullet k}}{n_{i\bullet\bullet}}, \qquad \mathrm{df} = I(J-1)(K-1).$$

Pozor: podmíněná nezávislost $A \perp B \mid C$ **neimplikuje** marginální nezávislost $A \perp B$ (a naopak) – viz Simpsonův paradox.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Model M4 – párová závislost (homogenní asociace)

Model $[AB][AC][BC]$**:**

$$\ln m_{ijk} = \lambda + \lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)} + \lambda_{ij}^{(AB)} + \lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)}$$

- Každá dvojice znaků je závislá, ale **podmíněné poměry šancí** mezi A a B jsou stejné pro všechny úrovně C (a analogicky pro ostatní dvojice) – „homogenní asociace“.
- **Neexistuje uzavřený vzorec** pro $\hat{m}_{ijk}$; MLE jsou určeny podmínkami (věrohodnostní rovnice)

$$\hat{m}_{ij\bullet} = n_{ij\bullet}, \qquad \hat{m}_{i\bullet k} = n_{i\bullet k}, \qquad \hat{m}_{\bullet jk} = n_{\bullet jk}.$$

- Řeší se iteračně: **IPF** (Iterative Proportional Fitting) nebo **Newtonova–Raphsonova metoda** (= Poissonův GLM, IRLS).
- Stupně volnosti:

$$\mathrm{df} = (I-1)(J-1)(K-1)$$

(počet parametrů trojné interakce, které model M4 vynechává oproti saturovanému modelu).

- Pro tabulku $2 \times 2 \times K$ je test M4 asymptoticky ekvivalentní Breslowovu–Dayovu testu homogenity poměrů šancí.

Iterative Proportional Fitting (IPF)

Iterační postup (Deming, Stephan 1940) pro model M4:

- Počáteční aproximace $\hat{m}_{ijk}^{(0)} = 1$ (libovolná konstanta, resp. libovolná tabulka splňující model).
- V cyklu $r = 0, 1, 2, \ldots$ postupně přizpůsobujeme odhad každému marginálu z generujících tříd:

$$\hat{m}_{ijk}^{(3r+1)} = \hat{m}_{ijk}^{(3r)} \frac{n_{ij\bullet}}{\hat{m}_{ij\bullet}^{(3r)}} \quad \text{(marginál } AB\text{)}$$

$$\hat{m}_{ijk}^{(3r+2)} = \hat{m}_{ijk}^{(3r+1)} \frac{n_{i\bullet k}}{\hat{m}_{i\bullet k}^{(3r+1)}} \quad \text{(marginál } AC\text{)}$$

$$\hat{m}_{ijk}^{(3r+3)} = \hat{m}_{ijk}^{(3r+2)} \frac{n_{\bullet jk}}{\hat{m}_{\bullet jk}^{(3r+2)}} \quad \text{(marginál } BC\text{)}$$

- Iterace končí, když se odhady $\hat{m}_{ijk}$ přestanou významně měnit (např. $\max |\hat{m}^{(new)} - \hat{m}^{(old)}| < \varepsilon$).
- Pro libovolný hierarchický model se postupuje stejně – cyklicky přes všechny generující třídy. Pro modely M1–M3 (s uzavřeným tvarem) IPF konverguje po prvním cyklu.
- Každý krok nezmenšuje věrohodnost a IPF konverguje k **MLE** $\hat{m}_{ijk}$ (pokud MLE existuje).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Newton–Raphson = Poissonův GLM (IRLS)

Log-lineární model zapíšeme maticově: $\ln \boldsymbol{m} = \boldsymbol{X}\boldsymbol{\lambda}$, kde $\boldsymbol{X}$ je návrhová matice (dummy proměnné pro hlavní efekty a interakce) a $\boldsymbol{n}$ vektor četností. Jde o **zobecněný lineární model** (GLM – generalized linear model) s Poissonovým rozdělením a logaritmickou linkovou funkcí.

Log-věrohodnost (Poissonův model):

$$\ell(\boldsymbol{\lambda}) = \sum_{i,j,k} \left(n_{ijk} \ln m_{ijk} - m_{ijk} \right) + \text{konst.} \;=\; \boldsymbol{n}^T \boldsymbol{X}\boldsymbol{\lambda} - \mathbf{1}^T \mathrm{e}^{\boldsymbol{X}\boldsymbol{\lambda}} + \text{konst.}$$

je **konkávní** v $\boldsymbol{\lambda} \Rightarrow$ jediné maximum (pokud existuje).

Gradient a Hessova matice:

$$\boldsymbol{g} = \frac{\partial \ell}{\partial \boldsymbol{\lambda}} = \boldsymbol{X}^T(\boldsymbol{n} - \boldsymbol{m}), \qquad \boldsymbol{H} = \frac{\partial^2 \ell}{\partial \boldsymbol{\lambda}\, \partial \boldsymbol{\lambda}^T} = -\boldsymbol{X}^T \operatorname{diag}(\boldsymbol{m})\, \boldsymbol{X}.$$

Iterační krok:

$$\boldsymbol{\lambda}^{(t+1)} = \boldsymbol{\lambda}^{(t)} - \boldsymbol{H}^{-1}\boldsymbol{g} = \boldsymbol{\lambda}^{(t)} + \left(\boldsymbol{X}^T \operatorname{diag}(\boldsymbol{m}^{(t)}) \boldsymbol{X}\right)^{-1} \boldsymbol{X}^T \left(\boldsymbol{n} - \boldsymbol{m}^{(t)}\right), \qquad \boldsymbol{m}^{(t)} = \mathrm{e}^{\boldsymbol{X}\boldsymbol{\lambda}^{(t)}}.$$

Pro kanonickou (log) linku je Newton–Raphson totožný s Fisher scoring a lze jej zapsat jako **iterativně vážené nejmenší čtverce** (IRLS) – standardní algoritmus GLM.

Konvergence: $\|\boldsymbol{\lambda}^{(t+1)} - \boldsymbol{\lambda}^{(t)}\| < \varepsilon$ nebo změna deviance $< \varepsilon$. Podmínka $\boldsymbol{g} = \mathbf{0}$ je přesně rovnost pozorovaných a odhadnutých marginálů.

IPF vs. Newton–Raphson – srovnání a doporučení

IPF – výhody jednoduchá implementace bez derivací a inverzí matic, malé paměťové nároky; pro každý hierarchický model konverguje k MLE (věrohodnost neklesá); přesně reprodukuje postačující marginály.

IPF – nevýhody nedává přímo odhady parametrů λ ani jejich směrodatné chyby; lineární (někdy pomalá) konvergence; jen modely zadané marginály (ne kovariáty, skóre, offset).

NR (GLM) – výhody odhady $\hat{\lambda}$, SE, Waldovy testy, intervaly spolehlivosti; kvadratická konvergence; obecný rámec (libovolná návrhová matice, nehierarchické modely).

NR (GLM) – nevýhody v každém kroku soustava s maticí $\boldsymbol{X}^T \mathrm{diag}(\boldsymbol{m})\boldsymbol{X}$ – náročné pro velmi velké tabulky; při nulových marginálech MLE neexistuje ($\hat{\lambda} \to \pm\infty$, varování o nekonvergenci).

Doporučení: v praxi Poissonův GLM (`statsmodels`); IPF pro velmi velké tabulky nebo jako kontrola.

Testování modelů

Shodu modelu s pozorovanými četnostmi testujeme statistikami

$$X^2 = \sum_{i,j,k} \frac{(n_{ijk} - \hat{m}_{ijk})^2}{\hat{m}_{ijk}} \text{ (Pearson)}, \qquad G^2 = 2\sum_{i,j,k} n_{ijk} \ln \frac{n_{ijk}}{\hat{m}_{ijk}} \text{ (věrohodnostní poměr, deviance)}.$$

Při platnosti modelu mají asymptoticky rozdělení $\chi^2(\text{df})$, df = počet buněk − počet nezávislých parametrů:

Model	Označení	Stupně volnosti
M1	$[A][B][C]$	$IJK - I - J - K + 2$
M2	$[AB][C]$; $[AC][B]$; $[BC][A]$	$(IJ-1)(K-1)$; $(IK-1)(J-1)$; $(JK-1)(I-1)$
M3	$[AC][BC]$; $[AB][BC]$; $[AB][AC]$	$K(I-1)(J-1)$; $J(I-1)(K-1)$; $I(J-1)(K-1)$
M4	$[AB][AC][BC]$	$(I-1)(J-1)(K-1)$
saturovaný	$[ABC]$	0

Porovnání vnořených modelů $M_0 \subset M_1$: $\Delta G^2 = G^2(M_0) - G^2(M_1) \sim \chi^2\left(\text{df}_0 - \text{df}_1\right)$ za platnosti M_0. Testuje, zda jsou členy navíc v M_1 potřebné.

Volba modelu: hledáme **nejjednodušší** model, který nezamítáme (případně podle AIC).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

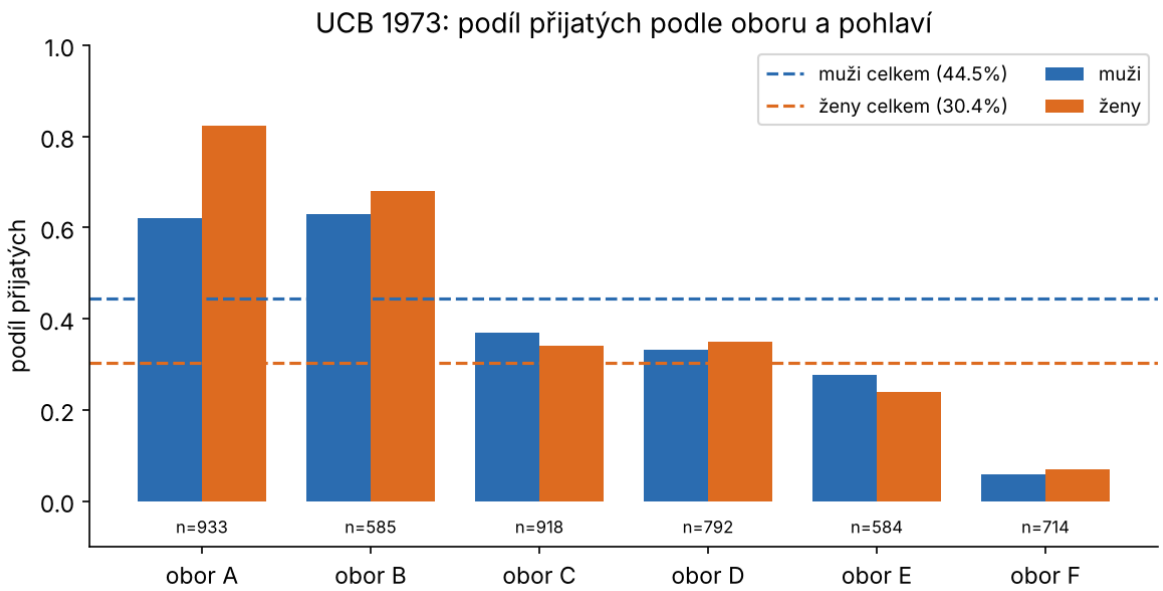
Data UCBAdmissions (Berkeley 1973)

Uchazeči o postgraduální studium na 6 největších oborech, $n = 4526$ (Bickel, Hammel, O'Connell, *Science* 1975). Tabulka $2 \times 2 \times 6$: A = výsledek, B = pohlaví, C = obor.

	Muži		Ženy		Podíl přijatých	
Obor	přijat	odmítnut	přijata	odmítnuta	muži	ženy
A	512	313	89	19	0,62	0,82
B	353	207	17	8	0,63	0,68
C	120	205	202	391	0,37	0,34
D	138	279	131	244	0,33	0,35
E	53	138	94	299	0,28	0,24
F	22	351	24	317	0,06	0,07
Celkem	1198	1493	557	1278	**0,45**	**0,30**

- Celkově jsou muži přijímáni častěji (44,5 % vs. 30,4 %), marginální poměr šancí (muži/ženy) $b = 1{,}84$, χ^2 test v tabulce 2×2 vysoce významný.
- V jednotlivých oborech ale rozdíly malé a v oborech A, B, D, F jsou úspěšnější ženy.

Simpsonův paradox



- Podmíněné poměry šancí (muži/ženy) v oborech A–F: 0,35; 0,80; 1,13; 0,92; 1,22; 0,83, ale marginální 1,84.
- **Simpsonův paradox**: směr asociace v agregované tabulce je opačný než v dílčích tabulkách. Příčina: obor (C) souvisí s pohlavím i s výsledkem – ženy se hlásily převážně na obory s nízkou úspěšností (viz rezidua).
- Agregace přes zavádějící proměnnou je nepřípustná; je třeba analyzovat podmíněnou asociaci A–B při daném C.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Cochranův–Mantelův–Haenszelův test a společný poměr šancí

Cíl

V K tabulkách 2×2 (vrstvy podle C) testovat podmíněnou nezávislost $A \perp B \mid C$ a odhadnout společný poměr šancí.

Hypotézy

H_0: $\beta_1 = \cdots = \beta_K = 1$ proti H_1: $\beta_k = \beta \neq 1$ (společný OR).

Statistika CMH

$$\chi^2_{MH} = \frac{\left(\sum_k (n_{11k} - \mathbb{E} n_{11k})\right)^2}{\sum_k \operatorname{var} n_{11k}}, \quad \mathbb{E} n_{11k} = \frac{n_{1\bullet k} n_{\bullet 1k}}{n_{\bullet\bullet k}},$$

$$\operatorname{var} n_{11k} = \frac{n_{1\bullet k} n_{2\bullet k} n_{\bullet 1k} n_{\bullet 2k}}{n^2_{\bullet\bullet k}(n_{\bullet\bullet k} - 1)}$$ (hypergeometrické momenty)

Rozdělení

$\chi^2_{MH} \sim \chi^2(1)$ asymptoticky za H_0 (příp. s korekcí $-0{,}5$ v čitateli).

MH odhad OR

$$\hat{\beta}_{MH} = \frac{\sum_k n_{11k} n_{22k} / n_{\bullet\bullet k}}{\sum_k n_{12k} n_{21k} / n_{\bullet\bullet k}}$$

Předpoklad

Test má největší sílu, když jsou OR ve vrstvách podobné. Homogenitu $H_0 : \beta_1 = \cdots = \beta_K$ ověřuje **Breslowův–Dayův test**, $\chi^2(K-1)$ (odpovídá testu modelu M4).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Mantel–Haenszel – výsledky pro data UCB

- Marginální OR (muži/ženy, přijetí) $b = 1{,}84$; podmíněné OR v oborech A–F: 0,35; 0,80; 1,13; 0,92; 1,22; 0,83.
- $\hat{\beta}_{MH} = 0{,}905$, 95% IS (0,772; 1,060) – po zohlednění oboru **žádná** výhoda mužů.
- CMH: $\chi^2_{MH} = 1{,}52$, $p = 0{,}217$ – podmíněnou nezávislost pohlaví a výsledku nezamítáme.
- Breslow–Day: 18,83, df $= 5$, $p = 0{,}002$ – OR nejsou homogenní (způsobeno oborem A, kde $b = 0{,}35$; bez oboru A $p = 0{,}63$).
- Souvislost s log-lineárními modely (asymptoticky ekvivalentní testy): CMH $\approx$ porovnání $[AC][BC]$ vs. $[AB][AC][BC]$ ($\Delta G^2 = 1{,}53$), Breslow–Day $\approx$ test shody modelu M4 ($X^2 = 18{,}82$) – viz další slidy.
- Interpretace: v oboru A jsou ženy přijímány výrazně častěji ($b = 0{,}35$, tj. šance mužů je asi třetinová); v ostatních oborech jsou rozdíly malé a nevýznamné.

Výsledky log-lineárních modelů (UCB)

A = výsledek, B = pohlaví, C = obor ($I = J = 2$, $K = 6$). Výstup kódu z předchozího slidu; deviance Poissonova GLM je přesně G^2 vůči saturovanému modelu, `df_resid` odpovídá tabulce stupňů volnosti.

Model	Značení	G^2	X^2	df	p-hodnota
M1	$[A][B][C]$	2097,67	2000,33	16	$< 10^{-300}$
M2	$[AB][C]$	2004,22	1748,16	15	$< 10^{-300}$
M2	$[AC][B]$	1242,35	1078,07	11	$1{,}2 \cdot 10^{-259}$
M2	$[BC][A]$	877,06	797,70	11	$5{,}3 \cdot 10^{-181}$
M3	$[AC][BC]$	21,74	19,94	6	0,0014
M3	$[AB][BC]$	783,61	715,30	10	$6{,}9 \cdot 10^{-162}$
M3	$[AB][AC]$	1148,90	1015,71	10	$1{,}5 \cdot 10^{-240}$
M4	$[AB][AC][BC]$	20,20	18,82	5	0,0011

- Modely bez $[AC]$ nebo $[BC]$ jsou zcela nevhodné: obor souvisí s výsledkem i s pohlavím.
- $[AC][BC]$ (výsledek $\perp$ pohlaví $|$ obor) je výrazně nejlepší z jednodušších modelů; přidání $[AB]$: $\Delta G^2 = 21{,}74 - 20{,}20 = 1{,}53$, df $= 1$, $p = 0{,}22$ – člen $[AB]$ není potřeba (v souladu s CMH testem).
- I M4 je ale zamítnut ($p = 0{,}001$) – je přítomna trojná interakce (obor A, viz Breslow–Day). Bez oboru A model $[AC][BC]$ vyhovuje ($G^2 = 2{,}68$, df $= 5$, $p = 0{,}75$).
- **Závěr:** rozdíl v celkové úspěšnosti mužů a žen vysvětluje volba oboru, ne diskriminace při přijímání.