KMA/MSM – Přednáška 8: Kontingenční tabulky

Kontrolní otázky (uzavřené) – verze s řešením

U otázek označených (*jedna odpověď*) je správná právě jedna možnost, u otázek označených (*více odpovědí*) může být správných více možností.

Otázka 1 (jedna odpověď)

Testujeme nezávislost dvou kategoriálních znaků v kontingenční tabulce s $r = 3$ řádky a $c = 4$ sloupci. Kolik stupňů volnosti má asymptotické rozdělení Pearsonovy statistiky X^2 při platnosti H_0?

a) 12

b) 11

c) 7

d) 6 **[správně]**

Řešení: $(r-1)(c-1) = 2 \cdot 3 = 6$. Počet buněk minus jedna (11) by odpovídal testu dobré shody se zcela zadaným rozdělením; odečítáme ještě $(r-1)+(c-1) = 5$ odhadnutých marginálních pravděpodobností.

Otázka 2 (více odpovědí)

Která tvrzení o Fisherově exaktním testu jsou pravdivá?

a) Test podmiňuje pozorovanými marginálními četnostmi; za H_0 má n_{11} hypergeometrické rozdělení. **[správně]**

b) P-hodnota se počítá exaktně, bez asymptotické aproximace rozdělením χ^2. **[správně]**

c) Test lze použít pouze tehdy, jsou-li všechny očekávané četnosti alespoň 5.

d) Kvůli diskrétnosti rozdělení testové statistiky je test konzervativní (skutečná hladina bývá menší než α). **[správně]**

e) Test je definován pouze pro tabulky typu 2×2.

Řešení: Správně a), b), d). Podmínka $\hat{m}_{ij} \geq 5$ se týká asymptotického χ^2 testu – Fisherův test se používá právě tehdy, když splněna není. Zobecnění na tabulky $r \times c$ existuje (Freemanův–Haltonův test), pro větší tabulky se p-hodnota často odhaduje simulací.

Otázka 3 (jedna odpověď)

Ve studii byla získána čtyřpolní tabulka

	$Y =$ ano	$Y =$ ne
$X =$ expozice	20	10
$X =$ bez expozice	5	15

Jaký je výběrový poměr šancí b (šance na $Y =$ ano u exponovaných vůči neexponovaným)?

a) $b = 1{,}5$

b) $b = 3$

c) $b = 6$ **[správně]**

d) $b = 0{,}17$

Řešení: $b = \dfrac{n_{11}n_{22}}{n_{12}n_{21}} = \dfrac{20/10}{5/15} = \dfrac{20 \cdot 15}{10 \cdot 5} = 6$. Hodnota $0{,}17 = 1/6$ je obrácený poměr (neexponovaní vůči exponovaným). Pozor na záměnu s relativním rizikem $\frac{20/30}{5/20} = 2{,}67$.

Otázka 4 (více odpovědí)

U n pacientů jsme zjišťovali přítomnost příznaku před léčbou a po léčbě. Data máme uspořádaná do čtyřpolní tabulky (řádky = před, sloupce = po). Která tvrzení jsou správná?

a) Vhodný je McNemarův test, nulová hypotéza je $p_{12} = p_{21}$. **[správně]**

b) Vhodný je Pearsonův χ^2 test nezávislosti, protože jde o tabulku 2×2.

c) Statistika McNemarova testu nezávisí na diagonálních četnostech n_{11} a n_{22}. **[správně]**

d) Exaktní varianta je binomický test pro n_{12} s parametry $n_{12} + n_{21}$ a $p = \frac{1}{2}$. **[správně]**

e) Hypotéza $p_{12} = p_{21}$ je ekvivalentní hypotéze $p_{1\bullet} = p_{\bullet 1}$ (stejná pravděpodobnost příznaku před a po). **[správně]**

Řešení: Správně a), c), d), e). Data jsou párová (tentýž pacient dvakrát), test nezávislosti by odpovídal na jinou otázku – zda stav po léčbě souvisí se stavem před léčbou. Pro tabulku 2×2 platí $p_{1\bullet} - p_{\bullet 1} = p_{12} - p_{21}$, proto symetrie a marginální homogenita splývají (pro $c \geq 3$ už ne – Bowker vs. Stuart–Maxwell).

Otázka 5 (jedna odpověď)

Pro trojrozměrnou tabulku se znaky A, B, C jsme přijali log-lineární model $[AC][BC]$, tj.

$$\log m_{ijk} = \lambda + \lambda_i^{(A)} + \lambda_j^{(B)} + \lambda_k^{(C)} + \lambda_{ik}^{(AC)} + \lambda_{jk}^{(BC)}.$$

Co tento model vyjadřuje?

a) Znaky A, B, C jsou vzájemně nezávislé.

b) Znak C je nezávislý na dvojici (A, B).

c) Znaky A a B jsou podmíněně nezávislé při dané hodnotě C. **[správně]**

d) Znaky A a B jsou nezávislé v marginální tabulce $A \times B$.

Řešení: Model neobsahuje člen $\lambda^{(AB)}$ ani $\lambda^{(ABC)}$, proto $\hat{m}_{ijk} = n_{i\bullet k}\, n_{\bullet jk} / n_{\bullet\bullet k}$ a podmíněné poměry šancí mezi A a B jsou v každé vrstvě k rovny 1. Marginální nezávislost (d) z toho *neplyne* – přes společnou závislost na C mohou být A a B marginálně závislé (Simpsonův paradox).