KMA/MSM – cvičení 9: Korelace

(verze s výsledky)

Část A počítejte ručně (kalkulačka), část B v Pythonu (`scipy.stats`, `pingouin`, `statsmodels`), viz notebook `P09_korelace.ipynb`. Pokud není řečeno jinak, volte hladinu $\alpha = 0{,}05$; $u_{0{,}975} = 1{,}96$.

A. Výpočty ručně

1. **Pearsonův koeficient, test a interval spolehlivosti.** U 8 studentů byl zaznamenán počet hodin přípravy x a počet bodů v testu y:

x	2	4	5	6	8	9	11	13
y	52	61	55	60	70	58	74	68

   (a) Spočtěte $S_{xx} = \sum(x_i - \bar{x})^2$, S_{yy}, S_{xy} a Pearsonův koeficient r.

   (b) Otestujte $H_0 : \rho = 0$ ($t_{0{,}975}(6) = 2{,}447$).

   (c) Pomocí Fisherovy transformace sestrojte 95% interval spolehlivosti pro ρ. Proč není symetrický kolem r?

   (d) Spočtěte přibližně nestranný odhad $r_{adj} = r\left(1 + \frac{1-r^2}{2(n-3)}\right)$.

   (e) Spočtěte reflexivní koeficient $\widehat{\mathrm{cor}}_r = \sum x_i y_i / \sqrt{\sum x_i^2 \sum y_i^2}$ ($\sum x_i y_i = 3763$, $\sum x_i^2 = 516$, $\sum y_i^2 = 31414$). Proč vychází tak vysoko a je zde jeho použití vhodné?

   Výsledky: a) $\bar{x} = 7{,}25$, $\bar{y} = 62{,}25$, $S_{xx} = 95{,}5$, $S_{yy} = 413{,}5$, $S_{xy} = 152{,}5$, $r = 152{,}5/\sqrt{95{,}5 \cdot 413{,}5} = 0{,}767$. b) $t = 0{,}767\sqrt{6/(1-0{,}589)} = 2{,}93 > 2{,}447$, $p = 0{,}026$ – zamítáme nezávislost. c) $z = \operatorname{artanh} 0{,}767 = 1{,}014$, $z \pm 1{,}96/\sqrt{5} = (0{,}137;\ 1{,}891)$, zpětně $(0{,}137;\ 0{,}955)$. Rozdělení r je pro $\rho \neq 0$ zešikmené (omezené hodnotou 1), symetrický je interval až pro z; při $n = 8$ je interval velmi široký. d) $r_{adj} = 0{,}767(1 + 0{,}411/10) = 0{,}799$. e) $\widehat{\mathrm{cor}}_r = 3763/\sqrt{516 \cdot 31414} = 0{,}935$. Body jsou daleko od počátku (body kolem 60), proto oba vektory míří „stejným směrem“ bez ohledu na vzájemný vztah odchylek. Body nemají přirozenou nulu, reflexivní koeficient zde nedává smysl.

2. **Fisherova transformace – test $\rho = \rho_0$ a plánování rozsahu.** Ve výběru $n = 40$ firem vyšla korelace mezi výdaji na reklamu a obratem $r = 0{,}62$. Z dřívějších let se uvádí $\rho_0 = 0{,}4$.

   (a) Sestrojte 95% interval spolehlivosti pro ρ.

   (b) Otestujte $H_0 : \rho = 0{,}4$ proti oboustranné alternativě a proti alternativě $\rho > 0{,}4$.

   (c) Proč zde nelze použít statistiku $t = r\sqrt{(n-2)/(1-r^2)}$?

   (d) Kolik firem by bylo třeba, aby polovina šířky 95% IS byla nejvýše 0,1 (předpokládejte $r \approx 0{,}6$)? Použijte přibližný vzorec pro šířku $2u_{1-\alpha/2}(1-r^2)/\sqrt{n}$.

   Výsledky: a) $z = 0{,}725$, $1/\sqrt{37} = 0{,}164$, $(0{,}403;\ 1{,}047) \to (0{,}382;\ 0{,}781)$. b) $Z = (0{,}725 - 0{,}424)\sqrt{37} = 1{,}83$; oboustranně $p = 0{,}067$ (nezamítáme), jednostranně $p = 0{,}033$ (zamítáme). Interval z a) obsahuje 0,4 jen těsně. c) t-statistika má rozdělení t_{n-2} jen pro $\rho = 0$. d) $n \approx (2 \cdot 1{,}96 \cdot 0{,}64/0{,}2)^2 = 157{,}3$, tj. asi 158 firem (přesně přes Fisherovu z vychází 161).

3. **Porovnání korelací ve skupinách.** Korelace mezi známkou z matematiky a z fyziky byla zjištěna na třech školách:

škola	1	2	3
n_j	60	45	50
r_j	0,45	0,28	0,64

   (a) Testem χ^2 ověřte shodu všech tří korelací ($\chi^2_{0,95}(2) = 5{,}99$) a spočtěte společný odhad ρ.

   (b) Porovnejte všechny dvojice škol Z-testem. Jak výsledek interpretovat ve srovnání s a)? Co se změní při Bonferroniho korekci?

Výsledky: a) $z_j = 0{,}485;\ 0{,}288;\ 0{,}758$, váhy $n_j - 3 = 57;\ 42;\ 47$, $\bar{z}_w = 0{,}516$, $\chi^2 = 5{,}00 < 5{,}99$, $p = 0{,}082$ – shodu nezamítáme; společný odhad $\hat{\rho} = \tanh 0{,}516 = 0{,}475$. b) $Z_{12} = 0{,}97$ ($p = 0{,}33$), $Z_{13} = -1{,}39$ ($p = 0{,}17$), $Z_{23} = -2{,}22$ ($p = 0{,}027$). Jediný „významný“ rozdíl (školy 2 a 3) je výsledkem tří testů; s Bonferroniho korekcí (hladina $0{,}05/3 = 0{,}0167$) jej neprokazujeme, což je v souladu s globálním testem.

4. **Mnohonásobná a parciální korelace z korelační matice.** U $n = 50$ zaměstnanců byly zjištěny korelace mezi výkonem Y, praxí X_1 (roky) a věkem X_2: $r_{YX_1} = 0{,}6$, $r_{YX_2} = 0{,}5$, $r_{X_1X_2} = 0{,}7$.

   (a) Spočtěte mnohonásobný koeficient $R_{Y\cdot(X_1,X_2)}$, R^2 a R^2_{adj}. Otestujte $H_0 : \rho_{Y\cdot X} = 0$ ($F_{0,95}(2, 47) = 3{,}20$).

   (b) Spočtěte parciální korelace $r_{YX_2\cdot X_1}$ a $r_{YX_1\cdot X_2}$ a otestujte je ($t_{0,975}(47) = 2{,}01$). Interpretujte.

   (c) Ověřte výsledky pomocí inverze korelační matice $\boldsymbol{R}^{-1} = \begin{pmatrix} 1{,}594 & -0{,}781 & -0{,}25 \\ -0{,}781 & 2{,}344 & -1{,}25 \\ -0{,}25 & -1{,}25 & 2 \end{pmatrix}$ (pořadí Y, X_1, X_2).

Výsledky: a) $R^2 = \frac{0{,}36+0{,}25-2\cdot 0{,}6\cdot 0{,}5\cdot 0{,}7}{1-0{,}49} = \frac{0{,}19}{0{,}51} = 0{,}373$, $R = 0{,}610$, $R^2_{adj} = 1 - \frac{49}{47}\,0{,}627 = 0{,}346$; $F = \frac{47}{2}\cdot\frac{0{,}373}{0{,}627} = 13{,}95 > 3{,}20$, $p = 1{,}8\cdot 10^{-5}$. b) $r_{YX_2\cdot X_1} = \frac{0{,}5-0{,}42}{\sqrt{0{,}64\cdot 0{,}51}} = 0{,}140$, $t = 0{,}97$, $p = 0{,}34$; $r_{YX_1\cdot X_2} = \frac{0{,}6-0{,}35}{\sqrt{0{,}75\cdot 0{,}51}} = 0{,}404$, $t = 3{,}03$, $p = 0{,}004$. Korelace výkonu s věkem je vysvětlena praxí (starší mají delší praxi); při stejné praxi věk s výkonem významně nesouvisí, naopak praxe ano i při stejném věku. c) $R^2 = 1 - 1/1{,}594 = 0{,}373$; $r_{YX_2\cdot X_1} = 0{,}25/\sqrt{1{,}594\cdot 2} = 0{,}140$, $r_{YX_1\cdot X_2} = 0{,}781/\sqrt{1{,}594\cdot 2{,}344} = 0{,}404$ (zde je kontrolní veličina vždy jen jedna, takže „všechny ostatní“ = ta jedna).

5. **Zdánlivá korelace.** V $n = 30$ letních týdnech byly zaznamenány tržby za zmrzlinu Y, počet utonutí Z a průměrná teplota X: $r_{YZ} = 0{,}52$, $r_{YX} = 0{,}80$, $r_{ZX} = 0{,}68$.

   (a) Je korelace r_{YZ} významná ($t_{0,975}(28) = 2{,}05$)?

   (b) Spočtěte parciální korelaci $r_{YZ\cdot X}$, otestujte ji a výsledek interpretujte.

Výsledky: a) $t = 0{,}52\sqrt{28/(1-0{,}27)} = 3{,}22$, $p = 0{,}003$ – významná. b) $r_{YZ\cdot X} = \frac{0{,}52-0{,}544}{\sqrt{0{,}36\cdot 0{,}538}} = -0{,}055$, $t = -0{,}28$ (27 st. v.), $p = 0{,}78$. Při stejné teplotě spolu tržby a utonutí nesouvisejí – korelace je zdánlivá, způsobená společnou příčinou (teplota).

6. **Spearmanův a Kendallův koeficient se shodami.** Dva porotci hodnotili 10 soutěžících body 1–10:

soutěžící	1	2	3	4	5	6	7	8	9	10
porotce A	7	5	8	6	9	5	4	8	3	6
porotce B	6	6	9	5	8	4	5	7	4	7

(a) Určete průměrná pořadí, $\sum d_i^2$ a Spearmanův koeficient korektním vzorcem se shodami. Porovnejte se zjednodušeným vzorcem $1 - 6\sum d_i^2/(n(n^2-1))$.

(b) Otestujte nezávislost pomocí $u = r_S\sqrt{n-1}$.

(c) Mezi 45 dvojicemi soutěžících je 34 konkordantních, 4 diskordantní a 7 dvojic má shodu alespoň u jednoho porotce. Spočtěte τ_a a τ_b.

Výsledky: a) Pořadí A: 7; 3,5; 8,5; 5,5; 10; 3,5; 2; 8,5; 1; 5,5; B: 5,5; 5,5; 10; 3,5; 9; 1,5; 3,5; 7,5; 1,5; 7,5. $\sum d_i^2 = 25$, $T_x = 3 \cdot 6 = 18$, $T_y = 4 \cdot 6 = 24$, $r_S = \frac{990-21-150}{\sqrt{972 \cdot 966}} = 0{,}845$; zjednodušený vzorec dá 0,848 (při málo shodách je rozdíl malý). b) $u = 0{,}845 \cdot 3 = 2{,}54 > 1{,}96$ – zamítáme nezávislost (`scipy`: $p = 0{,}002$). c) $\tau_a = (34-4)/45 = 0{,}667$; $n_1 = 3$, $n_2 = 4$, $\tau_b = 30/\sqrt{(45-3)(45-4)} = 0{,}723$ (`scipy`: $p = 0{,}006$).

7. **Kendallovo τ bez shod.** Pro 7 vzorků byla změřena koncentrace látky dvěma metodami:

x	3,1	1,2	4,5	2,8	5,0	3,9	2,2
y	2,0	1,5	3,1	2,6	2,9	3,5	1,1

(a) Seřaďte dvojice podle x, spočtěte počty konkordantních a diskordantních dvojic a τ.

(b) Otestujte nezávislost asymptotickým testem.

(c) Za předpokladu normality odhadněte ρ ze vztahu $\tau = \frac{2}{\pi}\arcsin\rho$.

Výsledky: a) Pořadí y seřazená podle x: $2, 1, 4, 3, 7, 6, 5$; $c = 16$, $d = 5$, $\tau = 11/21 = 0{,}524$. b) $\operatorname{var}\tau = \frac{2 \cdot 19}{9 \cdot 42} = 0{,}1005$, $Z = 0{,}524/0{,}317 = 1{,}65$, $p = 0{,}099$ – nezamítáme (přesný test v `scipy` $p = 0{,}136$; pro srovnání Pearson $r = 0{,}805$, $p = 0{,}029$). c) $\hat\rho = \sin(\pi \cdot 0{,}524/2) = 0{,}733$.

8. **Korelace opakovaných měření.** U 3 osob byla čtyřikrát změřena dávka léku x a odezva y:

osoba	1				2				3			
x	1	2	3	4	4	5	6	7	7	8	9	10
y	10	11	13	12	7	9	8	10	4	5	7	6

(a) Spočtěte r_{rm} (data centrujte průměry jednotlivých osob) a otestujte jej ($t_{0{,}975}(8) = 2{,}306$).

(b) Pearsonův koeficient přes všech 12 bodů je $r = -0{,}690$. Vysvětlete rozdíl a uveďte, který koeficient odpovídá na otázku „roste u pacienta odezva s dávkou?“

Výsledky: a) Průměry $\bar x_i = 2{,}5;\ 5{,}5;\ 8{,}5$, $\bar y_i = 11{,}5;\ 8{,}5;\ 5{,}5$. Po centrování $\sum x_c y_c = 12$, $\sum x_c^2 = \sum y_c^2 = 15$, $r_{rm} = 0{,}8$; $\nu = 12 - 3 - 1 = 8$, $t = 0{,}8\sqrt{8/0{,}36} = 3{,}77 > 2{,}306$, $p = 0{,}005$. b) Celkový r míchá vztah mezi osobami (průměry jsou dokonale záporně korelované) se vztahem uvnitř osob (kladný). Na otázku odpovídá r_{rm}. Navíc 12 bodů není 12 nezávislých pozorování.

9. **Mnohonásobné testování.** Pro 6 proměnných bylo testováno všech 15 párových korelací. Seřazené p-hodnoty: 0,0004; 0,003; 0,008; 0,012; 0,021; 0,035; 0,048; 0,11; 0,26; 0,47; zbylých 5 je větších než 0,5. Kolik korelací označíme za významné bez korekce, s Bonferroniho, Holmovou a Benjaminiho–Hochbergovou korekcí (FDR 0,05)?

   Výsledky: Bez korekce 7. Bonferroni (hranice $0{,}05/15 = 0{,}0033$): 2. Holm (hranice $0{,}05/15$, $0{,}05/14 = 0{,}0036$, $0{,}05/13 = 0{,}0038\ldots$): 2, třetí $0{,}008 > 0{,}0038$. BH (hranice $0{,}05\,k/15$: 0,0033; 0,0067; 0,010; 0,0133; 0,0167…): největší k s $p_{(k)} \le 0{,}05k/15$ je $k = 4$, tj. 4 korelace.

B. Výpočty v Pythonu

10. **Diabetes – inference o korelaci.** Načtěte data funkcí `sklearn.datasets.load_diabetes` s volbami `as_frame=True`, `scaled=False` ($n = 442$).

    (a) Spočtěte korelaci `bmi` a `target`, 95% IS a otestujte $H_0 : \rho = 0{,}5$.

    (b) Porovnejte tuto korelaci u mužů a žen (proměnná `sex`, hodnoty 1 a 2).

    (c) Spočtěte korelaci `bp` a `target` a parciální korelaci při kontrole `bmi` a `s5` (`pingouin.partial_corr`).

    (d) Spočtěte R^2 pro `target` na `bmi`, `bp`, `s5`, `s3` z korelační matice ($1 - 1/(\boldsymbol{R}^{-1})_{11}$) a ověřte regresí.

    Výsledky: a) $r = 0{,}586$, IS (0,522; 0,644), $Z = 2{,}58$, $p = 0{,}010$ – korelace je větší než 0,5. b) sex 1: $r = 0{,}532$ ($n = 235$), sex 2: $r = 0{,}652$ ($n = 207$); $Z = -1{,}93$, $p = 0{,}054$ – rozdíl na hranici významnosti, neprokázán. c) $r = 0{,}441$, parciální $r = 0{,}195$, IS (0,10; 0,28), $p = 4 \cdot 10^{-5}$ – vztah tlaku a progrese nemoci je z velké části zprostředkován BMI a `s5`, ale nezmizí. d) $R^2 = 0{,}4915$.

11. **Iris – Simpsonův paradox.** Pro data `load_iris` zkoumejte šířku kališního lístku (SW) a délku okvětního lístku (PL).

    (a) Spočtěte Pearsonův, Spearmanův a Kendallův koeficient pro všech 150 květů a nakreslete bodový graf obarvený podle druhu.

    (b) Spočtěte korelace uvnitř každého druhu a otestujte jejich shodu testem χ^2.

    (c) Spočtěte parciální korelaci při kontrole druhu (indikátory) a `pingouin.rm_corr` s druhem jako „subjektem“. Proč vycházejí stejně?

    Výsledky: a) $r = -0{,}428$, $r_S = -0{,}310$, $\tau_b = -0{,}186$. b) setosa 0,178, versicolor 0,561, virginica 0,401; $\chi^2 = 4{,}85$, $p = 0{,}088$, společný odhad 0,391. c) obojí 0,378 (146 st. v.), $p = 2 \cdot 10^{-6}$ – uvnitř druhů je závislost kladná, celkově záporná (Simpsonův paradox). Oba postupy počítají korelaci odchylek od skupinových průměrů se stejnými stupni volnosti $n - g - 1$.

12. **Simulace – spolehlivost Fisherova intervalu.** Pro $n = 20$ a $\rho = 0{,}5$ nasimulujte 10 000 výběrů (a) z dvourozměrného normálního rozdělení, (b) z dvourozměrného t-rozdělení se 3 stupni volnosti (`scipy.stats.multivariate_t`, stejná korelační matice). Pro každý výběr spočtěte 95% IS pomocí Fisherovy z. Odhadněte skutečné pokrytí, $\mathrm{E}\, r$ a $(n-3)\mathrm{var}\, z$. Pro data (b) porovnejte s bootstrapovým intervalem (`scipy.stats.bootstrap` na jednom výběru).

    Výsledky: (a) pokrytí $\approx 0{,}955$, $\mathrm{E}\, r \approx 0{,}489$ (vychýlení dolů), $(n-3)\mathrm{var}\, z \approx 0{,}96$. (b) pokrytí jen $\approx 0{,}80$, $(n-3)\mathrm{var}\, z \approx 2{,}6$ – při těžkých chvostech je rozptyl z mnohem větší než $1/(n-3)$

a interval je příliš úzký; bootstrap (nebo Spearman/Kendall) je zde vhodnější. Konkrétní čísla závisí na semínku generátoru.

13. **Mnohonásobné testování na šumu.** Vygenerujte matici 40×10 nezávislých $N(0,1)$ hodnot (`np.random.default_rng(2026)`) a funkcí `pingouin.pairwise_corr` s volbou `padjust='holm'` otestujte všech 45 korelací. Pak pokus zopakujte 2000krát a odhadněte pravděpodobnost alespoň jednoho falešně významného výsledku (FWER) bez korekce a s Holmovou korekcí.

    Výsledky: Pro uvedené semínko: 2 korelace významné bez korekce, 0 po korekci. FWER bez korekce $\approx 0{,}90$ (srovnej $1 - 0{,}95^{45} = 0{,}90$), průměrně 2,3 falešně významné korelace; s Holmovou korekcí FWER $\approx 0{,}05$.