Přednáška 9: Vztahy spojitých proměnných – korelace

Pearsonův koeficient, Fisherova transformace, intervaly a testy. Reflexivní, mnohonásobný a parciální koeficient. Korelace opakovaných měření. Spearman, Kendall, robustní korelace.

KMA/MSM Blanka Šedivá

verze 2026/2027
8. října 2026

Obsah

1. Závislost a její měření
2. Pearsonův koeficient korelace
   - Výpočet v Pythonu
   - Statistické vlastnosti výběrového koeficientu
   - Intervaly spolehlivosti a testy
3. Reflexivní koeficient korelace
4. Mnohonásobný koeficient korelace
5. Parciální koeficient korelace
6. Korelace opakovaných měření
7. Pořadové a robustní korelace
   - Spearmanův koeficient
   - Kendallovo tau
   - Robustní korelace
8. Praktická doporučení

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Typy závislostí mezi náhodnými veličinami

Dvě náhodné veličiny X a Y jsou **nezávislé**, pokud sdružená distribuční funkce je součinem marginálních:

$$F(x, y) = F_X(x) \cdot F_Y(y) \qquad \text{pro všechna } x, y \in \mathbb{R}.$$

Náhodné veličiny $X_1, \ldots, X_k$ jsou (vzájemně) nezávislé, pokud pro všechna $\boldsymbol{x} = (x_1, \ldots, x_k)^T \in \mathbb{R}^k$

$$F(x_1, \ldots, x_k) = F_1(x_1) \cdot F_2(x_2) \cdots F_k(x_k).$$

Vzájemná nezávislost **nevyplývá** z párové nezávislosti (nezávislosti všech dvojic).

Typy závislostí:

- **Symetrická závislost:** vztah je oboustranný, nerozlišujeme vstup a výstup – **korelace** (tato přednáška).
- **Asymetrická závislost:** jedna proměnná je vysvětlující (vstup), druhá vysvětlovaná (výstup) – **regrese** (P10).

Poznámka: Statistická závislost neimplikuje **kauzalitu**. Může být způsobena třetí proměnnou, náhodou nebo strukturou dat (výběrem). O kauzalitě lze uvažovat až v rámci experimentu nebo specifických kauzálních modelů.

Požadavky na míru závislosti

Pro míru závislosti $\delta(X, Y)$ spojitých veličin se obvykle požaduje (Scarsiniho axiomy pro míry „souhlasnosti“, *concordance*):

(i) $\delta(X, Y) = \delta(Y, X)$ — symetrie

(ii) $-1 \leq \delta(X, Y) \leq 1$ — normalizace

(iii) $\delta(X, Y) = 1$, právě když $Y = g(X)$ s.j. pro nějakou ostře rostoucí funkci g (*komonotónní* veličiny),
$\delta(X, Y) = -1$, právě když $Y = g(X)$ s.j. pro ostře klesající g (*kontramonotónní*)

(iv) pro ostře monotónní g: $\delta(g(X), Y) = \delta(X, Y)$ pro rostoucí g a
$\delta(g(X), Y) = -\delta(X, Y)$ pro klesající g

(v) X, Y nezávislé $\Rightarrow \delta(X, Y) = 0$

- Spearmanovo ρ_S a Kendallovo τ tyto vlastnosti splňují.
- Pearsonův ρ splňuje vždy (i), (ii), (v) (při konečných rozptylech). Vlastnosti (iii) a (iv) platí jen pro **lineární** $g(x) = a + bx$: $\rho = \pm 1$ právě při $Y = a + bX$ a $\rho(a + bX, Y) = \text{sign}(b)\, \rho(X, Y)$. Pro nelineární rostoucí g je obecně $\rho(X, g(X)) < 1$ (např. $Y = e^X$).

Přehled korelačních koeficientů

- **Pearsonův koeficient** – lineární vztah dvou spojitých proměnných, $\langle -1, 1 \rangle$.
- **Spearmanův koeficient** – Pearson z pořadí, monotónní vztahy.
- **Kendallův koeficient** τ – podíl souhlasných a nesouhlasných dvojic, monotónní vztahy, vhodný i pro ordinální data.
- **Robustní koeficienty** (bicor, percentage bend, skipped) – odolné vůči odlehlým hodnotám.
- **Bodově biseriální korelace** – jedna proměnná dichotomická, druhá spojitá (= Pearson s kódováním 0/1).
- **Koeficient** ϕ – obě proměnné dichotomické, tabulka 2×2 (P08).
- **Tetrachorická / polychorická korelace** – korelace latentních normálních veličin, které pozorujeme jen kategorizované.
- **Distance correlation, vzájemná informace** – obecná (i nemonotónní) závislost.

Pearsonův korelační koeficient

- Pro náhodné veličiny s konečnými druhými momenty

$$\rho(X, Y) = \frac{\operatorname{cov}(X, Y)}{\sqrt{\operatorname{var} X}\sqrt{\operatorname{var} Y}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}.$$

- **Míra lineární závislosti**: symetrický, $\rho(X, Y) \in \langle -1, 1 \rangle$, a $|\rho| = 1$, právě když $Y = a + bX$ s.j. ($\operatorname{sign} \rho = \operatorname{sign} b$).
- Pro $a, c \in \mathbb{R}$, $b, d \neq 0$: $\rho(a + bX,\ c + dY) = \operatorname{sign}(bd)\, \rho(X, Y)$ – invariance vůči lineární transformaci až na znaménko.
- X, Y nezávislé $\Rightarrow \rho(X, Y) = 0$.
- Pro **dvourozměrně normální** vektor (X, Y) je $\rho = 0$ ekvivalentní nezávislosti. (Nestačí, aby byly normální jen marginály!)
- Pro vektor $\boldsymbol{X} = (X_1, \ldots, X_k)^T$: korelační matice $\boldsymbol{P} = \boldsymbol{D}^{-1/2} \boldsymbol{\Sigma} \boldsymbol{D}^{-1/2}$, $\boldsymbol{D} = \operatorname{diag}(\boldsymbol{\Sigma})$; výběrově $\boldsymbol{R} = \operatorname{diag}(\boldsymbol{S})^{-1/2}\, \boldsymbol{S}\, \operatorname{diag}(\boldsymbol{S})^{-1/2}$.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Pearsonův korelační koeficient – nevýhody

(1) Nulovost ρ obecně **neimplikuje** nezávislost:
$\rho(X, Y) = 0 \not\Rightarrow F(x, y) = F_X(x)F_Y(y)$.
Příklad: $X \sim N(0, 1)$, $Y = X^2$; pak $\operatorname{cov}(X, Y) = \mathbb{E}X^3 = 0$, ale Y je funkcí X.

(2) Vyžaduje existenci druhých momentů. Pro rozdělení s těžkými konci (např. Studentovo t s $\nu \leq 2$ stupni volnosti, Cauchyho rozdělení) ρ neexistuje a výběrové r je velmi nestabilní – typické ve finančních datech.

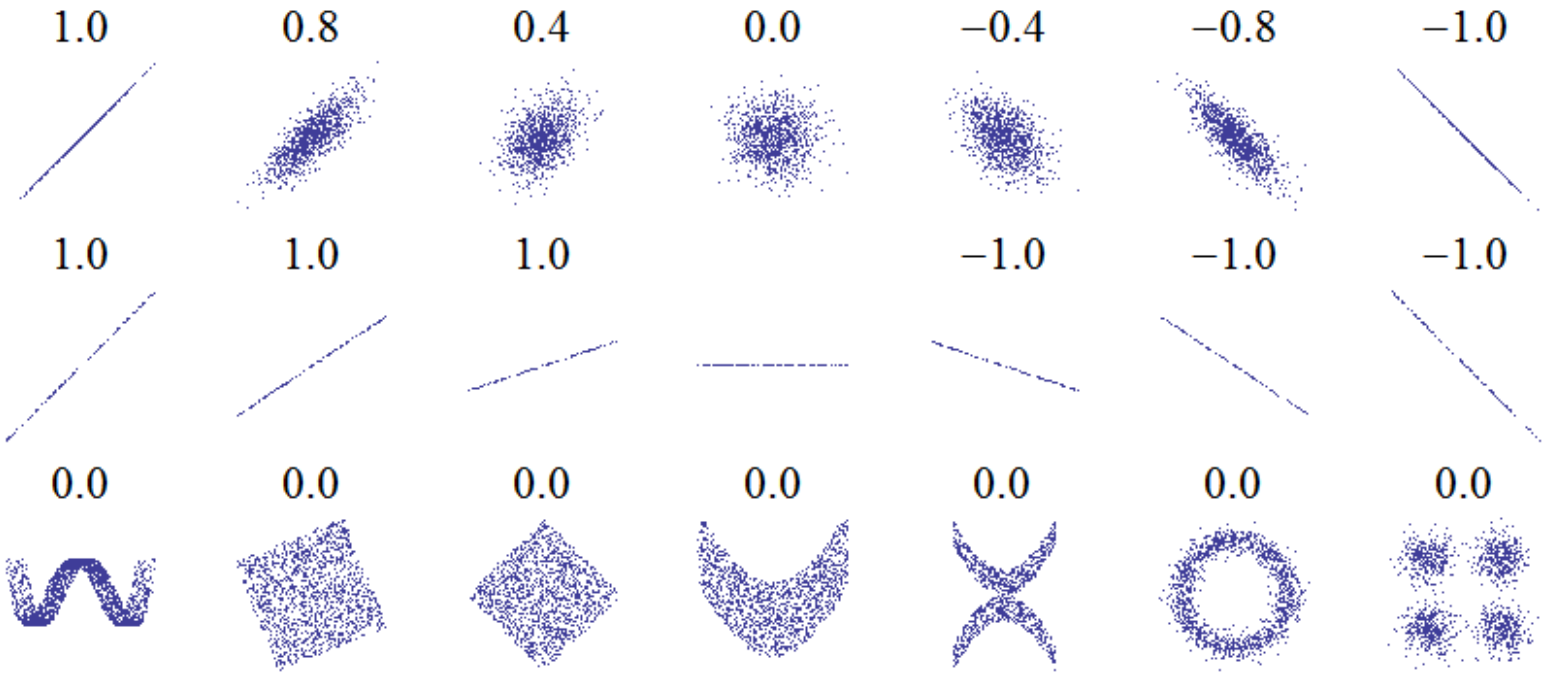
(3) Není invariantní vůči nelineárním monotónním transformacím g:

$$\rho(g(X), g(Y)) \neq \rho(X, Y) \quad \text{obecně.}$$

(4) Je citlivý na odlehlé hodnoty – jediné pozorování může změnit i znaménko r.

(5) Hodnota $|\rho| < 1$ je omezena i marginálními rozděleními: např. pro $X \sim LN(0, 1)$, $Y \sim LN(0, \sigma^2)$ je maximální dosažitelné ρ menší než 1 (Fréchetovy meze, viz P09b – kopule).

Pearsonův koeficient – ilustrace



Zdroj: `https://en.wikipedia.org/wiki/Correlation`. Horní řada: různá síla lineární závislosti. Prostřední: $|r| = 1$ pro jakýkoli nenulový sklon. Dolní: silná nelineární závislost, ale $r = 0$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vztah Pearsonovy korelace a regrese

- $y(x) = \mathbb{E}(Y|X = x)$ ... regresní funkce
- střední podmíněný rozptyl $\sigma^2_{Y|X} = \mathbb{E}(Y - \mathbb{E}(Y|X))^2$
- **korelační poměr** $\eta^2_{Y|X} = 1 - \dfrac{\sigma^2_{Y|X}}{\sigma^2_Y}$ (podíl rozptylu Y vysvětlený regresní funkcí); vždy $\rho^2 \leq \eta^2_{Y|X}$
- pokud je regresní funkce lineární, $y(x) = \mathbb{E}Y + \rho\frac{\sigma_Y}{\sigma_X}(x - \mathbb{E}X)$ (např. pro dvourozměrné normální rozdělení), pak

$$\sigma^2_{Y|X} = \sigma^2_Y\left(1 - \rho^2\right) \quad \text{a} \quad \eta^2_{Y|X} = \rho^2$$

- vztah $\eta^2_{Y|X}$ a ρ^2:
  - $\rho^2 = \eta^2_{Y|X} = 1$ ... funkční lineární závislost
  - $\rho^2 = \eta^2_{Y|X} < 1$ ... lineární regrese, ale ne funkční závislost
  - $\rho^2 < \eta^2_{Y|X} = 1$ ... funkční nelineární závislost
- $\eta^2_{Y|X}$ není symetrický: obecně $\eta^2_{Y|X} \neq \eta^2_{X|Y}$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Výběrový Pearsonův korelační koeficient

- Pro výběr (x_i, y_i), $i = 1, \ldots, n$:

$$r = r_{XY} = \frac{\sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \overline{x})^2} \sqrt{\sum_{i=1}^{n} (y_i - \overline{y})^2}} = \frac{s_{XY}}{s_X s_Y}$$

- alternativně $r = \frac{1}{n-1} \sum_{i=1}^{n} \left(\frac{x_i - \overline{x}}{s_X} \right) \left(\frac{y_i - \overline{y}}{s_Y} \right)$, kde s_X, s_Y jsou výběrové směrodatné odchylky (dělitel $n - 1$ se v r krátí)
- geometricky: $r = \cos \angle(\boldsymbol{x} - \overline{x}\mathbf{1},\ \boldsymbol{y} - \overline{y}\mathbf{1})$ – kosinus úhlu centrovaných vektorů
- r je maximálně věrohodný odhad ρ pro dvourozměrné normální rozdělení, ale **není nestranný** (viz dále)
- chybějící hodnoty: *listwise* (vynechat řádek s jakoukoli NaN) vs. *pairwise* (pro každou dvojici zvlášť) – pairwise korelační matice nemusí být pozitivně semidefinitní!

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Pearsonova korelace v Pythonu – scipy

- `scipy.stats.pearsonr(x, y)`: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.pearsonr.html
- Vstup: 1D pole; výstup: objekt s `statistic`, `pvalue` (test $H_0 : \rho = 0$) a metodou `confidence_interval()` (Fisherova z).
- NaN: výsledek je `nan` (bez varování o příčině) $\Rightarrow$ chybějící hodnoty odstraňte předem.

```
import numpy as np
from scipy.stats import pearsonr

x = np.array([1, 2, np.nan, 4, 5, 3])
y = np.array([2, 4, 6, 8, 7, 5])
print(pearsonr(x, y).statistic)           # nan

mask = ~np.isnan(x) & ~np.isnan(y)        # pairwise vynechání
res = pearsonr(x[mask], y[mask])
print(res.statistic, res.pvalue)
print(res.confidence_interval(confidence_level=0.95))
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Pearsonova korelace v Pythonu – numpy a pandas

- `numpy.corrcoef(x, y)`: https://numpy.org/doc/stable/reference/generated/numpy.corrcoef.html – implicitně **řádky** = proměnné (pro matici $n \times k$ použijte `rowvar=False`); NaN se propaguje.
- `DataFrame.corr(method=...)`: https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.corr.html – `'pearson'`, `'spearman'`, `'kendall'`; NaN vynechá **pairwise**; bez p-hodnot.

```
import numpy as np
import pandas as pd

x = np.array([1, 2, np.nan, 4, 5, 3])
y = np.array([2, 4, 6, 8, 7, 5])
mask = ~np.isnan(x) & ~np.isnan(y)
print(np.corrcoef(x[mask], y[mask]))      # matice 2x2
X = np.random.default_rng(1).normal(size=(100, 3))
print(np.corrcoef(X, rowvar=False).shape) # k x k = (3, 3)

df = pd.DataFrame({'X': x, 'Y': y,
                   'Z': [5, None, 7, 9, 8, 4]})
print(df['X'].corr(df['Y']))              # Series.corr
print(df.corr(method='pearson').round(3))
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Pearsonova korelace v Pythonu – pingouin

- `pingouin.corr(x, y, method='pearson')`: `https://pingouin-stats.org/build/html/generated/pingouin.corr.html`
- Vstup: seznamy, numpy pole, Series (chybějící hodnota musí být `np.nan`, ne `None`); NaN vynechá pairwise.
- Výstup: DataFrame – `n`, `r`, `CI95` (Fisherova z), `p_val`, `BF10` (Bayesův faktor pro H_1 proti H_0), `power` (síla testu pro $\rho = r$). Názvy sloupců se mezi verzemi liší (starší: `CI95%`, `p-val`).

```
import pingouin as pg
from sklearn.datasets import load_iris

iris = load_iris(as_frame=True).frame
x = iris['sepal length (cm)'][iris.target == 0]
y = iris['sepal width (cm)'][iris.target == 0]
print(pg.corr(x, y, method='pearson').round(4))
```

Výstup (setosa, délka a šířka kališního lístku):

```
           n       r           CI95  p_val       BF10   power
pearson   50  0.7425  [0.59, 0.85]    0.0  1.882e+07     1.0
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Korelace mezi více proměnnými – `pingouin.pairwise_corr`

- `pingouin.pairwise_corr`: `https://pingouin-stats.org/build/html/generated/pingouin.pairwise_corr.html`
- Vstup: DataFrame (případně `columns=`); výstup: řádek pro každou dvojici – `n`, `r`, `CI95`, `p_unc`, a při volbě `padjust` i korigované p-hodnoty `p_corr`.
- Při k proměnných provádíme $\binom{k}{2}$ testů $\Rightarrow$ korekce na mnohonásobné testování (Holm, FDR – viz P07).

```
import pingouin as pg
from sklearn.datasets import load_iris

df = load_iris(as_frame=True).frame.iloc[:, :4]
df.columns = ['SL', 'SW', 'PL', 'PW']
res = pg.pairwise_corr(df, method='pearson',
                       padjust='holm')
print(res[['X', 'Y', 'n', 'r', 'p_unc', 'p_corr']]
      .round(4).to_string())
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Rozdělení výběrového Pearsonova koeficientu

Předpokládejme náhodný výběr z dvourozměrného normálního rozdělení N_2 s korelací ρ.

- Pro $\rho = 0$:

$$t = r\sqrt{\frac{n-2}{1-r^2}} \sim t_{n-2}, \qquad f(r) = \frac{(1-r^2)^{(n-4)/2}}{B\left(\frac{1}{2}, \frac{n-2}{2}\right)}, \quad \mathbb{E}r = 0, \quad \operatorname{var} r = \frac{1}{n-1}.$$

- Test t platí přibližně (pro $n \to \infty$) i pro nenormální **nezávislé** veličiny; pro závislé, ale nekorelované veličiny může selhat (rozptyl r pak není $1/(n-1)$).
- Pro obecné ρ (Fisher 1915; Hotelling 1953):

$$f(r) = \frac{(n-2)\,\Gamma(n-1)\,(1-\rho^2)^{(n-1)/2}(1-r^2)^{(n-4)/2}}{\sqrt{2\pi}\,\Gamma(n-\frac{1}{2})\,(1-\rho r)^{n-3/2}}\; {}_2F_1\left(\tfrac{1}{2}, \tfrac{1}{2}; \tfrac{2n-1}{2}; \tfrac{\rho r+1}{2}\right),$$

  kde ${}_2F_1(a, b; c; z)$ je Gaussova hypergeometrická funkce.
- Rozdělení r je pro $\rho \neq 0$ **zešikmené** (k nule) a jeho rozptyl závisí na ρ: přibližně $\operatorname{var} r \approx (1-\rho^2)^2/n$.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Vychýlení výběrového Pearsonova koeficientu

- r **není nestranný** – v absolutní hodnotě ρ podhodnocuje:

$$\mathbb{E}r = \rho\left(1 - \frac{1-\rho^2}{2n}\right) + O\left(n^{-2}\right).$$

- Nestranný odhad s minimálním rozptylem (Olkin, Pratt 1958):

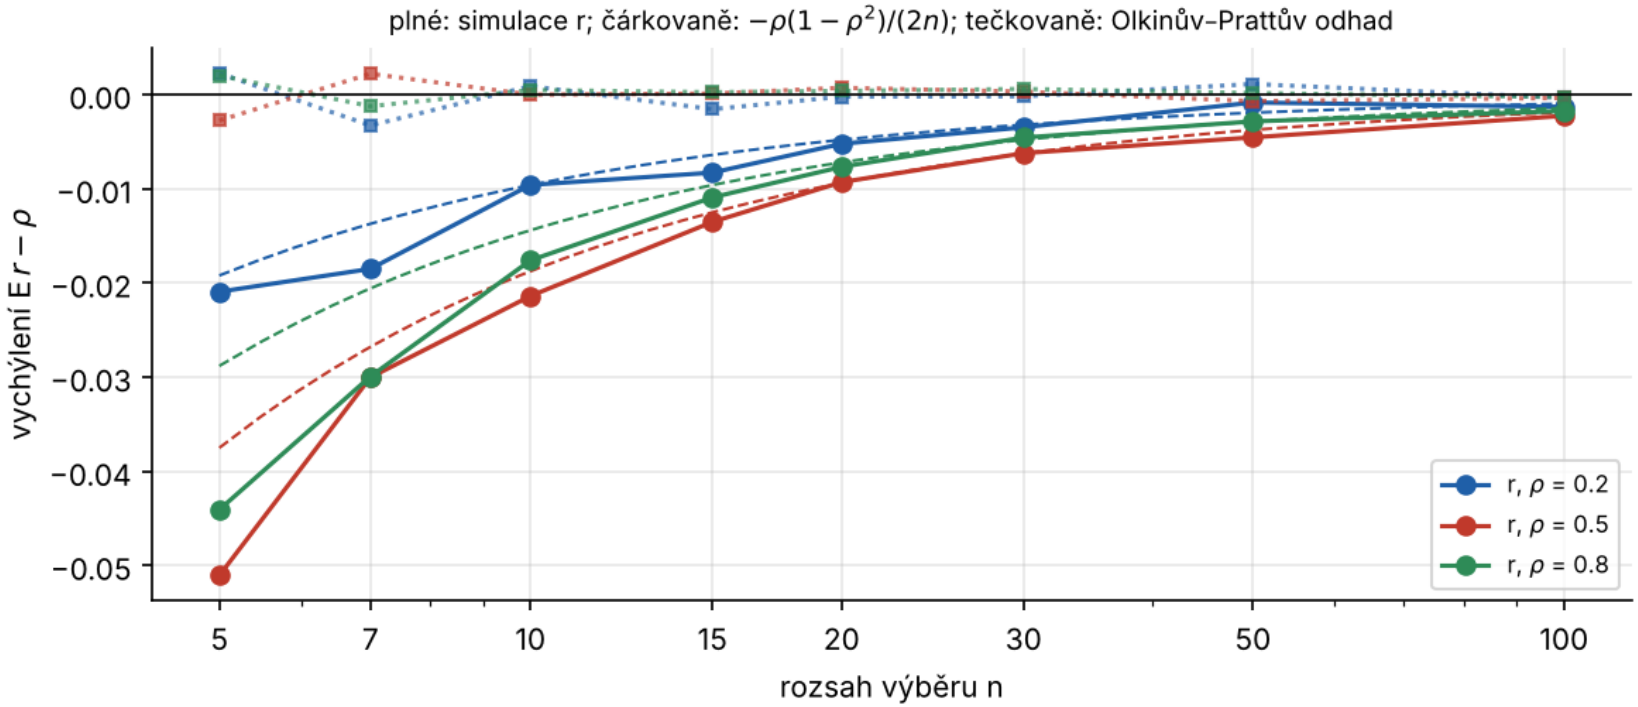
$$r^* = r\,{}_2F_1\left(\tfrac{1}{2}, \tfrac{1}{2}; \tfrac{n-2}{2}; 1-r^2\right) \approx r\left(1 + \frac{1-r^2}{2(n-3)}\right).$$

- Pro normální rozdělení platí $\mathbb{E}(\arcsin r) = \arcsin \rho$ (Harley 1956) – vychýlení r souvisí s nelinearitou transformace.
- Simulace ($B = 200\,000$, $\rho = 0{,}5$):

n	$\mathbb{E}r$	$\rho(1 - \frac{1-\rho^2}{2n})$	$\mathbb{E}r^*$ (Olkin–Pratt)	$\mathbb{E}\, r(1 + \frac{1-r^2}{2(n-3)})$
5	0,451	0,463	0,500	0,500
10	0,479	0,481	0,500	0,499
20	0,490	0,491	0,500	0,499

- Vychýlení je řádu $1/n$, tj. podstatně menší než směrodatná odchylka r (řádu $1/\sqrt{n}$) – v praxi důležité hlavně pro malé n a při průměrování mnoha korelací (metaanalýza).

Vychýlení odhadu – simulace



Plné čáry: simulované vychýlení $\mathbb{E}r - \rho$; čárkovaně: aproximace $-\rho(1-\rho^2)/(2n)$; tečkovaně: Olkinův–Prattův odhad r^* (vychýlení ≈ 0). Kód: `P09_obrazky.py`, výpočet r^* pomocí `scipy.special.hyp2f1` v notebooku.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Fisherova z-transformace

Fisherova transformace (transformace stabilizující rozptyl):

$$z = \operatorname{artanh} r = \frac{1}{2} \ln \frac{1+r}{1-r}, \qquad \text{zpětně} \quad r = \tanh z = \frac{e^{2z}-1}{e^{2z}+1}.$$

Vlastnosti (výběr z N_2):

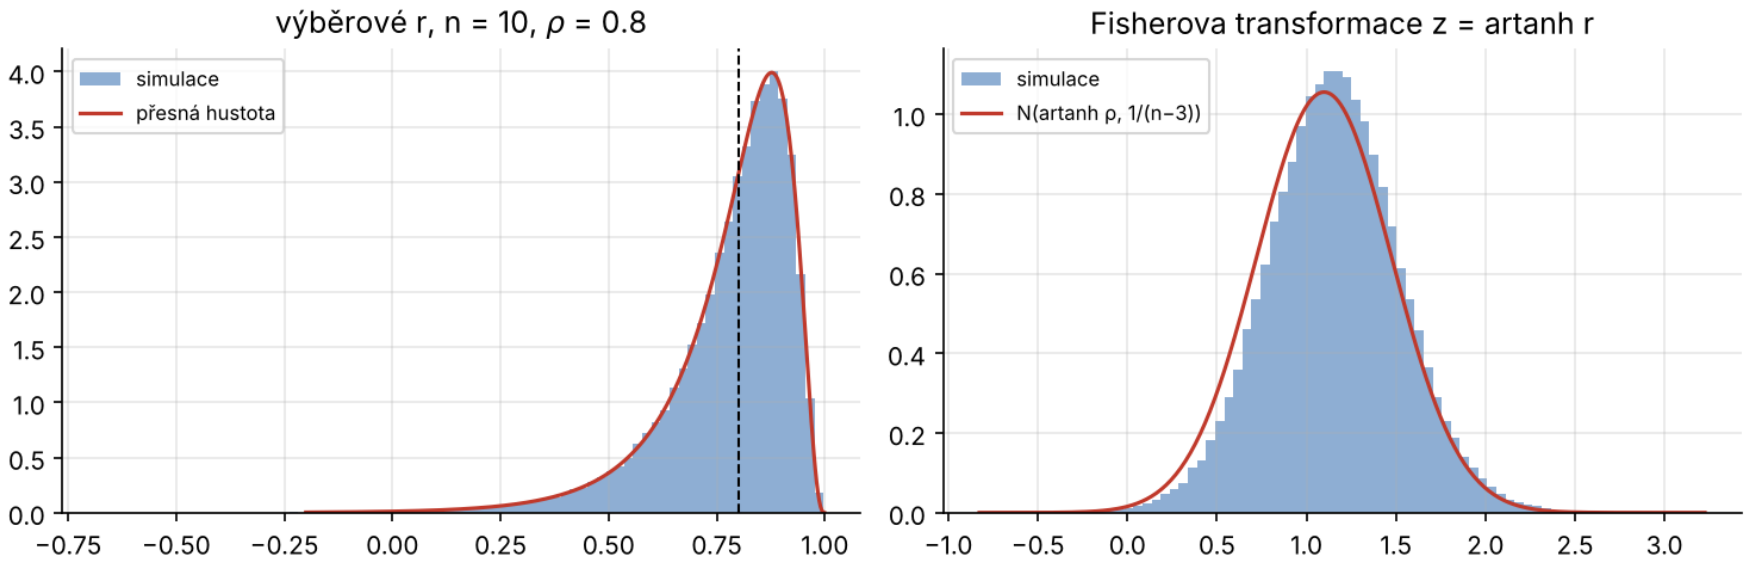
- z má přibližně normální rozdělení už pro malá n (na rozdíl od r):

$$z \mathrel{\dot\sim} N\left(\operatorname{artanh}\rho + \frac{\rho}{2(n-1)}, \frac{1}{n-3}\right).$$

- Rozptyl $1/(n-3)$ **nezávisí na** ρ; člen $\rho/(2(n-1))$ (vychýlení) se obvykle zanedbává.
- Simulace: $n = 10$, $\rho = 0{,}8$: $\operatorname{var} z = 0{,}136$ vs. $1/(n-3) = 0{,}143$; $\mathbb{E}z = 1{,}151$ vs. $\operatorname{artanh}\rho + \rho/(2(n-1)) = 1{,}143$.
- Pro nenormální data (zejména s těžkými konci) může být skutečný rozptyl z výrazně jiný $\Rightarrow$ bootstrap.

Použití: intervaly spolehlivosti pro ρ, test $H_0 : \rho = \rho_0$ pro $\rho_0 \neq 0$, porovnání korelací, průměrování korelací (metaanalýza).

Rozdělení r a Fisherova z – simulace



$n = 10$, $\rho = 0{,}8$, 100 000 simulací. Vlevo: výrazně zešikmené rozdělení r a přesná hustota. Vpravo: po transformaci téměř normální rozdělení.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Interval spolehlivosti a test $H_0 : \rho = \rho_0$

Cíl
Interval spolehlivosti pro ρ; test, zda korelace je rovna dané hodnotě ρ_0.

Předpoklady
Náhodný výběr (x_i, y_i), $i = 1, \ldots, n$, z dvourozměrného normálního rozdělení.

Interval spolehlivosti
$$\left(\tanh\left(z - \frac{u_{1-\alpha/2}}{\sqrt{n-3}} \right), \tanh\left(z + \frac{u_{1-\alpha/2}}{\sqrt{n-3}} \right) \right),$$
$z = \operatorname{artanh} r$; interval je **nesymetrický** kolem r.

Nulová hypotéza
$H_0 : \rho = \rho_0$

Alternativa
$H_1 : \rho \neq \rho_0$ (případně jednostranná)

Testovací statistika
$$Z = (\operatorname{artanh} r - \operatorname{artanh} \rho_0)\sqrt{n-3} \dot{\sim} N(0,1)$$

Speciální případ
Pro $\rho_0 = 0$ se používá přesný test $t = r\sqrt{(n-2)/(1-r^2)} \sim t_{n-2}$.

Vliv n
Pro $r = 0{,}5$: 95% IS při $n = 10$ je $(-0{,}19;\ 0{,}86)$, při $n = 200$ $(0{,}39;\ 0{,}60)$.

Plánování rozsahu
Šířka IS je přibližně $2u_{1-\alpha/2}(1-r^2)/\sqrt{n} \Rightarrow$ pro přesnost $\pm 0{,}1$ při $r \approx 0{,}5$ je potřeba $n \approx 220$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Interval spolehlivosti a test $H_0 : \rho = \rho_0$ – Python

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.pearsonr.html

```
import numpy as np
from scipy import stats
from sklearn.datasets import load_iris
X, y = load_iris(return_X_y=True)
x1, x2 = X[y == 0, 0], X[y == 0, 1]   # setosa: délka, šířka
n = len(x1)
res = stats.pearsonr(x1, x2)
r = res.statistic
z, se = np.arctanh(r), 1 / np.sqrt(n - 3)
u = stats.norm.ppf(0.975)
ci = np.tanh(z + np.array([-1, 1]) * u * se)
print(f"r = {r:.4f}, IS = {ci.round(4)}")
print(res.confidence_interval(0.95))      # totéž ve scipy
rho0 = 0.5                                # H0: rho = 0.5
Z = (z - np.arctanh(rho0)) / se
p = 2 * stats.norm.sf(abs(Z))
print(f"Z = {Z:.3f}, p = {p:.4f}")
```

Výstup: $r = 0{,}7425$, 95% IS $(0{,}5851;\ 0{,}8460)$, $Z = 2{,}789$, $p = 0{,}0053 \Rightarrow$ zamítáme $H_0 : \rho = 0{,}5$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Porovnání dvou korelací

Cíl

Rozhodnout, zda je korelace stejná ve dvou **nezávislých** populacích (skupinách).

Předpoklady

Dva nezávislé výběry rozsahů n_1, n_2 z dvourozměrných normálních rozdělení; výběrové korelace r_1, r_2.

Nulová hypotéza

$H_0 : \rho_1 = \rho_2$

Alternativa

$H_1 : \rho_1 \neq \rho_2$

Testovací statistika

$$Z = \frac{\operatorname{artanh} r_1 - \operatorname{artanh} r_2}{\sqrt{\frac{1}{n_1-3} + \frac{1}{n_2-3}}} \dot{\sim} N(0,1)$$

Více skupin

$$\chi^2 = \sum_{j=1}^{g} (n_j - 3)(z_j - \bar{z}_w)^2 \dot{\sim} \chi^2_{g-1},$$

kde $\bar{z}_w = \sum_j (n_j - 3) z_j / \sum_j (n_j - 3)$; $\tanh \bar{z}_w$ je společný odhad ρ.

Závislé korelace

Pokud korelace pocházejí ze **stejného** výběru (např. ρ_{XY} vs. ρ_{XZ}), uvedený test nelze použít – je nutné zohlednit korelaci mezi r_{XY} a r_{XZ} (Steigerův test, 1980; bootstrap).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Porovnání dvou nezávislých korelací – Python

```
import numpy as np
from scipy import stats
from sklearn.datasets import load_iris

X, y = load_iris(return_X_y=True)
r, n = [], []
for g in (0, 1):                    # setosa, versicolor
    Xg = X[y == g]
    r.append(stats.pearsonr(Xg[:, 0], Xg[:, 1]).statistic)
    n.append(len(Xg))
z = np.arctanh(r)
se = np.sqrt(1 / (n[0] - 3) + 1 / (n[1] - 3))
Z = (z[0] - z[1]) / se
p = 2 * stats.norm.sf(abs(Z))
print(f"r1 = {r[0]:.4f}, r2 = {r[1]:.4f}")
print(f"Z = {Z:.3f}, p = {p:.4f}")
```

Výstup: $r_1 = 0{,}7425$ (setosa), $r_2 = 0{,}5259$ (versicolor), $Z = 1{,}802$, $p = 0{,}0716 \Rightarrow$ na hladině 5 % rozdíl korelací neprokazujeme (i rozdíl 0,22 je při $n = 50$ ve skupině málo).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Modifikace Pearsonova korelačního koeficientu

upravený koeficient (adjusted) korekce vychýlení

$$r_{adj} = r\left(1 + \frac{1 - r^2}{2(n-3)}\right) \text{ (aproximace)},$$

$$r^* = r\,{}_2F_1\left(\tfrac{1}{2}, \tfrac{1}{2}; \tfrac{n-2}{2}; 1 - r^2\right).$$

Pozor: varianta $\sqrt{1 - (1 - r^2)\frac{n-1}{n-2}}$ (analogie upraveného R^2) **není** nestranný odhad ρ – naopak ρ výrazně podhodnocuje (simulace $n = 10$, $\rho = 0{,}5$: střední hodnota 0,38).

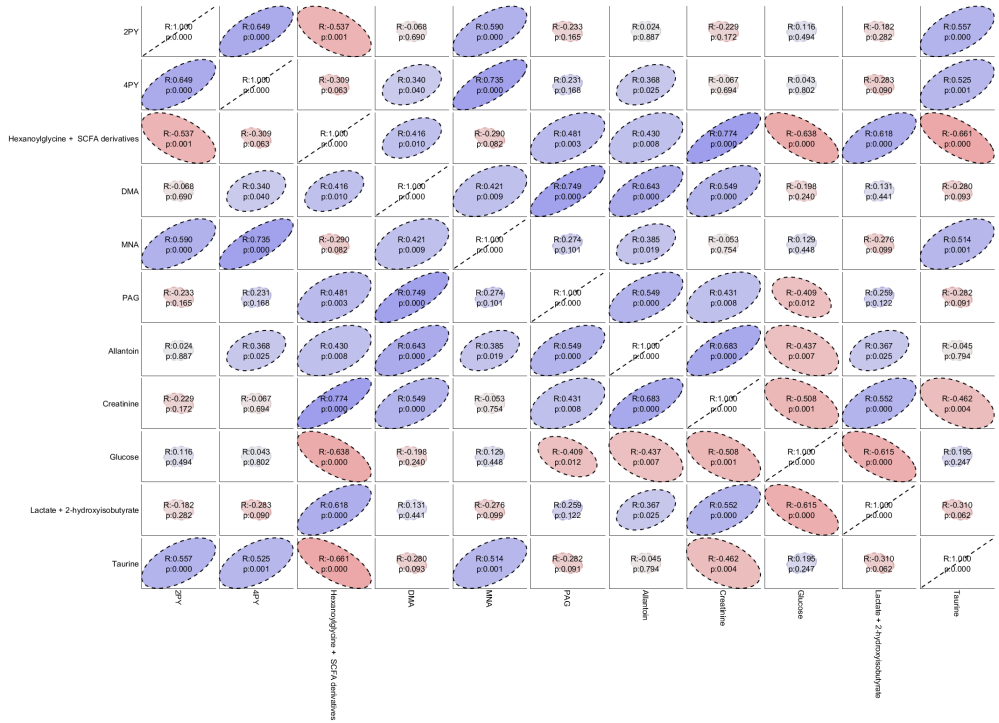
vážený koeficient pro váhy $w_i \geq 0$:

$$r_w = \frac{\mathrm{cov}_w(x, y)}{\sqrt{\mathrm{cov}_w(x, x)\mathrm{cov}_w(y, y)}}, \quad \mathrm{cov}_w(x, y) = \frac{\sum w_i(x_i - \overline{x}_w)(y_i - \overline{y}_w)}{\sum w_i},$$

kde $\overline{x}_w = \sum w_i x_i / \sum w_i$ je vážený průměr. Využití: data s různou přesností měření, agregovaná data, výběrová šetření s vahami.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vizualizace párových korelací



Korelační matice koncentrací metabolitů: tvar a barva elipsy odpovídají hodnotě r, v políčkách jsou r a p-hodnota. Při mnoha dvojicích je nutná korekce na mnohonásobné testování.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Reflexivní koeficient korelace

Definice:

$$\operatorname{cor}_r(X, Y) = \frac{\mathbb{E}(XY)}{\sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}}, \qquad \widehat{\operatorname{cor}}_r = \frac{\sum x_i y_i}{\sqrt{\sum x_i^2 \cdot \sum y_i^2}}$$

– „Pearson bez centrování“, kosinová podobnost vektorů $\boldsymbol{x}$ a $\boldsymbol{y}$.

Vlastnosti:

- symetrický: $\operatorname{cor}_r(X, Y) = \operatorname{cor}_r(Y, X)$, hodnoty v $\langle -1, 1 \rangle$ (Cauchyho–Schwarzova nerovnost);
- invariantní vůči změně měřítka: $\operatorname{cor}_r(X, bY) = \operatorname{sign}(b)\operatorname{cor}_r(X, Y)$;
- **není** invariantní vůči posunu: $\operatorname{cor}_r(X, a + bY) \neq \operatorname{cor}_r(X, Y)$;
- pro veličiny s nulovou střední hodnotou splývá s Pearsonovým koeficientem.

Použití:

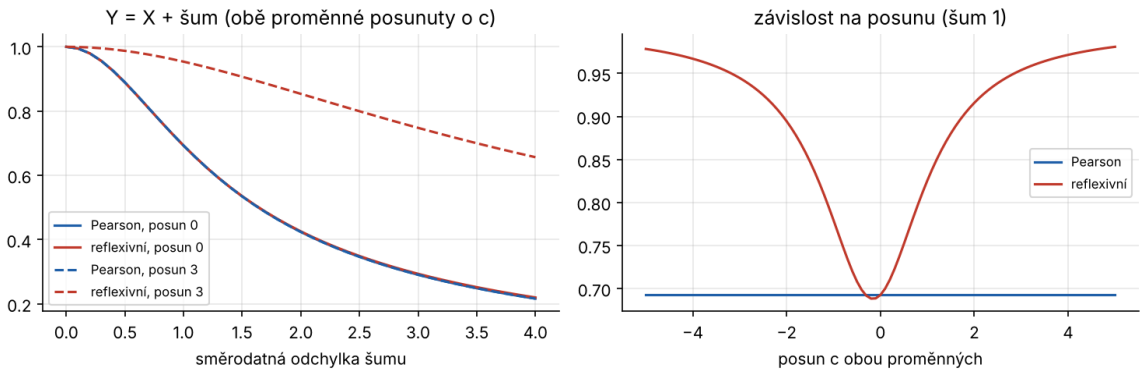
- data s přirozeným počátkem, kde odchylka od nuly má význam (poměry, signály, výnosy, genová exprese – „uncentered correlation“ ve shlukové analýze), porovnání tvaru profilů (kosinová podobnost v textové analytice).

Reflexivní koeficient korelace – vliv šumu a posunu

```
import numpy as np
from scipy.stats import pearsonr

def reflexive_corr(x, y):
    return np.sum(x * y) / np.sqrt(np.sum(x**2) * np.sum(y**2))

rng = np.random.default_rng(0)
X = rng.normal(0, 1, 200)
Y = X + rng.normal(0, 1, 200)
for c in [0, 1, 3]:
    print(c, round(pearsonr(X + c, Y + c)[0], 3),
          round(reflexive_corr(X + c, Y + c), 3))
```



FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Mnohonásobný koeficient korelace

- Závislost jedné veličiny Y na **skupině** veličin $X_1, \ldots, X_q$:

$$R_{Y\cdot(X_1,\ldots,X_q)} = \max_{\boldsymbol{a}} \operatorname{cor}\left(Y,\ \boldsymbol{a}^T\boldsymbol{X}\right) = \operatorname{cor}\left(Y, \widehat{Y}\right),$$

  kde $\widehat{Y} = a_0 + a_1X_1 + \cdots + a_qX_q$ je nejlepší **lineární** predikce Y z $X_1, \ldots, X_q$ (lineární regrese).
- $0 \leq R \leq 1$; $R = 1$ právě při přesné lineární závislosti Y na $X_1, \ldots, X_q$.
- R^2 je koeficient determinace lineární regrese Y na $X_1, \ldots, X_q$: $R^2 = 1 - \dfrac{RSS}{TSS}$ (podíl vysvětleného rozptylu).
- $R \geq |r_{YX_j}|$ pro všechna j; přidáním proměnné R nikdy neklesne; pro $q = 1$ je $R = |r_{YX}|$.
- Pro normální rozdělení a $\rho_{Y\cdot X} = 0$: $R^2 \sim \text{Beta}\left(\frac{q}{2}, \frac{n-q-1}{2}\right)$, $\mathbb{E}R^2 = \frac{q}{n-1} > 0 \Rightarrow R^2$ je vychýlený nahoru.
- Test $H_0 : \rho_{Y\cdot X} = 0$ (F-test regrese): $F = \frac{n-q-1}{q}\ \frac{R^2}{1-R^2} \sim F_{q,\,n-q-1}$.
- Upravený koeficient: $R^2_{adj} = 1 - \frac{RSS/(n-q-1)}{TSS/(n-1)} = 1 - \frac{n-1}{n-q-1}\left(1 - R^2\right)$.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Mnohonásobný koeficient korelace – výpočet

Korelační matici všech $k = q + 1$ veličin uspořádáme blokově $\boldsymbol{R} = \begin{pmatrix} 1 & \boldsymbol{r}_{YX}^T \\ \boldsymbol{r}_{XY} & \boldsymbol{R}_{XX} \end{pmatrix}$.

- maticový zápis:
$$R^2_{Y\cdot(X_1,\ldots,X_q)} = \boldsymbol{r}_{YX}^T \, \boldsymbol{R}_{XX}^{-1} \, \boldsymbol{r}_{XY}$$
- pomocí determinantů: $R^2_{Y\cdot(X_1,\ldots,X_q)} = 1 - \dfrac{\det \boldsymbol{R}}{\det \boldsymbol{R}_{XX}}$
- pomocí inverze celé korelační matice (Y je j-tá proměnná):
$$R^2_{j\cdot(\text{ostatní})} = 1 - \frac{1}{(\boldsymbol{R}^{-1})_{jj}}$$
– diagonála $\boldsymbol{R}^{-1}$ obsahuje tzv. **VIF** (variance inflation factor) $= 1/(1 - R_j^2)$, P10.
- speciální případ $q = 2$:
$$R^2_{Y\cdot(X_1,X_2)} = \frac{r^2_{YX_1} + r^2_{YX_2} - 2 r_{YX_1} r_{YX_2} r_{X_1X_2}}{1 - r^2_{X_1X_2}}$$

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Mnohonásobný koeficient korelace – Python

```
import numpy as np
from scipy import stats
from sklearn.datasets import load_diabetes
from sklearn.linear_model import LinearRegression
d = load_diabetes(as_frame=True).frame
cols = ['target', 'bmi', 'bp', 's5']      # Y a q = 3 regresory
R = d[cols].corr().to_numpy()
r_xy, R_xx = R[1:, 0], R[1:, 1:]
R2 = r_xy @ np.linalg.solve(R_xx, r_xy)
R2_inv = 1 - 1 / np.linalg.inv(R)[0, 0]   # totéž
n, q = len(d), len(cols) - 1
X, Y = d[cols[1:]].to_numpy(), d['target'].to_numpy()
R2_reg = LinearRegression().fit(X, Y).score(X, Y)
F = (n - q - 1) / q * R2 / (1 - R2)
p = stats.f.sf(F, q, n - q - 1)
R2_adj = 1 - (1 - R2) * (n - 1) / (n - q - 1)
print(f"R2 = {R2:.4f} {R2_inv:.4f} {R2_reg:.4f}")
print(f"R = {np.sqrt(R2):.4f}, R2_adj = {R2_adj:.4f}")
print(f"F = {F:.2f}, p = {p:.3g}")
```

Výstup: $R^2 = 0{,}4801$ (všemi třemi způsoby), $R = 0{,}6929$, $R^2_{adj} = 0{,}4765$, $F = 134{,}81$, $p \approx 7 \cdot 10^{-62}$.

Parciální koeficient korelace – definice

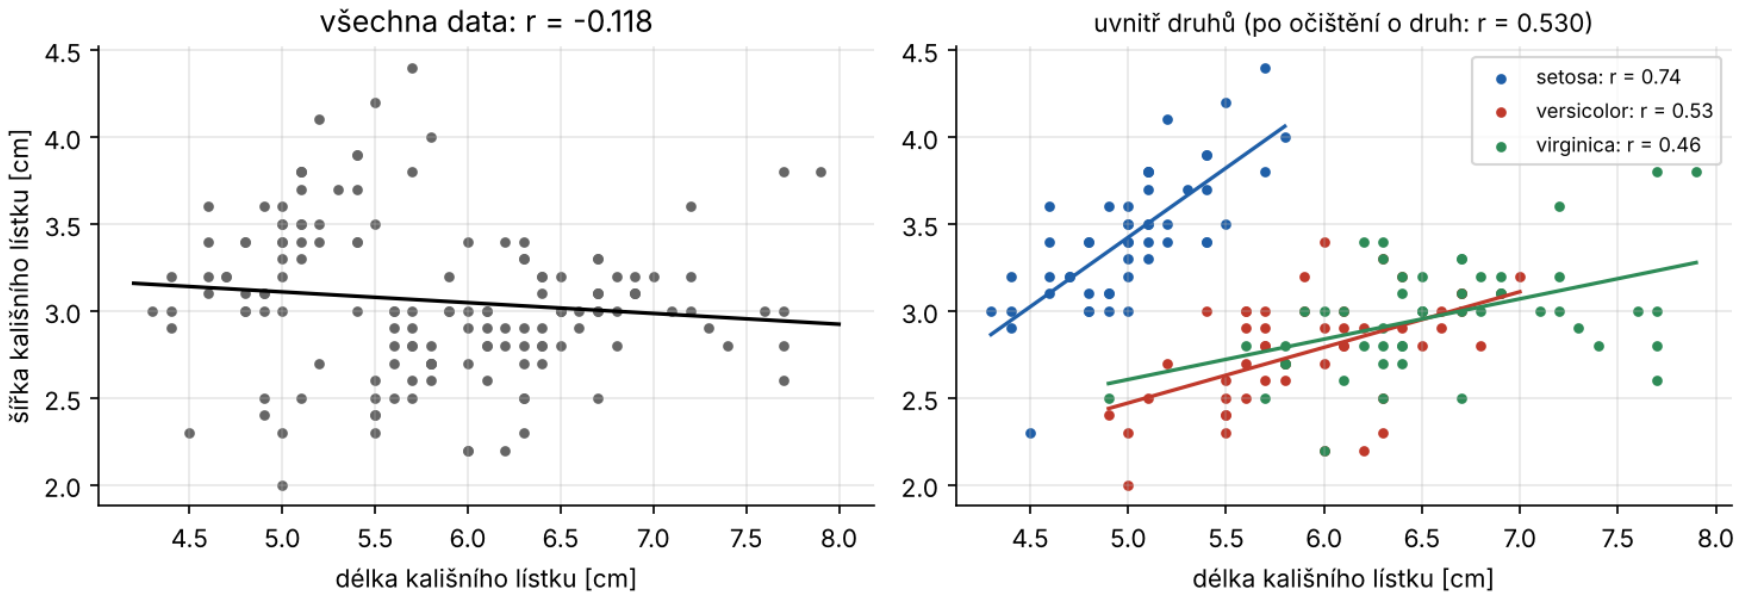
- Korelace Y a Z „očištěná“ o lineární vliv dalších veličin $X_1, \ldots, X_q$.
- Označení: $\rho_{YZ \cdot X}$, resp. $\operatorname{cor}(Y, Z \mid X_1, \ldots, X_q)$.
- Definice: korelace reziduí z lineárních regresí Y a Z na kontrolní veličiny

$$Y = \alpha_0 + \alpha_1 X_1 + \cdots + \alpha_q X_q + \varepsilon_Y,$$
$$Z = \beta_0 + \beta_1 X_1 + \cdots + \beta_q X_q + \varepsilon_Z,$$

$$\rho_{YZ \cdot X} = \operatorname{cor}(\varepsilon_Y, \varepsilon_Z).$$

- Pro vícerozměrné normální rozdělení je $\rho_{YZ \cdot X}$ korelace v **podmíněném** rozdělení (Y, Z) při daném $\boldsymbol{X}$; $\rho_{YZ \cdot X} = 0 \Leftrightarrow$ podmíněná nezávislost.
- Odhalí **zdánlivou korelaci** (společná příčina) i **potlačenou** korelaci (Simpsonův paradox).
- Kontrolní proměnné mohou být i kategoriální (kódované indikátory).

Parciální korelace – Simpsonův paradox (iris)



Celková korelace délky a šířky kališního lístku je $r = -0{,}118$, uvnitř druhů je ale silně kladná. Parciální korelace při kontrole druhu (dvě indikátorové proměnné) je 0,530 – rovná korelaci odchylek od druhových průměrů.

Parciální korelace – výpočet

- Pro jednu kontrolní veličinu ($q = 1$):

$$r_{YZ\cdot X} = \frac{r_{YZ} - r_{YX} r_{ZX}}{\sqrt{1 - r_{YX}^2}\sqrt{1 - r_{ZX}^2}}.$$

- Obecně (blokový zápis jako u mnohonásobné korelace):

$$r_{YZ\cdot X} = \frac{r_{YZ} - \boldsymbol{r}_{YX}^T \boldsymbol{R}_{XX}^{-1} \boldsymbol{r}_{XZ}}{\sqrt{1 - \boldsymbol{r}_{YX}^T \boldsymbol{R}_{XX}^{-1} \boldsymbol{r}_{XY}}\ \sqrt{1 - \boldsymbol{r}_{ZX}^T \boldsymbol{R}_{XX}^{-1} \boldsymbol{r}_{XZ}}}.$$

- **Přes inverzi korelační matice:** pro $\boldsymbol{P} = \boldsymbol{R}^{-1} = (p_{ij})$ je parciální korelace i-té a j-té veličiny při kontrole **všech ostatních**

$$r_{ij\cdot\text{ostatní}} = -\frac{p_{ij}}{\sqrt{p_{ii}\, p_{jj}}}.$$

  Totéž pomocí algebraických doplňků: $r_{ij\cdot\text{ost.}} = -(-1)^{i+j} \det \boldsymbol{R}_{(ij)} / \sqrt{\det \boldsymbol{R}_{(ii)} \det \boldsymbol{R}_{(jj)}}$, kde $\boldsymbol{R}_{(ij)}$ vznikne vynecháním i-tého řádku a j-tého sloupce.

- Matice $\boldsymbol{R}^{-1}$ (resp. $\boldsymbol{S}^{-1}$, *precision matrix*) tedy popisuje podmíněné závislosti – základ grafických modelů (graphical lasso).

Parciální korelace – testování

Cíl

Ověřit, zda jsou Y a Z lineárně závislé i po odstranění vlivu $X_1, \ldots, X_q$.

Předpoklady

Náhodný výběr z $(q+2)$-rozměrného normálního rozdělení (resp. lineární regresní modely s normálními chybami).

Nulová hypotéza

$H_0 : \rho_{YZ \cdot X} = 0$

Testovací statistika

$$t = \frac{r_{YZ \cdot X}}{\sqrt{1 - r^2_{YZ \cdot X}}} \sqrt{n-2-q} \sim t_{n-2-q}$$

– každá kontrolní veličina „spotřebuje“ jeden stupeň volnosti.

IS, test $\rho_0 \neq 0$

$$z = \operatorname{artanh} r_{YZ \cdot X} \dot{\sim} N\left(\operatorname{artanh} \rho_{YZ \cdot X}, \frac{1}{n-q-3}\right)$$

Ekvivalence

Test je totožný s t-testem koeficientu u Z v regresi $Y \sim Z + X_1 + \cdots + X_q$.

Ověření simulací

$n = 15$, $q = 3$: skutečná hladina testu 0,049 (nominální 0,05), $\operatorname{var} z = 0{,}110$ vs. $1/(n-q-3) = 0{,}111$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Parciální korelace – Python (ručně)

```
import numpy as np
import pandas as pd
from scipy import stats
from sklearn.datasets import load_iris
iris = load_iris(as_frame=True)
d = iris.frame.iloc[:, :2].copy()
d.columns = ['SL', 'SW']
dummies = pd.get_dummies(iris.target, prefix='g',
                         drop_first=True).astype(float)
D = pd.concat([d, dummies], axis=1)      # SL, SW, g_1, g_2
P = np.linalg.inv(D.corr().to_numpy())
r_p = -P[0, 1] / np.sqrt(P[0, 0] * P[1, 1])
n, q = len(D), dummies.shape[1]
t = r_p * np.sqrt((n - 2 - q) / (1 - r_p**2))
p = 2 * stats.t.sf(abs(t), n - 2 - q)
print(f"r = {D.SL.corr(D.SW):.4f}")
print(f"r_parc = {r_p:.4f}, t = {t:.3f}, p = {p:.3g}")
import pingouin as pg                    # kontrola
print(pg.partial_corr(D, x='SL', y='SW', covar=['g_1', 'g_2']))
```

Výstup: $r = -0{,}1176$, ale $r_{SL,SW\cdot\text{druh}} = 0{,}5302$, $t = 7{,}557$ (146 st. v.), $p \approx 4 \cdot 10^{-12}$. Viz též `D.pcorr()`, `x_covar=` (semiparciální).

Korelace opakovaných měření (rmcorr)

- Data: m subjektů, u subjektu i máme n_i dvojic (x_{ij}, y_{ij}), $N = \sum n_i$.
- Pozorování téhož subjektu **nejsou nezávislá** $\Rightarrow$ obyčejný Pearsonův koeficient na všech N bodech porušuje předpoklady (pseudoreplikace) a míchá dvě různé otázky:
  - vztah **mezi subjekty** (korelace průměrů subjektů),
  - vztah **uvnitř subjektu** (když u jedince roste X, roste i Y?).
- **rmcorr** (Bakdash, Marusich 2017) odhaduje společnou vnitrosubjektovou lineární závislost: model ANCOVA

$$y_{ij} = \alpha_i + \beta x_{ij} + \varepsilon_{ij},$$

  s **pevným** efektem subjektu α_i (různé úrovně) a společným sklonem β.
- Interpretace: r_{rm} je analogie Pearsonova koeficientu pro vztah uvnitř subjektů; nevyužívá variabilitu mezi subjekty.
- Alternativa: lineární smíšený model s náhodnými efekty (dovoluje i různé sklony).

Korelace opakovaných měření – výpočet

$$r_{rm} = \frac{\sum_{i=1}^{m}\sum_{j=1}^{n_i}(x_{ij}-\bar{x}_i)(y_{ij}-\bar{y}_i)}{\sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n_i}(x_{ij}-\bar{x}_i)^2 \cdot \sum_{i=1}^{m}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_i)^2}}$$

- $\bar{x}_i$, $\bar{y}_i$ – průměry subjektu i; r_{rm} je Pearsonův koeficient **po centrování uvnitř subjektů**.
- Ekvivalentně z ANCOVA: $r_{rm} = \text{sign}(\hat{\beta})\sqrt{\frac{SS_X}{SS_X + SS_{res}}}$, kde SS_X je součet čtverců pro x po odstranění efektu subjektu.
- Stupně volnosti: $\nu = N - m - 1$ (každý subjekt spotřebuje jeden parametr α_i); test $t = r_{rm}\sqrt{\nu/(1-r_{rm}^2)} \sim t_\nu$, IS pomocí Fisherovy z s ν.
- Stejný princip jako parciální korelace při kontrole indikátorů subjektu (viz iris: kontrola druhu).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Korelace opakovaných měření – Python

https://pingouin-stats.org/build/html/generated/pingouin.rm_corr.html

```
import numpy as np
import pingouin as pg

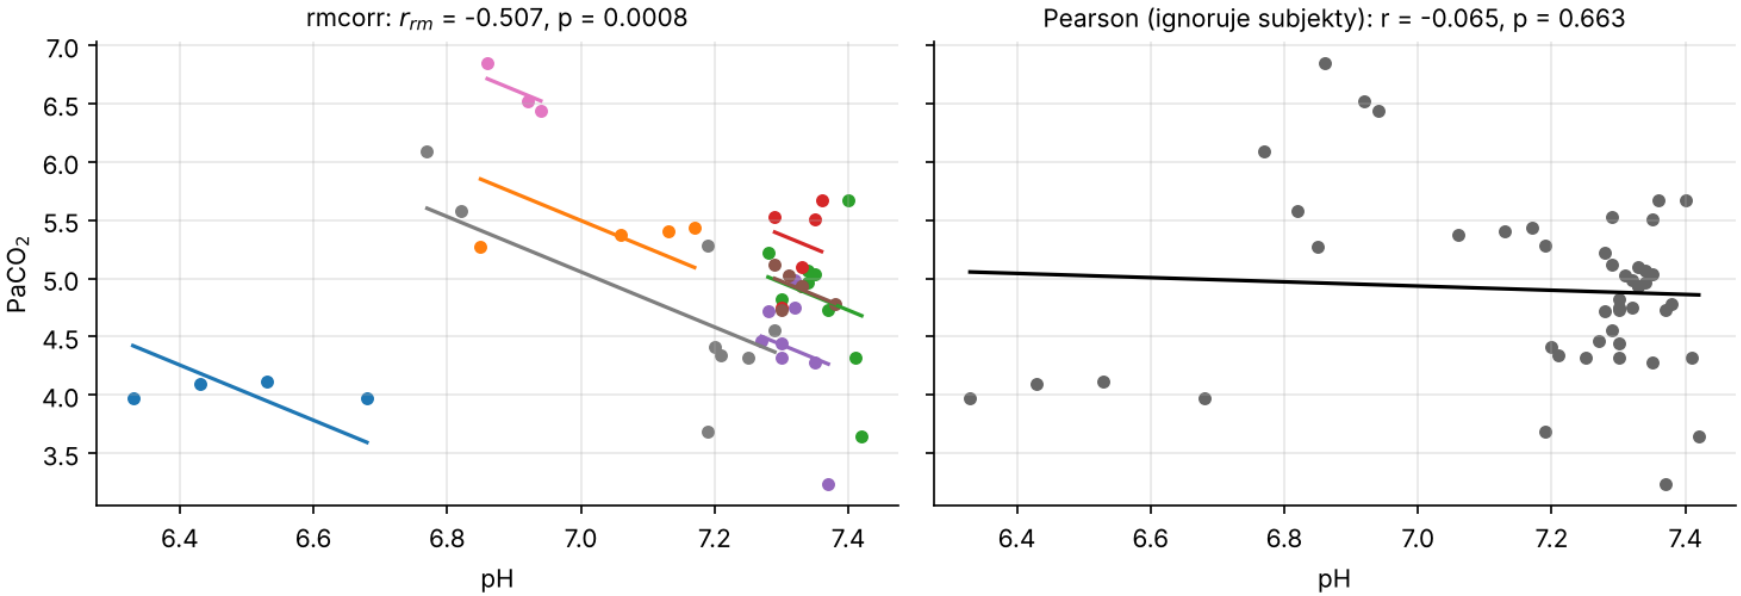
df = pg.read_dataset('rm_corr')   # 47 měření, 8 subjektů
res = pg.rm_corr(data=df, x='pH', y='PacO2',
                 subject='Subject')
print(res.round(4))
# ručně: centrování uvnitř subjektů
g = df.groupby('Subject')
x_c = df['pH'] - g['pH'].transform('mean')
y_c = df['PacO2'] - g['PacO2'].transform('mean')
r_rm = np.sum(x_c * y_c) / np.sqrt(np.sum(x_c**2)
                                   * np.sum(y_c**2))
nu = len(df) - df['Subject'].nunique() - 1
print(f"r_rm (ručně) = {r_rm:.4f}, dof = {nu}")
print(f"Pearson = {df['pH'].corr(df['PacO2']):.4f}")
```

```
             r  dof    pval            CI95   power
rm_corr -0.5068   38  0.0008  [-0.71, -0.23]  0.9296
r_rm (ručně) = -0.5068, dof = 38
Pearson = -0.0652
```

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Korelace opakovaných měření – vizualizace

Uvnitř subjektů je vztah pH a $PaCO_2$ středně silný záporný ($r_{rm} = -0{,}51$, $p = 0{,}0008$), Pearson přes všechna data ($r = -0{,}07$) jej zakrývá kvůli rozdílným úrovním subjektů.



Vlevo: rovnoběžné přímky se společným sklonem pro každý subjekt (model rmcorr).
Vpravo: jediná přímka přes všechna data.

Spearmanův koeficient korelace – definice

- Měří **monotónní** závislost; méně citlivý na odlehlá pozorování než Pearson.
- Populační definice (spojité marginály F_X, F_Y):

$$\rho_S(X,Y) = \rho\big(F_X(X), F_Y(Y)\big) = 12\,\mathbb{E}\big[F_X(X)F_Y(Y)\big] - 3,$$

  tj. Pearsonova korelace veličin transformovaných na rovnoměrné rozdělení.
- Výběrově nahradíme $F_X(x_i)$, $F_Y(y_i)$ **pořadími**: R_i je pořadí x_i mezi $x_1, \ldots, x_n$, Q_i pořadí y_i.

$$r_S = \frac{\sum(R_i - \overline{R})(Q_i - \overline{Q})}{\sqrt{\sum(R_i - \overline{R})^2 \sum(Q_i - \overline{Q})^2}}, \qquad \overline{R} = \overline{Q} = \frac{n+1}{2}.$$

- $-1 \le r_S \le 1$; $r_S = \pm 1$ pro jakoukoli ostře monotónní závislost.
- Invariantní vůči ostře rostoucím transformacím každé proměnné.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Výpočet Spearmanova koeficientu a shodné hodnoty

- **Bez shod** jsou pořadí permutací $1, \ldots, n$, platí $\sum (R_i - \overline{R})^2 = \frac{n(n^2-1)}{12}$ a

$$r_S = 1 - \frac{6 \sum_i d_i^2}{n(n^2-1)}, \qquad d_i = R_i - Q_i.$$

- **Se shodami** používáme průměrná pořadí (*midranks*) a r_S počítáme jako Pearsonův koeficient pořadí (tak to dělá `scipy`). Ekvivalentně

$$r_S = \frac{n^3 - n - \frac{1}{2}(T_x + T_y) - 6 \sum d_i^2}{\sqrt{(n^3 - n - T_x)(n^3 - n - T_y)}}, \qquad T_x = \sum_{\text{skupiny}} (t^3 - t),$$

  kde t jsou počty shodných hodnot v jednotlivých skupinách shod (T_y obdobně).

- Zjednodušený vzorec $1 - 6 \sum d_i^2 / (n(n^2-1))$ při shodách **nedává** správnou hodnotu (příklad na dalším slidu: 0,351 místo 0,327).

Statistické vlastnosti Spearmanova koeficientu

- Pro nezávislé spojité X, Y (bez ohledu na rozdělení): $\mathbb{E} r_S = 0$, $\quad \operatorname{var} r_S = \dfrac{1}{n-1}$.
- Test nezávislosti: pro malá n přesné rozdělení (permutace), jinak

$$u = r_S\sqrt{n-1} \mathrel{\dot\sim} N(0,1) \quad \text{nebo} \quad t = r_S\sqrt{\frac{n-2}{1-r_S^2}} \mathrel{\dot\sim} t_{n-2}\ (\texttt{scipy}),$$

  kritická hodnota $|r_S| \geq u_{1-\alpha/2}/\sqrt{n-1}$.
- Pro dvourozměrné normální rozdělení s korelací ρ:

$$\rho_S = \frac{6}{\pi}\arcsin\frac{\rho}{2}, \qquad \mathbb{E} r_S = \frac{6}{\pi(n+1)}\left[\arcsin\rho + (n-2)\arcsin\frac{\rho}{2}\right]$$

  (Moran 1948).
- Simulace ($n = 20$, $\rho = 0{,}7$): průměr $r_S = 0{,}658$, Moranův vzorec 0,656, $\rho_S = 0{,}683$ – i r_S je vychýlený.
- IS: Fisherova z s rozptylem přibližně $1{,}06/(n-3)$ (Fieller, Hartley, Pearson 1957) nebo bootstrap.

Spearmanův koeficient v Pythonu

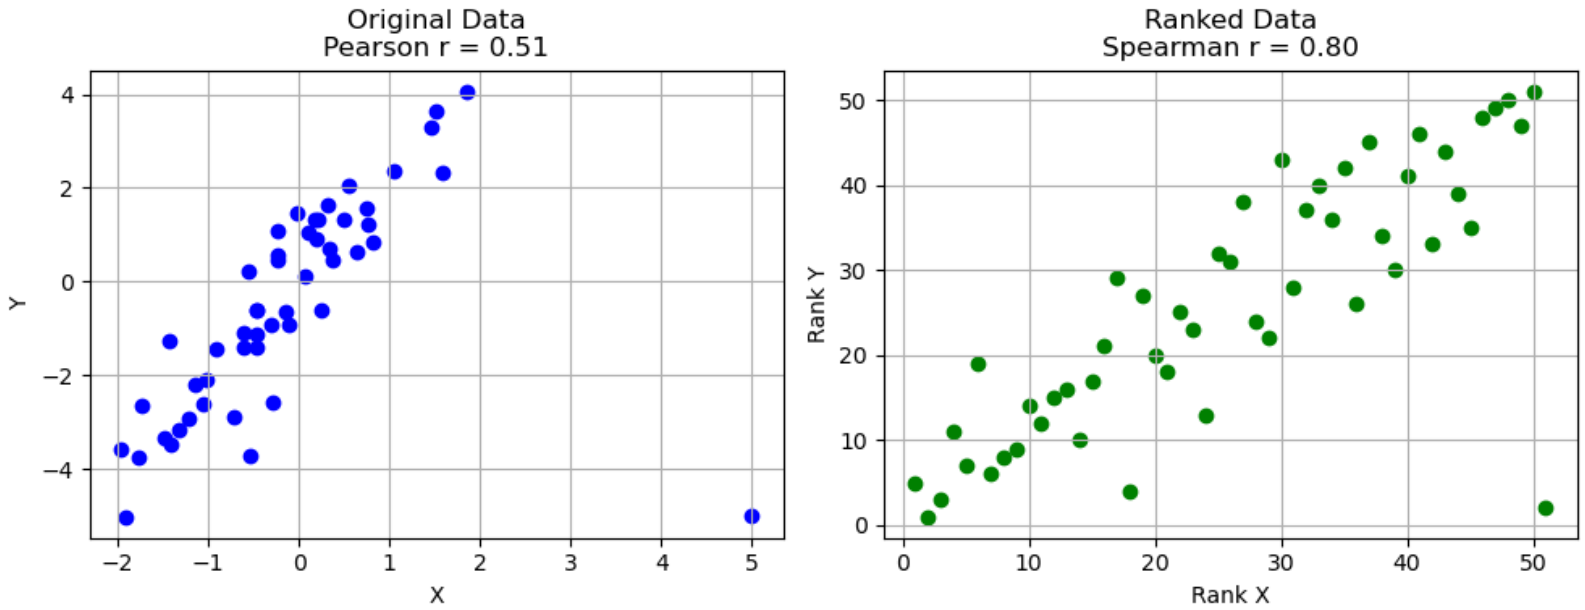
```
https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.
spearmanr.html

import numpy as np
import pingouin as pg
from scipy import stats

x = np.array([3, 1, 4, 1, 5, 9, 2, 6, 5, 3, 5, 8])
y = np.array([2, 7, 1, 8, 2, 8, 1, 8, 2, 8, 4, 9])
R, Q = stats.rankdata(x), stats.rankdata(y)   # midranks
n = len(x)
d2 = np.sum((R - Q)**2)
print(1 - 6 * d2 / (n * (n**2 - 1)))    # vzorec bez shod
print(np.corrcoef(R, Q)[0, 1])          # Pearson z pořadí
print(stats.spearmanr(x, y))
print(pg.corr(x, y, method='spearman').round(4))
```

Výstup: zjednodušený vzorec 0,3514 (chybně), Pearson z pořadí 0,3267 = `spearmanr` ($p = 0{,}300$).

Pearson vs. Spearman



- **Vlevo:** původní data, Pearsonův koeficient $r \approx 0{,}51$.
- **Vpravo:** pořadově transformovaná data, Spearmanův koeficient $r_S \approx 0{,}80$.
- Nelineární, ale monotónní vztah: r_S zachytí sílu monotónní závislosti lépe.

Kendallův koeficient τ – definice

- Dvojice pozorování (x_i, y_i) a (x_j, y_j) je
  - **konkordantní** (souhlasná), pokud $(x_i - x_j)(y_i - y_j) > 0$,
  - **diskordantní** (nesouhlasná), pokud $(x_i - x_j)(y_i - y_j) < 0$.
- Populační Kendallovo tau: pro nezávislé kopie (X_1, Y_1), (X_2, Y_2)

$$\tau(X, Y) = \mathcal{P}\big((X_1 - X_2)(Y_1 - Y_2) > 0\big) - \mathcal{P}\big((X_1 - X_2)(Y_1 - Y_2) < 0\big).$$

- Výběrové τ (bez shod), c = počet konkordantních, d = počet diskordantních dvojic:

$$\tau = \frac{c - d}{\binom{n}{2}} = \frac{1}{n(n-1)} \sum_{i \neq j} \operatorname{sgn}(R_i - R_j)\, \operatorname{sgn}(Q_i - Q_j).$$

- Interpretace: $\tau = 0{,}4$ znamená, že souhlasných dvojic je o 40 procentních bodů více než nesouhlasných (70 % vs. 30 %).
- Pro dvourozměrné normální rozdělení: $\tau = \frac{2}{\pi} \arcsin \rho$, a to **přesně** i pro střední hodnotu výběrového τ.

Kendallovo τ – shody a testování

- **Shody:** $\tau_a = (c-d)/\binom{n}{2}$ pak nedosahuje ± 1; používá se

$$\tau_b = \frac{c-d}{\sqrt{(n_0-n_1)(n_0-n_2)}}, \qquad n_0 = \binom{n}{2},\ n_1 = \sum_{\text{skup.}} \binom{t}{2},\ n_2 = \sum_{\text{skup.}} \binom{u}{2},$$

  kde t, u jsou počty shod v x, resp. y. Bez shod $\tau_b = \tau_a = (c-d)/(c+d)$. (`scipy` implicitně τ_b.)

- Pro nezávislé spojité X, Y:

$$\mathbb{E}\tau = 0, \qquad \operatorname{var}\tau = \frac{2(2n+5)}{9n(n-1)}.$$

- Test: $Z = \tau/\sqrt{\operatorname{var}\tau} \dot{\sim} N(0,1)$; pro malá n bez shod přesné rozdělení.
- Typicky $|\tau| < |r_S|$ (zhruba $r_S \approx 1{,}5\,\tau$ pro slabší závislost), ale p-hodnoty obou testů bývají podobné.
- τ má lepší asymptotické vlastnosti a jasnou pravděpodobnostní interpretaci; výpočet $O(n \log n)$.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Kendallovo τ v Pythonu

```
https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.
kendalltau.html

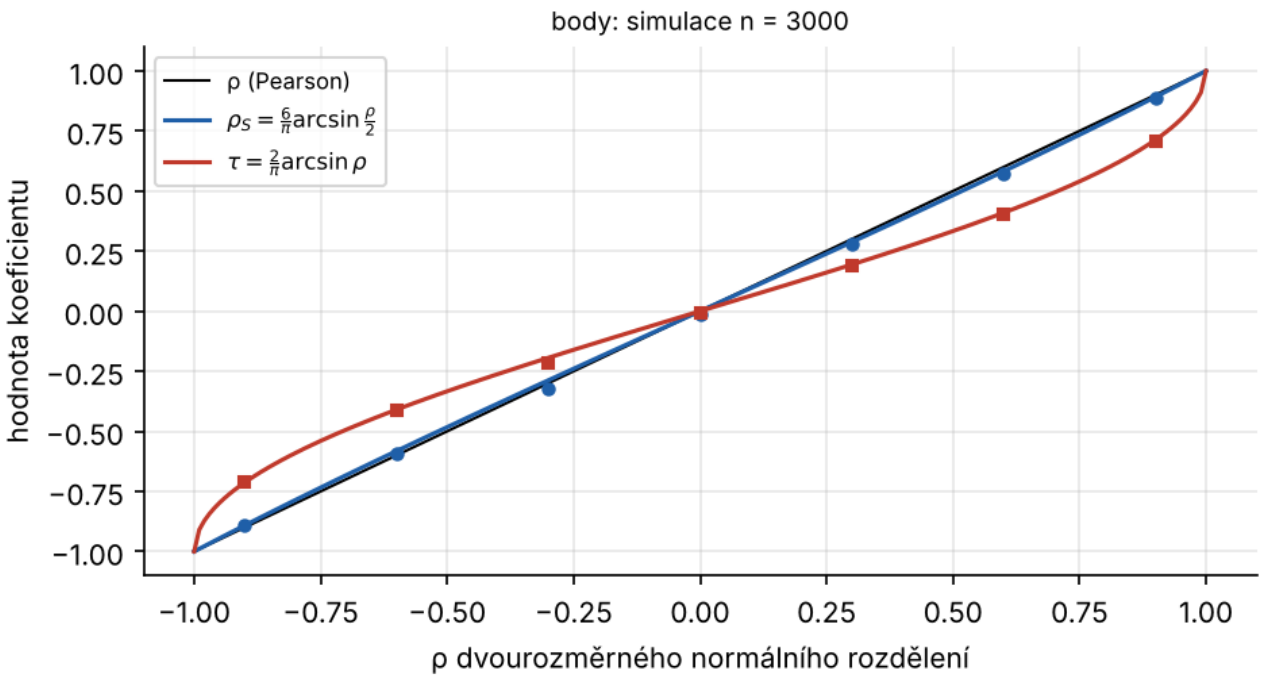
from itertools import combinations
import numpy as np
import pingouin as pg
from scipy.stats import kendalltau

x = [12, 2, 1, 12, 2]
y = [1, 4, 7, 1, 0]
tau, p_value = kendalltau(x, y)           # tau-b
print(f"Kendall tau = {tau:.3f}, p-hodnota = {p_value:.3g}")

s = [np.sign((x[i] - x[j]) * (y[i] - y[j]))
     for i, j in combinations(range(len(x)), 2)]
c, d = s.count(1), s.count(-1)
print("c =", c, " d =", d, " shody:", s.count(0))
print(pg.corr(x, y, method='kendall').round(3))
```

Výstup: $\tau_b = -0{,}471$, $p = 0{,}283$; $c = 2$, $d = 6$, 2 dvojice se shodou. Malá negativní závislost, při $n = 5$ zcela nevýznamná.

Vztah koeficientů pro normální rozdělení



Pro dvourozměrné normální rozdělení: $\rho_S = \frac{6}{\pi}\arcsin\frac{\rho}{2}$ (téměř shodné s ρ, rozdíl nejvýše 0,018) a $\tau = \frac{2}{\pi}\arcsin\rho$. Odtud robustní odhad $\hat{\rho} = \sin(\pi\hat{\tau}/2)$ pro eliptická rozdělení.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Robustní metody korelace

Biweight midcorrelation (bicor) Pearson z vážených odchylek od mediánu (váhy Tukeyho biweight, škála MAD); vliv extrémních hodnot je omezen. Často v bioinformatice (WGCNA).

Percentage bend (percbend) Hodnoty vzdálené od mediánu o více než zvolený kvantil absolutních odchylek se „ohnou“ na hranici (Wilcox).

Shepherd's pi (shepherd) Odlehlé body identifikuje bootstrapovanou Mahalanobisovou vzdáleností a na zbytku spočte Spearmana.

Skipped correlation (skipped) Odlehlé body určí robustní (MCD) odhad polohy a rozptylu, vynechá je a spočte Spearmana.

Všechny jsou v `pingouin.corr(x, y, method=...)`: `'bicor'`, `'percbend'`, `'shepherd'`, `'skipped'` (poslední dvě vracejí i masku odlehlých bodů). Výhody: odolnost vůči odlehlým hodnotám a těžkým chvostům; nevýhody: menší síla testu u čistě normálních dat, horší interpretace.

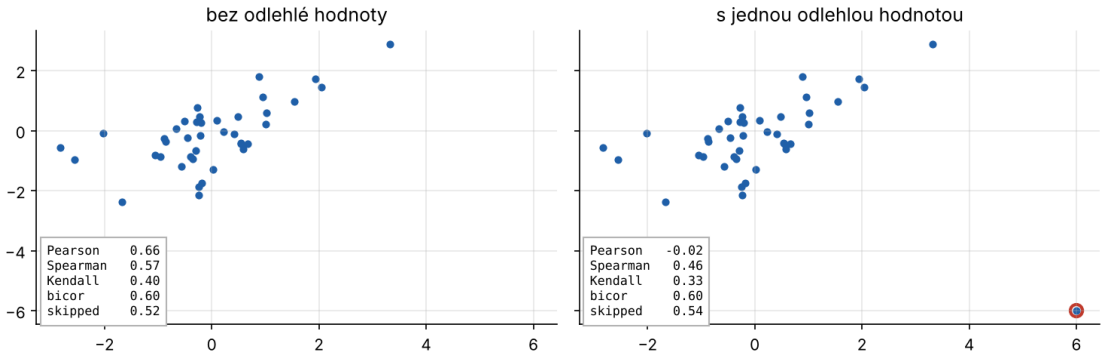
FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Vliv jediné odlehlé hodnoty

https://pingouin-stats.org/build/html/generated/pingouin.corr.html

```
import numpy as np
import pingouin as pg

rng = np.random.default_rng(3)
x = rng.normal(0, 1, 40)
y = 0.6 * x + rng.normal(0, 0.8, 40)
x, y = np.append(x, 6), np.append(y, -6)   # odlehlý bod
for m in ['pearson', 'spearman', 'kendall', 'bicor',
          'percbend', 'shepherd', 'skipped']:
    print(m, pg.corr(x, y, method=m)['r'].iloc[0].round(3))
```



Jediný bod $(6, -6)$ změní Pearsonův koeficient z 0,66 na $-0{,}02$; Spearman klesne z 0,57 na 0,46, Kendall z 0,40 na 0,33, bicor (0,60) a skipped (0,52 $\rightarrow$ 0,54) se téměř nezmění.

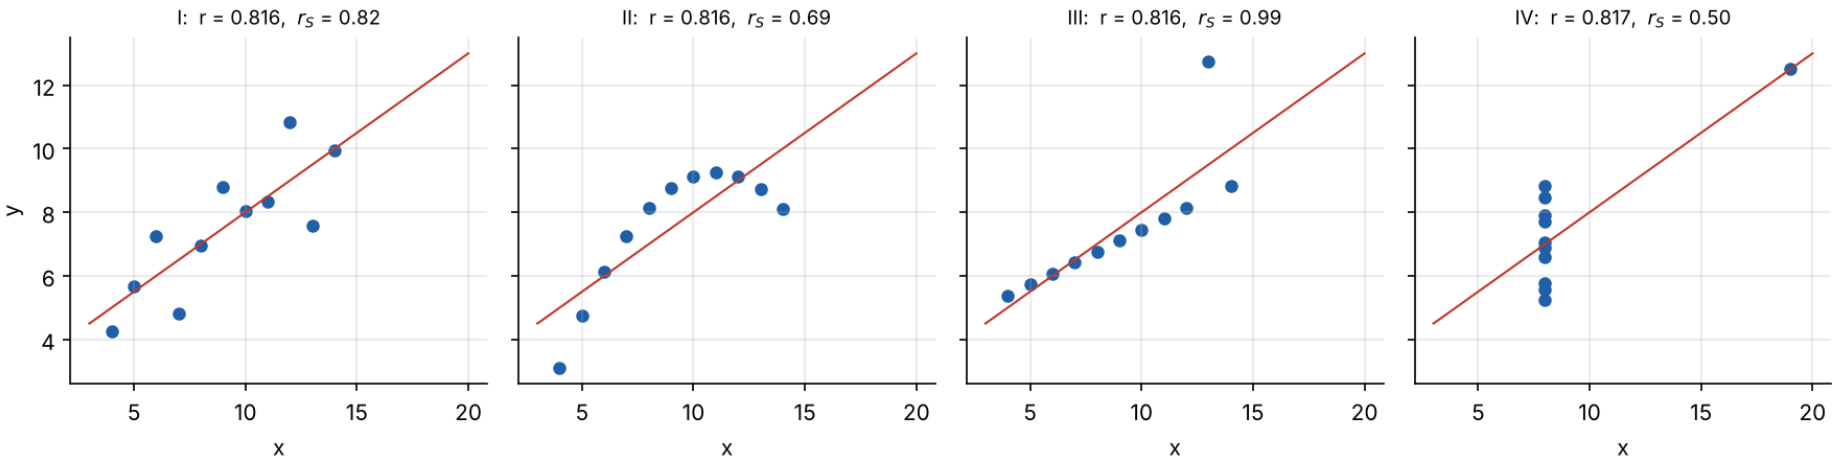
Korelace $\neq$ kauzalita

Silná a statisticky významná korelace mezi X a Y může vzniknout, aniž by X způsobovalo Y:

- **společná příčina** (confounder): $Z \to X$ a $Z \to Y$ (spotřeba zmrzliny a utonutí – teplota);
- **obrácená kauzalita**: $Y \to X$;
- **výběrové zkreslení** (selekce, Berksonův paradox): korelace vznikne výběrem jednotek;
- **trendy v čase**: dvě rostoucí časové řady jsou korelované, i když spolu nesouvisejí (zdánlivá regrese) – korelujte spíše přírůstky;
- **agregace**: korelace skupinových průměrů (ekologická korelace) může být úplně jiná než korelace jednotlivců; Simpsonův paradox;
- **náhoda a mnohonásobné testování**: mezi $k = 50$ proměnnými je 1225 dvojic, při $\alpha = 0{,}05$ očekáváme kolem 61 „významných“ korelací i při úplné nezávislosti.

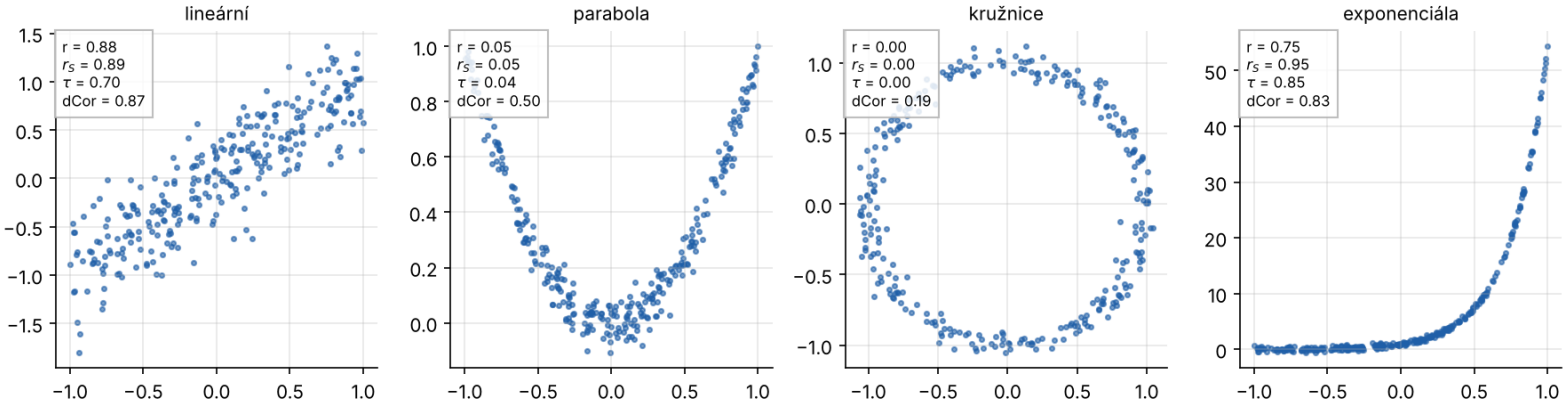
Parciální korelace pomůže jen proti **změřeným** a správně (lineárně) zahrnutým rušivým proměnným.

Anscombeho kvartet – vždy kreslete graf



- Čtyři datové soubory se (téměř) stejnými průměry, rozptyly, regresní přímkou a korelací $r \approx 0{,}816$ (Anscombe 1973).
- I: lineární vztah se šumem; II: přesná nelineární závislost; III: přesná lineární závislost s jednou odlehlou hodnotou; IV: korelace daná jediným vlivným bodem.
- Vždy doplňte číselné shrnutí bodovým grafem (`seaborn.pairplot`, `pandas.plotting.scatter_matrix`).

Nelineární závislosti



- Pearson, Spearman i Kendall měří jen lineární/monotónní složku – parabola a kružnice dávají $r \approx 0$.
- **Distance correlation** (dCor; Székely, Rizzo, Bakirov 2007): $\mathrm{dCor}(X, Y) \in \langle 0, 1 \rangle$ a $\mathrm{dCor} = 0$ **právě tehdy**, když jsou X a Y nezávislé (pro konečné první momenty); funguje i pro vektory. Test nezávislosti permutací.
- **Vzájemná informace** $I(X; Y) = \int\int f(x, y) \ln \frac{f(x,y)}{f_X(x) f_Y(y)} \, \mathrm{d}x \, \mathrm{d}y \geq 0$, nulová právě při nezávislosti; odhad metodou nejbližších sousedů (`sklearn.feature_selection.mutual_info_regression`).
- Dále: Chatterjeeho koeficient ξ (`scipy.stats.chatterjeexi`), MIC, HSIC; balík `dcor`.

Distance correlation a vzájemná informace – Python

```
import numpy as np
from sklearn.feature_selection import mutual_info_regression
def dcor(x, y):                          # distance correlation
    def centr(z):
        d = np.abs(z[:, None] - z[None, :])
        return d - d.mean(0) - d.mean(1)[:, None] + d.mean()
    A, B = centr(x), centr(y)
    return np.sqrt((A * B).mean()
                   / np.sqrt((A * A).mean() * (B * B).mean()))
rng = np.random.default_rng(2026)
x = rng.uniform(-1, 1, 300)
y = x**2 + rng.normal(0, 0.05, 300)          # parabola
mi = mutual_info_regression(x[:, None], y, random_state=0)
dc = dcor(x, y)
print(f"r = {np.corrcoef(x, y)[0, 1]:.3f}, dCor = {dc:.3f}")
print(f"MI = {mi[0]:.3f} nat")
perm = [dcor(x, rng.permutation(y)) for _ in range(199)]
print("p =", (1 + sum(np.array(perm) >= dc)) / 200)
```

Výstup: $r = 0{,}069$, dCor $= 0{,}507$, MI $= 1{,}49$ nat, permutační $p = 0{,}005$ (nejmenší možná při 199 permutacích).

Doporučený postup při analýze korelací

1. **Graf** – bodový graf (matice grafů), hledejte nelinearitu, shluky, odlehlé hodnoty, heteroskedasticitu.
2. **Volba koeficientu:** lineární vztah, přibližně normální data $\rightarrow$ Pearson; monotónní vztah, ordinální data nebo těžké chvosty $\rightarrow$ Spearman/Kendall; odlehlé hodnoty $\rightarrow$ robustní koeficienty; obecná závislost $\rightarrow$ dCor, MI.
3. **Struktura dat:** opakovaná měření $\rightarrow$ rmcorr / smíšený model; skupiny $\rightarrow$ korelace ve skupinách nebo parciální korelace (Simpsonův paradox); časové řady $\rightarrow$ pozor na trend a autokorelaci.
4. **Nejistota:** uvádějte r **s intervalem spolehlivosti** (Fisherova z nebo bootstrap), nejen p-hodnotu; pro malé n zvažte korekci vychýlení.
5. **Mnohonásobné testování:** korigujte (Holm, FDR) při testování mnoha dvojic.
6. **Interpretace:** statistická významnost $\neq$ praktická významnost (při $n = 10\,000$ je významné i $r = 0{,}02$); korelace $\neq$ kauzalita; r^2 je podíl „sdíleného“ rozptylu.
7. **Chybějící hodnoty:** pairwise vynechání může vést k nekonzistentní (ne PSD) korelační matici.

Shrnutí

- Pearsonův r měří **lineární** závislost; je mírně vychýlený k nule ($\mathbb{E}r \approx \rho(1 - \frac{1-\rho^2}{2n})$), korekce Olkin–Pratt.
- Fisherova transformace $z = \operatorname{artanh} r$, $\operatorname{var} z \approx \frac{1}{n-3}$: intervaly spolehlivosti, test $H_0 : \rho = \rho_0$, porovnání nezávislých korelací.
- Reflexivní koeficient = Pearson bez centrování (kosinová podobnost).
- Mnohonásobný $R^2 = \boldsymbol{r}_{YX}^T \boldsymbol{R}_{XX}^{-1} \boldsymbol{r}_{XY} = 1 - 1/(\boldsymbol{R}^{-1})_{jj}$ = koeficient determinace; F-test s $(q,\ n-q-1)$ st. v.
- Parciální korelace $= -p_{ij}/\sqrt{p_{ii}p_{jj}}$ z $\boldsymbol{P} = \boldsymbol{R}^{-1}$; t-test s $n-2-q$ st. v.; Simpsonův paradox.
- rmcorr: korelace po centrování uvnitř subjektů, $N - m - 1$ st. v.
- Spearman a Kendall: monotónní závislost, invariantní vůči monotónním transformacím; pro normální data $\rho_S = \frac{6}{\pi} \arcsin \frac{\rho}{2}$, $\tau = \frac{2}{\pi} \arcsin \rho$; robustní varianty bicor, skipped.
- Vždy graf, interval spolehlivosti, pozor na kauzalitu, odlehlé hodnoty a nelinearitu.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI