KMA/MSM – Přednáška 9: Korelace

Kontrolní otázky (uzavřené) – verze s řešením

U otázek označených (*jedna odpověď*) je správná právě jedna možnost, u otázek označených (*více odpovědí*) může být správných více možností.

Otázka 1 (více odpovědí)

Která tvrzení o Pearsonově korelačním koeficientu ρ jsou pravdivá?

a) Jsou-li X a Y nezávislé (s konečnými rozptyly), je $\rho = 0$. **[správně]**

b) Je-li $\rho = 0$, jsou X a Y vždy nezávislé.

c) Pro dvourozměrné normální rozdělení platí $\rho = 0$ právě tehdy, když jsou X a Y nezávislé. **[správně]**

d) ρ se nezmění, když X nahradíme $\ln X$.

e) $\rho(a + bX, Y) = \rho(X, Y)$ pro libovolné a a $b > 0$. **[správně]**

Řešení: Správně a), c), e). Protipříklad k b): $X \sim N(0,1)$, $Y = X^2$ – $\rho = 0$, ale Y je funkcí X. Pearsonův koeficient je invariantní jen vůči rostoucím *lineárním* transformacím; vůči všem rostoucím transformacím jsou invariantní Spearmanův a Kendallův koeficient.

Otázka 2 (jedna odpověď)

Z výběru rozsahu $n = 28$ vyšlo $r = 0{,}5$. Jaký je přibližný rozptyl $z = \operatorname{artanh} r$?

a) $(1 - r^2)^2/n = 0{,}020$

b) $1/(n - 3) = 0{,}04$ **[správně]**

c) $1/(n - 2) = 0{,}0385$

d) $1/\sqrt{n - 3} = 0{,}2$

Řešení: $\operatorname{var} z \approx 1/(n - 3)$ nezávisle na ρ – proto se Fisherova transformace nazývá transformace stabilizující rozptyl. Výraz a) je asymptotický rozptyl samotného r (závisí na ρ), d) je směrodatná odchylka z.

Otázka 3 (jedna odpověď)

Ve dvou nezávislých skupinách vyšla korelace $r_1 = 0{,}60$ ($n_1 = 50$) a $r_2 = 0{,}40$ ($n_2 = 50$). Pomocí kterého postupu je rozumné otestovat $H_0 : \rho_1 = \rho_2$?

a) $Z = (r_1 - r_2)/\sqrt{1/(n_1 - 3) + 1/(n_2 - 3)}$

b) $Z = (\operatorname{artanh} r_1 - \operatorname{artanh} r_2)/\sqrt{1/(n_1 - 3) + 1/(n_2 - 3)}$ **[správně]**

c) Dvouvýběrovým t-testem na hodnotách r_1, r_2.

d) Testem nezávislosti $t = r\sqrt{(n - 2)/(1 - r^2)}$ v každé skupině zvlášť; liší-li se výsledky (významná/nevýznamná), liší se i korelace.

Řešení: Rozptyl $1/(n-3)$ platí pro $z = \operatorname{artanh} r$, nikoli pro r. Zde $Z = (0{,}693 - 0{,}424)/0{,}206 = 1{,}31$, $p = 0{,}19$. Možnost d) je častá chyba: rozdíl „významná vs. nevýznamná“ sám o sobě není významný rozdíl.

Otázka 4 (jedna odpověď)

Parciální korelaci $r_{YZ\cdot X}$ při kontrole $q = 3$ veličin jsme spočetli z $n = 50$ pozorování. Kolik stupňů volnosti má statistika $t = r_{YZ\cdot X}\sqrt{(n-2-q)/(1-r^2_{YZ\cdot X})}$?

a) 48

b) 47

c) 45 **[správně]**

d) 44

Řešení: $n-2-q = 50-2-3 = 45$; každá kontrolní veličina spotřebuje jeden stupeň volnosti. Test je totožný s t-testem koeficientu u Z v regresi $Y \sim Z+X_1+X_2+X_3$ (reziduální st. v. $n-4-1 = 45$).

Otázka 5 (více odpovědí)

Která tvrzení o mnohonásobném koeficientu korelace $R_{Y\cdot(X_1,\ldots,X_q)}$ jsou pravdivá?

a) R je korelace mezi Y a predikcí $\widehat{Y}$ z lineární regrese Y na $X_1, \ldots, X_q$. **[správně]**

b) $R \geq |r_{YX_j}|$ pro všechna j. **[správně]**

c) Přidáním další proměnné se R^2 může zmenšit.

d) Pro nezávislé veličiny je $\mathrm{E}\, R^2 = q/(n-1) > 0$, proto se používá R^2_{adj}. **[správně]**

e) R může nabývat hodnot z intervalu $\langle -1, 1\rangle$.

Řešení: Správně a), b), d). R^2 přidáním proměnné nikdy neklesne (může klesnout jen R^2_{adj}) a $R \in \langle 0, 1\rangle$, protože jde o maximum korelace přes všechny lineární kombinace.

Otázka 6 (jedna odpověď)

U 10 pacientů bylo provedeno vždy 5 dvojic měření (x, y). Kolik stupňů volnosti má test korelace opakovaných měření r_{rm}?

a) 48

b) 39 **[správně]**

c) 8

d) 40

Řešení: $\nu = N - m - 1 = 50 - 10 - 1 = 39$ (každý subjekt má vlastní úroveň α_i). Hodnota 48 by odpovídala obyčejnému Pearsonovi na všech 50 bodech, který by ignoroval závislost měření téhož subjektu (pseudoreplikace); 8 odpovídá korelaci průměrů subjektů.

Otázka 7 (více odpovědí)

Která tvrzení o Spearmanově r_S a Kendallově τ jsou pravdivá?

a) Oba koeficienty se nezmění, pokud jednu proměnnou nahradíme jejím logaritmem. **[správně]**

b) Při shodných hodnotách dává vzorec $1-6\sum d_i^2/(n(n^2-1))$ obecně jinou hodnotu než Pearsonův koeficient spočtený z průměrných pořadí. **[správně]**

c) Pro dvourozměrné normální rozdělení s $\rho = 0{,}5$ je $\tau = 1/3$. **[správně]**

d) Obvykle platí $|\tau| > |r_S|$.

e) Pro nezávislé spojité veličiny je $\operatorname{var}\tau = \frac{2(2n+5)}{9n(n-1)}$ bez ohledu na rozdělení. **[správně]**

Řešení: Správně a), b), c), e). c) $\tau = \frac{2}{\pi}\arcsin 0{,}5 = \frac{2}{\pi}\cdot\frac{\pi}{6} = \frac{1}{3}$. d) Naopak, typicky $|\tau| < |r_S|$ (zhruba $r_S \approx 1{,}5\,\tau$), p-hodnoty obou testů jsou ale podobné.

Otázka 8 (jedna odpověď)

K 40 bodům se středně silnou kladnou lineární závislostí ($r = 0{,}66$) přidáme jediný odlehlý bod $(6, -6)$. Který koeficient se změní nejvíc?

a) Pearsonův **[správně]**

b) Spearmanův

c) Kendallův

d) biweight midcorrelation

Řešení: Pearsonův koeficient klesne až k $-0{,}02$, protože jeden bod s velkými odchylkami dominuje součtům součinů. Pořadové koeficienty se změní méně (bod dostane jen krajní pořadí), robustní koeficienty (bicor, skipped) téměř vůbec. Proto je třeba vždy nakreslit graf.

Otázka 9 (jedna odpověď)

Ve výběru $n = 10\,000$ osob vyšlo $r = 0{,}03$, $p = 0{,}003$. Co je správný závěr?

a) Proměnné jsou silně závislé, protože $p < 0{,}01$.

b) Lineární závislost je statisticky prokázaná, ale prakticky zanedbatelná ($r^2 < 0{,}1\,\%$). **[správně]**

c) Výsledek je chybný, při $r = 0{,}03$ nemůže být $p < 0{,}05$.

d) Jedna proměnná je příčinou druhé.

Řešení: $t = 0{,}03\sqrt{9998/(1-0{,}0009)} = 3{,}0$, $p = 0{,}003$. Při velkém n je významná i nepatrná korelace; o síle vypovídá r (s intervalem spolehlivosti), ne p-hodnota. Korelace navíc nic neříká o kauzalitě.

Otázka 10 (více odpovědí)

Pro $x \sim U(-1, 1)$ a $y = x^2 + \varepsilon$ s malým šumem vyšlo $r \approx 0$. Která tvrzení jsou pravdivá?

a) Výsledek ukazuje, že x a y jsou nezávislé.

b) Spearmanův a Kendallův koeficient budou také blízko nuly, protože závislost není monotónní. **[správně]**

c) Distance correlation (dCor) bude výrazně kladná, protože dCor $= 0$ právě při nezávislosti. **[správně]**

d) Vzájemná informace $I(X; Y)$ bude kladná. **[správně]**

e) Test nezávislosti pomocí dCor se obvykle provádí permutačně. **[správně]**

Řešení: Správně b)–e). Pearson, Spearman i Kendall měří jen lineární, resp. monotónní složku závislosti; nulová hodnota neznamená nezávislost. V notebooku vyšlo $r = 0{,}069$, dCor $= 0{,}507$, MI $= 1{,}49$ nat, permutační $p = 0{,}005$.