Přednáška 9b: Kopule jako modely závislosti

Definice kopule, Fréchetovy–Hoeffdingovy meze, Sklarova věta. Eliptické a Archimédovy kopule. Kopule a pořadové míry závislosti. Generování výběrů. Analýza reálných dat.

KMA/MSM Blanka Šedivá

verze 2026/2027

8. října 2026

Obsah

1. Kopule jako modely závislosti

2. Kopule v praxi – analýza reálných dat

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Kopule – oddělení marginálních rozdělení od struktury závislosti

- Navazuje na P09 (korelace): Pearsonův ρ, Spearmanův ρ_S, Kendallovo τ.
- Kopule, Fréchetovy–Hoeffdingovy meze, Sklarova věta
- Parametrické rodiny: Gaussova, t, Clayton, Gumbel, Frank
- Vztah kopulí a pořadových měr závislosti, závislost v chvostech
- Generování výběrů z kopule
- Praktická ukázka: závislost výnosů akciových indexů DAX a CAC, riziko portfolia

Ukázky v Pythonu: notebook `P09b_kopule.ipynb`.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Kopule – motivace

- Různá sdružená rozdělení mohou mít **stejná marginální rozdělení**.

  Např. hustota $f_\alpha(x, y) = 1 + \alpha(2x - 1)(2y - 1)$, $0 < x, y < 1$, $|\alpha| \leq 1$, má rovnoměrné marginály pro každé α, ale $\mathrm{cov}\,(X, Y) = \alpha/36$.

- **Kopule** je funkce, která „svazuje“ marginální rozdělení do sdruženého – popisuje **pouze strukturu závislosti**.

- Korelační koeficienty shrnují závislost jedním číslem:
  - Pearson zachytí jen lineární vztah a závisí na marginálech,
  - nezachytí závislost v chvostech (současný výskyt extrémů).

- Kopule umožňují:
  - oddělit modelování marginál od modelování závislosti,
  - modelovat asymetrickou závislost a závislost extrémů (*tail dependence*) – finance, pojišťovnictví, hydrologie,
  - generovat data s předepsanými marginály a závislostí.

Definice dvourozměrné kopule

Funkce $C : \langle 0,1\rangle^2 \to \langle 0,1\rangle$ je **kopule**, pokud

(i) $C(0,u) = C(u,0) = 0$ pro $u \in \langle 0,1\rangle$ (*groundedness*)

(ii) $C(u,1) = C(1,u) = u$ pro $u \in \langle 0,1\rangle$ (rovnoměrné marginály)

(iii) pro všechna $u_1 \le v_1$, $u_2 \le v_2$ z $\langle 0,1\rangle$ platí

$$C(v_1,v_2) - C(v_1,u_2) - C(u_1,v_2) + C(u_1,u_2) \ge 0$$

(*2-rostoucí*, kvazimonotonie)

- Ekvivalentně: kopule je distribuční funkce náhodného vektoru (U,V) s rovnoměrnými marginály $R(0,1)$.
- Podmínka (iii) říká, že pravděpodobnost obdélníku $\langle u_1,v_1\rangle \times \langle u_2,v_2\rangle$ je nezáporná.
- Pro d rozměrů analogicky (d-rostoucí: nezáporný „objem“ každého kvádru).

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Základní kopule Π, M, W

- **Nezávislá (produktová) kopule** – $U_1, \ldots, U_d$ nezávislé $R(0,1)$:

$$\Pi(u_1, \ldots, u_d) = \mathcal{P}(U_1 \leq u_1, \ldots, U_d \leq u_d) = \prod_{i=1}^{d} u_i.$$

- **Horní kopule** M (komonotónnost) – $(U_1, \ldots, U_d) = (U, \ldots, U)$, $U \sim R(0,1)$:

$$M(u_1, \ldots, u_d) = \mathcal{P}\left(U \leq \min(u_1, \ldots, u_d)\right) = \min(u_1, \ldots, u_d).$$

- **Dolní kopule** W (kontramonotónnost, jen $d = 2$) – $(U_1, U_2) = (U, 1-U)$:

$$W(u_1, u_2) = \mathcal{P}(1 - u_2 \leq U \leq u_1) = \max(u_1 + u_2 - 1,\ 0).$$

- Vztah k mírám závislosti:

kopule	Π	M	W
τ, ρ_S	0	1	-1
význam	nezávislost	$Y = g(X)$, g rostoucí	$Y = g(X)$, g klesající

Fréchetovy–Hoeffdingovy meze

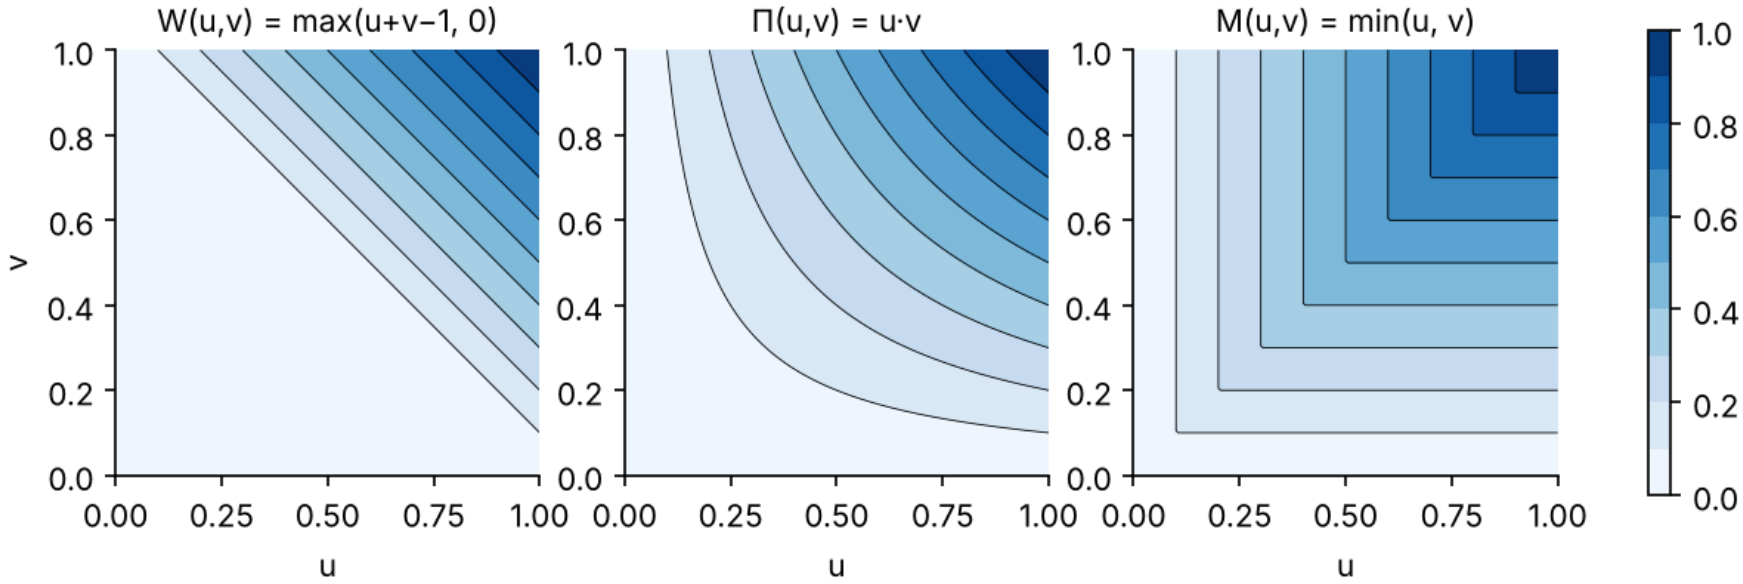
Pro každou d-rozměrnou kopuli C a všechna $(u_1, \ldots, u_d) \in \langle 0, 1 \rangle^d$ platí

$$W(u_1, \ldots, u_d) \leq C(u_1, \ldots, u_d) \leq M(u_1, \ldots, u_d),$$

$$\begin{aligned} W(u_1, \ldots, u_d) &= \max\left\{\sum_{i=1}^{d} u_i - (d-1),\ 0\right\}, \\ M(u_1, \ldots, u_d) &= \min\{u_1, \ldots, u_d\}. \end{aligned}$$

- M je kopule pro každé d; horní mez je dosažena.
- W je kopule **pouze pro** $d = 2$. Pro $d \geq 3$ porušuje podmínku d-rostoucí (např. pro $d = 3$ má kvádr $\langle \frac{1}{2}, 1 \rangle^3$ „objem“ $-\frac{1}{2}$), mez je však nejlepší možná bodově.
- Dvourozměrně: $\max(u + v - 1, 0) \leq C(u, v) \leq \min(u, v)$.
- Důsledek: pro dané marginály je rozsah dosažitelných Pearsonových korelací $\langle \rho_{\min}, \rho_{\max} \rangle$ často užší než $\langle -1, 1 \rangle$.

Kopule W, Π a M – vrstevnice



Každá kopule leží „mezi“ levým a pravým grafem; nezávislá kopule (uprostřed) je jedním z mnoha případů.

Sklarova věta

Věta (Sklar 1959)

Nechť F je d-rozměrná distribuční funkce s marginálními distribučními funkcemi $F_1, \ldots, F_d$. Pak existuje d-rozměrná kopule C taková, že pro všechna $\boldsymbol{x} \in \mathbb{R}^d$

$$F(x_1, \ldots, x_d) = C\left(F_1(x_1), \ldots, F_d(x_d)\right).$$

Jsou-li $F_1, \ldots, F_d$ spojité, je C určena jednoznačně. Naopak, pro libovolnou kopuli C a libovolné jednorozměrné distribuční funkce $F_1, \ldots, F_d$ je takto definovaná F distribuční funkcí s marginálami $F_1, \ldots, F_d$.

- Pro spojité marginály: $C(u_1, \ldots, u_d) = F\left(F_1^{-1}(u_1), \ldots, F_d^{-1}(u_d)\right)$.
- Hustota: $f(\boldsymbol{x}) = c\left(F_1(x_1), \ldots, F_d(x_d)\right) \prod_i f_i(x_i)$, kde $c = \partial^d C / \partial u_1 \cdots \partial u_d$.
- Kopule je invariantní vůči ostře rostoucím transformacím jednotlivých složek.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Parametrické rodiny kopulí

- **Eliptické kopule** – odvozené z vícerozměrného normálního, resp. t-rozdělení:

$$C^{Ga}_{\boldsymbol{P}}(\boldsymbol{u}) = \Phi_{\boldsymbol{P}}\big(\Phi^{-1}(u_1),\dots,\Phi^{-1}(u_d)\big), \qquad C^{t}_{\nu,\boldsymbol{P}}(\boldsymbol{u}) = t_{\nu,\boldsymbol{P}}\big(t_\nu^{-1}(u_1),\dots,t_\nu^{-1}(u_d)\big),$$

  $\boldsymbol{P}$ je korelační matice **normálních skórů** $\Phi^{-1}(F_i(X_i))$, nikoli korelace původních dat.

- **Archimédovy kopule** $C(\boldsymbol{u}) = \psi^{-1}\big(\psi(u_1)+\cdots+\psi(u_d)\big)$ s generátorem ψ (spojitý, klesající, konvexní, $\psi(1)=0$):

rodina	generátor $\psi(t)$	$C(u,v)$	τ
Clayton, $\theta>0$	$\frac{1}{\theta}(t^{-\theta}-1)$	$(u^{-\theta}+v^{-\theta}-1)^{-1/\theta}$	$\frac{\theta}{\theta+2}$
Gumbel, $\theta\geq 1$	$(-\ln t)^\theta$	$\exp\Big(-\big[(-\ln u)^\theta+(-\ln v)^\theta\big]^{1/\theta}\Big)$	$1-\frac{1}{\theta}$
Frank, $\theta\neq 0$	$-\ln\frac{\mathrm{e}^{-\theta t}-1}{\mathrm{e}^{-\theta}-1}$	$-\frac{1}{\theta}\ln\Big(1+\frac{(\mathrm{e}^{-\theta u}-1)(\mathrm{e}^{-\theta v}-1)}{\mathrm{e}^{-\theta}-1}\Big)$	(Debyeova fce)
nezávislá	$-\ln t$	uv	0

- Závislost v chvostech: Clayton – dolní ($\lambda_L = 2^{-1/\theta}$), Gumbel – horní ($\lambda_U = 2-2^{1/\theta}$), Gaussova – žádná ($\lambda=0$ pro $|\rho|<1$), t – obě, symetricky.

Kopule a míry závislosti

- Pořadové míry závislosti závisejí **jen na kopuli** (ne na marginálech):

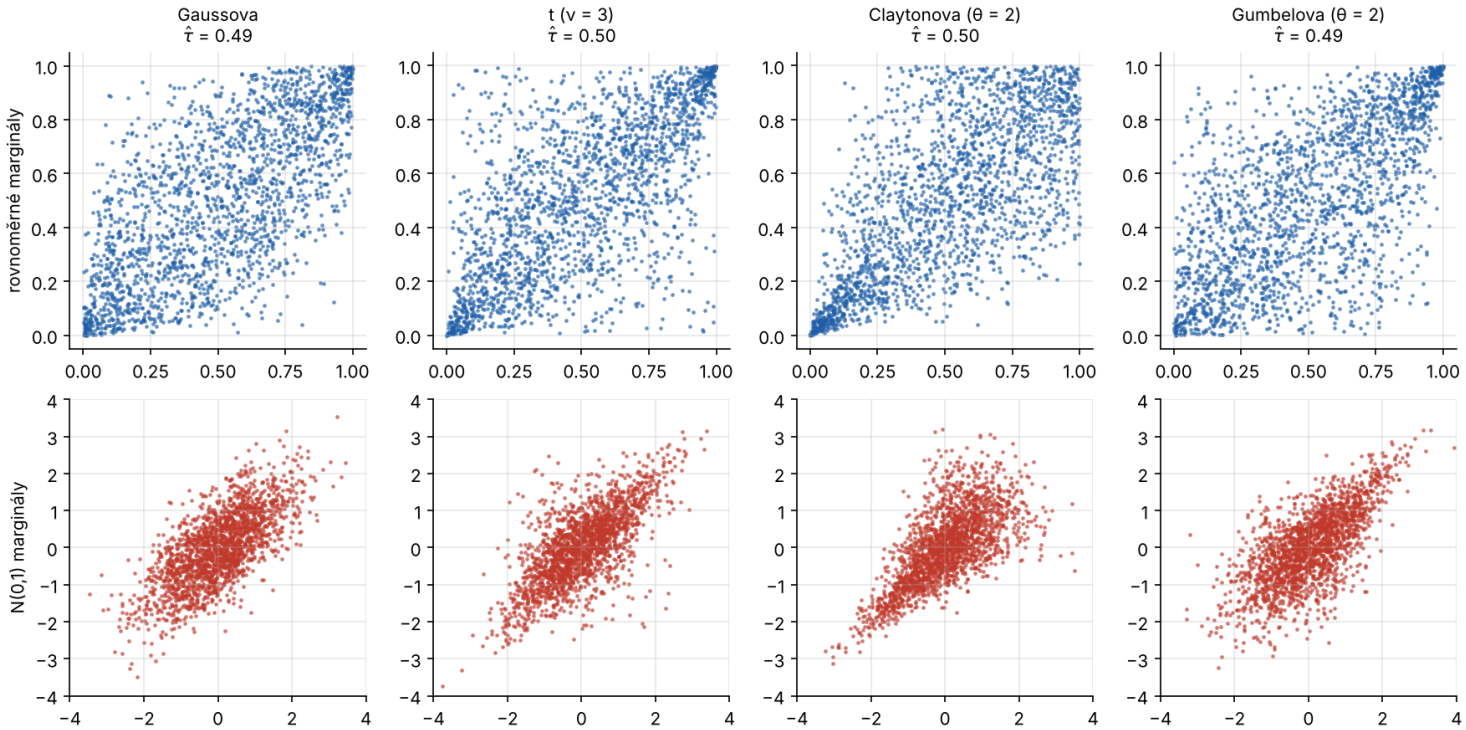
$$\tau = 4 \int_0^1 \int_0^1 C(u, v) \, \mathrm{d}C(u, v) - 1, \qquad \rho_S = 12 \int_0^1 \int_0^1 C(u, v) \, \mathrm{d}u \, \mathrm{d}v - 3.$$

- Pearsonův ρ závisí na kopuli **i** na marginálech.
- Gaussova (a t) kopule s parametrem ρ:

$$\tau = \frac{2}{\pi} \arcsin \rho, \qquad \rho_S = \frac{6}{\pi} \arcsin \frac{\rho}{2}.$$

- Kalibrace kopule pomocí $\hat{\tau}$: Clayton $\hat{\theta} = 2\hat{\tau}/(1 - \hat{\tau})$, Gumbel $\hat{\theta} = 1/(1 - \hat{\tau})$, Gaussova $\hat{\rho} = \sin(\pi\hat{\tau}/2)$.
- Kendallovo τ je proto přirozenou mírou závislosti pro kopule.
- Simulace (Marshall–Olkinův algoritmus, $\theta = 2$): Clayton $\hat{\tau} = 0{,}51$ (teorie 0,5), Gumbel $\hat{\tau} = 0{,}51$ (teorie 0,5).

Výběry z kopulí se stejným $\tau = 0{,}5$



Horní řada: rovnoměrné marginály (vlastní kopule). Dolní řada: tytéž kopule s marginálami $N(0, 1)$. Stejné τ, ale zcela odlišné chování extrémů (Clayton – dolní chvost, Gumbel – horní chvost).

Generování výběrů z kopule

Podmíněná metoda (obecná, $d = 2$): pro absolutně spojitou kopuli je

$$\mathcal{P}(U_1 \leq u_1 \mid U_2 = u_2) = \frac{\partial C(u_1, u_2)}{\partial u_2} =: h(u_1 \mid u_2).$$

1. vygeneruj $U_2 \sim R(0,1)$ a nezávisle $V \sim R(0,1)$,
2. polož $U_1 = h^{-1}(V \mid U_2)$ (inverze podmíněné distribuční funkce),
3. $(U_1, U_2) \sim C$; data s marginálami F_i získáme jako $X_i = F_i^{-1}(U_i)$.

Speciální algoritmy:

- Gaussova kopule: $\boldsymbol{Z} \sim N_d(\boldsymbol{0}, \boldsymbol{P})$, $U_i = \Phi(Z_i)$.
- t-kopule: $\boldsymbol{T} = \boldsymbol{Z}/\sqrt{W/\nu}$, $W \sim \chi^2_\nu$, $U_i = t_\nu(T_i)$.
- Archimédovy kopule: Marshall–Olkinův algoritmus (Clayton – gama rozdělení, Gumbel – stabilní rozdělení), viz notebook `P09b_kopule.ipynb`.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Gaussova kopule s nenormálními marginály – Python

```
https://docs.scipy.org/doc/scipy/reference/stats.html

import numpy as np
from scipy import stats

rng = np.random.default_rng(7)
rho, n = 0.7, 5000
Z = rng.multivariate_normal([0, 0], [[1, rho], [rho, 1]], n)
U = stats.norm.cdf(Z)                          # Gaussova kopule
X = stats.expon.ppf(U[:, 0])                   # Exp(1) marginála
Y = stats.lognorm.ppf(U[:, 1], s=1.5)  # lognormální
print("Pearson Z:", np.corrcoef(Z.T)[0, 1].round(3))
print("Pearson X,Y:", np.corrcoef(X, Y)[0, 1].round(3))
print("Kendall Z:", stats.kendalltau(*Z.T)[0].round(3))
print("Kendall X,Y:", stats.kendalltau(X, Y)[0].round(3))
print("2/pi asin rho:", (2 / np.pi * np.arcsin(rho)).round(3))
```

Výstup: Pearson se změnou marginál klesne z 0,70 na 0,57, Kendallovo $\tau = 0{,}493$ zůstane stejné (odpovídá $\frac{2}{\pi} \arcsin 0{,}7 = 0{,}494$).

Kopule v praxi – postup analýzy

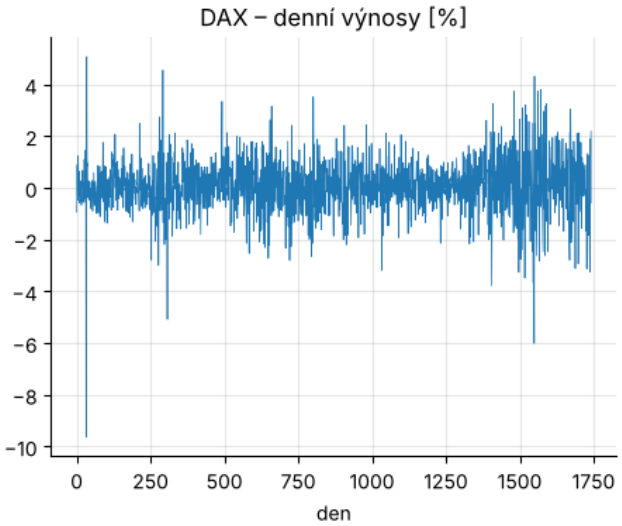
Sklarova věta dává návod, jak sdružené rozdělení stavět **po částech**:

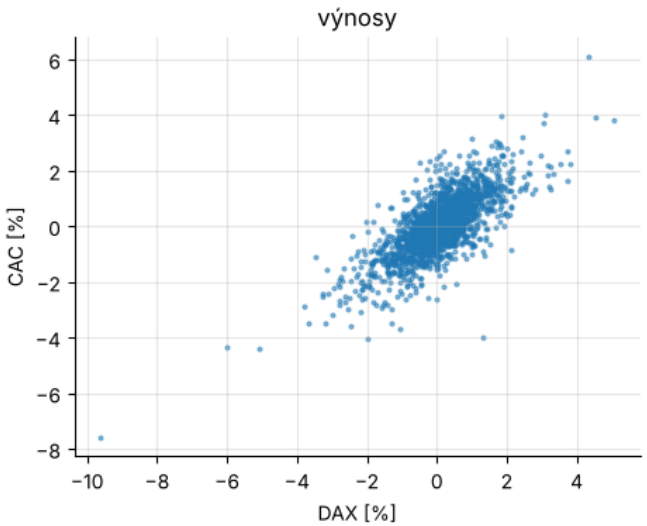
1. **Příprava a popis dat** – čištění, bodové grafy, r, r_S, τ, pseudo-pozorování $\hat{u}_i = R_i/(n+1)$, $\hat{v}_i = Q_i/(n+1)$.
2. **Marginální rozdělení** – každou proměnnou zvlášť (parametricky, nebo empirickou distribuční funkcí).
3. **Výběr a odhad kopule** – z pseudo-pozorování, tedy nezávisle na marginálách; maximum pseudo-věrohodnosti $\sum_i \ln c(\hat{u}_i, \hat{v}_i; \theta)$, porovnání rodin pomocí AIC.
4. **Kontrola modelu** – souhlasí závislost v chvostech, K-funkce, simulovaná data vs. skutečná?
5. **Použití** – simulace $(X, Y) = \left(F_X^{-1}(U), F_Y^{-1}(V)\right)$, $(U, V) \sim C$: rizika součtu, pravděpodobnosti současných extrémů, scénáře.

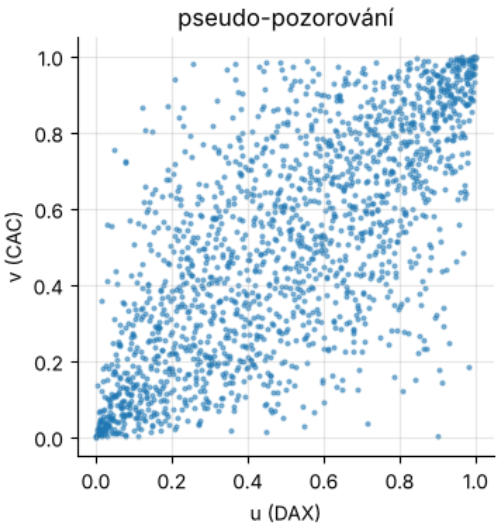
Příklad: data `EuStockMarkets` (R, *datasets*) – denní hodnoty indexů DAX, SMI, CAC, FTSE v letech 1991–1998. Modelujeme denní log-výnosy $r_t = 100 \ln(P_t/P_{t-1})$ [%] indexů **DAX** a **CAC**.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Krok 1: data – denní výnosy DAX a CAC







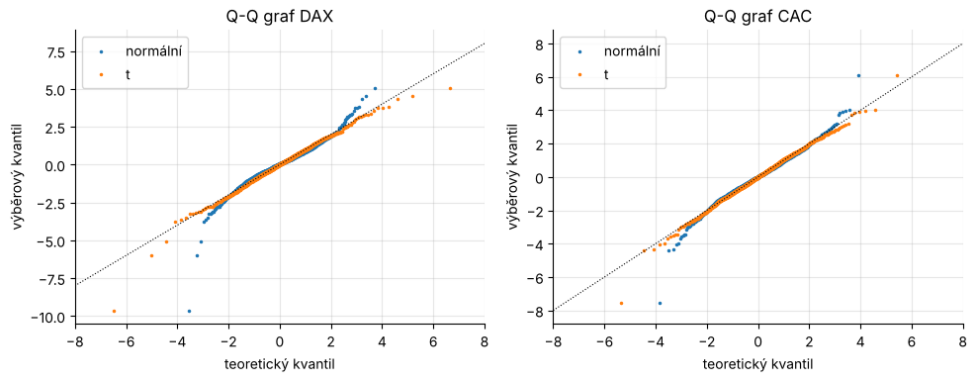
- Čištění: řada je doplněná o svátky (hodnota zkopírovaná z předchozího dne) $\Rightarrow$ nulové výnosy, v pseudo-pozorováních vodorovné a svislé řady shod. Vyřazeno 117 dní, zbývá $n = 1742$.
- Těžké chvosty: špičatost (excess) DAX 6,3, CAC 2,4; nejhorší den DAX $-9{,}6\,\%$ (19. 8. 1991, puč v Moskvě).
- $r = 0{,}747$, $r_S = 0{,}711$, $\tau = 0{,}525$. Pseudo-pozorování jsou zhuštěná v **obou rozích** – velké propady i růsty přicházejí současně.

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Krok 2: marginální rozdělení

Pro každý index porovnáme normální a Studentovo rozdělení s polohou a měřítkem, $t_\nu(\mu, \sigma)$:

	DAX	CAC
$\hat{\nu}$ (t)	4,7	7,9
AIC normální	5135	5371
AIC t	**4947**	**5305**
KS p normální	0,0002	0,12
KS p t	0,998	0,965



- t-rozdělení výrazně lepší, normální nezachytí extrémní dny.
- Kopuli odhadujeme z pořadí – volba marginál ji **neovlivní**. Marginály potřebujeme až pro simulaci.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

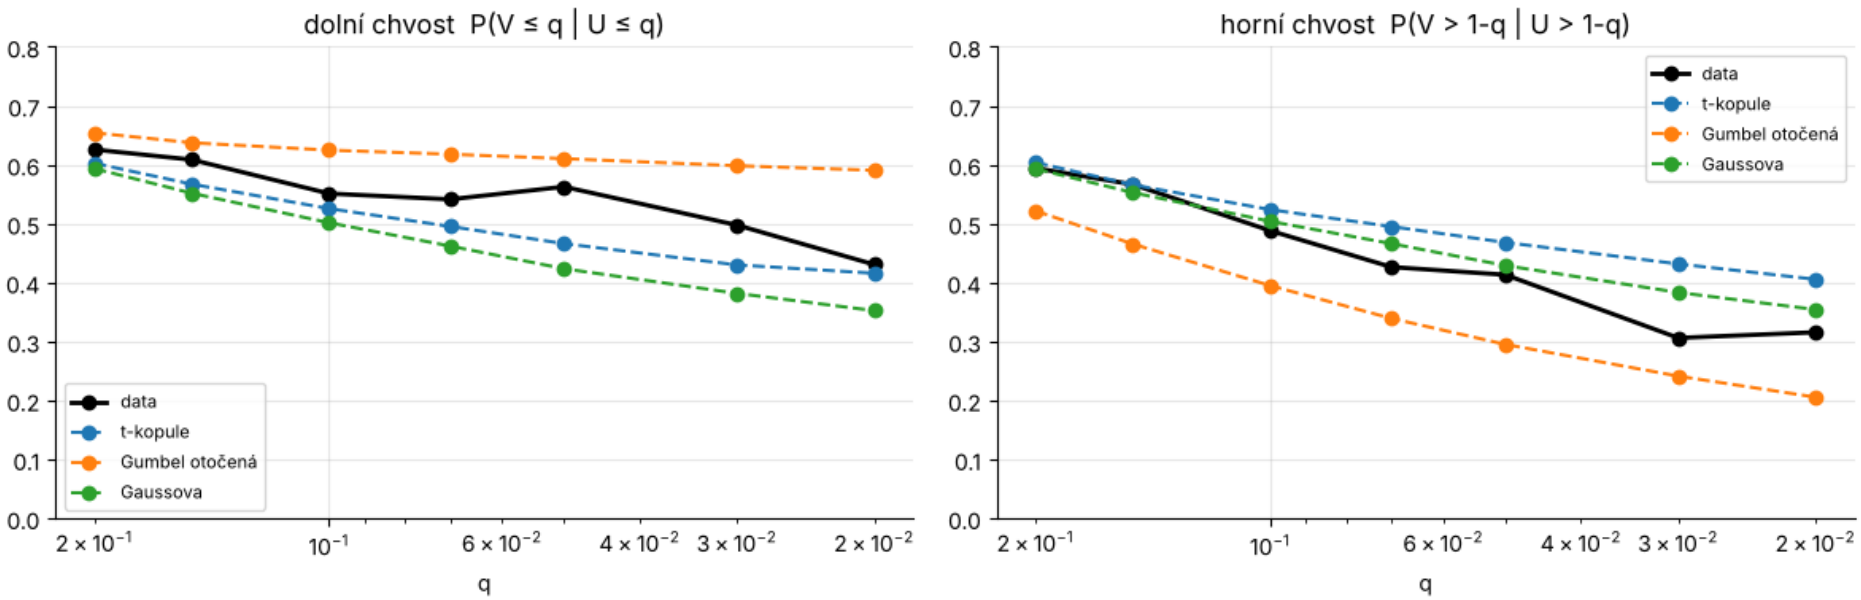
Krok 3: výběr a odhad kopule

Metoda pseudo-věrohodnosti, $n = 1742$; „otočená“ (survival) kopule $\bar{C}(u, v) = u + v - 1 + C(1 - u, 1 - v)$ je kopule vektoru $(1 - U, 1 - V)$ – Gumbelova kopule tak dostane závislost v **dolním** chvostu.

kopule	parametr	log-věrohodnost	AIC
t	$\hat{\rho} = 0{,}738$, $\hat{\nu} = 7{,}7$	696,6	$-$**1389**,**3**
Gumbel otočená	$\hat{\theta} = 2{,}05$	676,7	$-1351{,}5$
Gaussova	$\hat{\rho} = 0{,}737$	676,7	$-1351{,}3$
Gumbel	$\hat{\theta} = 1{,}98$	619,3	$-1236{,}7$
Frank	$\hat{\theta} = 6{,}21$	615,9	$-1229{,}8$
Clayton	$\hat{\theta} = 1{,}58$	582,4	$-1162{,}7$

- Nejlepší je ***t*-kopule**: symetrická závislost s těžkými chvosty, $\lambda_L = \lambda_U = 0{,}28$.
- Kopule jen s horním chvostem (Gumbel), bez chvostů (Frank) nebo jen se slabou závislostí mimo dolní chvost (Clayton) jsou výrazně horší.
- Kontrola: odhad z $\hat{\tau}$ ($\hat{\rho} = \sin(\pi\hat{\tau}/2) = 0{,}735$) je téměř stejný.

Krok 4: kontrola – závislost v chvostech



- Empirický odhad $\hat{\lambda}_L(q) = \#\{\hat{u}_i \le q,\ \hat{v}_i \le q\}/(nq)$, modely simulací z odhadnutých kopulí.
- Data: současný propad má podmíněnou pravděpodobnost kolem 0,5, současný růst 0,3–0,5 (mírná asymetrie).
- t-kopule je dobrý kompromis; Gaussova podhodnocuje hlavně **dolní** chvost – společné propady; otočená Gumbelova podhodnocuje horní chvost.
- Pro malá q jsou empirické hodnoty nejisté ($q = 0{,}02$ odpovídá asi 35 dnům).

FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

Krok 5: použití – Python (`statsmodels`)

`https://www.statsmodels.org/stable/distributions.html`

```
import numpy as np, pandas as pd
from scipy import stats
from statsmodels.distributions.copula.api import StudentTCopula, CopulaDis
eu = pd.read_csv('EuStockMarkets.csv')
R = 100 * np.log(eu).diff().dropna()
R = R[(R.DAX != 0) & (R.CAC != 0)]              # bez svátků
x, y = R.DAX.to_numpy(), R.CAC.to_numpy()
tau = stats.kendalltau(x, y)[0]
cop = StudentTCopula(corr=np.sin(np.pi * tau / 2), df=8)
marg = [stats.t(*stats.t.fit(x)), stats.t(*stats.t.fit(y))]
model = CopulaDistribution(cop, marg)           # Sklar: kopule + marginály
S = model.rvs(1_000_000, random_state=1)
P = S.mean(axis=1)                              # portfolio 50 % + 50 %
VaR = -np.quantile(P, 0.01)
ES = -P[P <= -VaR].mean()
print(f"tau = {tau:.3f}, VaR99 = {VaR:.2f} %, ES99 = {ES:.2f} %")
```

Výstup: `tau = 0.525, VaR99 = 2.54 %, ES99 = 3.29 %`

Modul obsahuje i `GaussianCopula`, `ClaytonCopula`, `GumbelCopula`, `FrankCopula` (metody `logpdf`, `cdf`, `rvs`, `fit_corr_param` – odhad z τ). Úplný postup včetně porovnání kopulí: notebook, oddíl 10.

Krok 5: použití – riziko portfolia a současné propady

Portfolio 50 % DAX + 50 % CAC, 10^6 simulovaných dní. VaR_{99} – denní ztráta překročená v 1 % dní, ES_{99} – průměrná ztráta v těchto dnech. Současný propad = oba indexy pod svým 1% kvantilem (počet dní za 10 let po 250 obchodních dnech).

model	VaR_{99} [%]	ES_{99} [%]	současné propady / 10 let
historie (data)	2,57	3,47	11,5
t-marginály + *t*-kopule	2,53	3,27	8,7
t-marginály + Gumbel otočená	2,63	3,43	13,7
t-marginály + Gaussova kopule	2,51	3,22	6,7
t-marginály + nezávislost	1,84	2,30	0,2
dvourozměrné normální	2,33	2,67	3,0

- Nezávislost hrubě podceňuje riziko: současný propad jednou za 50 let místo zhruba 11× za 10 let.
- Normální rozdělení podceňuje ES (tenké chvosty marginál i kopule).
- Gaussova kopule dává podobné VaR, ale počet současných propadů podhodnocuje – chybí závislost v chvostech.
- Výhoda modelu proti samotné historii: lze odhadovat i vzácnější události (např. 99,9% kvantil), kterých je v datech jen pár.

Kopule v praxi – na co si dát pozor

- **Časová závislost:** finanční výnosy nejsou nezávislé (shlukování volatility). Správně se nejprve modeluje každá řada zvlášť (např. GARCH) a kopule se odhaduje z **reziduí** – *copula-GARCH*.
- **Shody v datech** (zaokrouhlení, doplněné hodnoty) narušují pseudo-pozorování – data je třeba vyčistit, případně shody náhodně rozbít.
- **Výběr rodiny:** rozdíly AIC mohou být malé; rozhodovat i podle grafů chvostů a věcné úvahy (očekáváme společné propady? růsty?). Formální testy dobré shody: např. Cramérův–von Misesův test empirické kopule s parametrickým bootstrapem.
- **Nejistota odhadu:** intervaly spolehlivosti parametrů a odvozených rizik bootstrapem.
- **Více proměnných:** eliptické kopule s korelační maticí (Gaussova, t), Archimédovy kopule jsou pro $d > 2$ příliš omezující $\Rightarrow$ **vine kopule** (párové kopule skládané do stromů; balík `pyvinecopulib`).
- **Typická použití:** pojišťovnictví (souvislost škod a nákladů na jejich

Shrnutí

- Kopule je distribuční funkce vektoru s rovnoměrnými marginály $R(0,1)$; popisuje jen strukturu závislosti.
- Sklarova věta: $F(x_1,\dots,x_d) = C\big(F_1(x_1),\dots,F_d(x_d)\big)$, pro spojité marginály je C jednoznačná.
- Fréchetovy–Hoeffdingovy meze $W \le C \le M$; W je kopule jen pro $d = 2$.
- Eliptické kopule (Gaussova, t) a Archimédovy kopule (Clayton, Gumbel, Frank) – liší se závislostí v chvostech.
- τ a ρ_S závisejí jen na kopuli, Pearsonův ρ i na marginálech; parametr kopule lze kalibrovat z $\hat{\tau}$.
- Generování: podmíněná metoda, speciální algoritmy (Gaussova, t, Marshall–Olkin), pak $X_i = F_i^{-1}(U_i)$.
- Praxe: marginály a kopule odhadujeme zvlášť (pseudo-pozorování, AIC), kontrolujeme chvosty; na výnosech DAX a CAC Gaussova kopule a nezávislost podceňují riziko společných propadů.

FAKULTA APLIKOVANÝCH VĚD
ZÁPADOČESKÉ UNIVERZITY
V PLZNI

Literatura a odkazy

- Nelsen, R. B.: *An Introduction to Copulas*. 2nd ed., Springer, 2006.
- Joe, H.: *Dependence Modeling with Copulas*. CRC Press, 2014.
- McNeil, A. J., Frey, R., Embrechts, P.: *Quantitative Risk Management*. Revised ed., Princeton University Press, 2015.
- Sklar, A.: Fonctions de répartition à *n* dimensions et leurs marges. *Publ. Inst. Statist. Univ. Paris* 8 (1959), 229–231.
- Embrechts, P., McNeil, A. J., Straumann, D.: Correlation and dependence in risk management: properties and pitfalls. In: *Risk Management: Value at Risk and Beyond*, Cambridge University Press, 2002, 176–223.
- Genest, C., Favre, A.-C.: Everything you always wanted to know about copula modeling but were afraid to ask. *Journal of Hydrologic Engineering* 12 (2007), 347–368.
- `https://docs.scipy.org/doc/scipy/reference/stats.html`, `https://www.statsmodels.org/stable/distributions.html`