

Přednáška 10: Regresní modely

KMA/MSM Blanka Šedivá

verze 2026/2027

14. září 2026

Obsah

- 1 Regresní modely
 - Lineární regresní model
 - Statistické odhady koeficientů
- 2 Multikolinearita
- 3 Detekce multikolinearity
 - Korelační koeficienty
 - Metoda pomocných regresí
 - Metoda založená na $\det(\mathbf{X}^T \mathbf{X})$
 - Leamerova metoda
 - Variance Inflation Factor (VIF)
 - Farrar-Glauberův postup
 - Metody využívající vlastní čísla matice $\mathbf{X}^T \mathbf{X}$
- 4 Řešení multikolinearity

Úvod do regresní analýzy

Definice:

- Regrese je statistická metoda sloužící k modelování **funkční závislosti** mezi **závislou proměnnou** Y a jednou či více **nezávislými proměnnými** $X_1, X_2, \dots, X_k$.
- Cílem je **kvantifikace vlivu** jednotlivých regresorů na vysvětlovanou proměnnou a **predikce** hodnot Y .

Rozdíl oproti korelaci:

- Korelace měří **sílu a směr lineární závislosti** mezi dvěma veličinami (symetrický vztah).
- Regrese předpokládá **asymetrický vztah** – jedna veličina je *vysvětlovaná*, ostatní jsou *vysvětlující*.

Typy regresních modelů a metody odhadů

Typy regresních modelů:

- Jednoduchá lineární regrese ($k = 1$)
- Vícenásobná lineární regrese ($k > 1$)
- Nelineární regrese, generalizované lineární modely (GLM)

Metody odhadu koeficientů:

- **Metoda nejmenších čtverců (OLS)** – klasický přístup, minimalizace $\sum (y_i - \hat{y}_i)^2$
- **Metoda maximální věrohodnosti (MLE)** – využívá pravděpodobnostní model reziduí
- **Regularizační metody** – Ridge regrese (L2 penalizace), Lasso regrese (L1 penalizace)
- **Bayesovské odhady** – zahrnutí apriorních informací o parametrech

Lineární regresní model

Budeme uvažovat následující maticový zápis

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} x_{1,1} & x_{1,2} & \dots & x_{1,k} \\ x_{2,1} & x_{2,2} & \dots & x_{2,k} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \dots & x_{n,k} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

kde

- $\mathbf{Y} = [Y_1, Y_2, \dots, Y_n]^T$ je vektor hodnot vysvětlované proměnné;
- $\mathbf{X} = [x_{i,j}]_{i=1,\dots,n; j=1,\dots,k}$ je matice typu $n \times p$ hodnot vysvětlující proměnné;
- $\boldsymbol{\beta} = [\beta_1, \beta_2, \dots, \beta_k]^T$ je vektor hledaných k neznámých parametrů;
- $\boldsymbol{\varepsilon} = [\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n]^T$ je vektor náhodné složky.

Lineární regresní model

- Cílem lineární regrese je najít regresní funkci $\mu(\mathbf{x}) = \mathbb{E}(\mathbf{y}|\mathbf{X} = \mathbf{x})$. Pro stanovení odhadů regresní funkce je třeba zavést předpoklady kladené na lineární regresní model.
- Odhady parametrů lineárního regresního modelu získáváme zejména metodou nejmenších čtverců.
- $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ a přidáme předpoklady pro metodu nejmenších čtverců zapsané též v maticovém tvaru:
 - (P1) $\mathbb{E}(\varepsilon) = \mathbf{0}$;
 - (P2) $\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}_n$;
 - (P3) silnější podmínka zahrnující předcházející $\varepsilon \sim N_n(0; \sigma^2 \mathbf{I}_n)$.
 - (P4) $\mathbf{X}$ je nestochastická matice, která má plnou hodnost.
- Pokud jsou splněny (P1)-(P2) mluvíme o lineárním modelu, pokud je splněn předpoklad (P3) nazýváme model normální lineární regresní model.

Možnosti odhadu regresního modelu v Pythonu

1. **numpy** – přímý výpočet OLS:

```
beta_hat = np.linalg.inv(X.T @ X) @ X.T @ y
```

2. **statsmodels** – detailní statistika:

```
import statsmodels.api as sm  
model = sm.OLS(y, sm.add_constant(X)).fit()
```

3. **scikit-learn** – predikce a ML workflow:

```
from sklearn.linear_model import LinearRegression  
reg = LinearRegression().fit(X, y)
```

4. **pingouin** – rychlá statistická regrese:

```
import pingouin as pg  
df = pd.DataFrame({'X': X.flatten(), 'Y': y})  
pg.linear_regression(df[['X']], df['Y'])
```

Ukázka: Lineární regrese v Pythonu

Použití knihovny `statsmodels`:

```
import numpy as np
import statsmodels.api as sm

# Simulace dat
np.random.seed(42)
X = np.random.rand(100, 1) * 10
y = 3 + 2 * X.flatten() + np.random.randn(100) * 2

# Přidání konstanty (intercept)
X_const = sm.add_constant(X)

# Odhad modelu metodou OLS
model = sm.OLS(y, X_const)
results = model.fit()

print(results.summary())
```

Statistické vlastnosti odhadů lineárního regresního modelu

Nechť je dán lineární regresní model $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, kde náhodný vektor (vektor chyb) $\boldsymbol{\varepsilon}$ splňuje podmínky $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$, $\mathbf{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$ a hod $(\mathbf{X}) = k$.

- 1 Pak odhad parametrů $\beta_1, \beta_2, \dots, \beta_p$ metodou nejmenších čtverců minimalizující výraz $Q(\boldsymbol{\beta}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$ má tvar
$$\mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$
- 2 Pro odhad $\mathbf{b}$ platí $\mathbb{E}(\mathbf{b}) = \boldsymbol{\beta}$ a $\mathbf{Var}(\mathbf{b}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$.
- 3 Výraz $s^2 = \frac{R}{n-k}$ je nestranným odhadem σ^2 , kde $R = (\mathbf{Y} - \mathbf{X}\mathbf{b})^T (\mathbf{Y} - \mathbf{X}\mathbf{b})$ je reziduální součet čtverců.

Statistické vlastnosti odhadů normálního lineárního regresního modelu

Nechť je dán lineární regresní model $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, kde náhodný vektor (vektor chyb) ε splňuje podmínku $\varepsilon \sim N_n(0; \sigma^2 \mathbf{I}_n)$. Pak platí

- ❶ $\mathbf{b} \sim N_n\left(\mathbf{X}\beta; \sigma^2 \left(\mathbf{X}^T \mathbf{X}\right)^{-1}\right);$
- ❷ $\frac{R}{\sigma^2} \sim \chi^2$ rozdělení se stupni volnosti $\nu = n - k;$
- ❸ $\mathbf{b}$ a R jsou nezávislé.

Testy hypotéz a intervalové odhady

Nechť je dán normální lineární regresní model $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, kde náhodný vektor (vektor chyb) ε splňuje podmínku $\varepsilon \sim N_n(0; \sigma^2 \mathbf{I}_n)$ a necht $\mathbf{a} = (a_1, a_2, \dots, a_p)^T \neq \mathbf{0}$ je libovolný daný vektor. Pak platí

$$(i) \quad \mathbb{E}(\mathbf{a}^T \mathbf{b}) = \mathbf{a}^T \beta;$$

$$(ii) \quad \text{Var}(\mathbf{a}^T \mathbf{b}) = s^2 \mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a};$$

$$(iii) \quad T = \frac{\mathbf{a}^T \mathbf{b} - \mathbf{a}^T \beta}{s \sqrt{\mathbf{a}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{a}}} \sim \text{t-rozdělení se stupni volnosti } \nu = n - k.$$

Na základě uvedených vět lze ukázat, že pro normální lineární regresní model je odhad metodou nejmenších čtverců **BLUES -Best Linear Unbiased Estimation** (nejlepší lineární nestranný odhad parametrů β .)

Hodnocení modelu jako celku - koeficient determinace

TSS = $\sum_i (y_i - \bar{y})^2$ (celkový součet čtverců - total sum of squares)
celkový rozptyl $s_T^2 = \frac{TSS}{n-1}$ (total variance, total mean square)

ESS = $\sum_i (\hat{y}_i - \bar{y})^2$ (vysvětlený součet čtverců - explained sum of squares)
regresní rozptyl $s_E^2 = \frac{ESS}{k}$ (regression mean square)

RSE = $\sum_i (y_i - \hat{y}_i)^2$ (reziduální součet čtverců odchylek - residual sum of squares errors)
reziduální rozptyl $s_R^2 = \frac{RSE}{n-k-1}$ (residual mean square)
Pro lineární regresní model platí $TSS = ESS + RSE$.

Koeficient determinace = $R^2 = 1 - \frac{RSE}{TSS}$

Adjusted Koeficient determinace = $R_a^2 = 1 - \frac{RSE/(n-k-1)}{TSS/(n-1)}$.

F test a významnosti modelu $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$ a
 H_1 : alespoň jeden koeficient je nenulový

Výstup vícenásobné lineární regrese (Python)

Shrnutí modelu (statsmodels OLS):

R-squared: 0.834 Adj. R-squared: 0.829
 F-statistic: 160.8 Prob(F-statistic): 2.63e-37

coef	std err	t	P> t	[0.025	0.975]	
const	3.7999	0.983	3.864	0.000	1.848	5.752
X1	1.6248	0.100	16.278	0.000	1.427	1.823
X2	2.1251	0.205	10.383	0.000	1.719	2.531
X3	-0.4506	0.051	-8.815	0.000	-0.552	-0.349

Interpretace:

- $R^2 = 0.834$ – model vysvětluje 83% variability Y .
- Všechny regresory jsou statisticky významné ($p < 0.001$).
- Intervaly spolehlivosti potvrzují stabilitu odhadů.

Multikolinearita

- Podmínka (P4) zachycuje pro regresní modely typický požadavek, že vysvětlující proměnné (vyjádřené sloupcemi matice $\mathbf{X}$ jsou nezávislé.
- Protože předpokládáme, že počet měření, která máme k dispozici (n) je větší než počet vysvětlujících proměnných, které odhadujeme (k), tedy $k < n$, je hodnota matice $\mathbf{X}$ rovna k . Tento předpoklad mimo jiné zaručuje regularitu matice $\mathbf{X}^T \mathbf{X}$ a tím existenci inverzní matice k této matici.
- Při klasickém lineárním regresním modelu předpokládáme, že regresní matice $\mathbf{X}$ má lineárně nezávislé sloupce.
- U reálných dat je však často velmi obtížné o lineární závislost či nezávislosti rozhodnout.
- Vysoký stupeň závislosti mezi sloupci matice $\mathbf{X}$ nazýváme **multikolinearita**.

Příčiny a důsledky multikolinearity

- Malé změny v regresní matici $\mathbf{X}$ mají za následek velké změny v odhadech parametrů $\mathbf{b}$;
- Odhadnuté koeficienty $\mathbf{b}$ mají vysoké hodnoty směrodatné chyby S_{b_j} , $j = 1, 2, \dots, k$ (směrodatná odchylka odhadu příslušného parametru β_j je odmocnina z j -tého prvku na diagonále matice $\mathbf{Var} \mathbf{b}$) a s tím spojené nízké hodnoty testů statistické významnosti těchto koeficientů, ale koeficient determinace R^2 charakterizující model jako celek je relativně vysoký a testy významnosti modelu jako celku jsou statisticky signifikantní;
- Koeficienty $\mathbf{b}$ mají "chybné" znaménko nebo neočekávané hodnoty, které neodpovídají původní interpretaci modelu.
- Známkou multikolinearity je i skutečnost, že zvětšující se rozsah výběru nepřispěje k odstranění výše uvedených problémů.

- Střední hodnota čtverce délky odhadu vektoru $\mathbb{E}y$ závisí pouze na hodnotě matice $\mathbf{X}$.

$$\mathbb{E} \|\hat{\mathbf{y}}\|^2 = \|\mathbf{X}\boldsymbol{\beta}\|^2 + \sigma^2 \cdot \text{hod}(\mathbf{X})$$

- Naproti tomu střední hodnota čtverce délky odhadu $\mathbb{E}b$ závisí významným způsobem na vlastních číslech matice $(\mathbf{X}^T \mathbf{X})$.

$$\mathbb{E} \|\mathbf{b}\|^2 = \|\boldsymbol{\beta}\|^2 + \sigma^2 \cdot \text{tr}(\mathbf{X}^T \mathbf{X})^{-1} = \|\boldsymbol{\beta}\|^2 + \sigma^2 \cdot \sum_{j=1}^p \frac{1}{\lambda_j}$$

Možnosti detekce multikolinearity

Neexistují žádné obecně platné testy jednoznačně identifikující multikolinearitu. Obvykle je vhodné využít více přístupů.

- A. Korelační koeficienty
- B. Metoda pomocných regresí
- C. Metoda založená na $\det(\mathbf{X}^T \mathbf{X})$
- D. Leamerova metoda
- E. Variance Inflation Factor (VIF)
- F. Farrar-Glauberův postup
- G. Metody využívající čísla podmíněnosti matice $\mathbf{X}^T \mathbf{X}$

A. Korelační koeficienty

Nejjednodušší přístup k identifikaci multikolinearity je na základě párových korelačních koeficientů mezi sloupci matice $\mathbf{X}$. Spočteme

$$r_{ij} = \text{cor}(\mathbf{X}_i, \mathbf{X}_j), i, j = 1, 2, \dots, k$$

O multikolinearitě potom rozhodujeme například podle některého z následujících pravidel:

- a) pokud existuje $|r_{ij}| > 0.75$ (některá literatura považuje za kritickou hranici až hodnoty 0.8 nebo 0.9);
- b) pokud existuje r_{ij} tak, že $|r_{ij}| \geq R^2$, kde R^2 je koeficient determinace lineárního regresního modelu $\mathbf{y} = \mathbf{X}\beta + \varepsilon_i$;
- c) pokud odhadnutý koeficient korelace r_{ij} je statisticky významně různý od nulové hodnoty.

Tato metoda však není příliš spolehlivá v případech, kdy závislost sloupců je generována třemi a více sloupci.

Ukázka v Pythonu: Korelační koeficienty

Výpočet korelační matice mezi regresory:

```
import pandas as pd

# DataFrame s regresory
df = pd.DataFrame({
    'X1': [...], 'X2': [...], 'X3': [...] # vaše data
})

# Korelační matice
corr_matrix = df.corr()
print(corr_matrix)

# Vizualizace (volitelně)
import seaborn as sns
import matplotlib.pyplot as plt
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title('Korelační matice regresorů')
plt.show()
```

B. Metoda pomocných regresí

Uvažujme pomocné lineární regresní modely, kde závislou proměnnou jsou postupně $X_1, X_2, \dots, X_k$ matice $\mathbf{X}$ a nezávislými proměnnými jsou zbylé sloupce. Přesněji uvažujme modely

$$X_j = X_1\alpha_1 + \dots + X_{j-1}\alpha_{j-1} + X_{j+1}\alpha_{j+1} + \dots + X_k\alpha_k + \eta.$$

Metodou nejmenších čtverců odhadneme parametry $\hat{\mathbf{a}}$ a spočteme koeficient determinace R_j^2 příslušného modelu.

Multikolinearitu považujeme za vysokou, pokud

- a) existuje R_j^2 , $j = 1, 2, \dots, k$, tak, že $R_j^2 > R^2$.
- b) případně můžeme testovat významnost modelu pomocných regresí pomocí testovací statistiky

$$F_j = \frac{R_j^2}{1-R_j^2} \cdot \frac{n-k+1}{k-2}$$

kteřá má při platnosti nulové hypotézy (nulovosti parametrů pomocné regrese) F_{ν_1, ν_2} a pro multikolinearitu svědčí hodnoty větší než kritická hodnota tohoto testu.

Ukázka v Pythonu: Metoda pomocných regresí

Cíl: Pro každý regresor X_j odhadnout pomocný model $X_j \sim X_{-j}$ a získat R_j^2 a F-test.

```
results = []
X_cols = df.columns.tolist()
for j, col in enumerate(X_cols):
    y_aux = df[col].values                                # X_j jako zá
    X_aux = df.drop(columns=[col]).values                 # ostatní reg
    X_aux = sm.add_constant(X_aux)                       # intercept
    model = sm.OLS(y_aux, X_aux).fit()
    results.append({
        'regresor': col,
        'R2_j': model.rsquared,
        'F_stat': model.fvalue,
        'p_F': model.f_pvalue,
        'adj_R2_j': model.rsquared_adj
    })
aux_df = pd.DataFrame(results).set_index('regresor')
```

Interpretace:

- Velké R_j^2 (např. > 0.8) $\Rightarrow X_j$ je dobře vysvětlitelný ostatními, indikace multikolinearity.
- Významný F-test ($p_F \ll 0.05$) $\Rightarrow$ pomocný model je statisticky významný.
- Porovnejte R_j^2 s R^2 původního modelu; pokud $R_j^2 > R^2$, multikolinearita je „vysoká“ (viz teorie).

C. Metoda založená na $\det(\mathbf{X}^T \mathbf{X})$

Princip: Pokud jsou sloupce matice $\mathbf{X}$ lineárně závislé, platí:

$$\det(\mathbf{X}^T \mathbf{X}) = 0.$$

Kritérium: Vysokou multikolinearitu indikují stavy, kdy:

$$|\det(\mathbf{X}^T \mathbf{X})| < \varepsilon,$$

kde ε je zvolená malá kladná konstanta.

Charakteristika:

- Metoda odhalí závislost více sloupců současně.
- Neposkytuje informaci o konkrétním charakteru závislosti.
- Hodnota $\det(\mathbf{X}^T \mathbf{X})$ je *silně závislá na měřítku* sloupců $\mathbf{X}$; proto je vhodná standardizace.
- Pro numerickou stabilitu preferujte slogdet (log-determinant); prahujte na $\log |\det|$ nebo na $|\det|$ po převodu.
- Kritérium identifikuje *existenci* lineární závislosti, nikoli její charakter; doplňte např. VIF/condition number.

Python: výpočet $\det(\mathbf{X}^T \mathbf{X})$

```
X = np.column_stack([x1, x2, x3, x4])

Xs = zscore_cols(X) # doporučená standardizace
# Výpočet  $(\mathbf{X}^T \mathbf{X})$  a determinantu
XtX = Xs.T @ Xs
# Klasický determinant
det_xtx = np.linalg.det(XtX)
# Klasický determinant (pozor na škálování a přetečení)
det_xtx = np.linalg.det(XtX)
# Numericky stabilnější varianta: log-determinant
sign, logdet = np.linalg.slogdet(XtX) # sign in{-1,0,1}, 1
abs_det = float(np.exp(logdet)) if sign != 0 else 0.0
# Prahování pro multikolinearitu (zvolte malé epsilon)
epsilon = 1e-6
if abs_det < epsilon or sign == 0:
    print("Indikace multikolinearity:  $|\det(\mathbf{X}^T \mathbf{X})| < \epsilon$ ")
else:
    print("Bez zjevné multikolinearity.")
```

D. Leamerova metoda

Definice: Míra efektu multikolinearity pro j -tou proměnnou:

$$c_j = \left(\frac{\left(\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 \right)^{-1}}{((\mathbf{X}^T \mathbf{X})^{-1})_{jj}} \right)^{1/2}, \quad j = 1, 2, \dots, k.$$

Interpretace:

- Pokud jsou X_j nekorelovány s ostatními, pak $c_j = 1$.
- V případě závislosti platí:

$$c_j = \sqrt{1 - R_j^2},$$

kde R_j^2 je koeficient determinace pomocné regrese.

Python: výpočet Leamerova c_j

```
import numpy as np
# X ... matice regresorů (n x k)
def leamer_cj(X):
    n, k = X.shape
    XtX_inv = np.linalg.inv(X.T @ X)
    cj_values = []
    for j in range(k):
        sum_sq = np.sum((X[:, j] - X[:, j].mean())**2)
        cj = np.sqrt((1 / sum_sq) / XtX_inv[j, j])
        cj_values.append(cj)
    return np.array(cj_values)
```

Interpretace: Hodnoty $c_j < 1$ indikují závislost proměnné na ostatních.

E. Variance Inflation Factor (VIF)

Definice: Metoda vychází z pomocných regresí a koeficientů R_j^2 . Tolerance: $(1 - R_j^2)$, její převrácená hodnota je:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad j = 1, 2, \dots, k.$$

Interpretace:

- $\text{VIF} = 1$: žádná multikolinearita.
- $\text{VIF} > 5$: potenciální problém.
- $\text{VIF} > 10$: vážná multikolinearita.

Pozn.: VIF roste s korelací mezi regresory; doporučuje se kontrolovat max VIF a průměrný VIF.

Python: výpočet VIF

```
import pandas as pd
import numpy as np
from statsmodels.stats.outliers_influence import
    variance_inflation_factor
import statsmodels.api as sm
# Simulace dat
df = pd.DataFrame({'X1': X1, 'X2': X2, 'X3': X3})
# Přidání konstanty pro intercept
X = sm.add_constant(df)
# Výpočet VIF pro každý sloupec kromě interceptu
vif_values = [variance_inflation_factor(X.values, i)
               for i in range(1, X.shape[1])]
for col, vif in zip(df.columns, vif_values):
    print(f"{col}: VIF = {vif:.2f}")
```

Interpretace: Hodnoty $VIF > 10$ indikují vážnou multikolinearitu.

F. Farrar-Glauberův postup

Princip: Metoda vychází z testování ortogonalit sloupců matice $\mathbf{X}$ pomocí χ^2 a F-testů.

Postup:

1 **Test existence multikolinearity:**

$$T = - \left(n - 1 - \frac{2k + 5}{6} \right) \ln \det(\mathbf{R}),$$

kde $\mathbf{R}$ je korelační matice regresorů. $T \sim \chi^2_{\nu}$, $\nu = \frac{k(k-1)}{2}$.

2 **Identifikace nejvíce závislých sloupců:** F-testy pro pomocné regrese.

Interpretace: Pokud $T > \chi^2_{1-\alpha, \nu}$, zamítáme hypotézu ortogonalit $\Rightarrow$ multikolinearita přítomna.

Python: Farrar-Glauberův test

```
import numpy as np
import pandas as pd

# Korelační matice
R = df.corr().values
n, k = df.shape

# Výpočet testovací statistiky T
det_R = np.linalg.det(R)
T = -(n - 1 - (2*k + 5)/6) * np.log(det_R)

# Stupně volnosti
nu = k*(k-1)/2
print(f"Chi-square test statistic T = {T:.3f}, df = {nu}")
# Kritická hodnota pro alfa=0.05
lze_získat_z_scipy_stats_chi2_ppf
```

Interpretace: Velké T (nad kritickou hodnotu χ^2) $\Rightarrow$ multikolinearita přítomna.

G. Metody využívající vlastní čísla matice $\mathbf{X}^T \mathbf{X}$

Princip: Nízké hodnoty vlastních čísel matice $\mathbf{X}^T \mathbf{X}$ indikují multikolinearitu.

Postup:

- Označme $\lambda_1, \lambda_2, \dots, \lambda_k$ vlastní čísla matice $\mathbf{X}^T \mathbf{X}$.
- Matice $\mathbf{X}^T \mathbf{X}$ je symetrická a pozitivně definitní $\Rightarrow$ všechna $\lambda_j > 0$.
- Uspořádejme:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k > 0.$$

Interpretace: Velmi malé $\lambda_k \Rightarrow$ silná multikolinearita.

Číslo podmíněnosti

Definice:

$$\kappa = \frac{\lambda_1}{\lambda_k}, \quad \kappa^* = \sqrt{\frac{\lambda_1}{\lambda_k}}.$$

Použití:

- Index nestability odhadu koeficientů OLS.
- Vysoké hodnoty $\kappa^* > 10$ signalizují závažnou multikolinearitu.

Nevýhoda: Hodnoty závisí na měřítku sloupců $\mathbf{X} \Rightarrow$ doporučena standardizace.

Python: výpočet čísla podmíněnosti

```
import numpy as np

# Standardizace sloupců (doporučeno)
def zscore_cols(X):
    mu = X.mean(axis=0, keepdims=True)
    sd = X.std(axis=0, ddof=1, keepdims=True)
    return (X - mu) / sd

Xs = zscore_cols(X)
XtX = Xs.T @ Xs
lambda_vals = np.linalg.eigvalsh(XtX)
lambda_vals.sort()
kappa = lambda_vals[-1] / lambda_vals[0]
kappa_star = np.sqrt(kappa)
```

Interpretace: Hodnota $\kappa^* > 10 \Rightarrow$ závažná multikolinearita.

Farrar-Glauberovy testy multikolinearity

Postup:

- 1 Testujeme, zda je multikolinearita v datech přítomna.
- 2 Identifikujeme sloupce matice $\mathbf{X}$, které jsou „nejvíce“ závislé.
- 3 Odhalujeme typ (charakter) závislosti.

Poznámka: Vzhledem k závislosti na měřítku je vhodné před testováním data **standardizovat**.

Farrar-Glauberovy testy: statistiky

1. χ^2 -test existence multikolinearity:

$$T = -\left(n - 1 - \frac{1}{6}(2k + 5)\right) \cdot \ln(\det(\mathbf{R})),$$

kde $\mathbf{R}$ je korelační matice regresorů. $T \sim \chi^2_\nu$, $\nu = \frac{k(k-1)}{2}$.

2. F-test pro jednotlivé sloupce:

$$F_i = \frac{R_j^2}{1 - R_j^2} \cdot \frac{n - k}{k - 1},$$

kde R_j^2 je z pomocné regrese. Pokud $F_i > F_{1-\alpha}(\nu_1, \nu_2)$, zamítáme hypotézu nezávislosti.

Python: Farrar–Glauberův χ^2 test

```
# --- data: df obsahuje pouze regresory X1, X2, ... Xk ---
# doporučeno: standardizace
df_std = (df - df.mean()) / df.std(ddof=1)
n, k = df_std.shape
R = df_std.corr().values    # korelační matice R
det_R = np.linalg.det(R)
# testovací statistika
T = -(n - 1 - (2*k + 5)/6) * np.log(det_R)
nu = k * (k - 1) / 2
p_val = chi2.sf(T, nu)      # pravostranná p-hodnota
print(f"T = {T:.3f}, df = {nu:.0f}, p = {p_val:.3g}")
# Interpretace: p < alpha - zamítáme ortogonalitu sloupců
- multikolinearita
```

Shrnutí metod detekce multikolinearity

- **Korelační koeficienty:** Párové korelace mezi regresory; problém indikují hodnoty $|r_{ij}| > 0.75$ (někdy 0.8–0.9).
- **Pomocné regrese:** Sleduje se vysoké R_j^2 z regrese X_j na ostatní; pokud $R_j^2 > R^2$ původního modelu, multikolinearita je vysoká.
- **Determinant $\mathbf{X}^T \mathbf{X}$:** Hodnota blízká nule znamená silnou závislost; metoda je citlivá na měřítko.
- **Leamerova metoda:** $c_j = \sqrt{1 - R_j^2}$; pokud $c_j < 1$, proměnná závisí na ostatních.
- **VIF (Variance Inflation Factor):** $VIF_j = \frac{1}{1 - R_j^2}$; $VIF > 10$ značí vážnou multikolinearitu (někdy hranice 5).
- **Farrar–Glauber test:** Globální test: χ^2 na $\ln \det(\mathbf{R})$; dále F-testy pro jednotlivé sloupce.
- **Číslo podmíněnosti:** $\kappa^* = \sqrt{\lambda_1 / \lambda_k}$; pokud $\kappa^* > 10$, jde o závažnou multikolinearitu.

Řešení multikolinearity

- A. Znormovat případně jinak transformovat sloupce matice X tak, aby byla multikolinearita odstraněna.
- B. Pro odhad parametrů modelu použít postup vedoucí na vychýlené odhady s menším rozptylem, tzv. **hřebenová regrese (ridge regression)**, **lasso regrese**,
- C. Přeformulovat model tak, že bude obsahovat pouze některé z regresorů. Jedná se tedy o výběr vhodného podmodelu **stepwise regrese**,
- D. Místo původních regresorů $X_1, X_2, \dots, X_k$ použít nové regresory, které budou lineární kombinací původních (jedná se o metodu regrese na hlavních komponentách **PCA regrese**, resp. regrese na datech po redukci dimenze) **PLS regrese (partial least square regres)**
- E. Použít **Bayesovskou regresi**, která zahrnuje apriorní informace o parametrech a poskytuje posteriorní rozdělení odhadů.
- F. Použít **nelineární metody**, které nejsou citlivé na multikolinearitu, například **regresní stromy**, **Random Forest** nebo **Gradient Boosting**.